Генеративные классификаторы

>

Рассмотрим генеративный подход к классификации.

Дискриминативные и генеративные алгоритмы

Некоторые алгоритмы, например логистическая регрессия, стремятся найти разделяющую классы границу (гиперплоскость). Такие алгоритмы называются **дискриминативными** от англ. discriminate — «различать», «разграничивать»).

Более формально, речь идет о модели h с параметрами $\theta \in \Theta$, отображающей признаки $x \in X$ на целевую переменную $y \in Y$.

$$h_\theta : X \to Y$$

В случае логистической регрессии, $h_\theta : X \to [0, 1]$. Вероятностная интерпретация дискриминативной модели заключается в использовании *метода максимального условного правдоподобия* (conditional maximum likelihood estimation)

$$\max_\theta \frac{1}{N} \prod_{i=1}^{N} P_\theta(y_i \mid x_i) = \max_\theta \frac{1}{N} \sum_{i=1}^{N} \log P_\theta(y_i \mid x_i)$$

Другими словами, мы должны выбрать такие значения θ, чтобы для каждого из N наблюдений x_i вероятность правильного значения y_i была наиболее высокой.

В случае логистической регрессии функция потерь (бинарная кросс-энтропия) будет иметь вид

$$
\begin{aligned}
\ell(\theta) &= \frac{1}{N}\sum_{i=1}^{N}\log P_\theta(y_i \mid x_i) \\
&= \frac{1}{N}\sum_{i=1}^{N} y_i \cdot \log\sigma(\theta^\top x_i) + (1-y_i)\cdot\log(1-\sigma(\theta^\top x_i)).
\end{aligned}
$$

Другой тип **генеративных** (generative) алгоритмов строит вероятностную модель данных x для *каждого* класса $c \in C$

$$
P_\theta(x \mid y = c),
$$

а также учитывает долю класса в объеме общего набора данных $P_\theta(y = c)$, максимизируя, таким образом, совместную вероятность данных и меток.

$$
\max_\theta \frac{1}{N}\sum_{i=1}^{N}\log P_\theta(x_i, y_i)
$$

Формула Байеса позволяет объединить вероятностную модель (в контексте формулы речь идет о правдоподобии признака для класса c) и долю класса в общей выборке (априорное знание) для создания апостериорной вероятности принадлежности нового наблюдения x' к одному из классов.

$$
\begin{aligned}
\operatorname*{argmax}_c P_\theta(y = c \mid x') &= \operatorname*{argmax}_c \frac{P_\theta(x' \mid y = c)P_\theta(y = c)}{P_\theta(x')} \\
&\propto \operatorname*{argmax}_c P_\theta(x' \mid y = c)P_\theta(y = c)
\end{aligned}
$$

Рассмотрим сказанное выше на примере.

Классификатор спама

Поставим задачу создать классификатор спама, используя теорему Байеса. Рассмотрим электронные письма, в которых обычные сообщения (ham) отнесены к классу $y = 0$, а спам (spam) — к $y = 1$.

Для простоты предположим, что у нас 15 сообщений (10 обычных и 5 спам сообщений), которые состоят из $d = 4$ слов: x_1 «добрый», x_2 «день», x_3 «спасибо», x_4 «деньги».

Пусть задана следующая частота (правдоподобие), с которой каждое из слов встречается в обычных (17 слов)

$$
\begin{aligned}
P(x_1 \mid y=0) &= \tfrac{8}{17} \\
P(x_2 \mid y=0) &= \tfrac{5}{17} \\
P(x_3 \mid y=0) &= \tfrac{3}{17} \\
P(x_4 \mid y=0) &= \tfrac{1}{17}
\end{aligned}
$$

и спам (7 слов) сообщениях

$$
\begin{aligned}
P(x_1 \mid y=1) &= \tfrac{2}{7} \\
P(x_2 \mid y=1) &= \tfrac{1}{7} \\
P(x_3 \mid y=1) &= \tfrac{0}{7} \\
P(x_4 \mid y=1) &= \tfrac{4}{7}
\end{aligned}
$$

Априорной вероятностью будет частота класса в общем наборе данных, то есть $P(y=0) = \frac{10}{15} = \frac{2}{3}$ и $P(y=1) = \frac{5}{15} = \frac{1}{3}$.

Априорную вероятность классов и правдоподобие каждого из слов можно представить и так.

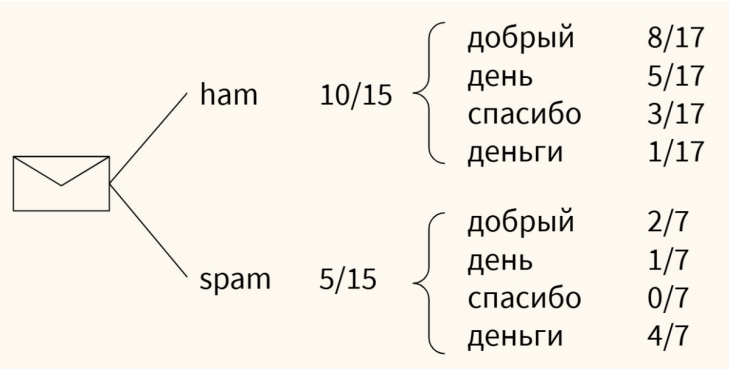

Найдем апостериорную вероятность принадлежности слова «день» к обычным

$$
\begin{aligned}
P(y=0 \mid x_2) &= \frac{P(x_2|y=0)P(y=0)}{P(x_2)} \\
&= \frac{P(x_2|y=0)P(y=0)}{P(x_2|y=0)P(y=0)+P(x_2|y=1)P(y=1)} \\
&= \frac{\frac{5}{17}\cdot\frac{10}{15}}{\frac{5}{17}\cdot\frac{10}{15}+\frac{1}{7}\cdot\frac{5}{15}} \approx 0{,}8
\end{aligned}
$$

и спам сообщениям

$$
\begin{aligned}
P(y=1 \mid x_2) &= \tfrac{P(x_2|y=1)P(y=1)}{P(x_2)} \\
&= \tfrac{P(x_2|y=1)P(y=1)}{P(x_2|y=0)P(y=0)+P(x_2|y=1)P(y=1)} \\
&= \tfrac{\frac{1}{7}\cdot\frac{5}{15}}{\frac{5}{17}\cdot\frac{10}{15}+\frac{1}{7}\cdot\frac{5}{15}} \approx 0{,}2
\end{aligned}
$$

Поскольку знаменатель в обоих случаях одинаковый, достаточно рассчитать числитель.

$$
P(y=0 \mid x_2) \propto P(x_2 \mid y=0)P(y=0) = \frac{5}{17}\cdot\frac{10}{15} \approx 0{,}2
$$

$$
P(y=1 \mid x_2) \propto P(x_2 \mid y=1)P(y=1) = \frac{1}{7}\cdot\frac{5}{15} \approx 0{,}05
$$

Предположим, что нам нужно классифицировать новое сообщение, состоящее из двух слов «добрый день». Другими словами, нам нужно найти

$$
P(y \mid x_1, x_2) = \frac{P(x_1, x_2 \mid y)P(y)}{P(x_1, x_2)},
$$

что предполагает нахождение совместной вероятности нескольких *зависимых* событий (слов) x_j.

$$
\begin{aligned}
P(y \mid x_1, x_2) &= \tfrac{P(x_1|y,x_2)P(x_2|y)P(y)}{P(x_1,x_2)} \\
&\propto P(x_1 \mid y, x_2)P(x_2 \mid y)P(y)
\end{aligned}
$$

Ведь, в самом деле, логично предположить, что появление в сообщении слова «добрый» влияет на появление в этом же сообщении слова «день».

При этом байесовский классификатор «**наивно**» допускает, что эти события (появление слов) не зависят друг от друга (independence assumption). В этом случае расчет совместной вероятности упрощается.

$$
\begin{aligned}
P(y \mid x_1, x_2) &= \tfrac{P(x_1|y)P(x_2|y)P(y)}{P(x_1,x_2)} \\
&\propto P(x_1 \mid y)P(x_2 \mid y)P(y)
\end{aligned}
$$

В нашем примере,

$$
P(x_1 \mid y=0)P(x_2 \mid y=0)P(y=0) = \frac{8}{17}\cdot\frac{5}{17}\cdot\frac{10}{15} \approx 0{,}09
$$

$$P(x_1 \mid y=1)P(x_2 \mid y=1)P(y=1) = \frac{2}{7} \cdot \frac{1}{7} \cdot \frac{5}{15} \approx 0{,}01$$

В общем случае для d признаков, совместная вероятность событий

$$P(y \mid x_1, \ldots, x_d) = \frac{P(y)P(x_1, \ldots, x_d \mid y)}{P(x_1, \ldots, x_d)}$$

на основе допущения об их независимости

$$P(x_j \mid y, x_1, \ldots, x_{j-1}, x_{j+1}, \ldots, x_d) = P(x_j \mid y)$$

принимает вид

$$P(y \mid x_1, \ldots, x_d) = \frac{P(y) \prod_{j=1}^{d} P(x_i \mid y)}{P(x_1, \ldots, x_d)} \propto P(y) \prod_{j=1}^{d} P(x_j \mid y)$$

Таким образом, задача предсказания класса сводится к

$$\begin{aligned} \hat{y} &= \operatorname*{argmax}_c P(y=c) \textstyle\prod_{j=1}^{d} P(x_j \mid y=c) \\ &= \operatorname*{argmax}_c \log P(y=c) + \textstyle\sum_{j=1}^{d} \log P(x_j \mid y=c) \end{aligned}$$

Сглаживание по Лапласу

Предположим, что нам нужно классифицировать новое сообщение, состоящее из слов «спасибо деньги деньги». Найдем вероятность того, что это спам.

$$P(y=1 \mid x_3, x_4, x_4) \propto \frac{0}{7} \cdot \left(\frac{4}{7}\right)^2 \cdot \frac{5}{15} = 0$$

Получается, что любое сообщение, содержащее слово «спасибо», автоматически классифицируется как обычное, хотя очевидно, что некоторые сообщения могут быть спамом.

Для решения этой проблемы используется аддитивное сглаживание, при котором частота каждого слова $\hat{\theta}_j$ увеличивается на α. Если $\alpha = 1$, речь идет о **сглаживании по Лапласу** (Laplace smoothing или add-one smoothing).

$$\hat{\theta}_j = \frac{x_j + \alpha}{N + \alpha d},$$

где N — общее количество слов в данном классе, а d — количество уникальных слов. В примере выше, при использовании сглаживания по Лапласу правдоподобие слова «спасибо» в классе «спам» будет равно

$$\hat{\theta}_3 = \frac{x_3 + \alpha}{N + \alpha d} = \frac{0 + 1}{7 + 1 \cdot 4} = \frac{1}{11}$$

Найдем сглаженные вероятности сообщения «спасибо деньги деньги».

$$P(y = 0 \mid x_3, x_4, x_4) \propto \frac{4}{21} \cdot \left(\frac{2}{21}\right)^2 \cdot \frac{10}{15} \approx 0{,}001$$

$$P(y = 1 \mid x_3, x_4, x_4) \propto \frac{1}{11} \cdot \left(\frac{5}{11}\right)^2 \cdot \frac{5}{15} \approx 0{,}006$$

Multinomial Naïve Bayes

Рассмотренный выше наивный байесовский классификатор называется **мультиномиальным** (Multinomial Naïve Bayes), потому что признаки (слова) следуют мультиномиальному распределению

$$X \sim M_d(N; p_1, \ldots, p_d),$$

где N — общее количество слов в одном классе, а d — количество уникальных слов.

В частности, распределение слов в классе спам сообщений (с учетом сглаживания) имеет параметры

$$X \sim M_4\left(11; \frac{3}{11}, \frac{2}{11}, \frac{1}{11}, \frac{5}{11}\right)$$

Реализуем классификатор в коде. Возьмем набор данных SMS Spam Collection.

spam.csv

Скачать

Откроем блокнот к занятию

Создадим класс MultinomialNaiveBayes.

```
class MultinomialNaiveBayes:
  def __init__(self, alpha = 1):
    self.alpha = alpha
    self.token_spam_counts = defaultdict(int)
    self.token_ham_counts = defaultdict(int)
    self.spam_messages = self.ham_messages = 0

  def tokenize(self, text):
    text = text.lower()
    all_words = re.findall("[a-z']+", text)
    return all_words

  def fit(self, data):
    for message in data.itertuples():
      if message.is_spam:
        self.spam_messages += 1
      else:
        self.ham_messages += 1

      for token in self.tokenize(message.text):
        if message.is_spam:
          self.token_spam_counts[token] += 1
        else:
          self.token_ham_counts[token] += 1

  def _likelihood(self, token):
    spam = self.token_spam_counts[token]
    ham = self.token_ham_counts[token]

    total_spam_words = sum(self.token_spam_counts.values())
    total_ham_words = sum(self.token_ham_counts.values())

    unique_spam_words = len(self.token_spam_counts)
    unique_ham_words = len(self.token_ham_counts)

    p_token_spam = (spam + self.alpha) / (total_spam_words + self.alpha *
    p_token_ham = (ham + self.alpha) / (total_ham_words + self.alpha * un
```

```
    return p_token_spam, p_token_ham

  def predict(self, data):
    log_spam_prior = np.log(self.spam_messages / len(data))
    log_ham_prior = np.log(self.ham_messages / len(data))

    data['predictions'] = False

    for message in data.itertuples():
      text_tokens = self.tokenize(message.text)
      log_prob_if_spam = log_prob_if_ham = 0.0

      for token in text_tokens:
        prob_if_spam, prob_if_ham = self._likelihood(token)
        log_prob_if_spam += np.log(prob_if_spam)
        log_prob_if_ham += np.log(prob_if_ham)

      log_prob_if_spam = log_spam_prior + log_prob_if_spam
      log_prob_if_ham = log_ham_prior + log_prob_if_ham

      data.loc[message.Index, 'predictions'] = log_prob_if_spam > log_pro

    return data
```

Обучим модель, сделаем прогноз и оценим качество.

```
model = MultinomialNaiveBayes()
model.fit(spam_df)
spam_df = model.predict(spam_df)

accuracy_score(spam_df.is_spam, spam_df.predictions)
```

```
0.9883923389437028
```

Генеративная модель

Хотя в данном случае это не имеет большого практического смысла, продемонстрируем, как генеративная модель, запомнив параметры распределений обычных и спам сообщений, способна создавать новые тексты.

Дважды используем функцию **np.random.multinomial()** для обычных и спам сообщений. В каждом случае передадим количество слов в сообщении (пусть их будет три), правдоподобие (с учетом сглаживания) и количество сообщений (соответствующее априорной вероятности).

```
np.random.multinomial(3, [9/21, 6/21, 4/21, 2/21], size = 10)
```

```
array([[3, 0, 0, 0],
       [0, 1, 1, 1],
       [3, 0, 0, 0],
       [3, 0, 0, 0],
       [0, 2, 0, 1],
       [1, 0, 2, 0],
       [1, 1, 1, 0],
       [2, 0, 0, 1],
       [1, 0, 0, 2],
       [0, 1, 1, 1]])
```

```
np.random.multinomial(3, [3/11, 2/11, 1/11, 5/11], size = 5)
```

```
array([[1, 1, 0, 1],
       [2, 1, 0, 0],
       [1, 0, 2, 0],
       [0, 0, 1, 2],
       [1, 1, 0, 1]])
```

Первое спам сообщение [1, 1, 0, 1] состоит из слов x_1, x_2, x_4, то есть «добрый день деньги».

Gaussian Naïve Bayes

В случае если данные содержат количественные признаки, можно использовать **гауссовский наивный байесовский классификатор** (Gaussian Naïve Bayes). Основными допущениями такой модели являются:

- независимость признаков x_j; а также их
- нормальное распределение

$$P(x_{cj} \mid y = c, \mu_{cj}, \sigma_{cj}^2) = \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp\left[-\frac{(x_{cj} - \mu_{cj})^2}{2\sigma_{cj}^2}\right]$$

Этапы моделирования, таким образом, заключаются в том, чтобы:

1. оценить априорную вероятность класса $P(y = c)$;
2. для каждого признака j внутри каждого класса c найти выборочные параметры $\hat{\mu}_{cj}$ и $\hat{\sigma}_{cj}$, задав $P(x_{cj} \mid y = c, \mu_{cj}, \sigma_{cj}^2)$,

3. для нового наблюдения:

   - для каждого признака и внутри каждого предсказываемого класса, используя параметры $\hat{\mu}_{cj}$ и $\hat{\sigma}_{cj}$, найти значения плотности вероятности;
   - найти апостериорную вероятность для каждого класса c и выбрать тот класс, апостериорная оценка которого наиболее высока

$$P(y = c \mid x_1, \ldots, x_d) \propto P(y = c) \prod_{j=1}^{d} P(x_j \mid y = c)$$

$$\begin{aligned} \hat{y} &= \operatorname*{argmax}_c P(y = c) \textstyle\prod_{j=1}^{d} P(x_j \mid y = c) \\ &= \operatorname*{argmax}_c \log P(y = c) + \textstyle\sum_{j=1}^{d} \log P(x_j \mid y = c). \end{aligned}$$

MLE-оценка. Докажем, что параметры $\hat{\mu}_{cj}$ и $\hat{\sigma}_{cj}$ максимизируют правдоподобие данных внутри каждого класса. Будем рассматривать данные $x = \{x_1, \ldots, x_N\}$, состоящие из одного признака в рамках одного класса

$$x_i \sim \mathcal{N}(\mu, \sigma^2), \quad i = 1, \ldots, N \ .$$

Таким образом, необходимо продемонстрировать, что

$$\begin{aligned} \hat{\mu} &= \frac{1}{N} \sum_{i=1}^{N} x_i \\ \hat{\sigma}^2 &= \frac{1}{N} \sum_{i=1}^{N} (x_i - \bar{x})^2 \ , \end{aligned}$$

где $\bar{x} = \frac{1}{N} \sum_{i=1}^{N} x_i$. Правдоподобие одного наблюдения можно задать через

$$p(x_i \mid \mu, \sigma^2) = \mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left[-\frac{1}{2}\left(\frac{x_i - \mu}{\sigma}\right)^2\right]$$

Предполагая независимость наблюдений,

$$p(x \mid \mu, \sigma^2) = \prod_{i=1}^{N} p(x_i \mid \mu) = \sqrt{\frac{1}{(2\pi\sigma^2)^N}} \cdot \exp\left[-\frac{1}{2} \sum_{i=1}^{N} \left(\frac{x_i - \mu}{\sigma}\right)^2\right]$$

Преобразуем выражение,

$$
\begin{aligned}
p(x \mid \mu, \sigma^2) &= \left(\frac{1}{2\pi\sigma^2}\right)^{N/2} \cdot \exp\left[-\frac{1}{2}\sum_{i=1}^{N}\left(\frac{x_i^2 - 2x_i\mu + \mu^2}{\sigma^2}\right)\right] \\
&= \left(\frac{1}{2\pi\sigma^2}\right)^{N/2} \cdot \exp\left[-\frac{1}{2\sigma^2}\left(x^{\mathrm{T}}x - 2N\bar{x}\mu + N\mu^2\right)\right],
\end{aligned}
$$

где $\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i$ и $x^{\mathrm{T}}x = \sum_{i=1}^{N} x_i^2$.

Логарифмическая функция правдоподобия будет иметь вид

$$
\begin{aligned}
\ell(\mu, \sigma^2) &= \log p(x \mid \mu, \sigma^2) \\
&= -\frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\left(x^{\mathrm{T}}x - 2N\bar{x}\mu + N\mu^2\right)
\end{aligned}
$$

Найдем производную относительно μ

$$
\frac{\mathrm{d}\ell(\mu, \sigma^2)}{\mathrm{d}\mu} = \frac{N\bar{y}}{\sigma^2} - \frac{N\mu}{\sigma^2} = \frac{N}{\sigma^2}(\bar{y} - \mu)
$$

и приравняем ее к нулю

$$
\begin{aligned}
\frac{\mathrm{d}\ell(\hat{\mu}, \sigma^2)}{\mathrm{d}\mu} &= 0 \\
0 &= \frac{N}{\sigma^2}(\bar{x} - \hat{\mu})\ 0 = \bar{x} - \hat{\mu} \\
\hat{\mu} &= \bar{x} \\
\hat{\mu} &= \frac{1}{N}\sum_{i=1}^{N} x_i
\end{aligned}
$$

Найдем производную функции правдоподобия со значением $\hat{\mu}$ относительно σ^2

$$
\begin{aligned}
\frac{\mathrm{d}\ell(\hat{\mu}, \sigma^2)}{\mathrm{d}\sigma^2} &= -\frac{N}{2}\frac{1}{\sigma^2} + \frac{1}{2(\sigma^2)^2}\left(x^{\mathrm{T}}x - 2N\bar{x}\hat{\mu} + N\hat{\mu}^2\right) \\
&= -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{N}\left(x_i^2 - 2x_i\hat{\mu} + \hat{\mu}^2\right) \\
&= -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2}\sum_{i=1}^{N}(x_i - \hat{\mu})^2
\end{aligned}
$$

и приравняем ее к нулю

$$\frac{\mathrm{d}\ell(\hat{\mu}, \hat{\sigma}^2)}{\mathrm{d}\sigma^2} = 0$$

$$0 = \frac{1}{2(\hat{\sigma}^2)^2} \sum_{i=1}^{N} (x_i - \hat{\mu})^2$$

$$\frac{N}{2\hat{\sigma}^2} = \frac{1}{2(\hat{\sigma}^2)^2} \sum_{i=1}^{N} (x_i - \hat{\mu})^2$$

$$\frac{2(\hat{\sigma}^2)^2}{N} \cdot \frac{N}{2\hat{\sigma}^2} = \frac{2(\hat{\sigma}^2)^2}{N} \cdot \frac{1}{2(\hat{\sigma}^2)^2} \sum_{i=1}^{N} (x_i - \hat{\mu})^2$$

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^{N} (x_i - \hat{\mu})^2$$

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^{N} (x_i - \bar{x})^2$$

Приведем пример. Предположим, что параметры первого признака:

- для класса $y = 0$ равны $\hat{\mu}_{01} = 24$ и $\hat{\sigma}_{01} = 4$; а для
- $y = 1$ соответственно $\hat{\mu}_{11} = 15$ и $\hat{\sigma}_{11} = 2$;

Для второго признака:

- для класса $y = 0$ равны $\hat{\mu}_{02} = 480$ и $\hat{\sigma}_{02} = 25$;
- $y = 1 : \hat{\mu}_{12} = 505$ и $\hat{\sigma}_{12} = 30$;

Наконец для третьего признака:

- для класса $y = 0$ равны $\hat{\mu}_{03} = 35$ и $\hat{\sigma}_{03} = 4$;
- $y = 1 : \hat{\mu}_{13} = 25$ и $\hat{\sigma}_{13} = 4$;

Кроме того, поскольку 10 из двадцати наблюдений относятся к одному классу, а ещё 10 — ко второму, то априорная вероятность принадлежности к каждому из классов равна:

$$P(y = 0) = P(y = 1) = \frac{1}{2}$$

Пусть новое наблюдение имеет следующие значения признаков:

$$x_1 = 20, \quad x_2 = 500, \quad x_3 = 25$$

С учётом приведенных выше параметров, значения правдоподобия (функции плотности нормального распределения) равны для класса $y = 0$:

- $P(x_1 = 20 \mid y = 0) \approx 0{,}06$
- $P(x_2 = 500 \mid y = 0) \approx 0{,}01$
- $P(x_3 = 25 \mid y = 0) \approx 0{,}004$

и для класса $y = 1$:

- $P(x_1 = 20 \mid y = 0) \approx 0{,}009$
- $P(x_2 = 500 \mid y = 0) \approx 0{,}013$
- $P(x_3 = 25 \mid y = 0) \approx 0{,}1$

Найдем апостериорную вероятность каждого из классов.

$$\begin{aligned} P(y = 0 \mid x_1, x_2, x_3) \quad & \propto \log P(y = 0) + \textstyle\sum_{j=1}^{d} \log P(x_j \mid y = 0) \\ & = \log(0{,}5) + \log(0{,}06) + \log(0{,}01) + \log(0{,}004) \\ & \approx -13{,}6 \end{aligned}$$

$$\begin{aligned} P(y = 1 \mid x_1, x_2, x_3) \quad & \propto \log P(y = 1) + \textstyle\sum_{j=1}^{d} \log P(x_j \mid y = 1) \\ & = \log(0{,}5) + \log(0{,}009) + \log(0{,}003) + \log(0{,}1) \\ & \approx -12{,}04 \end{aligned}$$

Поскольку $-12{,}04 > -13{,}6$ модель считает, что $\hat{y} = 1$.

Гауссовский дискриминантный анализ

Многомерное нормальное распределение

Правдоподобие признаков можно задать и через многомерное нормальное распределение (Multivariate Gaussian distribution).

$$P(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}|}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right],$$

где d — количество признаков, $\boldsymbol{\mu} = \mathbb{E}[\mathbf{x}]$ и $\boldsymbol{\Sigma} = \mathbb{E}[\mathbf{x}\mathbf{x}^\top] - \mathbb{E}[\mathbf{x}]\mathbb{E}[\mathbf{x}]^\top$. Одновременно, вектор $\mathbf{x}^\top$ содержит значения признаков для одного наблюдения

$$\mathbf{x}^\top = (x_1\ x_2\ \dots\ x_d) \in \mathbb{R}^{1\times d}$$

Вектор $\boldsymbol{\mu}^\top$ соответствующие средние значения

$$\boldsymbol{\mu}^\top = (\mu_1\ \mu_2\ \dots\ x_d) \in \mathbb{R}^{1\times d},$$

а $\boldsymbol{\Sigma}$ — <u>матрицу ковариаций</u>

$$\boldsymbol{\Sigma} = \begin{pmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1d} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \dots & \sigma_{dd} \end{pmatrix} \in \mathbb{R}^{d\times d},$$

в которой на главной диагонали находится дисперсия каждого из признаков.

Для набора данных из N независимых одинаково распредёленных наблюдений функция правдоподобия примет вид

$$P(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \prod_{i=1}^{N} \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}|}} \exp\left[-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right]$$

Возьмем логарифм правдоподобия

$$\ell(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \sum_{i=1}^{N} \left(-\frac{d}{2}\log 2\pi + \frac{1}{2}\log|\boldsymbol{\Sigma}^{-1}| - \frac{1}{2}(\mathbf{x}_i-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i-\boldsymbol{\mu})\right)$$

Найдем максимум логарифмической функции правдоподобия

$$\hat{\theta} = \operatorname*{argmax}_{\theta} \ell(\theta)$$

Для этого вначале дифференцируем относительно $\boldsymbol{\mu}$ и приравняем производную к нулю (приводится без доказательства).

$$\frac{\partial \ell(\theta)}{\partial \boldsymbol{\mu}} = \frac{\partial}{\partial \mu} \sum_{i=1}^{N} \left(-\frac{1}{2}(\mathbf{x}_i-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i-\boldsymbol{\mu})\right)$$

$$\boldsymbol{\mu} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{x}_i$$

Затем относительно $\boldsymbol{\Sigma}$ и также приравняем производную к нулю.

$$\frac{\partial \ell(\theta)}{\partial \boldsymbol{\Sigma}} = \frac{\partial}{\partial \boldsymbol{\Sigma}}\left(\sum_{i=1}^{N}\frac{1}{2}\log|\boldsymbol{\Sigma}^{-1}| - \sum_{i=1}^{N}\left(\frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu})^\top\boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu})\right)\right)$$

$$\boldsymbol{\Sigma} = \frac{1}{N}\sum_{i=1}^{N}(\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \mu)^\top$$

Кроме этого, можно показать, что MLE-оценка априорной вероятности класса $P(y = c) = \pi_c$ равна

$$\pi_c = \frac{N_c}{N},$$

где N_c — количество наблюдений в классе c.

Задача при этом по-прежнему сводится к выбору класса исходя из наибольшей апостериорной вероятности.

$$\hat{y}(\mathbf{x}) = \operatorname*{argmax}_c P(y = c \mid \mathbf{x}, \boldsymbol{\mu}_c, \boldsymbol{\Sigma}_c)$$

Виды алгоритмов

Семейство алгоритмов, основывающееся на допущении о том, что признаки следуют нормальному распределению называется **гауссовским дискриминантным анализом** (Gaussian discriminant analysis, GDA).

При этом,

- в случае, если мы считаем, что ковариация существует, и она различна внутри каждого из классов $\boldsymbol{\Sigma}_c$, то такой алгоритм называется **квадратичным дискриминантным анализом** (quadratic discriminant analysis, QDA);
- если же мы допускаем, что ковариация между признаками существует, однако дисперсия/ковариация одинаковы для всех классов $\boldsymbol{\Sigma}_c = \boldsymbol{\Sigma}$, то

речь идет о **линейном дискриминантном анализе** (linear discriminant analysis, LDA); и наконец

- если признаки независимы и ковариация между ними отсутствует (ковариационная матрица сохраняет лишь дисперсию признаков на главной диагонали) $diag(\mathbf{\Sigma}_c)$ алгоритм называется **гауссовским наивным байесовским классификатором** (Gaussian Naïve Bayes).

Рассмотрим каждый из этих алгоритмов более подробно.

Квадратичный дискриминантный анализ

Логарифм апостериорной вероятности $\log P(\mathbf{y} \mid \pi_c, \boldsymbol{\mu}_c, \mathbf{\Sigma}_c)$ имеет вид

$$\sum_{i=1}^{N}\sum_{c=1}^{C}\delta_{ic}\left(\log\pi_c - \frac{d}{2}\log 2\pi + \frac{1}{2}\log|\mathbf{\Sigma}_c^{-1}| - \frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top\mathbf{\Sigma}_c^{-1}(\mathbf{x}_i - \boldsymbol{\mu}_c)\right),$$

где $\delta_{ic} = 1$, если $\mathbf{x}_i$ принадлежит классу c, и $\delta_{ic} = 0$, если не принадлежит.

Дифференцируя по $\pi_c, \boldsymbol{\mu}_c, \mathbf{\Sigma}_c$ и приравнивая производные к нулю, получим следующие MLE-оценки:

$$\pi_c = \frac{N_c}{N}; \qquad \boldsymbol{\mu}_c = \frac{1}{N_c}\sum_{i=1}^{N}\delta_{ic}\mathbf{x}_i;$$

$$\mathbf{\Sigma}_c = \frac{1}{N_c}\sum_{i=1}^{N}\delta_{ic}(\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top$$

Задача для квадратичного дискриминантного анализа, таким образом, сводится к

$$\hat{y}(\mathbf{x}) = \operatorname*{argmax}_c \log\pi_c + \frac{1}{2}\log|\mathbf{\Sigma}_c^{-1}| - \frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top\mathbf{\Sigma}_c^{-1}(\mathbf{x}_i - \boldsymbol{\mu}_c)$$

Одновременно, функция $P(y = c \mid \mathbf{x}, \theta)$ также называется **дискриминантной функцией** (discriminant function), поскольку позволяет разделить объекты по классам.

При этом логично предположить, что **решающей границей** (decision

boundary) будут те точки пространства признаков, где апостериорные вероятности одинаковы.

При наличии двух классов c_1 и c_2 решающая граница задается через

$$P(y = c_1 \mid \mathbf{x}, \theta) = P(y = c_2 \mid \mathbf{x}, \theta)$$

$$P(y = c_1 \mid \theta) P(\mathbf{x} \mid y = c_1, \theta) = P(y = c_2 \mid \theta) P(\mathbf{x} \mid y = c_2, \theta)$$

Подставив формулу многомерного нормального распределения для c_1 и c_2, получим

$$\begin{aligned}
P(y = c_1 \mid \mathbf{x}, \theta) &= P(y = c_1 \mid \theta) P(\mathbf{x} \mid y = c_1, \theta) \\
&= \pi_{c_1} \frac{1}{(\sqrt{2\pi})^d \sqrt{|\Sigma_{c_1}|}} \exp\left[-\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_{c_1})^\top \boldsymbol{\Sigma}_{c_1}^{-1} (\mathbf{x} - \boldsymbol{\mu}_{c_1})\right] \\
&= \pi_{c_1} \frac{1}{(\sqrt{2\pi})^d \sqrt{|\Sigma_{c_1}|}} \exp\left[\boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \boldsymbol{\mu}_{c_1} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_1} \mathbf{x}\right]
\end{aligned}$$

$$\begin{aligned}
P(y = c_2 \mid \mathbf{x}, \theta) &= P(y = c_2 \mid \theta) P(\mathbf{x} \mid y = c_2, \theta) \\
&= \pi_{c_2} \frac{1}{(\sqrt{2\pi})^d \sqrt{|\Sigma_{c_2}|}} \exp\left[-\tfrac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_{c_2})^\top \boldsymbol{\Sigma}_{c_2}^{-1} (\mathbf{x} - \boldsymbol{\mu}_{c_2})\right] \\
&= \pi_{c_2} \frac{1}{(\sqrt{2\pi})^d \sqrt{|\Sigma_{c_2}|}} \exp\left[\boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \boldsymbol{\mu}_{c_2} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_2} \mathbf{x}\right]
\end{aligned}$$

Выразим $P(y = c_1 \mid \mathbf{x}, \theta) = P(y = c_2 \mid \mathbf{x}, \theta)$ и упростим выражения.

$$\begin{aligned}
&\pi_{c_1} |\boldsymbol{\Sigma}_{c_1}|^{-\frac{1}{2}} \exp\left[\boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \boldsymbol{\mu}_{c_1} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_1} \mathbf{x}\right] \quad = \\
&\pi_{c_2} |\boldsymbol{\Sigma}_{c_2}|^{-\frac{1}{2}} \exp\left[\boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \boldsymbol{\mu}_{c_2} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_2} \mathbf{x}\right]
\end{aligned}$$

Возьмем логарифм обеих частей.

$$\begin{aligned}
&\log \pi_{c_1} - \log \tfrac{1}{2} |\boldsymbol{\Sigma}_{c_1}| + \boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}_{c_1}^{-1} \boldsymbol{\mu}_{c_1} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_1} \mathbf{x} \quad = \\
&\log \pi_{c_2} - \log \tfrac{1}{2} |\boldsymbol{\Sigma}_{c_2}| + \boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \mathbf{x} - \tfrac{1}{2} \boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}_{c_2}^{-1} \boldsymbol{\mu}_{c_2} - \tfrac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}_{c_2} \mathbf{x}
\end{aligned}$$

Если положить

$$\mathbf{a} = \frac{1}{2}(\boldsymbol{\Sigma}_{c_1}^{-1} - \boldsymbol{\Sigma}_{c_2}^{-1})$$

$$\mathbf{b}_c = \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}_c^{-1}$$

$$c_c = \log \pi_c - \log \frac{1}{2} |\boldsymbol{\Sigma}_c| - \frac{1}{2} \boldsymbol{\mu}_c^\top \boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c,$$

то в уравнении решающей границы несложно увидеть **квадратичную** функцию

$$-\frac{1}{2}\mathbf{x}^\top \mathbf{a}\mathbf{x} + (\mathbf{b}_{c_1} - \mathbf{b}_{c_2})\mathbf{x} + (c_{c_1} - c_{c_2}) = 0.$$

Создадим алгоритм на Питоне. Будем использовать датасет Iris.

```
X, y = load_iris(return_X_y=True)
# возьмем признаки Petal Length и Petal Width
X = X[:, [2,3]]
```

Напишем класс QDA.

```
class QDA:
  def __init__(self):
    self.priors = dict()
    self.means = dict()
    self.covariances = dict()
    self.classes = None

  def fit(self, X, y):
    self.classes = np.unique(y)

    for c in self.classes:
      X_c = X[y == c]
      self.priors[c] = X_c.shape[0] / X.shape[0]
      self.means[c] = np.mean(X_c, axis=0)
      self.covariances[c] = np.cov(X_c, rowvar=False)

  def predict(self, X):
    predictions = list()
    for x in X:
      log_posteriors = list()
      for c in self.classes:
        log_priors = np.log(self.priors[c])
        inv_cov = np.linalg.inv(self.covariances[c])
        inv_cov_det = np.linalg.det(inv_cov)
        diff = x-self.means[c]
        log_likelihood = 0.5 * np.log(inv_cov_det) - 0.5 * diff.T @ inv_c
        log_posterior = log_priors + log_likelihood
        log_posteriors.append(log_posterior)

      prediction = self.classes[np.argmax(log_posteriors)]
      predictions.append(prediction)
    return np.array(predictions)

  def decision_boundary(self, X, y):
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
```

```
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.1),
                         np.arange(y_min, y_max, 0.1))

    Z = self.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)

    plt.contourf(xx, yy, Z, alpha=0.4)
    plt.scatter(X[:, 0], X[:, 1], c=y, s=20, edgecolor='k')

    for i, _ in enumerate(self.classes):
      mean = self.means[i]
      cov = self.covariances[i]

      rv = multivariate_normal(mean, cov)
      x_grid, y_grid = np.mgrid[x_min:x_max:0.1, y_min:y_max:0.1]
      points = np.dstack((x_grid, y_grid))
      pdf_values = rv.pdf(points)

      plt.contour(x_grid, y_grid, pdf_values, levels=3, colors=f'C{i}', a
      plt.scatter(mean[0], mean[1], marker='x', color=f'C{i}', s=100)

    plt.title('QDA Decision Boundary')
    plt.xlabel('Feature 1')
    plt.ylabel('Feature 2')
    plt.show()
```

Обучим модель и оценим ее качество.

```
qda = QDA()
qda.fit(X, y)
accuracy_score(y, qda.predict(X))
```

```
0.98
```

Посмотрим на разделяющую границу.

```
qda.decision_boundary(X, y)
```

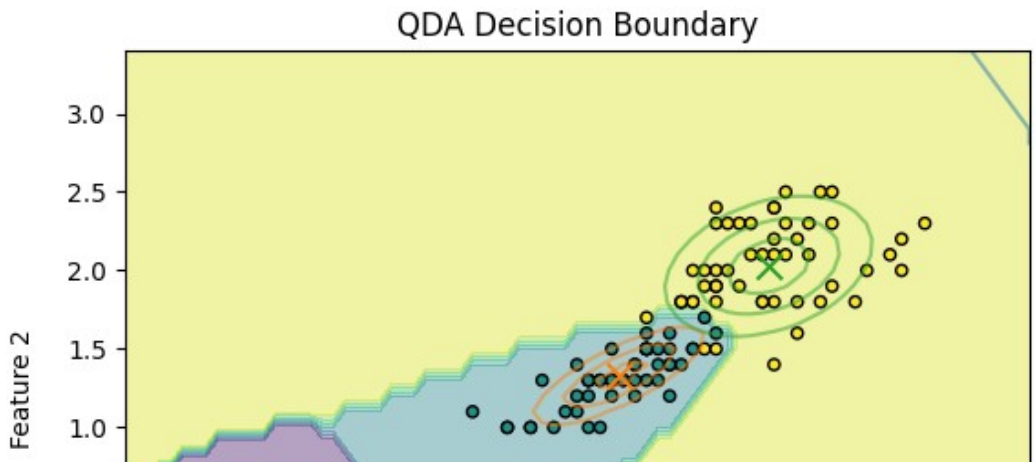

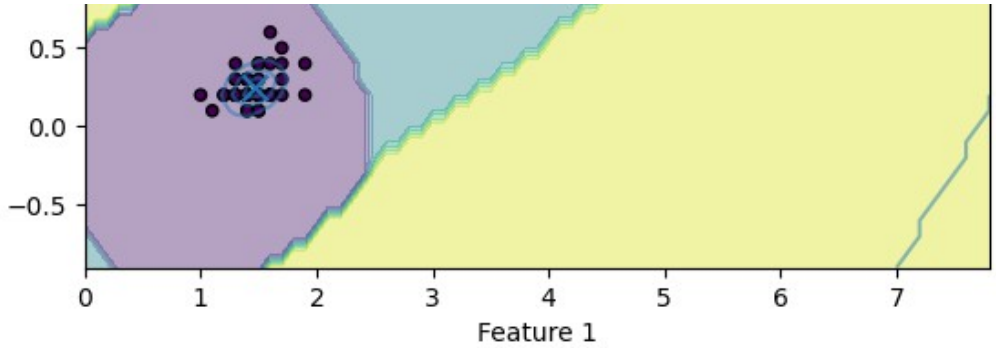

Линейный дискриминантный анализ

Допуская одинаковую для всех классов ковариацию и дисперсию признаков, задача сводится к нахождению следующей апостериорной вероятности $\log P(\mathbf{y} \mid \pi_c, \boldsymbol{\mu}_c, \boldsymbol{\Sigma})$

$$\sum_{i=1}^{N}\sum_{c=1}^{C}\delta_{ic}\left(\log\pi_c - \frac{d}{2}\log 2\pi + \frac{1}{2}\log|\boldsymbol{\Sigma}^{-1}| - \frac{1}{2}(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top\boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}_c)\right)$$

Дифференцируя по π_c и $\boldsymbol{\mu}_c$ и приравнивая производные к нулю, мы получим те же оценки максимального правдоподобия, что и в случае квадратичного анализа

$$\pi_c = \frac{N_c}{N}; \qquad \boldsymbol{\mu}_c = \frac{1}{N_c}\sum_{i=1}^{N}\delta_{ic}\mathbf{x}_i.$$

MLE-оценка для $\boldsymbol{\Sigma}$ будет иной.

$$\boldsymbol{\Sigma} = \frac{1}{N}\sum_{i=1}^{N}\sum_{c=1}^{C}\delta_{ic}(\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top$$

В силу того, что ковариационная матрица одинакова для всех классов, уравнение решающей границы будет **линейным**. Воспользуемся полученными выше результатами

$$\begin{aligned}\pi_{c_1}|\boldsymbol{\Sigma}|^{-\frac{1}{2}}\exp\left[\boldsymbol{\mu}_{c_1}^\top\boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_1}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_1} - \tfrac{1}{2}\mathbf{x}^\top\boldsymbol{\Sigma}\mathbf{x}\right] \quad = \\ \pi_{c_2}|\boldsymbol{\Sigma}|^{-\frac{1}{2}}\exp\left[\boldsymbol{\mu}_{c_2}^\top\boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_2}^\top\boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_2} - \tfrac{1}{2}\mathbf{x}^\top\boldsymbol{\Sigma}\mathbf{x}\right]\end{aligned}$$

и дополнительно упростим выражения

$$\pi_{c_1} \exp\left[\boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_1}\right] =$$
$$\pi_{c_2} \exp\left[\boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_2}\right]$$

Взяв логарифм, получим

$$\log \pi_{c_1} + \boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_1}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_1} =$$
$$\log \pi_{c_2} + \boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}^{-1}\mathbf{x} - \tfrac{1}{2}\boldsymbol{\mu}_{c_2}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_{c_2}$$

Положив,

$$\gamma_c = \frac{1}{2}\mu_c^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c + \log \pi_c$$

$$\beta_c = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}_c$$

получим

$$\beta_{c_1}\mathbf{x} + \gamma_{c_1} = \beta_{c_2}\mathbf{x} + \gamma_{c_2}$$

$$(\beta_{c_1} - \beta_{c_2})\mathbf{x} = \gamma_{c_2} - \gamma_{c_1}$$

Реализуем алгоритм в коде.

```
class LDA:
  def __init__(self):
    self.priors = dict()
    self.means = dict()
    self.covariances = None
    self.classes = None

  def fit(self, X, y):
    self.covariances = np.cov(X, rowvar=False)
    self.classes = np.unique(y)

    for c in self.classes:
      X_c = X[y == c]
      self.priors[c] = X_c.shape[0] / X.shape[0]
      self.means[c] = np.mean(X_c, axis=0)

  def predict(self, X):
    predictions = list()
    for x in X:
      log_posteriors = list()
      for c in self.classes:
        log_priors = np.log(self.priors[c])
        inv_cov = np.linalg.inv(self.covariances)
        inv_cov_det = np.linalg.det(inv_cov)
```

```
        diff = x-self.means[c]
        log_likelihood = 0.5 * np.log(inv_cov_det) - 0.5 * diff.T @ inv_c
        log_posterior = log_priors + log_likelihood
        log_posteriors.append(log_posterior)
      prediction = self.classes[np.argmax(log_posteriors)]
      predictions.append(prediction)
    return np.array(predictions)

  def decision_boundary(self, X, y):
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.1),
                         np.arange(y_min, y_max, 0.1))

    Z = self.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)

    plt.contourf(xx, yy, Z, alpha=0.4)
    plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k')

    for i, _ in enumerate(self.classes):
      mean = self.means[i]
      rv = multivariate_normal(mean, self.covariances)
      x_grid, y_grid = np.mgrid[x_min:x_max:0.1, y_min:y_max:0.1]
      points = np.dstack((x_grid, y_grid))
      pdf_values = rv.pdf(points)

      plt.contour(x_grid, y_grid, pdf_values, levels=3, colors=f'C{i}', a
      plt.scatter(mean[0], mean[1], marker='x', color=f'C{i}', s=100)

    plt.title('LDA Decision Boundary')
    plt.xlabel('Feature 1')
    plt.ylabel('Feature 2')
    plt.show()
```

```
lda = LDA()
lda.fit(X, y)
accuracy_score(y, lda.predict(X))
```

```
0.86
```

```
lda.decision_boundary(X, y)
```

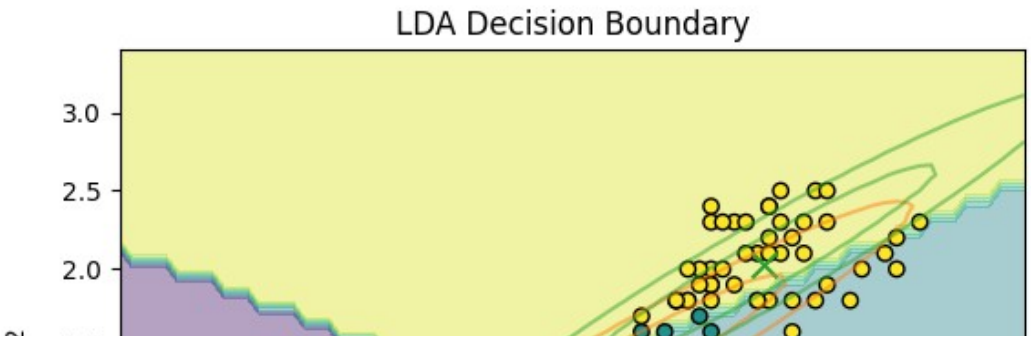

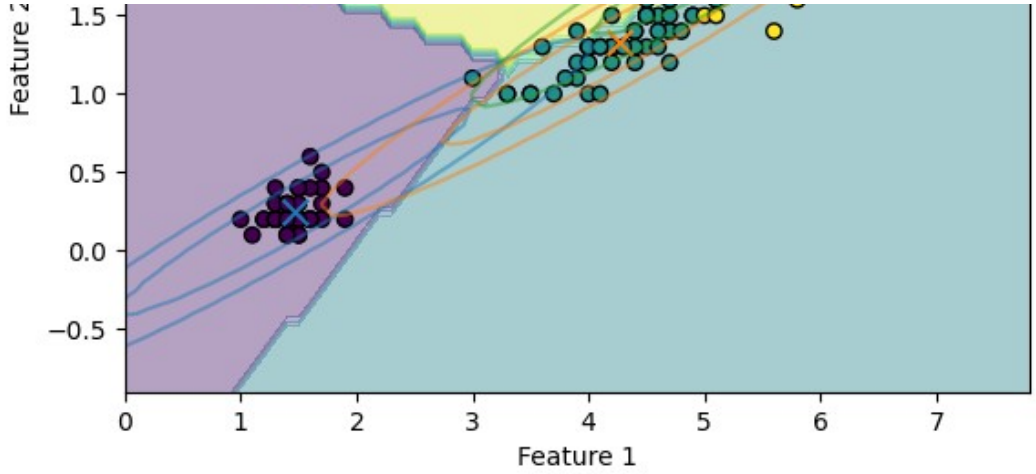

Gaussian Naïve Bayes

Поскольку признаки считаются независимыми, то (отдельная для каждого класса) ковариационная матрица $\mathbf{\Sigma}_c$ примет вид диагональной матрицы

$$\pi_c = \frac{N_c}{N}; \qquad \boldsymbol{\mu}_c = \frac{1}{N_c}\sum_{i=1}^{N}\delta_{ic}\mathbf{x}_i;$$

$$\mathbf{\Sigma}_c = diag\left(\frac{1}{N_c}\sum_{i=1}^{N}\delta_{ic}(\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top\right)$$

Покажем, что при условии независимости признаков моделирование данных с помощью d-мерного нормального распределения с $\boldsymbol{\mu} \in \mathbb{R}^d$ и ковариационной матрицы $\mathbf{\Sigma} = diag(\sigma_1^2, \sigma_1^2, \ldots, \sigma_d^2)$ аналогично произведению d независимых одномерных нормальных распределений со средним μ_j и дисперсией σ_j^2.

Для наглядности пусть $d = 2$. Тогда,

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \mathbf{\Sigma} = \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}$$

В этом случае, многомерное нормальное распределение примет вид

$$
\begin{aligned}
P(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \frac{1}{2\pi \begin{vmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{vmatrix}^{1/2}} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right) \\
&= \frac{1}{2\pi(\sigma_1^2 \cdot \sigma_2^2 - 0 \cdot 0)^{1/2}} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \frac{1}{\sigma_1^2} & 0 \\ 0 & \frac{1}{\sigma_2^2} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right),
\end{aligned}
$$

где мы явным образом прописываем определитель матрицы второго порядка и находим матрицу, обратную к диагональной.

$$
\begin{aligned}
P(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^\top \begin{bmatrix} \frac{1}{\sigma_1^2}(x_1 - \mu_1) \\ \frac{1}{\sigma_2^2}(x_2 - \mu_2) \end{bmatrix} \right) \\
&= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(\frac{1}{2\sigma_1^2}(x_1 - \mu_1)^2 - \frac{1}{2\sigma_2^2}(x_2 - \mu_2)^2 \right) \\
&= \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{1}{2\sigma_1^2}(x_1 - \mu_1)^2 \right) \cdot \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{1}{2\sigma_2^2}(x_2 - \mu_2)^2 \right)
\end{aligned}
$$

Напишем код.

```
class GaussianNaiveBayes:
  def __init__(self):
    self.priors = dict()
    self.means = dict()
    self.covariances = dict()
    self.classes = None

  def fit(self, X, y):
    self.classes = np.unique(y)

    for c in self.classes:
      X_c = X[y == c]
      self.priors[c] = X_c.shape[0] / X.shape[0]
      self.means[c] = np.mean(X_c, axis=0)
      self.covariances[c] = np.diag(np.diag(np.cov(X_c, rowvar=False)))

  def predict(self, X):
    predictions = list()
    for x in X:
      log_posteriors = list()
      for c in self.classes:
        log_priors = np.log(self.priors[c])
        inv_cov = np.linalg.inv(self.covariances[c])
        inv_cov_det = np.linalg.det(inv_cov)
        diff = x-self.means[c]
        likelihood = 0.5 * np.log(inv_cov_det) - 0.5 * diff.T @ inv_cov @
        log_posterior = log_priors + likelihood
```

```
        log_posteriors.append(log_posterior)
      prediction = self.classes[np.argmax(log_posteriors)]
      predictions.append(prediction)
    return np.array(predictions)

  def decision_boundary(self, X, y):
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.1),
                         np.arange(y_min, y_max, 0.1))

    Z = self.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)

    plt.contourf(xx, yy, Z, alpha=0.4)
    plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k')

    for i, _ in enumerate(self.classes):
      mean = self.means[i]
      cov = np.diag(self.covariances[i])

      rv = multivariate_normal(mean, cov)
      x_grid, y_grid = np.mgrid[x_min:x_max:0.1, y_min:y_max:0.1]
      points = np.dstack((x_grid, y_grid))
      pdf_values = rv.pdf(points)

      plt.contour(x_grid, y_grid, pdf_values, levels=3, colors=f'C{i}', a
      plt.scatter(mean[0], mean[1], marker='x', color=f'C{i}', s=100)

    plt.title('Gaussian Naive Bayes Decision Boundary')
    plt.xlabel('Feature 1')
    plt.ylabel('Feature 2')
    plt.show()
```

```
gnb = GaussianNaiveBayes()
gnb.fit(X, y)
accuracy_score(y, gnb.predict(X))
```

```
0.96
```

```
gnb.decision_boundary(X, y)
```

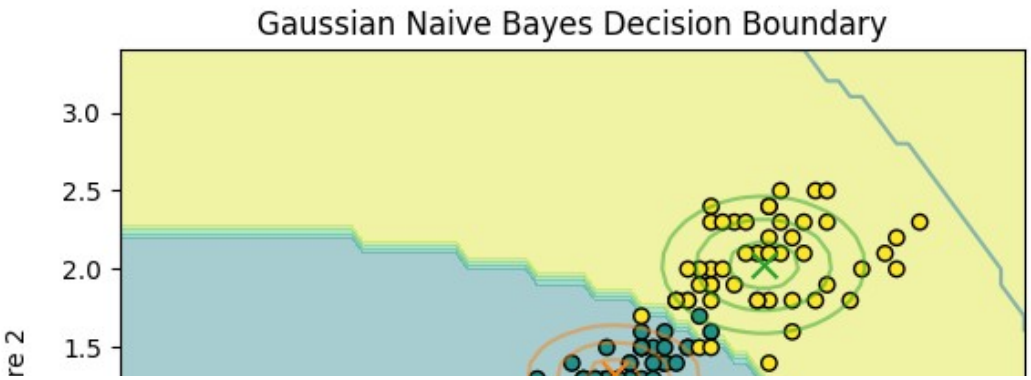

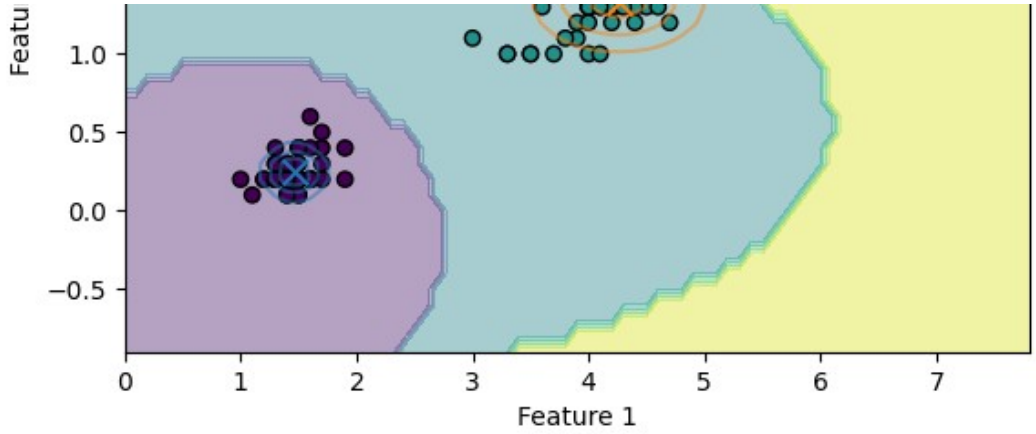

LDA для понижения размерности

Можно сказать, что линейный дискриминантный анализ стремится минимизировать **внутриклассовый разброс** (within-class scatter) $\mathbf{S}_W$.

$$\mathbf{S}_W = \sum_{i=1}^{N} \sum_{c=1}^{C} \delta_{ic} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top$$

Примечание. Поясним, что разброс $\mathbf{S}$ — это *общее* квадратичное отклонение от среднего арифметического, в то время как дисперсия является *средним* квадратичным отклонением,

$$\mathbf{S} = N\boldsymbol{\Sigma}$$

При этом мы можем пойти дальше и не только минимизировать внутриклассовый разброс, но и максимизировать **межклассовый разброс** (between-class scatter) $\mathbf{S}_B$.

$$\mathbf{S}_B = \sum_{c=1}^{C} N_c \cdot (\boldsymbol{\mu}_c - \boldsymbol{\mu}) \cdot (\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top,$$

где $\boldsymbol{\mu}$ — вектор средних значений, рассчитанных для всех n наблюдений по каждому из d признаков.

Одновременное решение обеих задач можно сформулировать через максимизацию отношения $\mathbf{S}_B / \mathbf{S}_W$ (критерий или **дискриминант Фишера**, Fisher's criterion). Поставим задачу найти такой вектор $\mathbf{w}$, что

$$\max_{w} J(\mathbf{w}) = \frac{\mathbf{w}^\top \mathbf{S}_B \mathbf{w}}{\mathbf{w}^\top \mathbf{S}_W \mathbf{w}}$$

Данная задача аналогична

$$\max_{w} J(\mathbf{w}) = \mathbf{w}^\top \mathbf{S}_B \mathbf{w}$$

с ограничением $\mathbf{w}^\top \mathbf{S}_W \mathbf{w} = 1$. Преобразуем задачу в задачу без ограничений с помощью множителей Лагранжа

$$\mathcal{L}(\mathbf{w}, \lambda) = \mathbf{w}^\top \mathbf{S}_B \mathbf{w} - \lambda(\mathbf{w}^\top \mathbf{S}_W \mathbf{w} - 1)$$

Дифференцируя по $\mathbf{w}$, получим

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial \mathbf{w}} &= 2\mathbf{S}_B \mathbf{w} - \lambda 2 \mathbf{S}_W \mathbf{w} &= 0 \\ \mathbf{S}_B \mathbf{w} &= \lambda \mathbf{S}_W \mathbf{w} \end{aligned}$$

Если $\mathbf{S}_W$ невырожденна, то

$$\mathbf{S}_W^{-1} \mathbf{S}_B \mathbf{w} = \lambda \mathbf{w}$$

Таким образом, задача сводится к нахождению собственных значений и соответствующих им собственных векторов матрицы $\mathbf{S}_W^{-1} \mathbf{S}_B$ (generalized eigenvalue problem).

Используя первые m собственных векторов $\mathbf{w}$, соответствующих наибольшим m собственным значениям, мы получим матрицу $\mathbf{W}_{d \times m}$, которая при умножении на матрицу данных $\mathbf{X}_{n \times d}$ преобразует последнюю в пространство меньшей размерности $\mathbf{Z}_{n \times m}$.

$$\mathbf{Z} = \mathbf{X} \cdot \mathbf{W}$$

В частности, для $m = 2$ получим,

$$\mathbf{Z} = \mathbf{X} \cdot \mathbf{W} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix} \cdot \underbrace{\begin{pmatrix} w_1^{(1)} & w_1^{(2)} \\ w_2^{(1)} & w_2^{(2)} \\ \vdots & \vdots \\ w_d^{(1)} & w_d^{(2)} \end{pmatrix}}_{m=2} = \begin{pmatrix} | & | \\ \mathbf{LD1} & \mathbf{LD2} \\ | & | \end{pmatrix}$$

Новые признаки, максимизирующие $\mathbf{S}_B$ и минимизирующие $\mathbf{S}_W$, называются **линейными дискриминантами** (linear discriminants, LD).

```
class LDA:
  def __init__(self):
    self.priors = dict()
    self.means = dict()
    self.covariances = None
    self.classes = None

  def fit(self, X, y):
    self.covariances = np.cov(X, rowvar=False)
    self.classes = np.unique(y)

    for c in self.classes:
      X_c = X[y == c]
      self.priors[c] = X_c.shape[0] / X.shape[0]
      self.means[c] = np.mean(X_c, axis=0)

  def predict(self, X):
    predictions = list()
    for x in X:
      log_posteriors = list()
      for c in self.classes:
        log_priors = np.log(self.priors[c])
        inv_cov = np.linalg.inv(self.covariances)
        inv_cov_det = np.linalg.det(inv_cov)
        diff = x-self.means[c]
        log_likelihood = 0.5 * np.log(inv_cov_det) - 0.5 * diff.T @ inv_c
        log_posterior = log_priors + log_likelihood
        log_posteriors.append(log_posterior)
      prediction = self.classes[np.argmax(log_posteriors)]
      predictions.append(prediction)
    return np.array(predictions)

  def fit_transform(self, X, y, n_components=2):
    self.classes = np.unique(y)
    n_features = X.shape[1]
    overall_mean = np.mean(X, axis=0)
    SW = np.zeros((n_features, n_features))
    SB = np.zeros((n_features, n_features))

    for c in self.classes:
      X_c = X[y == c]
      mean_c = np.mean(X_c, axis=0)
      SW += (X_c - mean_c).T.dot((X_c - mean_c))
      n_c = X_c.shape[0]
      mean_diff = (mean_c - overall_mean).reshape(n_features, 1)
      SB += n_c * (mean_diff).dot(mean_diff.T)
```

```
    A = np.linalg.inv(SW).dot(SB)
    eigenvalues, eigenvectors = np.linalg.eig(A)
    eigenvalues = np.real(eigenvalues)
    eigenvectors = np.real(eigenvectors.T)

    idxs = np.argsort(np.abs(eigenvalues))[::-1]
    eigenvalues = np.abs(eigenvalues[idxs])
    eigenvectors = eigenvectors[idxs]
    W = eigenvectors[:n_components]

    return np.dot(X, W.T)

  def decision_boundary(self, X, y):
    x_min, x_max = X[:, 0].min() - 1, X[:, 0].max() + 1
    y_min, y_max = X[:, 1].min() - 1, X[:, 1].max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, 0.1),
                         np.arange(y_min, y_max, 0.1))

    Z = self.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)

    plt.contourf(xx, yy, Z, alpha=0.4)
    plt.scatter(X[:, 0], X[:, 1], c=y, edgecolors='k')

    for i, _ in enumerate(self.classes):
      mean = self.means[i]
      rv = multivariate_normal(mean, self.covariances)
      x_grid, y_grid = np.mgrid[x_min:x_max:0.1, y_min:y_max:0.1]
      points = np.dstack((x_grid, y_grid))
      pdf_values = rv.pdf(points)

      plt.contour(x_grid, y_grid, pdf_values, levels=3, colors=f'C{i}', a
      plt.scatter(mean[0], mean[1], marker='x', color=f'C{i}', s=100)

    plt.title('Linear Discriminant Analysis Decision Boundary')
    plt.xlabel('Feature 1')
    plt.ylabel('Feature 2')
    plt.show()
```

```
iris = load_iris()
X, y = iris.data, iris.target
target_names = iris.target_names
```

```
lda = LDA()
# понизим размерность с четырех до двух измерений
X_lda = lda.fit_transform(X, y, n_components=2)
X.shape, X_lda.shape
```

```
((150, 4), (150, 2))
```

```
colors = ['navy', 'turquoise', 'darkorange']
```
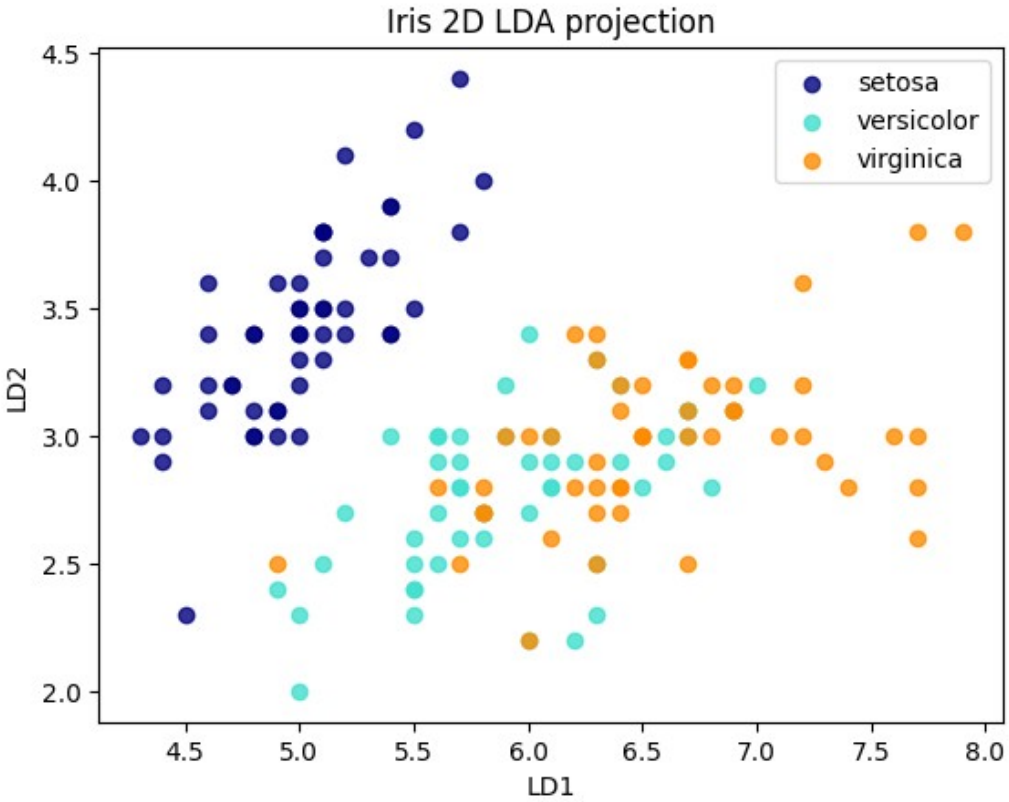
```
plt.figure()
for color, i, target_name in zip(colors, [0, 1, 2], iris.target_names):
  plt.scatter(X[y == i, 0], X[y == i, 1],
              alpha=0.8, color=color, label=target_name)

plt.legend(loc='best', shadow=False, scatterpoints=1)
plt.title('Iris 2D LDA projection')
plt.xlabel('LD1')
plt.ylabel('LD2')

plt.show()
```