Искусственная нейронная сеть

Искусственная нейронная сеть (artificial neural network, ANN) представляет собой (значительно) упрощенную модель естественной нейронной сети.

Модель естественного нейрона

Рассмотрим модель естественного нейрона.

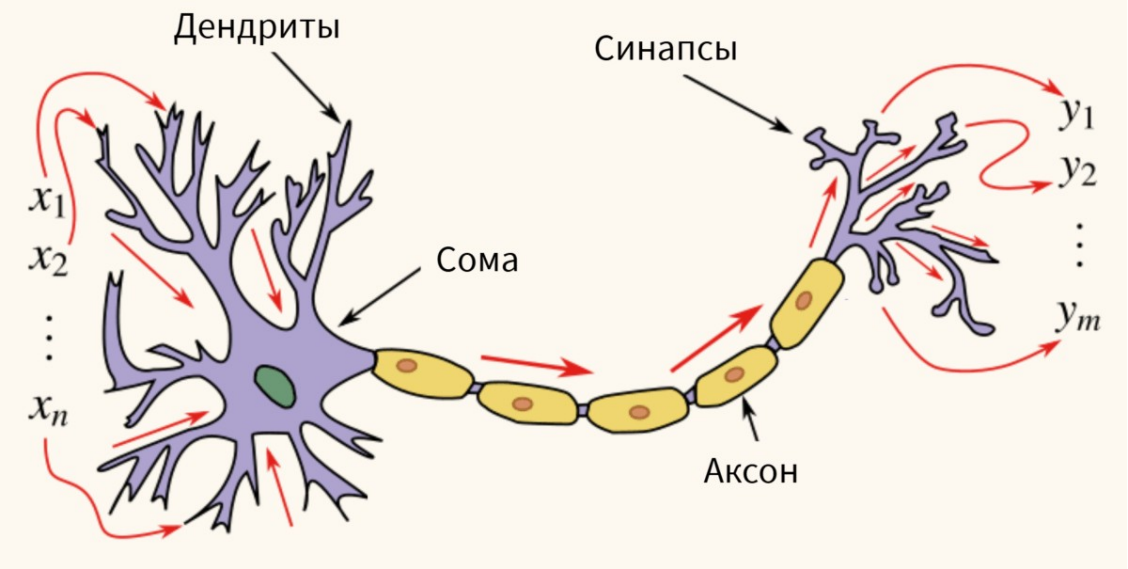

Источник: Википедия

Сигнал (небольшой электрический импульс) поступает на разветвленные отростки, называемые *дендритами*, аккумулируется в *соме* (теле клетки) и, если его суммарное значение превосходит некоторый порог, генерирует импульс, проходящий по *аксону* в *синапсы*, соединенные с дендритами другой нервной клетки.

Синапсы имеют разную способность пропускать импульс и соответственно передают заряды различной величины следующим нейронам.

Модель МакКаллока-Питтса

Именно эту сильно упрощенную схему действия естественного нейрона взяли за основу МакКаллок и Питтс (McCulloch and Walter Pitts model).

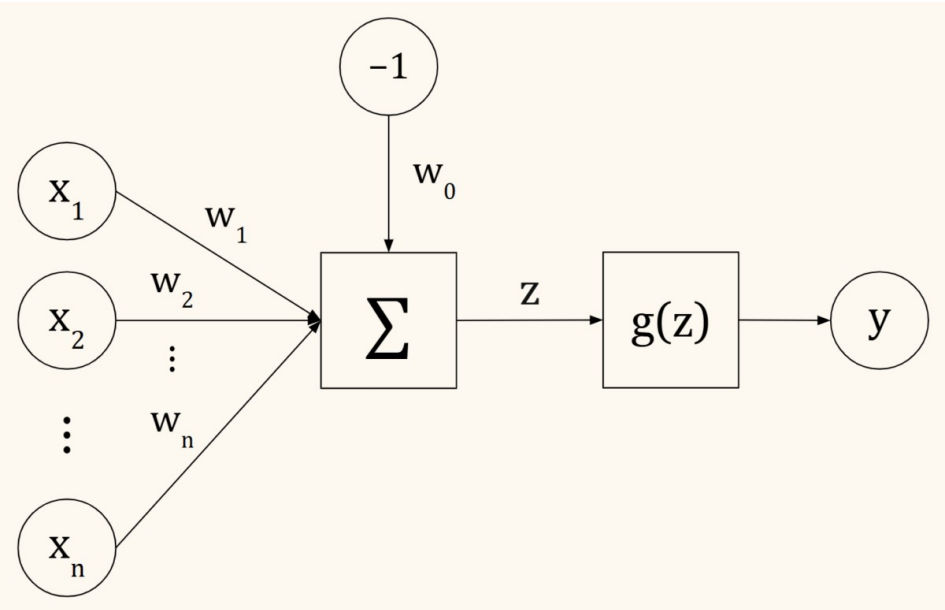

Они предложили использовать вектор бинарных признаков $\mathbf{x} = (x_1, \ldots, x_n)$ (сигнал, поступающий в дендриты) и вектор соответствующих весов $\mathbf{w} = (w_1, \ldots, w_n)$ (способность синапсов пропускать импульс), которые бы генерировали суммарное значение (импульса).

$$z = w_1 x_1 + \ldots + w_n x_n = \sum_{j=1}^{n} w_i x_i = \mathbf{w}^\top \mathbf{x}$$

При достижении определенного порога w_0 сигнал бы либо передавался дальше (выдавал единицу), либо не передавался (выдавал ноль).

$$g(z) = \begin{cases} 1 & \text{если } \mathbf{z} > w_0 \\ 0 & \text{если } \mathbf{z} \leq w_0. \end{cases}$$

Перенесем w_0 в левую часть неравенства и добавим признак $x_0 = -1$. Тогда,

$$z = w_0 x_0 + w_1 x_1 + \ldots + w_n x_n = \sum_{j=0}^{n} x_j w_j \ = \mathbf{w}^\top \mathbf{x}$$

$$g(z) = \begin{cases} 1 & \text{если } \mathbf{z} > 0 \\ 0 & \text{если } \mathbf{z} \leq 0, \end{cases}$$

где g — ступенчатая функция Хевисайда (**Heaviside step function** или **unit step function**).

Функция Хевисайда в общем случае называется **функцией активации** (activation function) и может быть заменена на другую функцию, в частности, сигнум-функцию или сигмоиду.

Линейный классификатор

Сведем задачу классификации к построению элементарной логической функции И.

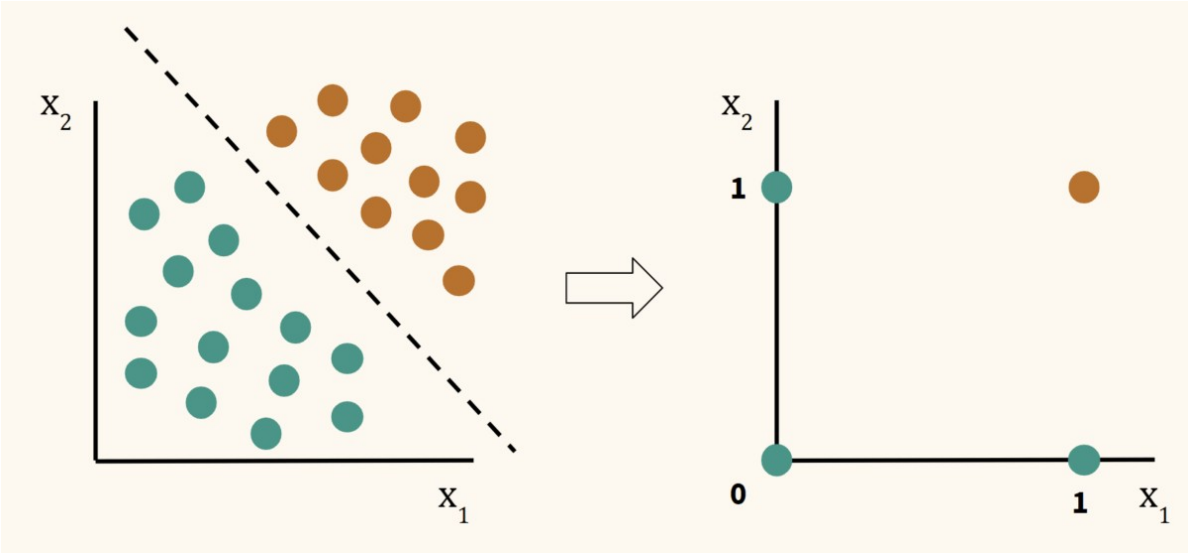

Решающая граница может быть задана, в частности, уравнением

$$2x_1 + 2x_2 - 3 = 0,$$

что соответствует искусственной нейросети с двумя входящими сигналами $x_1, x_2 \in \{0, 1\}$ и функции активации Хевисайда.

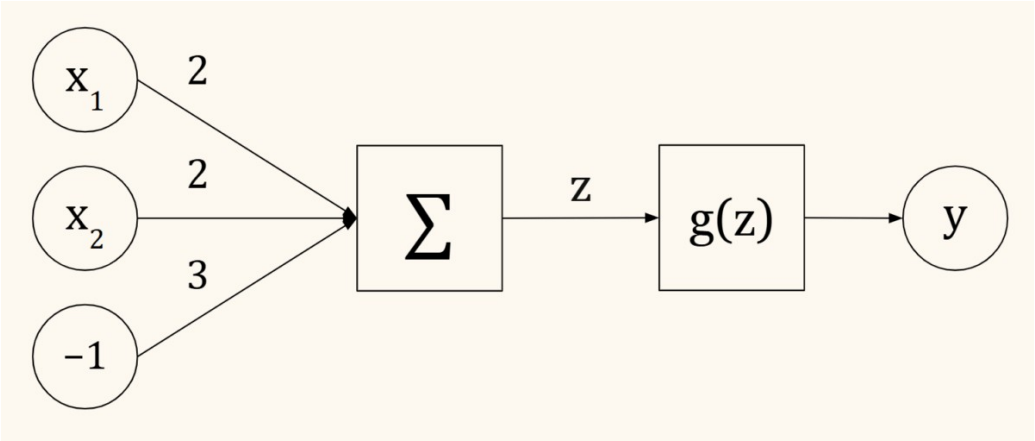

Аналогичным образом можно построить границу для логического ИЛИ.

$$2x_1 + 2x_2 - 1 = 0$$

Несложно построить и логическое НЕ.

$$2x_1 - 1 = 0$$

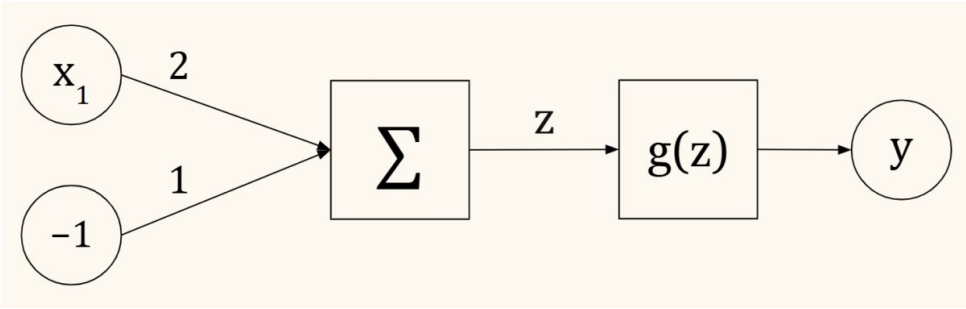

Персептрон Розенблатта

Остается открытым вопрос о том, как автоматически подбирать веса $\mathbf{w}$. Вновь проводя аналогию с естественной нейронной сетью, заметим, что при запоминании информации «правильные» связи между нейронами сохраняются, а «неправильные» — исчезают.

Правило Хэбба

Посмотрим, как это правило можно формализовать с помощью искусственной нейронной сети. Возьмем набор данных $\mathcal{D} = \{\mathbf{x}_i, y_i\}_{i=1}^N$ и преобразуем для удобства метки классов

$$y \in \{0, 1\} \to \{-1, +1\}$$

Вначале положим $\mathbf{w}$ равными нулю. Для построения разделяющей границы нам необходимо найти такие $\mathbf{w}$, чтобы

$$\begin{cases} \mathbf{w}^\top \mathbf{x} > 0 & \text{если } y = +1 \\ \mathbf{w}^\top \mathbf{x} \leq 0 & \text{если } y = -1. \end{cases}$$

Заменим функцию Хевисайда на сигнум-функцию

$$g(z) = sgn(\mathbf{w}^\top \mathbf{x}),$$

которая будет выдавать $+1$, если скарярное произведение положительно, и -1, если отрицательно, и тогда,

- если значение $g(z)$ совпадет с меткой класса, мы оставим веса $\mathbf{w}$ без изменений, т.е. сохраним синаптическую связь; но
- если не совпадет — изменим связь между нейронами, и, в частности,
  - если $y = +1$ и $g(z) = -1$, прибавим вектор $\mathbf{x}$ к вектору $\mathbf{w}$;
  - если $y = -1$ и $g(z) = +1$, вычтем вектор $\mathbf{x}$ из вектора $\mathbf{w}$.

Такое правило обновления весов удобно записать следующим образом

$$\mathbf{w} := \mathbf{w} + \Delta\mathbf{w}$$

$$\Delta\mathbf{w} = \eta \left(y_i - g(z)_i\right) \mathbf{x}_i,$$

где $\mathbf{x}_i$ — один из N объектов, y_i — соответствующая метка класса,

$g(z)_i$ — прогноз для $\mathbf{x}_i$ объекта и η — коэффициент скорости обучения. В самом деле,

- если значение $g(z)_i$ совпадает с меткой класса, то $(y_i - g(z)_i)$ будет равно нулю;
- если нет, то опять же возможны два сценария:
  - $\Delta\mathbf{w} = \eta(1_i - (-1_i))\ \mathbf{x}_i = \eta(2)\ \mathbf{x}_i$
  - $\Delta\mathbf{w} = \eta(-1_i - 1_i)\ \mathbf{x}_i = \eta(-2)\ \mathbf{x}_i$

Почему это работает? Вспомним, что скалярное произведение характеризует угол между векторами.

$$\begin{aligned} \cos\theta &= \frac{\mathbf{w}^\top\mathbf{x}}{||\mathbf{w}||||\mathbf{x}||} \\ &\propto \mathbf{w}^\top\mathbf{x} \end{aligned}$$

В случае правильно классифицированных данных,

- если $\mathbf{w}^\top\mathbf{x} > 0 \implies \cos\theta > 0 \implies \theta < 90^\circ$;
- если $\mathbf{w}^\top\mathbf{x} < 0 \implies \cos\theta < 0 \implies \theta > 90^\circ$.

Например,

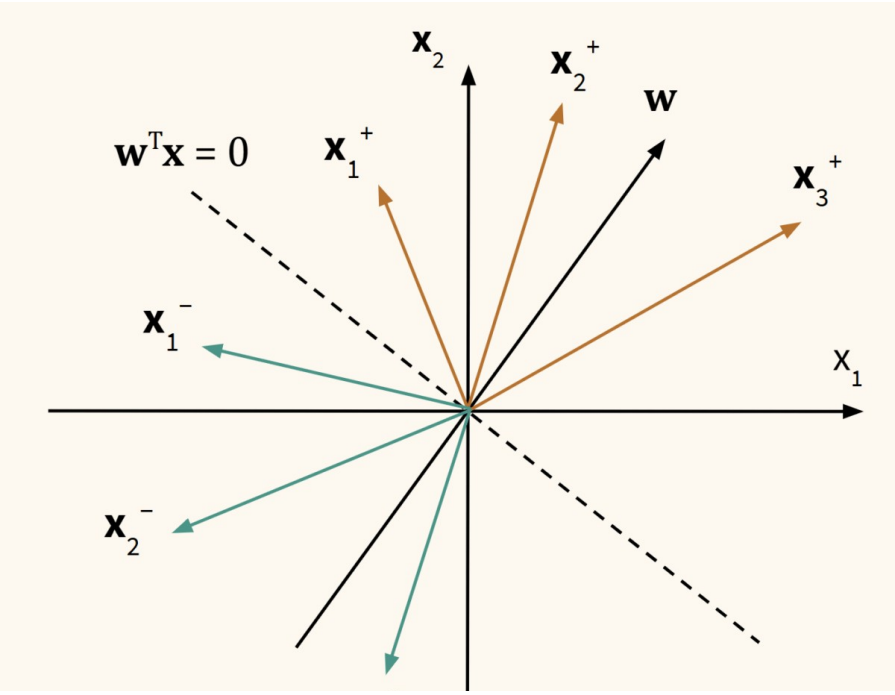

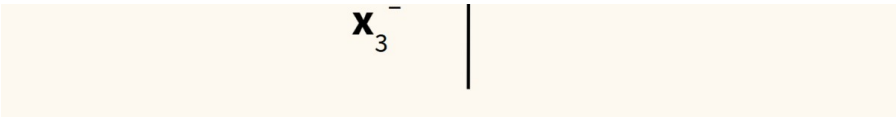

Если же данные классифицированы неправильно, то в случае если мы прибавляем вектор $\mathbf{x}$ к вектору $\mathbf{w}$, то есть $\mathbf{w}' = \mathbf{w} + \mathbf{x}$, то $\cos\theta'$ будет больше $\cos\theta$

$$
\begin{aligned}
\cos\theta' &\propto \mathbf{w}'^\top \mathbf{x} \\
&\propto (\mathbf{w} + \mathbf{x})^\top \mathbf{x} \\
&\propto \mathbf{w}^\top + \mathbf{x}^\top \mathbf{x} \\
&\propto \cos\theta + \mathbf{x}^\top \mathbf{x} \\
\cos\theta' &> \cos\theta
\end{aligned}
$$

Таким образом, мы уменьшаем угол между положительным объектом-нарушителем и вектором $\mathbf{w}$. Например, на рисунке ниже, таким объектом является вектор $\mathbf{x}_1^+$.

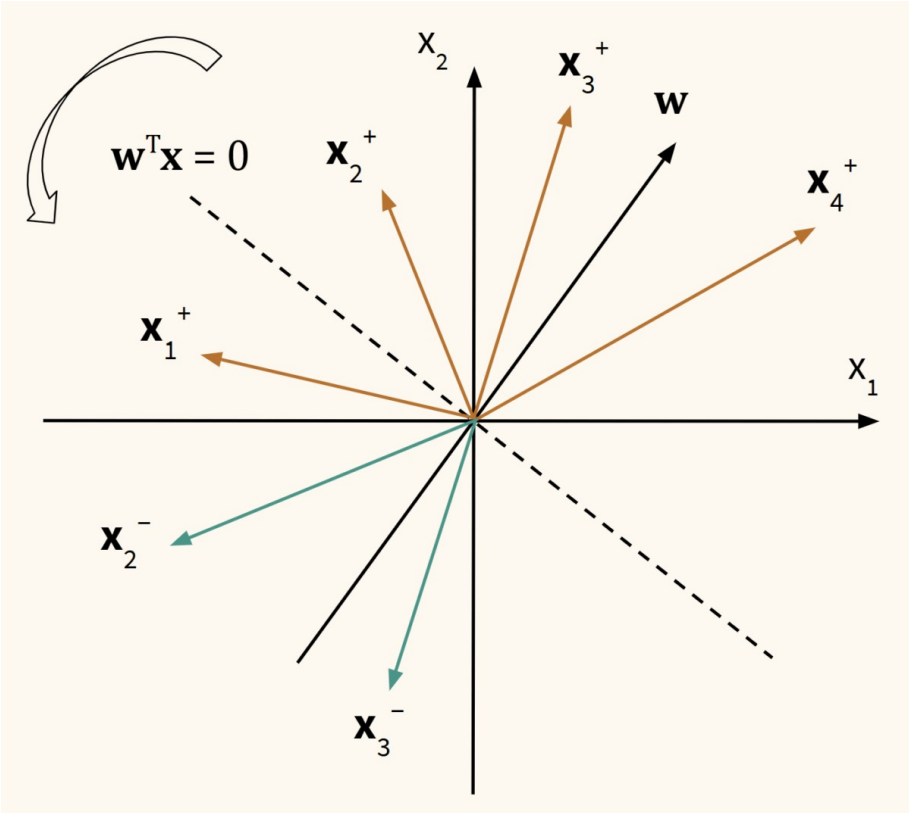

Сложив $\mathbf{x}_1^+$ и $\mathbf{w}$ мы повернем границу против часовой стрелки и добьемся правильной классификации всех объектов. Аналогичное рассуждение можно провести и для отрицательного объекта-

нарушителя.

$$
\begin{aligned}
\cos\theta'' &\propto \mathbf{w}''^{\top}\mathbf{x} \\
&\propto (\mathbf{w}-\mathbf{x})^{\top}\mathbf{x} \\
&\propto \mathbf{w}^{\top}-\mathbf{x}^{\top}\mathbf{x} \\
&\propto \cos\theta-\mathbf{x}^{\top}\mathbf{x} \\
\cos\theta'' &< \cos\theta
\end{aligned}
$$

Такое правило обновления весов называется **правилом Хэбба** (Hebb's rule), а сам алгоритм — **персептроном Розенблатта** (Rosenblatt's Perceptron).

Теорема Новикова

В случае линейно разделимых данных для правила Хэбба доказана сходимость к оптимальному $\mathbf{w}^*$ за конечное число t шагов (Новиков, 1962).

Доказательство. Будем исходить из следующих допущений:

- вектор $\mathbf{w}^0 = \mathbf{0}$ — вектор весов на $t = 0$ шаге;
- без ограничения общности положим $\eta = 1$;
- на шагах $t = (1, \ldots, T)$:
  - если $y^t(\mathbf{w}^{\top}\mathbf{x}^t) \leq 0$, обновим веса $\mathbf{w}^{t+1} = \mathbf{w}^t + y^t\mathbf{x}^t$;
  - если $y^t(\mathbf{w}^{\top}\mathbf{x}^t) > 0$, оставим веса без изменений $\mathbf{w}^{t+1} = \mathbf{w}^t$.

Критерием сходимости будет выполнение $y_i(\mathbf{w}^{*\top}\mathbf{x}_i) > 0$ для каждого объекта $\{\mathbf{x}_i, y_i\}_{i=1}^N$.

Рассмотрим только те шаги, на которых алгоритм ошибается, а также для простоты только класс $y = +1$, поскольку мы всегда можем обобщить это правило умножив на y^t. Тогда,

$$\mathbf{w}^{t+1} = \mathbf{w}^t + \mathbf{x}^t$$

и поскольку $\mathbf{w}^0 = \mathbf{0}$, то по индукции

$$\begin{array}{rcl} \mathbf{w}^1 & = & \mathbf{x}^0 \\ \mathbf{w}^2 & = & \mathbf{x}^1 + \mathbf{x}^0 \\ \dots & & \dots \\ \mathbf{w}^{t+1} & = & \mathbf{x}^1 + \mathbf{x}^2 + \ldots + \mathbf{x}^t \end{array} \tag{1}$$

В силу того что данные линейно разделимы, $\mathbf{w}^*$ существует, а значит

$$\mathbf{w}^{*\top}\mathbf{x}^t > 0 \quad \text{для} \quad \mathbf{x}^1, \mathbf{x}^2, \ldots, \mathbf{x}^t$$

Пусть α — положительное число, такое что $\alpha = \min \mathbf{w}^{*\top}\mathbf{x}^t$. Умножим обе части (1) на $\mathbf{w}^{*\top}$.

$$\underbrace{\mathbf{w}^{*\top}\mathbf{w}^{t+1}}_{\geq t\alpha} = \underbrace{\mathbf{w}^{*\top}\mathbf{x}^1}_{\geq \alpha} + \underbrace{\mathbf{w}^{*\top}\mathbf{x}^2}_{\geq \alpha} + \ldots + \underbrace{\mathbf{w}^{*\top}\mathbf{x}^t}_{\geq \alpha}$$

$$\mathbf{w}^{*\top}\mathbf{w}^{t+1} \geq t\alpha$$

По неравенству Коши-Буняковского,

$$\begin{array}{rcl} \|\mathbf{w}^*\|^2\|\mathbf{w}^{t+1}\|^2 & \geq & [\mathbf{w}^{*\top} \cdot \mathbf{w}^{t+1}]^2 \\ \|\mathbf{w}^*\|^2\|\mathbf{w}^{t+1}\|^2 & \geq & t^2\alpha^2 \\ \|\mathbf{w}^{t+1}\|^2 & \geq & \dfrac{t^2\alpha^2}{\|\mathbf{w}^*\|^2} \end{array} \tag{2}$$

Одновременно, поскольку согласно допущению мы рассматриваем только ошибочно классифицированные объекты, то справедливо, что

$$\mathbf{w}^{k+1} = \mathbf{w}^k + \mathbf{x}^k, \quad k = 1, \ldots, t.$$

Найдем евклидово расстояние.

$$\|\mathbf{w}^{k+1}\|^2 = \|\mathbf{w}^k + \mathbf{x}^k\|^2$$

$$\|\mathbf{w}^{k+1}\|^2 = \|\mathbf{w}^k\|^2 + \|\mathbf{x}^k\|^2 + 2\mathbf{w}^{k\top}\mathbf{x}^k$$

В силу того, что опять же алгоритм ошибается,

$$\mathbf{w}^{k\top}\mathbf{x}^k < 0 \implies 2\mathbf{w}^{k\top}\mathbf{x}^k < 0,$$

а значит

$$\|\mathbf{w}^{k+1}\|^2 \leq \|\mathbf{w}^k\| + \|\mathbf{x}^k\|^2$$

С учетом того, что $\|\mathbf{w}^0\|^2 = \|\mathbf{0}\|^2 = \mathbf{0}$, то по индукции

$$\|\mathbf{w}^{t+1}\|^2 \leq \sum_{k=1}^{t} \|\mathbf{x}^k\|^2$$

Пусть β — положительное число, такое что $\beta = \max \|\mathbf{x}^k\|^2$. Тогда,

$$\|\mathbf{w}^{t+1}\|^2 \leq t\beta \tag{3}$$

Соответственно, из (2) и (3) получаем, что

$$\frac{t^2\alpha^2}{\|\mathbf{w}^*\|^2} \leq \|\mathbf{w}^{t+1}\|^2 \leq t\beta$$

Заметим, что $\frac{t^2\alpha^2}{\|\mathbf{w}^*\|^2}$ увеличивается быстрее, чем $t\beta$.

Пусть $t = t_{\max}$ — шаг, на котором

$$\frac{t_{\max}^2\alpha^2}{\|\mathbf{w}^*\|^2} = t_{\max}\beta$$

Тогда достаточное число корректировок $\mathbf{w}$ не превосходит

$$t_{\max} = \frac{\beta\|\mathbf{w}^*\|^2}{\alpha^2}$$

Код на Питоне

Откроем блокнот к занятию

Создадим класс Perceptron.

```
class Perceptron:

  def __init__(self, eta=0.01, epochs=50, const=0):
    self.eta = eta
    self.const = const
    self.epochs = epochs
    self.w = None

  def fit(self, X, y):

    X = np.c_[np.ones((len(X), 1)), X]
    # константа добавляется для вычислительной устойчивости
    self.w = np.zeros(X.shape[1]) + self.const

    for _ in range(self.epochs):
      for xi, target in zip(X, y):
        delta = self.eta * (target - np.where(np.dot(xi, self.w) >
        self.w += delta * xi

    return self

  def predict(self, X):
    X = np.c_[np.ones((len(X), 1)), X]
    scores = np.dot(X, self.w)
    y_pred = np.where(np.dot(X, self.w) > .0, 1, -1)
    return y_pred, scores
```

Возьмем линейно разделимые данные.

```
def get_separable_data():
  X_train = np.array([[-3.5, -1],[-3, 0], [-3, 1], [-2.7, -1.3], [
                      [-1, -2.5], [0, -3], [0, 1], [0, 2.5], [1, 2
                      [2.1, 0.2], [2.3, 1], [2.8, 1.8], [2.2, 2.8]
  y_train = np.array([-1, -1, -1, -1, -1, -1, -1, -1, 1, 1, 1, 1,
  X_test = np.array([[0, 0], [1, -3]])
  y_test = np.array([1, -1])

  return X_train, y_train, X_test, y_test
```

```
X_train, y_train, X_test, y_test = get_separable_data()
```

Обучим однослойный персептрон.

```
slp = Perceptron().fit(X_train, y_train)
```

```
accuracy_score(y_train, slp.predict(X_train)[0])
```

```
1.0
```

Посмотрим на решающую границу.

```
def plot_data(X, y, title, w=None, b=None, ticks=None):
  plt.figure(figsize=(5, 5))
  plt.scatter(X_train[:, 0], X_train[:, 1], c=y_train,
              cmap=colors.ListedColormap(clrs))

  ax_min, ax_max = min(X_train.ravel() - 1), max(X_train.ravel() +
  xx = np.linspace(ax_min, ax_max)

  hyperplane_slope = -w[0]/w[1]
  hyperplane_intercept = -b/w[1]
  yy = hyperplane_slope*xx + hyperplane_intercept
  hyperplane = np.array(list(zip(xx, yy)))
  plt.plot(hyperplane[:, 0], hyperplane[:, 1], 'k-')

  if ticks != None:
    plt.xticks(ticks)
    plt.yticks(ticks)
  plt.xlim(ax_min, ax_max)
  plt.ylim(ax_min, ax_max)
  plt.title(title)
  plt.xlabel('x1')
  plt.ylabel('x2')
  plt.show()
```

```
plot_data(X_train, y_train, title='Single Layer Perceptron Boundar
          w=slp.w[1:], b=slp.w[0])
```

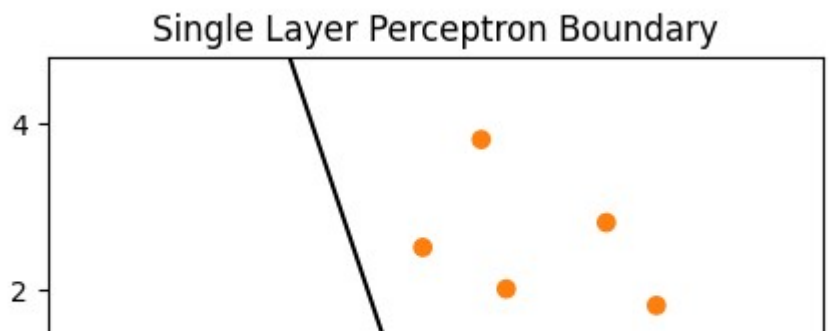

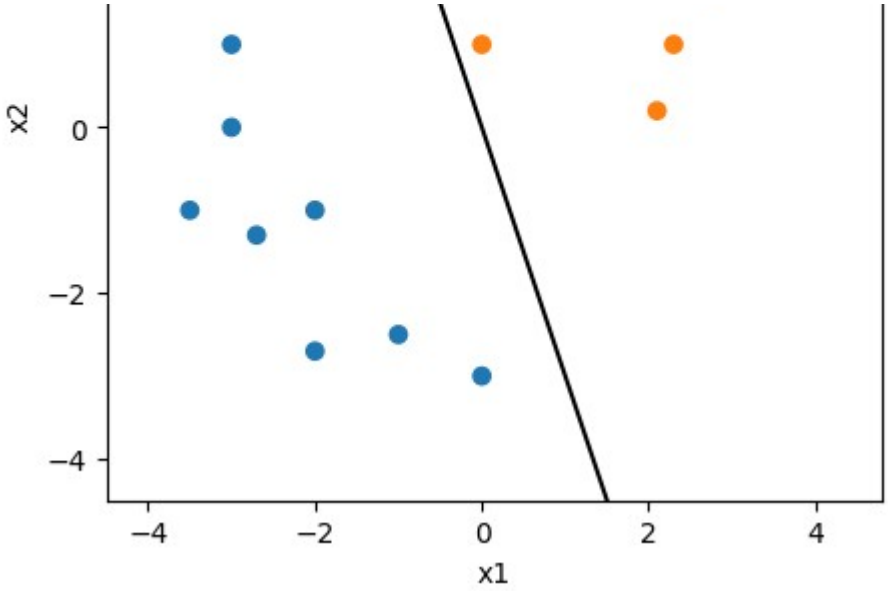

Ширина зазора

Персептрон перестает искать разделяющую границу, как только все объекты оказываются правильно классифицированы. Такая граница может не быть оптимальной с точки зрения ширины зазора (обобщающей способности алгоритма).

```
slp.predict(X_test)[0], y_test
```

```
(array([-1, -1]), array([ 1, -1]))
```

Сравните результат выше с границей, построенной на тех же данных методом опорных векторов.

Адаптивный линейный нейрон

Заменим функцию Хевисайда на линейную функцию

$$g(z) = g(\mathbf{w}^\top \mathbf{x}) = \mathbf{w}^\top \mathbf{x}$$

В этом случае мы можем определить уровень ошибки алгоритма как сумму квадратов отклонений прогнозных значений от метки класса.

$$J(\mathbf{w}) = \frac{1}{2}\sum_{i=1}^{N}(y_i - g(z)_i)^2$$

Уточним, что $g(z) \in \mathbb{R}$. Найти минимум $J(\mathbf{w})$ можно методом градиентного спуска

$$\Delta\mathbf{w} = -\eta\nabla J(\mathbf{w})$$

или, для одного параметра, w_j

$$\Delta w_j = -\eta\frac{\partial J}{\partial w_j}$$

Найдем частные производные

$$\begin{aligned}
\frac{\partial J}{\partial w_j} &= \frac{\partial}{\partial w_j}\frac{1}{2}\sum_{i=1}^{N}(y_i - g(z)_i)^2 \\
&= \frac{1}{2}\sum_{i=1}^{N}\frac{\partial}{\partial w_j}(y_i - g(z)_i)^2 \\
&= \frac{1}{2}\sum_{i=1}^{N}2(y_i - g(z)_i)\frac{\partial}{\partial w_j}(y_i - g(z)_i) \\
&= \sum_{i=1}^{N}(y_i - g(z)_i)\frac{\partial}{\partial w_j}\left(y_i - \sum_{j=1}^{n}w_j x_{ij}\right) \\
&= \sum_{i=1}^{N}(y_i - g(z)_i)(-x_{ij})
\end{aligned}$$

Тогда правило обновления весов можно определить как

$$\Delta w_j = -\eta\frac{\partial J}{\partial w_j} = -\eta\sum_{i=1}^{N}(y_i - g(z)_i)(-x_{ij}) = \eta\sum_{i=1}^{N}(y_i - g(z)_i)x_{ij}$$

или, в векторизованной форме,

$$\Delta\mathbf{w} = \eta \odot X^{\top}(\mathbf{y} - g(\mathbf{z}))$$

$$\mathbf{w} := \mathbf{w} + \Delta\mathbf{w}$$

Такое правило обучения называется **дельта-правилом** (delta-rule), а сам алгоритм — **адаптивным линейным нейроном** (ADALINE).

Приведем код на Питоне.

```
class AdalineGD:

  def __init__(self, eta=0.01, epochs=50):
    self.eta = eta
    self.epochs = epochs
    self.w = None
    self.loss_history = []

  def fit(self, X, y):

    X = np.c_[np.ones((len(X), 1)), X]
    self.w = np.zeros(X.shape[1])

    for i in range(self.epochs):
      errors = (y - np.dot(X, self.w))
      self.w += self.eta * X.T.dot(errors)
      loss = (errors**2).sum() / 2
      self.loss_history.append(loss)

    return self

  def predict(self, X):
    X = np.c_[np.ones((len(X), 1)), X]
    y_pred = np.where(np.dot(X, self.w) > .0, 1, -1)

    return y_pred
```

```
adaline_gd = AdalineGD().fit(X_train, y_train)
```

```
accuracy_score(y_train, adaline_gd.predict(X_train))
```

```
1.0
```

```
plot_data(X_train, y_train, title='Adaline with GD Boundary',
          w=adaline_gd.w[1:], b=adaline_gd.w[0])
```

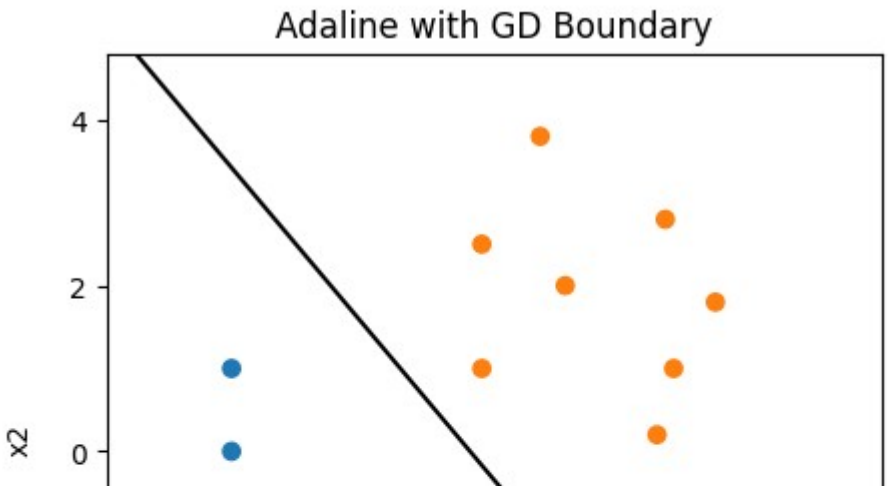

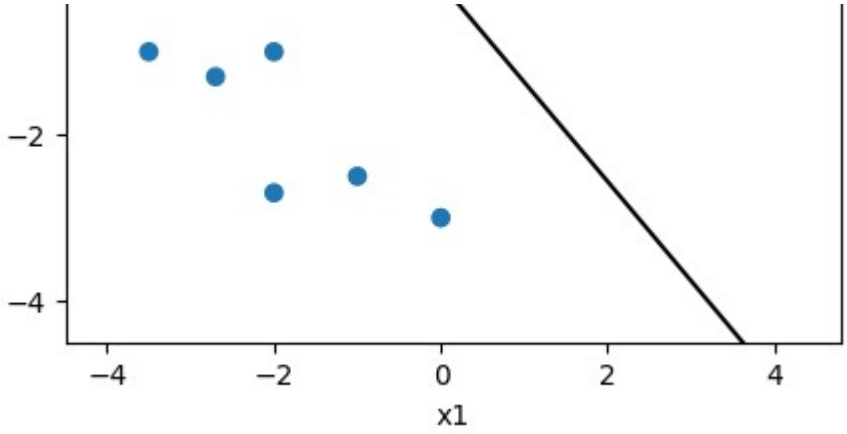


```
plt.plot(adaline_gd.loss_history)
plt.title('Adaline with GD Loss History')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.show()
```

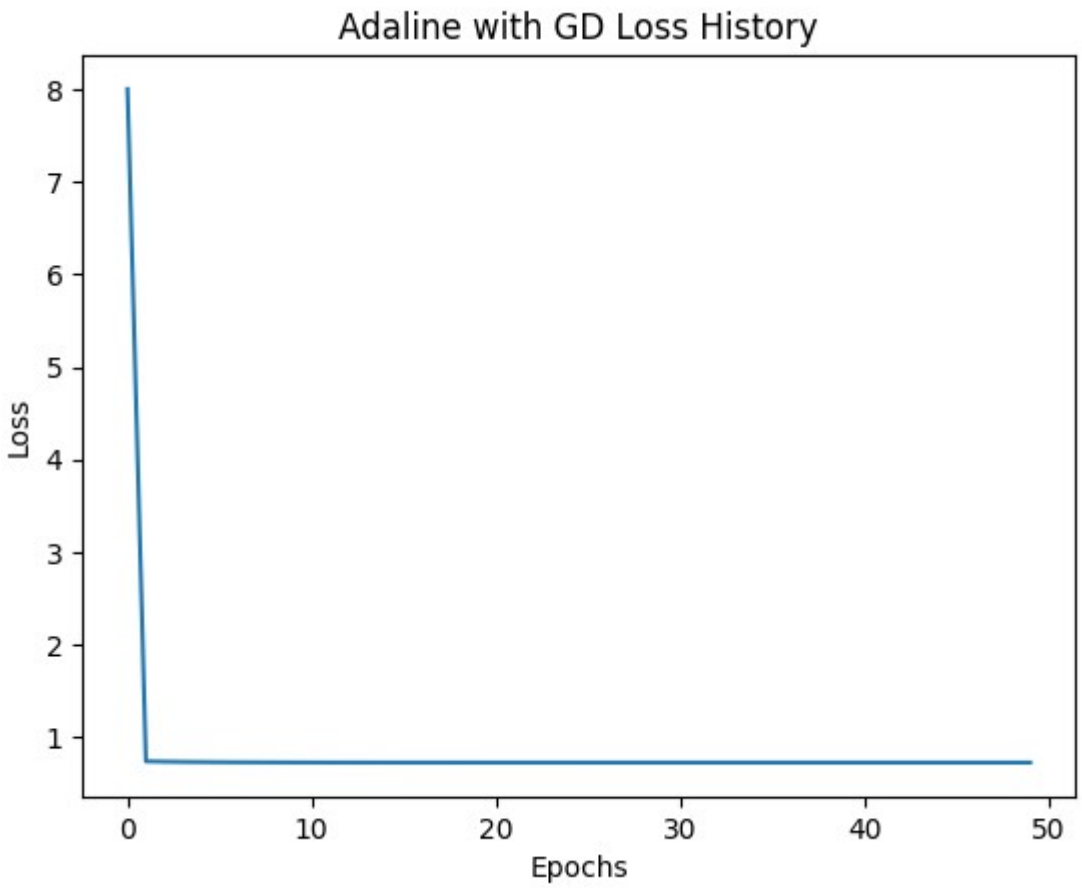

Выше мы обновляли веса на основе всех объектов обучающей выборки (full-batch gradient descent).

Обновлять параметры можно после предъявления одного (случайного) объекта. В этом случае речь идет о стохастическом градиентном

спуске (stochastic gradient descent, SGD).

```
class AdalineSGD:

  def __init__(self, eta=0.01, epochs=50):
    self.eta = eta
    self.epochs = epochs
    self.w = None
    self.loss_history = []

  def fit(self, X, y):

    X = np.c_[np.ones((len(X), 1)), X]
    self.w = np.zeros(X.shape[1])

    for i in range(self.epochs):
      for xi, yi in zip(X,y):
        errors = (yi - np.dot(xi, self.w))
        self.w += self.eta * xi.T.dot(errors)

      loss = ((y - np.dot(X, self.w))**2).sum() / 2
      self.loss_history.append(loss)

    return self

  def predict(self, X):
    X = np.c_[np.ones((len(X), 1)), X]
    y_pred = np.where(np.dot(X, self.w) > .0, 1, -1)

    return y_pred
```

```
accuracy_score(y_train, AdalineSGD().fit(X_train, y_train).predict
```

```
1.0
```

Помимо ширины зазора еще одним ограничением персептрона Розенблатта является невозможность найти границу линейно неразделимых данных.

Линейно неразделимые данные

Сведем линейно неразделимые данные к построению функции

исключающего ИЛИ-НЕ (XNOR).

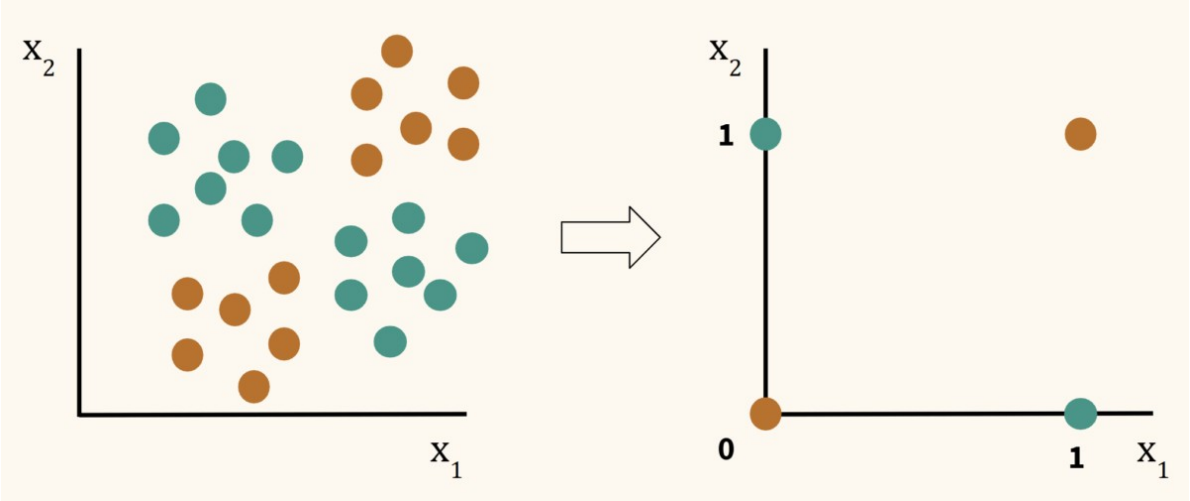

Приведем таблицу истинности.

x1	x2	XNOR
0	0	1
0	1	0
1	0	0
1	1	1

Полиномиальные коэффициенты

Одним из решений было бы нелинейное преобразование признаков, как в случае полиномиальной логистической регрессии. В задаче исключающего ИЛИ-НЕ достаточно добавить признак $x_1 x_2$.

$$x_1 \odot x_2 = w_0 x_0 + w_1 x_1 + w_2 x_2 + w_3 x_1 x_2,$$

где $\odot$ — оператор исключающего ИЛИ-НЕ. Найдем оптимальные веса с помощью персептрона Розенблатта.

```
# добавим x1 * x2 (третий столбец)
X_train = np.array([[0, 0, 0],
                    [0, 1, 0],
```

```
                    [1, 0, 0],
                    [1, 1, 1]])

y_train = np.array([1, -1, -1, 1])
```

```
slp_poly = Perceptron(const=1e-10).fit(X_train, y_train)
accuracy_score(y_train, slp_poly.predict(X_train)[0])
```

```
1.0
```

Вначале посмотрим на разделяющую гиперплоскость в трехмерном признаковом пространстве $\mathcal{H}$.

```
fig = plt.figure(figsize=(6,6))
ax = plt.axes(projection='3d')

# выведем данные
ax.scatter3D(X_train[:, 0], X_train[:, 1], X_train[:, 2], c=y_trai
             cmap=colors.ListedColormap(clrs))

# выведем разделяющую гиперплоскость
x = np.linspace(0,1,10)
y = np.linspace(0,1,10)

# ax + by + cz = d
d,a,b,c = slp_poly.w
xx,yy = np.meshgrid(x,y)
Z = (d - a*xx - b*yy) / c
ax.plot_surface(xx, yy, Z, alpha=0.2)

ticks = [0, 1]
ax.set_xticks(ticks)
ax.set_yticks(ticks)
ax.set_zticks(ticks)
ax.set_title('3D decision boundary')
ax.set_xlabel('x1')
ax.set_ylabel('x2')
ax.set_zlabel('x1 * x2')
ax.grid(False)
ax.set_box_aspect(aspect=None, zoom=0.8)
plt.show()
```

3D decision boundary

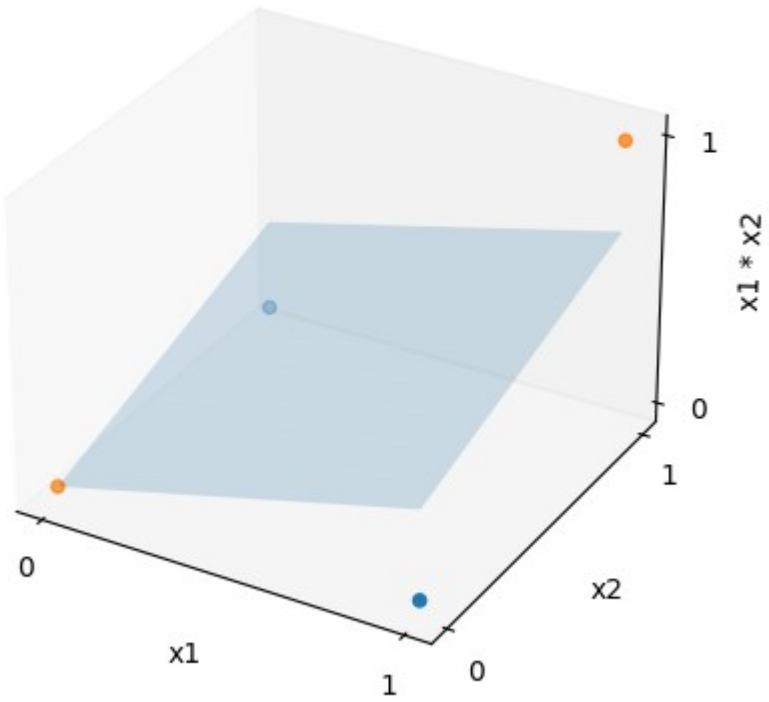

Также выведем решающую границу в изначальном двумерном пространстве $\mathcal{L}$.

```
plt.scatter(X_train[:, 0], X_train[:, 1],
            c=y_train, s=40, cmap=colors.ListedColormap(clrs))

x_min, x_max = X_train[:, 0].min() - 1, X_train[:, 0].max() + 1
y_min, y_max = X_train[:, 1].min() - 1, X_train[:, 1].max() + 1
xx, yy = np.meshgrid(np.linspace(x_min, x_max, 1000),
                     np.linspace(y_min, y_max, 1000))
Z = slp_poly.predict(np.c_[xx.ravel(), yy.ravel(), xx.ravel() * yy
Z = Z.reshape(xx.shape)
plt.contour(xx, yy, Z, levels = [0], colors = ['k'])

ticks = [0, 1]
plt.xticks(ticks)
plt.yticks(ticks)
plt.title('2D decision boundary')
plt.xlabel('x1')
plt.ylabel('x2')
plt.show()
```

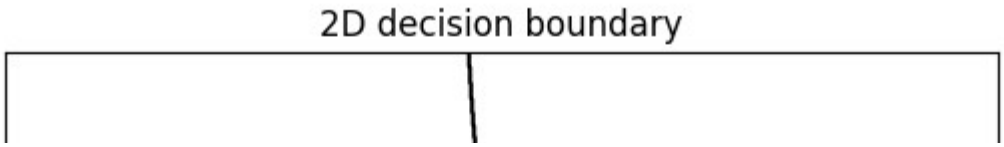

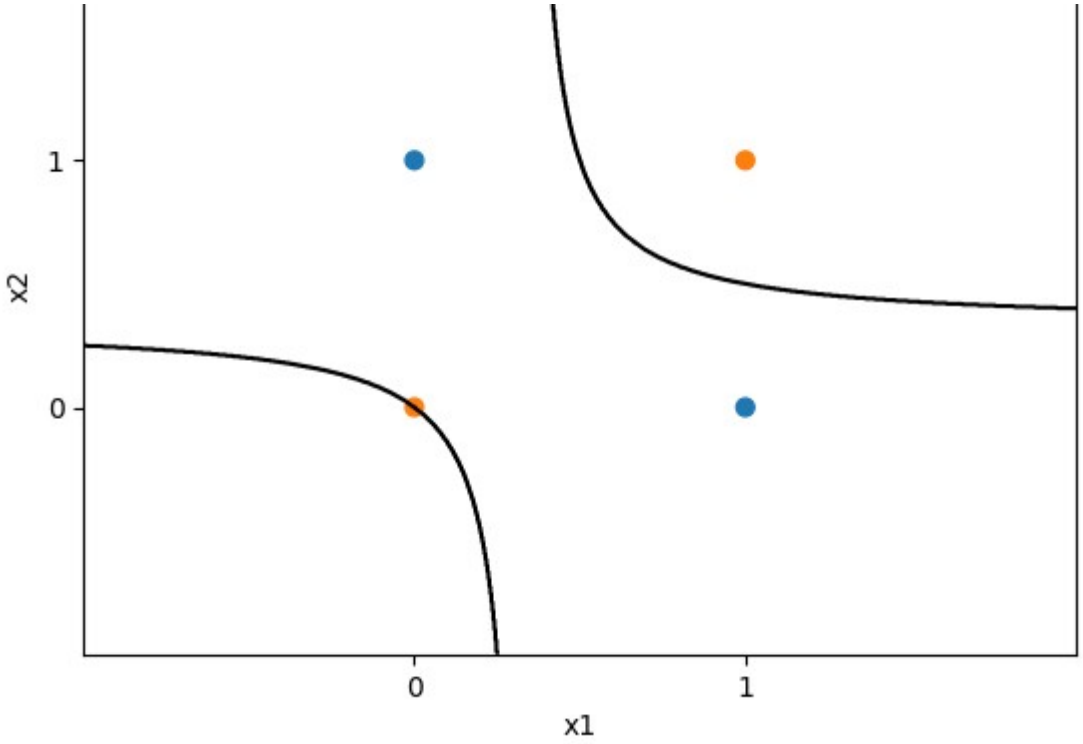

Ожидаемо, линейной границе в $\mathcal{H}$ соответствует нелинейная граница в $\mathcal{L}$.

Заметим, что с ростом количества признаков и степени полинома итоговое количество признаков, а значит и «затратность» алгоритма будут расти.

Для полинома n-ой степени *с одним признаком* формула выглядит следующим образом.

$$y = \sum_{j=0}^{n} w_j x^j$$

Например, полином второй степени будет иметь три коэффициента.

$$y = w_0 + w_1 x + w_2 x^2$$

Полином второй степени *с двумя признаками* будет иметь уже шесть коэффициентов.

$$y = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_1^2 + w_4 x_1 x_2 + w_5 x_2^2$$

В целом, количество полиномиальных коэффициентов K можно рассчитать по формуле.

$$K(n, d) = C(n + d, d),$$

где,

- n — количество линейных признаков;
- d — степень полинома;
- C — количество возможных сочетаний.

Используя пример выше, получим

$$K(2, 2) = C(4, 2) = 6$$

Полином третьей степени на основе десяти линейных признаков уже потребует создать 286 коэффициентов.

$$K(10, 3) = C(13, 10) = 286$$

Если речь идет о картинках 28 x 28 пикселей, то после «вытягивания» каждой картинки у нас появится датасет с 784 признаками. Значит, количество членов полинома второй степени составит

$$K(784, 2) = C(786, 2) = 308505$$

Замечу, что примерное количество признаков полинома второй степени также можно рассчитать по формуле $\frac{(n)^2}{2}$, то есть $\frac{(784)^2}{2} = 307328.$

Многослойный персептрон

Альтернативным решением было бы использование нескольких «слоев» персептрона или **многослойный персептрон** (multilayer perceptron, MLP).

В самом деле, используя лишь один скрытый слой из двух нейронов, несложно подобрать подходящие веса (функцией активации $g(z)$ снова будет функция Хевисайда).

$$x_1 \odot x_2 = [2g(2x_1 + 2x_2 - 3) + 2g(-2x_1 - 2x_2 + 1) - 1]$$

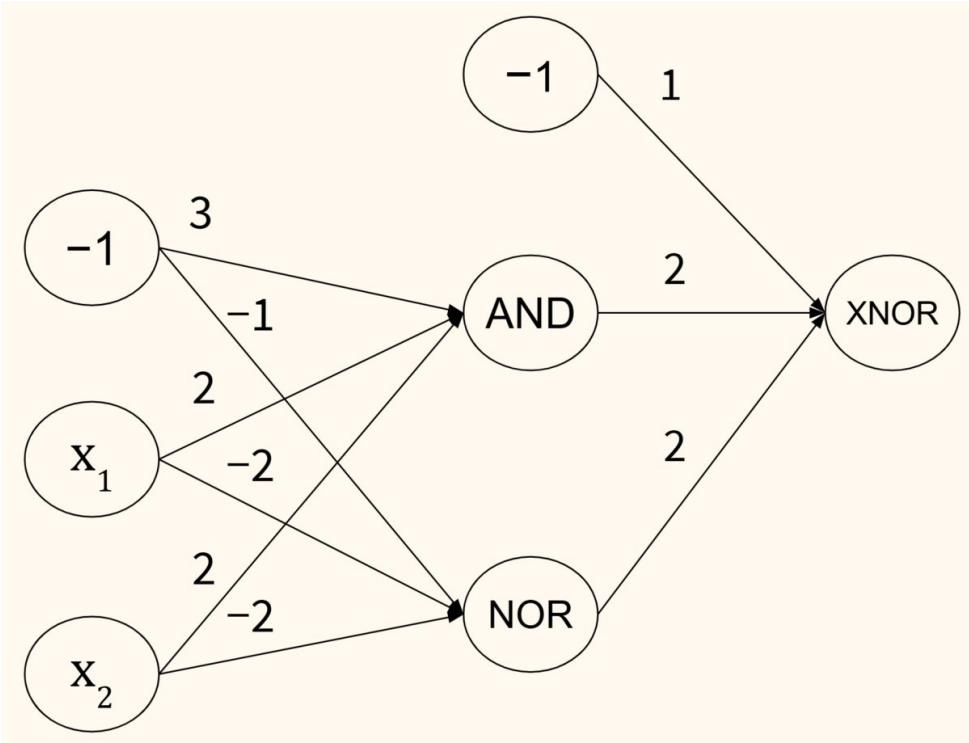

На каждом последующем слое нейросеть строит все более сложную зависимость:

- первый скрытый нейрон обучился зависимости И;
- второй нейрон дополнил это знание зависимостью ИЛИ-НЕ; и вместе
- они обучились выдавать результат исключающего ИЛИ-НЕ.

Приведем таблицу истинности.

x1	x2	AND	NOR	XNOR
0	0	0	1	1
0	1	0	0	0
1	0	0	0	0

1	1	1	0	1

Создадим классификатор на основе многослойного персептрона с помощью класса MLPClassifier библиотеки sklearn.

```
# вернемся к исходным данным XNOR
X_train = np.array([[0, 0], [0, 1], [1, 0], [1, 1]])
y_train = np.array([1, 0, 0, 1])
```

```
from sklearn.neural_network import MLPClassifier
```

```
mlp = MLPClassifier(hidden_layer_sizes=(2),
                    # будем использовать сигмоиду в качестве
                    # функции активации
                    activation='logistic',
                    solver='lbfgs',
                    random_state=1).fit(X_train, y_train)
```

Оптимизация многослойного персептрона в примере выше происходит квазиньютоновским методом LBFGS. Его рассмотрение выходит за рамки сегодняшнего занятия.

```
accuracy_score(y_train, mlp.predict(X_train))
```

```
1.0
```

Посмотрим на нелинейную решающую границу на **исходном** представлении данных (data representation).

```
# выведем исходное представление данных
plt.scatter(X_train[:, 0], X_train[:, 1],
            c=y_train, s=40, cmap=colors.ListedColormap(clrs))

# выведем решающую границу
x_min, x_max = X_train[:, 0].min() - 1, X_train[:, 0].max() + 1
y_min, y_max = X_train[:, 1].min() - 1, X_train[:, 1].max() + 1
XX, YY = np.meshgrid(np.linspace(x_min, x_max, 1000),
                     np.linspace(y_min, y_max, 1000))
Z = mlp.predict(np.c_[XX.ravel(), YY.ravel()])
Z = Z.reshape(XX.shape)
plt.contour(XX, YY, Z, levels = [0], colors = ['k'])

ticks = [0, 1]
```

```
plt.xticks(ticks)
plt.yticks(ticks)
plt.title('MLP input layer representation')
plt.xlabel('x1')
plt.ylabel('x2')
plt.show()
```

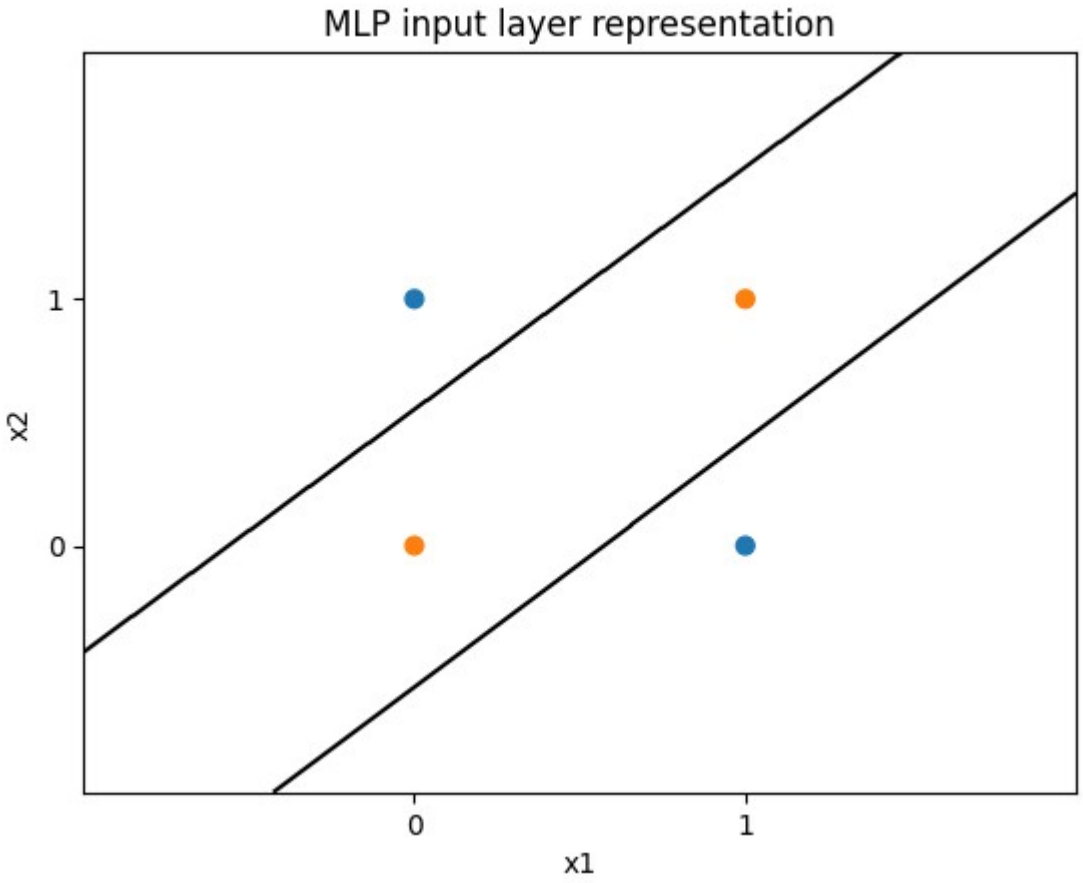

Кроме этого, в данном случае мы можем посмотреть, какому представлению данных обучились нейроны **скрытого** слоя.

```
# умножим веса первого слоя на матрицу данных, добавим смещение и
# пропустим через сигмоиду
hidden = expit(np.dot(X_train, mlp.coefs_[0]) + mlp.intercepts_[0]
np.round(hidden)
```

```
array([[1., 0.],
       [0., 0.],
       [1., 1.],
       [1., 0.]])
```

Несложно заметить, что первое и четвертое наблюдения теперь имеют одни и те же координаты `[1, 0]`. Другими словами, данные стали линейно разделимыми.

Убедимся в этом, рассчитав метки классов на выходном слое,

```
np.heaviside(np.dot(hidden, mlp.coefs_[1]) + mlp.intercepts_[1], .
```

```
array([[1.],
       [0.],
       [0.],
       [1.]])
```

а также выведя на графике скрытое представление данных и решающую границу, построенную для этого представления.

```
# выведем скрытое представление данных
plt.scatter(hidden[:, 0], hidden[:, 1], c=y_train,
            cmap=colors.ListedColormap(clrs))

# рассчитаем наклон и сдвиг решающей границы
# на основе весов скрытого слоя
hyperplane_slope = -mlp.coefs_[1][0]/mlp.coefs_[1][1]
hyperplane_intercept = -mlp.intercepts_[1]/mlp.coefs_[1][1]

# построим уравнение решающей границы и выведем границу на графике
ax_min, ax_max = -.5, 1.5
xx = np.linspace(ax_min, ax_max)
yy = hyperplane_slope*xx + hyperplane_intercept
hyperplane = np.array(list(zip(xx, yy)))
plt.plot(hyperplane[:, 0], hyperplane[:, 1], 'k-')

ticks=[0,1]
plt.xticks(ticks)
plt.yticks(ticks)
plt.xlim(ax_min, ax_max)
plt.ylim(ax_min, ax_max)
plt.title('MLP hidden layer representation')
plt.xlabel('x1')
plt.ylabel('x2')
plt.show()
```

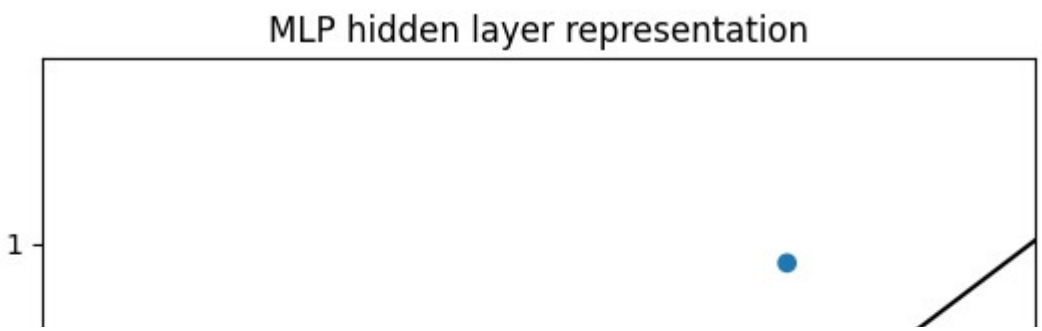

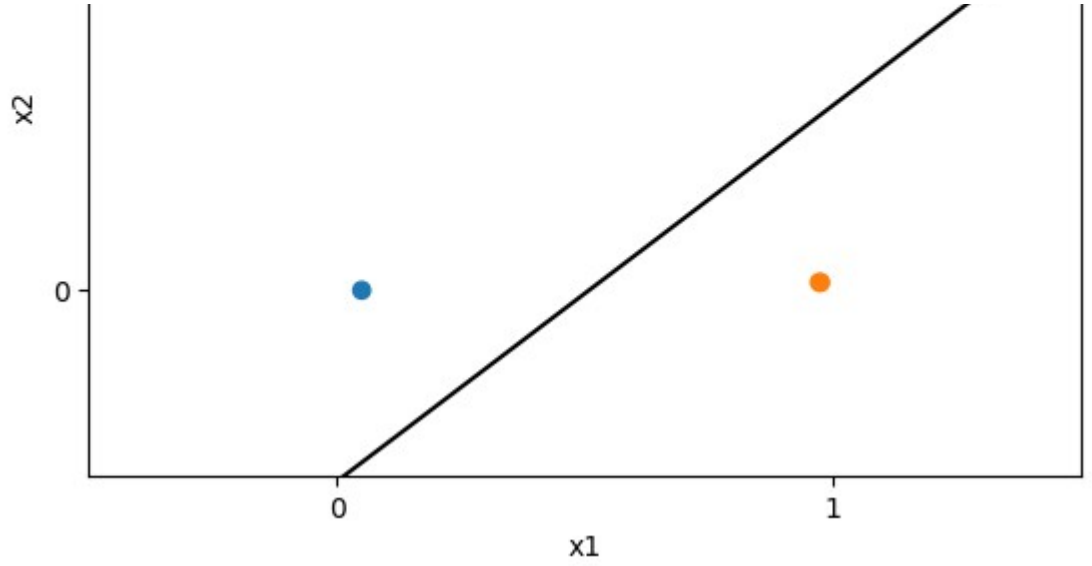

Список литературы

- Воронцов К.В. Лекции по искусственным нейронным сетям
- McCulloch W. S., Pitts W. A logical calculus of the ideas immanent in nervous activity, 1943
- Rosenblatt F., The perceptron, a perceiving and recognizing automaton, 1957
- Widrow B. et al. Adaptive «Adaline» neuron using chemical «memistors», 1960
- Olah C., Neural Networks, Manifolds, and Topology