Линейная регрессия. Часть 1

Корреляция показывает степень совместного изменения двух признаков. При этом, как уже было сказано, в корреляционном анализе нет зависимых и независимых переменных. Они эквивалентны.

Количественным предсказанием одной переменной (зависимой) на основании другой (независимой) занимается регрессионный анализ.

В рамках сегодняшнего занятия мы с нуля построим несколько алгоритмов множественной линейной регрессии.

РЕГРЕССИОННЫЙ АНАЛИЗ

В первую очередь обсудим некоторые теоретические вопросы регрессионного анализа.

Генеральная совокупность и выборка

Как мы уже знаем (***Статистический вывод***), множество всех имеющихся наблюдений принято считать генеральной совокупностью (population). И эти наблюдения, если в них есть взаимосвязи, можно теоретически аппроксимировать, например, линией регрессии. При этом важно понимать, что это некоторая идеальная модель, которую мы никогда не сможем построить.

Единственное, что мы можем сделать, взять выборку (sample) и на ней построить нашу модель, предполагая, что если выборка достаточно велика, она сможет достоверно описать генсовокупность.

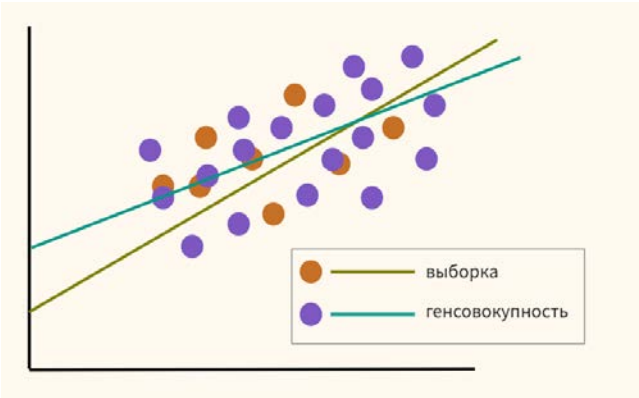

Отклонение прогнозного значения от фактического для «идеальной» линии принято называть ошибкой (error или true error).

$$\varepsilon = y - \hat{y}$$

Отклонение прогноза от факта для выборочной модели (которую мы и строим) называют остатками (residuals или residual error).

$$\varepsilon = y - f(x)$$

В этом смысле среднеквадратическую ошибку (Оптимизация: поиск весов) (mean squared error, MSE) корректнее называть средними квадратичными остатками (mean squared residuals).

На практике ошибку и остатки нередко используют как взаимозаменяемые термины.

Уравнение множественной линейной регрессии

Посмотрим на уравнение множественной линейной регрессии.

$$y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \ldots + \theta_j x_j + \varepsilon$$

В отличие от простой линейной регрессии в данном случае у нас несколько признаков x_j (независимых переменных) и несколько коэффициентов θ («тета»).

Интерпретация результатов модели

Коэффициент θ_0 задает некоторый базовый уровень (baseline) при условии, что остальные коэффициенты равны нулю и зачастую не имеет смысла с точки зрения интерпретации модели (нужен лишь для того, что поднять линию на нужный уровень).

Параметры $\theta_1, \theta_2, \ldots, \theta_n$ показывают изменение зависимой переменной при условии «неподвижности» остальных коэффициентов. Например, каждая дополнительная комната может увеличивать цену дома в 1,3 раза.

Переменная ε (ошибка) представляет собой отклонение фактических данных от прогнозных. В этой переменной могут быть заложены две составляющие:

- во-первых, она может включать вариативность целевой переменной, описанную другими (не включенными в нашу модель) признаками;
- во-вторых, «улавливать» случайный шум, случайные колебания.

Категориальные признаки

Модель линейной регрессии может включать категориальные признаки. Продолжая пример с квартирой, предположим, что мы строим модель, в которой цена зависит от того, находится ли квартира в центре города или в спальном районе.

Перед этим переменную необходимо закодировать (*Кодирование категориальных переменных*), создав, например, через Label Encoder признак «центр», который примет значение 1, если квартира в центре, и 0, если она находится в спальном районе.

стоимость жилья = 8 + 2,1 x центр

В модели, представленной выше, если квартира находится в центре (переменная «центр» равна единице), ее стоимость составит 10,1 миллиона рублей, если на окраине (переменная «центр» равна нулю) — лишь восемь.

Для категориального признака с множеством классов можно использовать one-hot encoding, если между классами признака отсутствует иерархия

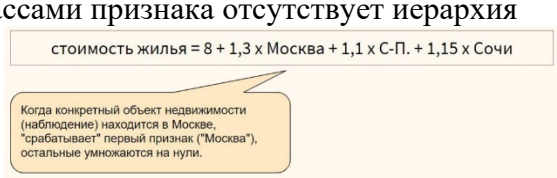

или, например, ordinal encoding в случае наличия иерархии классов в признаке

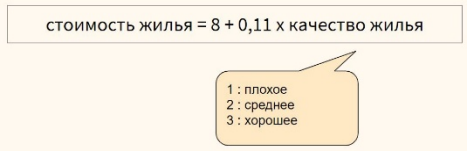

Выбросы в линейной регрессии

Как и коэффициент корреляции Пирсона (*Выбросы в данных*), модель линейной регрессии чувствительна к выбросам (*Выбросы в данных* outliers), то есть наблюдениям, заметно отличающимся от общей совокупности. Сравните рисунки ниже.

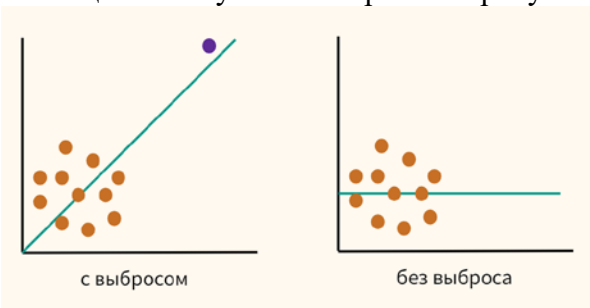

При наличии выброса (слева), линия регрессии имеет наклон и может использоваться для построения прогноза. Удалив это наблюдение (справа), линия регрессии становится горизонтальной и построение прогноза теряет смысл.

При этом различают два типа выбросов:

• **горизонтальные выбросы** или влиятельные точки (leverage points) — они сильно отклоняются от среднего по оси x; и

• **вертикальные выбросы** или просто выбросы (influential points) — отклоняются от среднего по оси *y*.

Ключевое отличие заключается в том, что вертикальные выбросы влияют на наклон модели (изменяют ее коэффициенты), а горизонтальные — нет.

Сравним два графика.

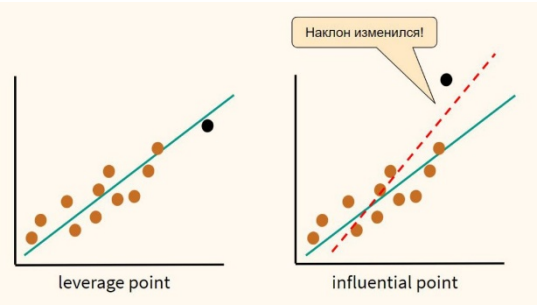

На левом графике черная точка (leverage point) сильно отличается от остальных наблюдений, но наклон прямой линии регрессии с ее появлением не изменился. На правом графике, напротив, появление выброса (influential point) существенно изменяет наклон прямой.

На практике нас конечно больше интересуют influential points, потому что именно они существенно влияют на качество модели.

Если в простой линейной регрессии мы можем оценить leverage и influence наблюдения графически, в многомерной модели это сделать сложнее. Можно использовать график остатков (об этом ниже) или применить один из уже известных нам методов выявления выбросов.

Про выявление leverage и infuential points можно почитать здесь.

Допущения модели регрессии

Применение алгоритма линейной регрессии предполагает несколько **допущений** (assumptions) или условий, при выполнении которых мы можем говорить о качественно построенной модели.

1. Правильный выбор модели

Вначале важно убедиться, что данные можно аппроксимировать с помощью линейной модели (correct model specification).

Оценить распределение данных можно через **график остатков** (residuals plot), где по оси x отложен прогноз модели, а на оси y — сами остатки.

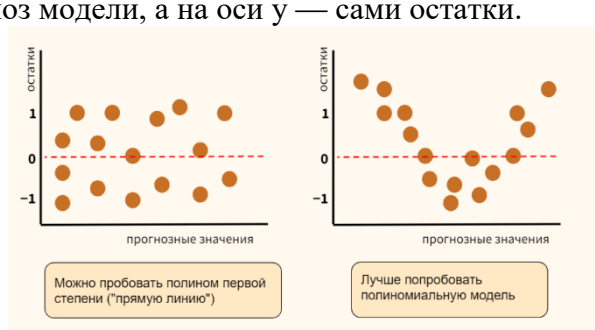

В отличие от простой линейной регрессии мы не используем точечную диаграмму *X* vs. *y*, потому что хотим оценить зависимость целевой переменной от всех признаков сразу.

Остатки модели относительно ее прогнозных значений должны быть распределены случайным образом без систематической составляющей (residuals do not follow a pattern). При этом,

- если вы попробовали применить линейную модель с коэффициентами первой степени (x_n^1) и выявили некоторый паттерн в данных, можно попробовать полиномиальную или какую-либо еще функцию (об этом ниже); кроме того,
- количественные признаки можно попробовать преобразовать таким образом, чтобы их можно было аппроксимировать прямой линией;
- если ни то, ни другое не помогло, вероятно данные не стоит моделировать линейной регрессией.

Также замечу, что график остатков показывает выбросы в данных.

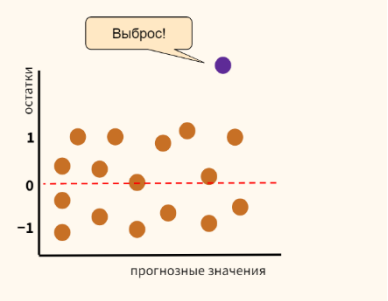

2. Нормальность распределения остатков

Среднее значение остатков должно быть равно нулю. Если это не так, и среднее значение *меньше нуля* (скажем -5), то это значит, что модель регулярно недооценивает (underestimates) фактические значения. В противном случае, если среднее *больше нуля*, переоценивает (overestimated).

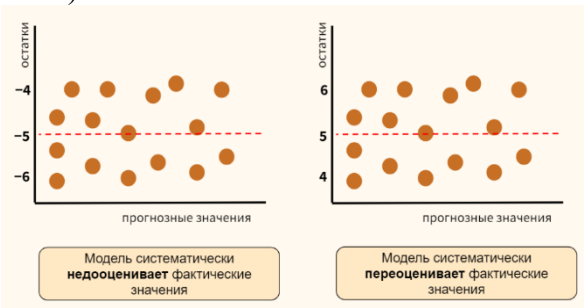

Кроме того, предполагается, что остатки следуют нормальному распределению.

$$\varepsilon \sim N(0, \sigma)$$

Проверить нормальность (*Модуль random. Часть 3*) остатков можно визуально с помощью гистограммы или рассмотренных ранее критериев нормальности распределения.

Причинами могут быть (1) выбросы в данных или (2) неверный выбор модели. Решением может быть, соответственно, исследование выбросов, выбор новой модели и преобразование как признаков, так и целевой переменной.

3. Гомоскедастичность остатков

Гомоскедастичность (homoscedasticity) или одинаковая изменчивость остатков предполагают, что дисперсия остатков не изменяется для различных наблюдений. Противоположное и нежелательное явление называется **гетероскедастичностью** (heteroscedasticity) или разной изменчивостью.

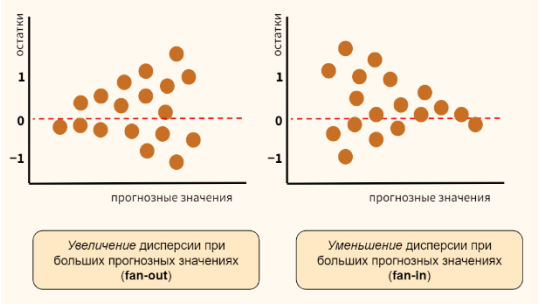

Гетероскедастичность остатков показывает, что модель ошибается сильнее при более высоких или более низких значениях признаков. Как следствие, если для разных прогнозов у нас разная погрешность, модель нельзя назвать надежной (robust).

Как правило, гетероскедастичность бывает изначально заложена в данные. Ее можно попробовать исправить через преобразование целевой переменной (например, логарифмирование).

4. Отсутствие мультиколлинеарности

Еще одним важным допущением является отсутствие мультиколлинеарности. **Мультиколлинеарность** (multicollinearity) — это корреляция между независимыми переменными. Например, если мы предсказываем стоимость жилья по квадратным метрам и количеству комнат, то метры и комнаты логичным образом также будут коррелировать между собой.

Почему плохо, если такая корреляция существует? Базовое предположение линейной регрессии — каждый коэффициент θ оказывает влияние на конечный результат при условии, что остальные коэффициенты постоянны. При мультиколлинеарности на целевую переменную оказывают эффект сразу несколько признаков, а значит мы не можем с точностью интерпретировать каждый из них.

Также говорят о том, что нужно стремиться к экономной (parsimonious) модели, то есть такой модели, которая при наименьшем количестве признаков в наибольшей степени объясняет поведение целевой переменной.

Variance inflation factor

Расчет коэффициента

Variance inflation factor (VIF) или коэффициент увеличения дисперсии позволяет выявить корреляцию между признаками модели.

Принцип расчета VIF заключается в том, чтобы поочередно делать каждый из признаков целевой переменной и строить модель линейной регрессии на основе оставшихся независимых переменных. Например, если у нас есть три признака x_1, x_2, x_3, мы поочередно построим три модели линейной регрессии: $x_1 \sim x_2 + x_3, x_2 \sim x_1 + x_3$ и $x_3 \sim x_1 + x_3$.

Обратите внимание на новый для нас формат записи целевой и зависимых переменных модели через символ $\sim$.

Затем для каждой модели (то есть для каждого признака x_1, x_2, x_3) мы рассчитаем коэффициент детерминации R^2 (*Регрессия*). Если он велик, значит данный признак можно объяснить с помощью других независимых переменных и имеется мультиколлинеарность. Если R^2 мал, то нельзя и мультиколлинеарность отсутствует.

Теперь рассчитаем *VIF* на основе R^2:

$$VIF = \frac{1}{1 - R^2}$$

При таком способе расчета большой (близкий к единице) R^2 уменьшит знаменатель и существенно увеличит *VIF*, при небольшом коэффициенте детерминации коэффициент увеличения дисперсии наоборот уменьшится.

Замечу, что $1 - R^2$ принято называть tolerance.

Другие способы выявления мультиколлинеарности

Для выявления корреляции между независимыми переменными можно использовать точечные диаграммы или корреляционные матрицы. При этом важно понимать, что в данном случае мы выявляем зависимость лишь между двумя признаками. Корреляцию множества признаков выявляет только коэффициент увеличения дисперсии.

Интерпретация *VIF*

VIF находится в диапазоне от единицы до плюс бесконечности. Как правило, при интерпретации показателей variance inflation factor придерживаются следующих принципов:

- $\text{VIF} = 1$, между признаками отсутствует корреляция;

- $1 < \text{VIF} \le 5$ — умеренная корреляция;
- $5 < \text{VIF} \le 10$ — высокая корреляция;
- более 10 — очень высокая.

После расчета VIF можно по одному удалять признаки с наибольшей корреляцией и смотреть, как изменится этот показатель для оставшихся независимых переменных.

5. Отсутствие автокорреляции остатков

На занятии по временным рядам (time series) (*Временные ряды*), мы сказали, что автокорреляция (autocorrelation) — это корреляция между значениями одной и той же переменной в разные моменты времени.

Применительно к модели линейной регрессии автокорреляция целевой переменной (для простой линейной регрессии) и **автокорреляция остатков**, residuals autocorrelation (для модели множественной регрессии) означает, что результат или прогноз зависят не от признаков, а от самой целевой переменной. В такой ситуации признаки теряют свою значимость, и применение модели регрессии становится нецелесообразным.

Причины автокорреляции остатков

Приведем две возможные причины:

- прогнозирование целевой переменной с высокой автокорреляцией (например, если мы моделируем цену акций с помощью других переменных, то можем ожидать высокую автокорреляцию остатков, поскольку цена акций как правило сильно зависит от времени);
- удаление значимых признаков.

Автокорреляция первого порядка

Дадим формальное определение автокорреляции первого порядка (first order correlation), то есть автокорреляции с лагом 1.

$$\varepsilon_t = p\varepsilon_{t-1} + u_t, \quad \text{где}$$

- u_t — некоррелированная при различных t одинаково распределенная случайная величина (independent and identically distributed (i.i.d.) random variable); а
- p — коэффициент автокорреляции, который находится в диапазоне $-1 < p < 1$.

Чем он ближе к нулю, тем меньше зависимость остатка ε_t от остатка предыдущего периода ε_{t-1}.

Такое уравнение также называется схемой Маркова первого порядка (Markov first-order scheme).

Обратите внимание, что для модели автокорреляции первого порядка коэффициент автокорреляции p совпадает с коэффициентом авторегрессии AR(1) φ.

$$y_t = c + \varphi \cdot y_{t-1}$$

Разумеется, мы можем построить модель автокорреляции, например, третьего порядка.

$$\varepsilon_t = p_1\varepsilon_{t-1} + p_2\varepsilon_{t-2} + p_3\varepsilon_{t-3} + u_t$$

Выявление автокорреляции остатков

Для выявления автокорреляции остатков можно использовать график последовательности и график остатков с лагом 1, график автокорреляционной функции или критерий Дарбина-Уотсона.

График последовательности и график остатков с лагом 1

На **графике последовательности** (sequence plot) по оси x откладывается время (или порядковый номер наблюдения), а по оси y — остатки модели. Кроме того, на **графике остатков с лагом 1** (lag-1 plot) остатки (ось y) можно сравнить с этими же значениями, взятыми с лагом 1 (ось x).

Рассмотрим вариант **положительной автокорреляции** (positive autocorrelation).

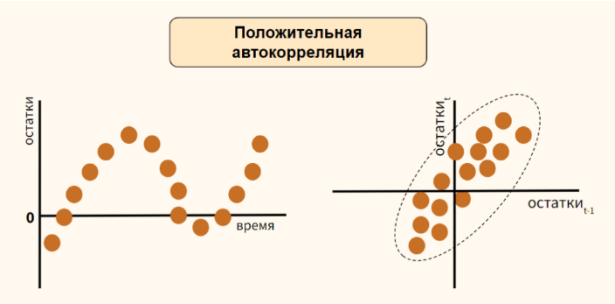

Как вы видите, при положительной автокорреляции в большинстве случаев, если одно наблюдение демонстрирует рост по отношению к предыдущему значению, то и последующее будет демонстрировать рост, и наоборот.

Теперь обратимся к **отрицательной автокорреляции** (negative autocorrelation).

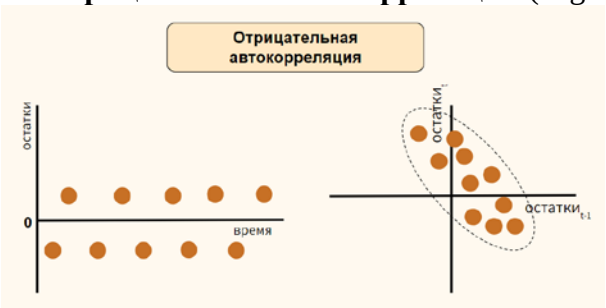

Здесь наоборот, если одно наблюдение демонстрирует рост показателя по отношению к предыдущему значению, то последующее наблюдение будет наоборот снижением. Опять же справедливо и обратное утверждение.

В случае **отсутствия автокорреляции** мы не должны увидеть на графиках какого-либо паттерна.

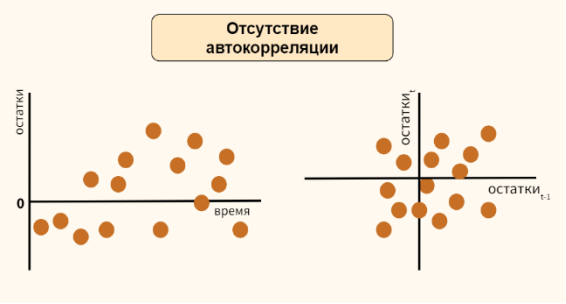

График автокорреляционной функции

Еще один способ выявить автокорреляцию — построить **график автокорреляционной функции** (autocorrelation function, ACF).

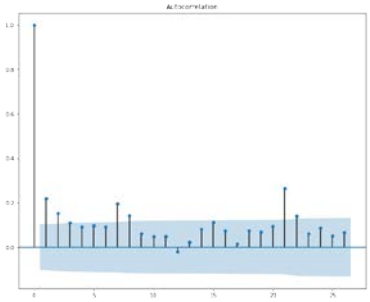

Занятие по временным рядам(Временные ряды) (данные о рождаемости)

Напомню, такой график показывает автокорреляцию данных с этими же данными, взятыми с первым, вторым и последующими лагами.

Критерий Дарбина-Уотсона

Количественным выражением автокорреляции является **критерий Дарбина-Уотсона** (Durbin-Watson test). Этот критерий выявляет только автокорреляцию первого порядка:

- **нулевая гипотеза** (*Статистический вывод*) утверждает, что такая автокорреляция отсутствует (p=0);
- **альтернативная гипотеза** соответственно утверждает, что присутствует:
  - положительная ($p \approx -1$) ; или
  - отрицательная ($p \approx 1$) автокорреляция.

Значение теста находится в диапазоне от 0 до 4. При этом,

- при показателе близком к двум можно говорить об отсутствии автокорреляции;
- приближение к четырем говорит о положительной автокорреляции;
- к нулю, об отрицательной.

Как избавиться от автокорреляции

Автокорреляцию можно преодолеть, добавив значимый признак в модель, выбрав иной тип модели (например, полиномиальную регрессию) или в целом перейдя к моделированию и прогнозированию временного ряда.

Рассмотрение этих методов находится за рамками сегодняшнего занятия.