Обобщенные линейные модели (generalized linear model, GLM), как следует из названия обобщают и систематизируют наше понимание различных линейных моделей к которым например относятся линейная и логистичерегрессия

Обыкновенная линейная регрессия

Еще раз рассмотрим модель **обыкновенной линейной регрессии**

(ordinary linear regression)

$$y = \beta_0 + \beta_1 x + \varepsilon, \varepsilon \sim \mathcal{N}(0, \sigma^2),$$

где, помимо других допущений:

- отклонение истинного значения y от прогнозного $\hat{y}$ нормально распределено;
- между предикторами и целевой переменной существует прямая линейная зависимость.

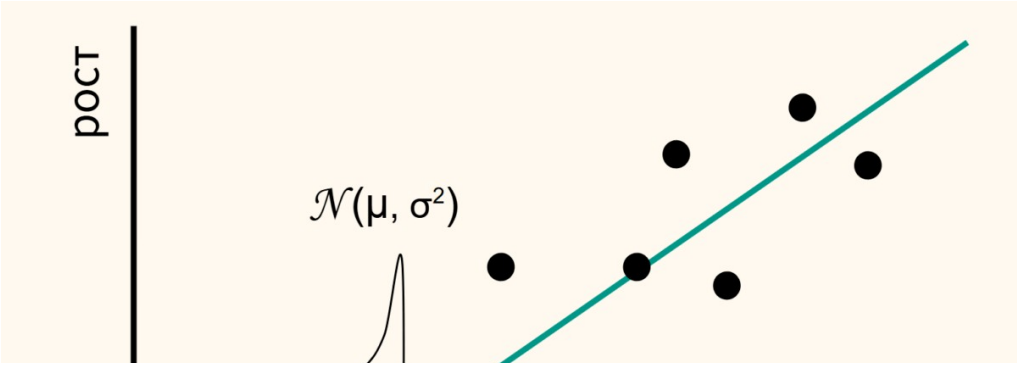

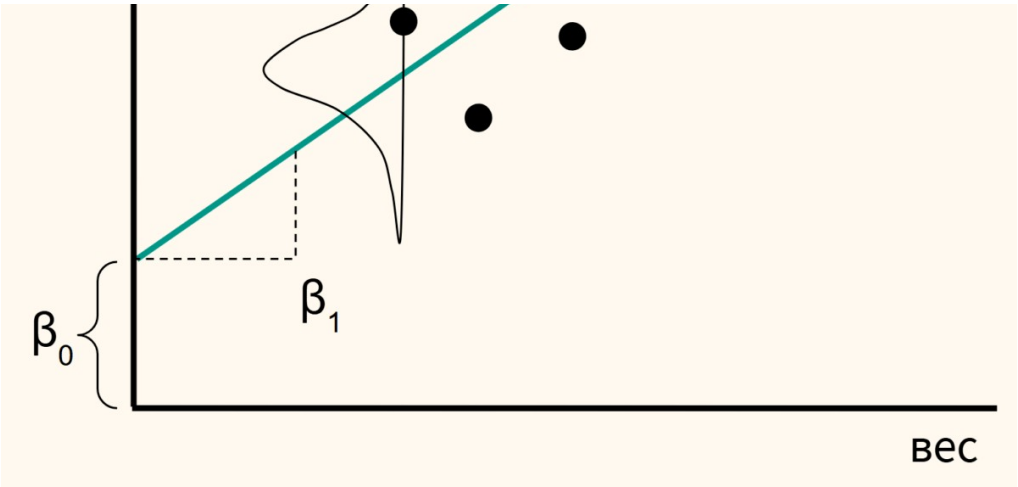

Такие допущения оправданы, если мы моделируем некоторый непрерывный количественный признак, например, рост человека.

При этом модель линейной регрессии можно задать и так.

$$y \mid x \sim \mathcal{N}(\beta_0 + \beta_1 x, \sigma^2)$$

В самом деле, для каждого значения x среднее значение соответствующего нормального распределения определяется как $\mu = \beta_0 + \beta_1 x$.

Заметим, что нормальное распределение определяется не только средним, но и дисперсией, которая, впрочем, не влияет на поиск оптимальных параметров β_j.

Регрессия Пуассона

Теперь предположим, что нам необходимо смоделировать счетные данные (count data). Например, зависимость количества ДТП от времени суток.

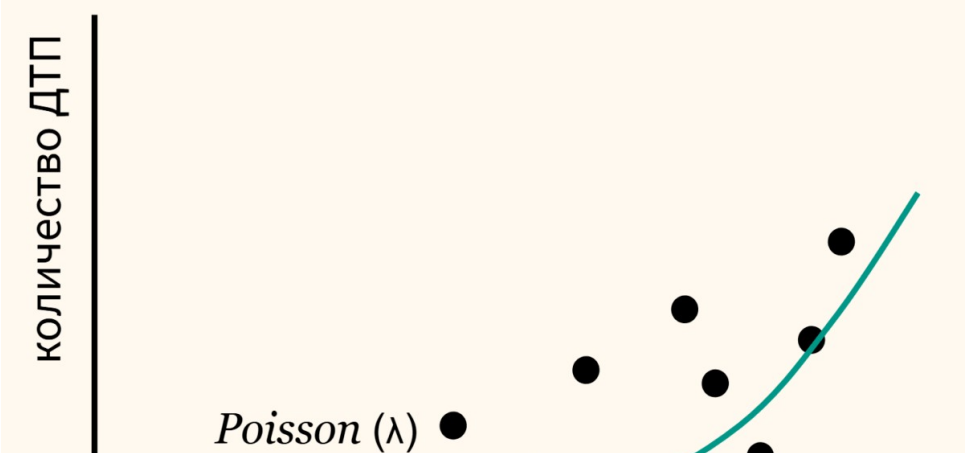

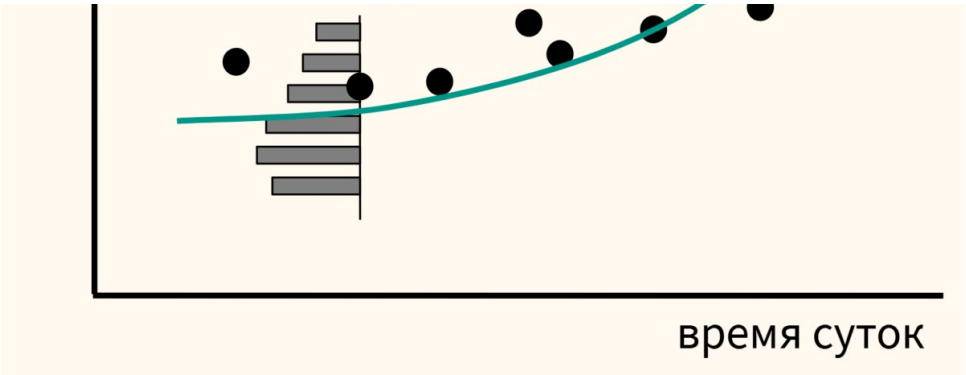

Попробуем допустить, что целевая переменная каждого наблюдения следует распределению Пуассона.

$$y \mid x \sim Poisson(\lambda)$$

Это разумно, поскольку именно распределение Пуассона используется для оценки вероятности частоты событий с матожиданием λ и имеет дискретный носитель. Попробуем предсказать λ с помощью линейной модели.

$$y \mid x \sim Poisson(\beta_0 + \beta_1 x)$$

К сожалению, линейная модель допускает отрицательные значения, при этом очевидно, что среднее количество ДТП не может быть отрицательным.

Функция связи

Введем **функцию связи** g (link function), которая будет ограничивать диапазон возможных значений λ

$$g(\lambda) = \beta_0 + \beta_1 x$$

Например, возведем прогнозные значения линейной модели в квадрат

$$\lambda = (\beta_0 + \beta_1 x)^2$$

и тогда функцией связи g будет функция квадратного корня

$$\sqrt{\lambda} = \beta_0 + \beta_1 x$$

При этом для преобразования значения линейной модели в параметр

выбранного распределения лучше использовать так называемую **каноническую функцию связи** (canonical link function).

В случае распределения Пуассона, канонической функцией связи будет функция логарифма (**log link**).

$$\log(\lambda) = \beta_0 + \beta_1 x$$

Соответственно, значение λ можно найти через

$$\lambda = \exp(\beta_0 + \beta_1 x)$$

$$y \mid x \sim Poisson(\exp(\beta_0 + \beta_1 x))$$

Заметим, что в модели линейной регрессии функцией связи будет **тождественная функция** (identity function) $g(u) = u$.

Структура обобщенной линейной модели

Таким образом, обобщенная линейная модель будет включать три составляющих:

- **случайный компонент** (random component) — выбранное распределение;
- **систематический компонент** (systematic component) — линейную зависимость; и
- **функцию связи**.

Экспоненциальное семейство распределений

Обсудим, почему функция логарифма является канонической функцией связи для распределения Пуассона.

Можно сказать, что функция связи g позволяет соединить математическое ожидание $\mathbb{E}(y \mid x)$ выбранного распределения с линейным

систематическим компонентом $\beta_0 + \beta_1 x$

$$g(\mathbb{E}(y \mid x)) = \beta_0 + \beta_1 x,$$

при этом прогноз для нового объекта x задается через

$$\hat{y} = \mathbb{E}(y \mid x) = g^{-1}(\beta_0 + \beta_1 x)$$

В случае если выбранное распределение относится к **экспоненциальному семейству распределений** (exponential family of distributions), у нас есть возможность связать линейную зависимость, обозначим ее через параметр θ, с матожиданием $\mathbb{E}(y \mid x)$

$$g(\mathbb{E}(y \mid x)) = \theta$$

Экспоненциальное семейство включает те распределения, которые можно параметризовать через канонический (canonical) или натуральный (natural) параметр θ следующим образом:

$$P(y \mid \theta) = h(y) \exp\left[g(\theta)^\top T(y) - A(g(\theta))\right]$$

Нормальное распределение

В экспоненциальной форме одномерное нормальное распределение можно записать так:

$$\begin{aligned} P(y \mid \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2\sigma^2}(y-\mu)^2\right] \\ &= \frac{1}{\sqrt{2\pi}} \exp\left[\frac{\mu}{\sigma^2} y - \frac{1}{2\sigma^2} y^2 - \frac{1}{2\sigma^2}\mu^2 - \log\sigma\right], \end{aligned}$$

где:

$$
\begin{aligned}
\theta &= \begin{bmatrix} \mu/\sigma^2 \\ -1/2\sigma^2 \end{bmatrix} \\
T(y) &= \begin{bmatrix} x \\ x^2 \end{bmatrix} \\
A(\theta) &= \frac{\mu^2}{2\sigma^2} + \log\sigma = -\frac{\theta_1^2}{4\theta_2} - \frac{1}{2}\log(-2\theta_2) \\
h(y) &= \frac{1}{\sqrt{2\pi}}
\end{aligned}
$$

При фиксированном σ^2 тождественная функция $g(\mu) = \mu$ действительно напрямую связывает линейный компонент θ с матожиданием нормального распределения μ.

Распределение Пуассона

Рассмотрим распределение Пуассона.

$$
P(y \mid \lambda) = \frac{\lambda^y e^{-\lambda}}{y!}
$$

В экспоненциальной форме:

$$
P(y \mid \lambda) = \frac{1}{y!}\exp\left[y\log\lambda - \lambda\right],
$$

где:

$$
\begin{aligned}
\theta &= \log\lambda \\
T(y) &= y \\
A(\theta) &= \lambda = \exp\theta \\
h(y) &= \frac{1}{y!}
\end{aligned}
$$

Несложно увидеть, что $g(\lambda) = \log\lambda$ и $\lambda = g^{-1}(\theta) = \exp\theta$.

Бинарная логистическая регрессия

В **бинарной логистической регрессии** (binary logistic regression) прогнозная случайная величина следует распределению Бернулли или, что то же самое, биномиальному распределению с параметром $n = 1$.

$$y \mid x \sim Bern(\pi)$$

Например, мы можем моделировать вероятность возвращения кредита на основе возраста заемщика.

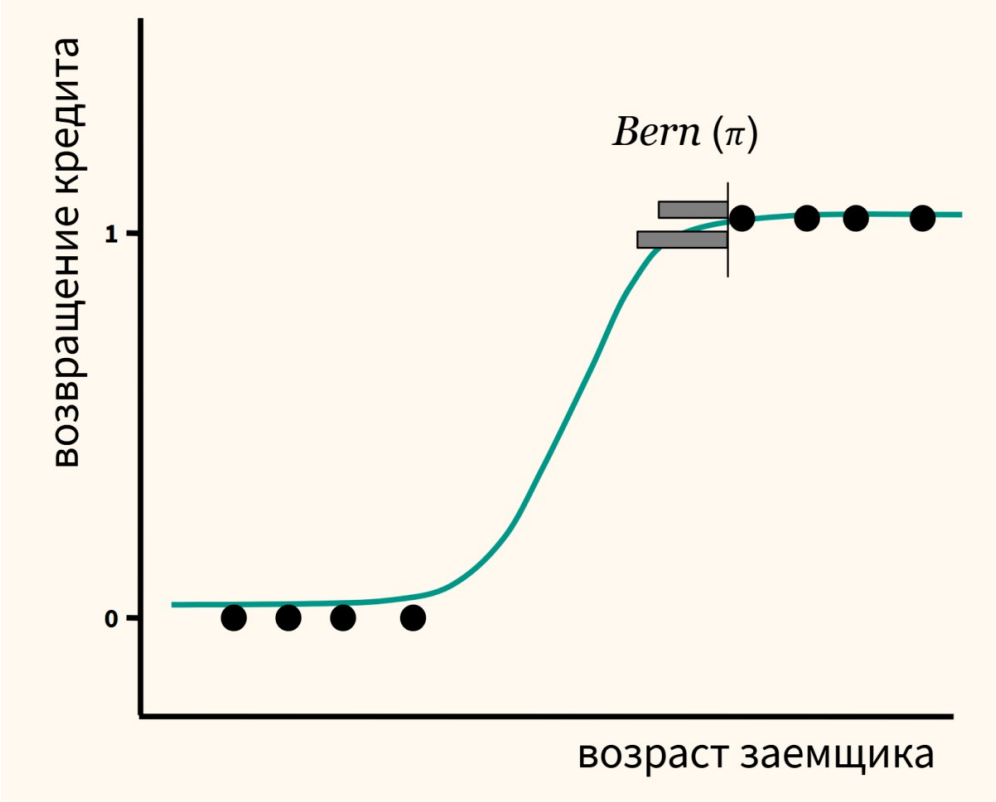

Посмотрим, какая функция связи подходит для распределения Бернулли. Определим функцию вероятности и перепишем ее в экспоненциальной форме:

$$\begin{aligned} P(y \mid \pi) &= \pi^y (1-\pi)^{(1-y)} \\ &= \exp\left[\log\left(\frac{\pi}{1-\pi}\right) y + \log(1-\pi)\right], \end{aligned}$$

где:

$$
\begin{aligned}
\theta &= \frac{\pi}{1-\pi} \\
T(y) &= y \\
A(\theta) &= -\log(1-\pi) = \log(1+\exp\theta) \\
h(y) &= 1
\end{aligned}
$$

Таким образом, $g(\pi) = \log \frac{\pi}{1-\pi}, \pi \in \{0, 1\}$, является логит функцией, а

$$
\pi = g^{-1}(\theta) = \frac{1}{1+\exp(-\theta)}
$$

представляет собой логистическую функцию (logistic function) или сигмоиду (sigmoid).

Сделаем два дополнительных комментария.

Логарифм шансов. Логит функцию также называют логарифмом шансов (log odds). Интересно, что если вероятность $\pi \in [0, 1]$, то шансы могут быть любым неотрицательным числом, $odds \in [0, \infty)$.

Например, при вероятности $0{,}75$, шансы того, что событие произойдет, равны $odds = \frac{0{,}75}{1-0{,}75} = \frac{3}{1} = 3$. При вероятности $0{,}99$, шансы равны 99.

Взятие логарифма позволяет сделать областью определения все действительные числа $\mathbb{R}$. Одновременно логарифм шансов симметричен относительно нуля при вероятности $\pi = 0,5, \log\left(\frac{0{,}5}{1-0{,}5} = 0\right)$.

Обратная к ней функция, сигмоида, выдает вероятность $0{,}5$ в случае, если систематический компонент выдает ноль.

Серия испытаний. Целевая переменная может представлять собой вероятность $1, 2, \ldots, k$ успехов в n испытаниях.

Например, речь может идти о вероятности успешного ответа $1, 2, \ldots, 10$ вопросов теста в зависимости от потраченного на учебу времени. В этом случае целевая переменная следует биномиальному распределению с параметром $n = 10$.

$$
y \mid x \sim Binom(n = 10, \pi)
$$

На практике, можно применить тот же подход, что и для дихотомической целевой переменной, дополнительно умножив предсказанное значение π на число испытаний n.

Например, если модель при восьми часах подготовки предсказывает вероятность успешного ответа на экзамене, равную $0{,}3$, то мы можем предсказать, что получится правильно ответить на три вопроса из десяти.

Мультиномиальная логистическая регрессия

В случае многоклассовой классификации целевая переменная следует мультиномиальному распределению

$$y \mid x \sim Multinomial(\pi)$$

с функцией вероятности случайной величины $Y_i, i = 1, \ldots, k$

$$P(y \mid \pi) = \frac{n!}{y_1! \ldots y_k!} \pi_1^{y_1} \ldots \pi_k^{y_k},$$

где $n \in \mathbb{N}$ — количество испытаний, $y_i \in \mathbb{N}$ — i-ое событие в серии из n испытаний и $\pi_i \in [0, 1]$. При этом

$$\sum_{i=1}^{k} y_i = n, \quad \sum_{i=1}^{k} \pi_i = 1$$

Покажем, что мультиномиальное распределение относится к экспоненциальному семейству. С учетом того, что $\pi_k = 1 - \sum_{i=1}^{k-1} \pi_i$,

$$
\begin{aligned}
P(y \mid \pi) &= \frac{n!}{y_1! \dots y_k!} \pi_1^{y_1} \dots \pi_k^{y_k} \\
&= \left(\frac{n!}{y_1! \dots y_k!} \right) \pi_1^{y_1} \dots \pi_k^{1-\sum_{i=1}^{k-1} y_i} \\
&= \left(\frac{n!}{y_1! \dots y_k!} \right) \exp \left[y_1 \log \pi_1 + \dots + \left(1 - \sum_{i=1}^{k-1} y_i \right) \log \pi_k \right], \\
&= \left(\frac{n!}{y_1! \dots y_k!} \right) \exp \left[y_1 \log \left(\frac{\pi_1}{\pi_k} \right) + \dots + y_{k-1} \log \left(\frac{\pi_1}{\pi_{k-1}} \right) \right. \\
&\quad \left. + \log \pi_k \right] \\
&= h(y_1, \dots, y_k) \exp \left[\theta^T T(y_1, \dots, y_k) - A(\theta) \right]
\end{aligned}
$$

где:

$$
\begin{aligned}
\theta &= \begin{bmatrix} \log(\pi_1/\pi_k) \\ \log(\pi_2/\pi_k) \\ \vdots \\ \log(\pi_{k-1}/\pi_k) \end{bmatrix} \\
T(y_1, \dots, y_k) &= \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_k \end{bmatrix} \\
A(\theta) &= -\log \pi_k \\
h(y_1, \dots, y_k) &= \frac{n!}{y_1! \dots y_k!}.
\end{aligned}
$$

Таким образом, если $\theta_i = g(\pi_i) = \log \left(\frac{\pi_i}{\pi_k} \right)$ представляет собой мультиномиальную логит функцию, то обратная к ней

$$
\pi = g^{-1}(\theta) = \frac{\exp(\theta_k)}{\sum_{j=1}^{k} \exp(\theta_j)}
$$

известна как многопеременная логистическая функция или softmax.

Оптимальные параметры

Оптимальные параметры можно найти аналитически методом максимального правдоподобия или используя численные методы и, в частности, метод наименьших квадратов с итеративным пересчётом весов (iteratively reweighted least squares, IRLS).

Библиотека Statsmodels

Линейная регрессия

Обучим модель линейной регрессии с помощью класса OLS (ordinary least squares) и класса GLM библиотеки Statsmodels.

Откроем блокнот к этому занятию

Подготовим синтетические данные.

```
random_state = 42
```

```
n_samples = 100
n_features = 2
bias = 10

X, y, coef = make_regression(n_samples=n_samples,
                             n_features=n_features,
                             bias=bias,
                             noise=20,
                             coef=True,
                             random_state=random_state)
```

Посмотрим на параметры, которые мы хотим предсказать.

```
coef, bias
```

```
(array([87.73730719, 74.07686178]), 10)
```

Дополнительно преобразуем данные в датафрейм.

```
linear_regression_data = pd.DataFrame({'X1': X[:,0], 'X2': X[:,1], '
```

Заметим, что в statsmodels модель можно задать двумя способами:

- через statsmodels.api и
- через statsmodels.formula.api.

В первом случае, как и в случае библиотеки Sklearn, мы передаем модели **эндогенную** (endogenous), т.е. зависимую и **экзогенные** (exogenous) или независимые переменные.

```
import statsmodels.api as sm
sm.OLS(endog=y, exog=X).fit()
```

Во втором случае можно определить так называемую формулу, связывающую эндогенную и экзогенные переменные, а также указать данные, в которых эти переменные содержатся.

```
import statsmodels.formula.api as smf
smf.ols(formula='y ~ X1 + X2', data=linear_regression_data).fit()
```

Такой подход близок к API, используемому в языке R. Кроме этого обратим внимание, что классы, использующие переменные, обозначаются заглавными буквами, а те, что используют формулу — строчными.

Одновременно для обыкновенной линейной регрессии мы можем использовать:

- класс OLS, передавая эндогенную и экзогенные переменные или используя формулу; а также
- класс GLM с указанием того, что остатки следуют нормальному распределению.

Класс OLS

OLS: statsmodels.api. Обучим модель и выведем результаты регрессионного анализа.

```
# для того чтобы получить оценку сдвига, необходимо добавить столбец
X_ones = sm.add_constant(X)
linreg_ols = sm.OLS(y, X_ones).fit()
```

```
print(linreg_ols.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:
Model:                            OLS   Adj. R-squared:
Method:                 Least Squares   F-statistic:
Date:                Sat, 05 Jul 2025   Prob (F-statistic):
Time:                        09:43:00   Log-Likelihood:
No. Observations:                 100   AIC:
Df Residuals:                      97   BIC:
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025
------------------------------------------------------------------------------
const         10.4327      2.199      4.744      0.000       6.068
x1            84.2679      2.557     32.951      0.000      79.192
x2            74.1566      2.192     33.824      0.000      69.805
==============================================================================
Omnibus:                        2.843   Durbin-Watson:
Prob(Omnibus):                  0.241   Jarque-Bera (JB):
Skew:                           0.198   Prob(JB):
Kurtosis:                       3.645   Cond. No.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors
```

ols: statsmodels.formula.api. Теперь используем api с формулой.

```
# при использовании API с формулой добавлять фиктивную переменную не
linreg_ols = smf.ols(formula='y ~ X1 + X2', data=linear_regression_d
print(linreg_ols.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:
Model:                            OLS   Adj. R-squared:
Method:                 Least Squares   F-statistic:
Date:                Sat, 05 Jul 2025   Prob (F-statistic):
Time:                        09:43:00   Log-Likelihood:
No. Observations:                 100   AIC:
Df Residuals:                      97   BIC:
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025
------------------------------------------------------------------------------
Intercept     10.4327      2.199      4.744      0.000       6.068
```

```
X1            84.2679      2.557     32.951      0.000      79.192
X2            74.1566      2.192     33.824      0.000      69.805
==============================================================================
Omnibus:                        2.843   Durbin-Watson:
Prob(Omnibus):                  0.241   Jarque-Bera (JB):
Skew:                           0.198   Prob(JB):
Kurtosis:                       3.645   Cond. No.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors
```

Поговорим подробнее про некоторые из полученных результатов.

Степени свободы остатков. Имея $n = 100$ наблюдений и $p = 2$ предиктора без учета сдвига β_0, у нас осталось $df_{residuals} = n - p - 1 = 97$ степеней свободы (degrees of freedom) остатков. При этом степени свободы модели равны количеству независимых переменных $df_{model} = p = 2$.

Отклонения от прогнозных значений и отклонения от среднего. Для дальнейшего анализа найдем сумму квадратов отклонений фактических значений от прогнозных (residual sum of squares)

$$SS_{residuals} = \sum (y_i - \hat{y}_i)^2$$

```
np.sum(linreg_ols.resid ** 2), linreg_ols.ssr
```

```
(np.float64(46005.49837010103), np.float64(46005.49837010103))
```

Это та дисперсия, которую наша модель не объясняет. Также найдем сумму квадратов отклонений прогнозных значений от среднего фактических данных или объясненную дисперсию (explained sum of squares)

$$SS_{explained} = \sum (\hat{y}_i - \bar{y})^2$$

```
np.sum(np.square(linreg_ols.fittedvalues-np.mean(y))), linreg_ols.es
```

```
(np.float64(1092881.16069544), np.float64(1092881.1606954413))
```

Наконец, общая дисперсия (total sum of squares) рассчитывается как сумма квадратов отклонений фактических данных от их среднего значения

$$SS_{total} = \sum (y_i - \bar{y})^2$$

```
np.sum(np.square(y-np.mean(y))), linreg_ols.centered_tss
```

```
(np.float64(1138886.6590655423), np.float64(1138886.6590655423))
```

или, что то же самое, сумму $SS_{residuals}$ и $SS_{explained}$.

```
linreg_ols.ssr + linreg_ols.ess
```

```
np.float64(1138886.6590655423)
```

R^2 **и скорректированный** R^2. На приведенных выше показателях основывается такой критерий **степени согласия** (goodness of fit) модели (т.е. ее способности представлять наблюдаемые данные), как коэффициент детерминации или R^2. Он показывает долю объясненной изменчивости данных.

$$R^2 = \frac{SS_{explained}}{SS_{total}} = 1 - \frac{SS_{residuals}}{SS_{total}}$$

```
r_squared = linreg_ols.ess / linreg_ols.centered_tss
r_squared
```

```
np.float64(0.959604849170989)
```

```
r_squared = 1 - linreg_ols.ssr / linreg_ols.centered_tss
r_squared
```

```
np.float64(0.959604849170989)
```

Наконец скорректированный коэффициент детерминации понижает степень согласия с увеличением количества признаков.

$$R^2_{adj} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1}$$

```
adjusted_r_squared = 1 - (1 - r_squared) * (n_samples - 1) / (n_samp
adjusted_r_squared
```

```
np.float64(0.9587719594631743)
```

f-критерий (f-test) позволяет определить, насколько хорошо независимые переменные *совместно* объясняют целевую переменную (в случае простой линейной регрессии и одного предиктора было бы достаточно t-критерия):

- если ни один из предикторов не объясняет зависимую переменную, то

все параметры должны быть равны нулю; это и будет нулевой гипотезой f-теста, $H_0 : \beta_1 = \beta_2 = \ldots = \beta_p = 0$;

- альтернативная гипотеза заключается в том, что по крайней мере один параметр не равен нулю, $H_1 : \beta_j \neq 0$.

f-критерий сравнивает количество дисперсии, объясненной моделью с количеством необъясненной дисперсии. Найдем F-статистику

$$F = \frac{\frac{SS_{explained}}{df_{model}}}{\frac{SS_{residuals}}{df_{residuals}}} = \left(\frac{\frac{SS_{explained}}{SS_{total}}}{p}\right) / \left(\frac{\frac{SS_{residuals}}{SS_{total}}}{n-p-1}\right) = \left(\frac{R^2}{p}\right) / \left(\frac{1-R^2}{n-p-1}\right)$$

```
df_model = n_features
df_resid = n_samples - n_features - 1

F = (linreg_ols.ess / df_model) / (linreg_ols.ssr / df_resid)
F
```

```
np.float64(1152.139161004648)
```

Числитель, $SS_{explained}$, и знаменатель, $SS_{residuals}$, приведенной выше формулы следуют распределению χ^2, каждое со своими степенями свободы df_{model} и $df_{residuals}$ соответственно. Отношение этих распределений представляет собой F-распределение с теми же степенями свободы.

```
from scipy.stats import f
x_fdist = np.linspace(0, 5, 120)
y_fdist = f.pdf(x_fdist, df_model, df_resid)

plt.figure(figsize=(8, 5))
plt.plot(x_fdist, y_fdist)
plt.title(f'F-distribution PDF for df_model={df_model}, df_residual
plt.xlabel('F-statistic')
plt.ylabel('Probability Density')
plt.grid(True)
plt.show()
```

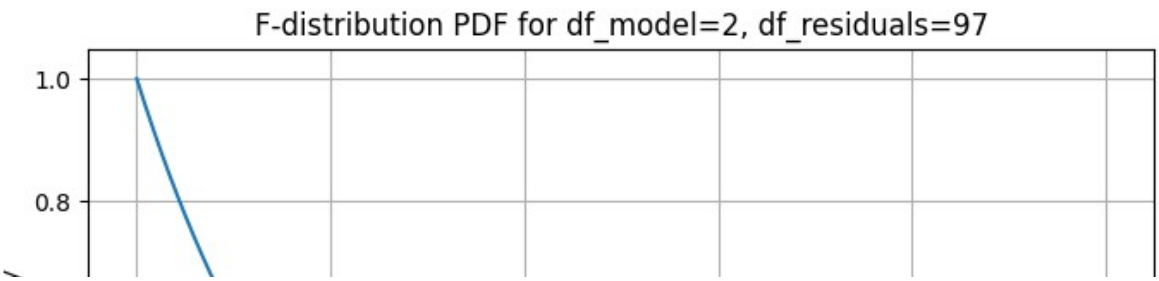

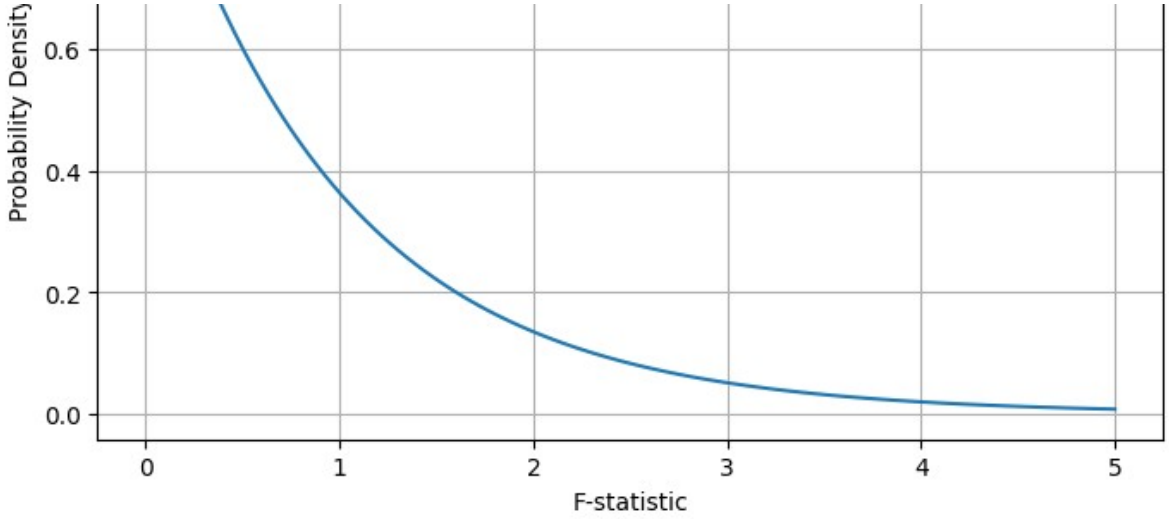

F-распределение позволяет оценить вероятность H_0. В частности, поскольку это односторонний тест, нас будет интересовать площадь под кривой справа от F-статистики (однако уже на графике видно, что площадь справа от значения $F \approx 1152{,}14$ чрезвычайно мала).

```
p_value = f.sf(F, df_model, df_resid)
p_value
```

```
np.float64(2.55251234812177e-68)
```

При любом самом строгом пороговом значении, p-value окажется ниже. Как следствие, мы можем отвергнуть нулевую гипотезу.

Логарифм правдоподобия. Помимо коэффициента детерминации степень согласия можно оценить через логарифм максимального значения функции правдоподобия.

> Обратите внимание, здесь мы ищем именно максимальное значение функции $\max \ell(\hat{\beta})$, а не значение аргумента $\operatorname{argmax} \ell(\hat{\beta})$, при котором функция правдоподобия достигает максимального значения.

В самом деле, более высокие (менее отрицательные) значения ℓ говорят о том, что модель лучше описывает данные.

Максимум логарифма правдоподобия можно найти по следующей формуле

$$\max \ell(\hat{\beta}) = \log \hat{L} = -\frac{n}{2}\log 2\pi - \frac{n}{2}\log \sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^{n} \varepsilon^2$$

Заметим, что оптимальные $\hat{\sigma}^2$ и $\hat{\beta}$ нам уже известны. В частности, коэффициенты $\hat{\beta}_j$ заложены в остатки ε.

```
# вначале найдем дисперсию и остатки
sigma_squared = linreg_ols.scale
error = linreg_ols.resid
```

```
# применим формулу
log_likelihood_terms = -0.5 * n_samples * np.log(2 * np.pi) - 0.5 *
log_likelihood = np.sum(log_likelihood_terms)
log_likelihood
```

```
np.float64(-448.48411430094427)
```

```
# сравним с результатом statsmodels
linreg_ols.llf
```

```
np.float64(-448.46115392670873)
```

Выбор модели. Логарифм правдоподобия удобно использовать, если нам нужно выбрать между, например, *полной* или *длинной моделью* (full, unrestricted model), т.е. такой моделью, которая использует все β_j и некоторой вложенной (nested) в нее *ограниченной* или *короткой* моделью (reduced, restricted model).

```
# ограниченная модель, X2 = 0
restricted = smf.ols('y ~ X1', data=linear_regression_data).fit()

# полная модель
unrestricted = smf.ols('y ~ X1 + X2', data=linear_regression_data).f
```

```
restricted.llf, unrestricted.llf
```

```
(np.float64(-575.9119363801976), np.float64(-448.46115392670873))
```

Тест отношения правдоподобия (likelihood ratio test, LR). Тестовую статистику λ_{LR} можно вычеслить через

$$\lambda_{LR} = -2\left(\frac{\hat{L}_R}{\hat{L}_F}\right) = -2(\log \hat{L}_R - \log \hat{L}_F),$$

где $\hat{L}_R$ и $\hat{L}_F$ — максимальное правдоподобие ограниченной и полной модели соответственно.

- нулевая гипотеза H_0 теста утверждает, что короткой модели

достаточно для объяснения данных;

- альтернативная гипотеза H_1 предполагает, что длинная регрессия значимо лучше подходит для моделирования данных.

В случае если верна H_0, λ_{LR} асимптотически при $n \to \infty$ следует распределению $\chi^2(q)$, где q — число ограничений модели (разница между степенями свободы полной и ограниченной модели).

```
from scipy.stats import chi2
lambda_LR = -2 * (restricted.llf - unrestricted.llf)
print(lambda_LR)
```

```
254.9015649069778
```

```
# найдем разницу в степенях свободы
df_diff = 2 - 1
# вычислим p-value
pvalue = 1 - chi2(df_diff).cdf(lambda_LR)
print(pvalue)
```

```
0.0
```

При этом, как правило, модели с бóльшим количеством параметров склонны иметь более высокие значения $\hat{L}$. Кроме того, тест отношения правдоподобия подходит только для вложенных моделей.

Для преодоления этих сложностей можно использовать так называемые информационные критерии (information criteria).

Информационный критерий Акаике (Akaike information criterion, AIC) рассчитывается по формуле

$$AIC = -2 \log \hat{L} + 2(p+1)$$

Другими словами, меньшее (положительное) значение критерия означает бóльшую степень согласия. Одновременно, AIC увеличивается с увеличением количества коэффициентов p.

```
p_restricted = 1
p_unrestricted = 2
```

```
-2 * restricted.llf + 2 * (p_restricted + 1), -2 * unrestricted.llf
```

```
(np.float64(1155.8238727603953), np.float64(902.9223078534175))
```

```
restricted.aic, unrestricted.aic
```

```
(np.float64(1155.8238727603953), np.float64(902.9223078534175))
```

Байесовский информационный критерий (Bayesian information criterion, BIC) или **критерий Шварца** (Schwarz information criterion, SIC)

$$BIC = -2 \log \hat{L} + p \log n$$

сильнее, чем AIC «наказывает» за увеличение количества параметров модели.

```
# рассчитаем BIC только для полной модели
-2 * unrestricted.llf + np.log(n_samples) * (p_unrestricted + 1)
```

```
np.float64(910.7378184113818)
```

```
unrestricted.bic
```

```
np.float64(910.7378184113818)
```

Класс GLM

Теперь применим класс GLM с традиционным API.

```
linreg_glm = smf.glm(formula='y ~ X1 + X2', data=linear_regression_d
                     family=sm.families.Gaussian()).fit()
print(linreg_glm.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:                      y   No. Observations:
Model:                            GLM   Df Residuals:
Model Family:                Gaussian   Df Model:
Link Function:               Identity   Scale:
Method:                          IRLS   Log-Likelihood:
Date:                Sat, 05 Jul 2025   Deviance:
Time:                        13:25:53   Pearson chi2:
No. Iterations:                     3   Pseudo R-squ. (CS):
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          z      P>|z|      [0.025
------------------------------------------------------------------------------
Intercept     10.4327      2.199      4.744      0.000       6.122
X1            84.2679      2.557     32.951      0.000      79.255
X2            74.1566      2.192     33.824      0.000      69.860
```

```
==================================================================
```

Здесь, в отличие от класса OLS, ожидаемо используется метод IRLS и появляются новые способы оценить степень согласия.

Подробнее про эти показатели мы поговорим на примере другой модели — логистической регрессии.

Логистическая регрессия

Подготовим данные.

```
n_samples = 200

X, y = make_blobs(n_samples=n_samples,
                  n_features=2,
                  centers=2,
                  cluster_std=2.8,
                  random_state=random_state)

logistic_regression_data = pd.DataFrame({'X1': X[:,0], 'X2': X[:,1],
```

```
fig, ax = plt.subplots()
for name, group in logistic_regression_data.groupby('y'):
    ax.scatter(group['X1'], group['X2'], label=f'Class {name}')

ax.set_xlabel('X1')
ax.set_ylabel('X2')
ax.set_title('Scatter Plot of Two Features by Class')
ax.legend()
plt.show()
```

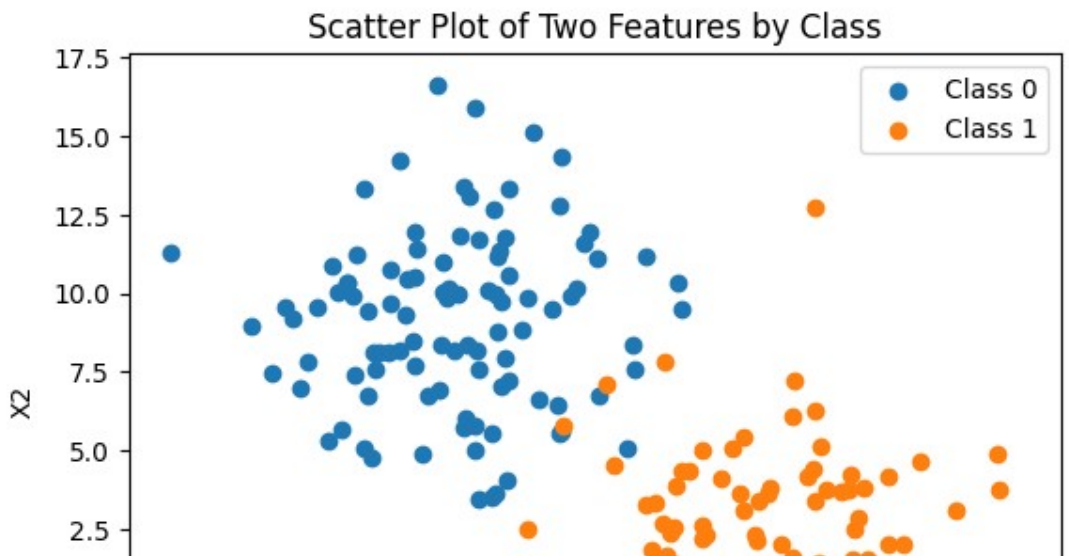

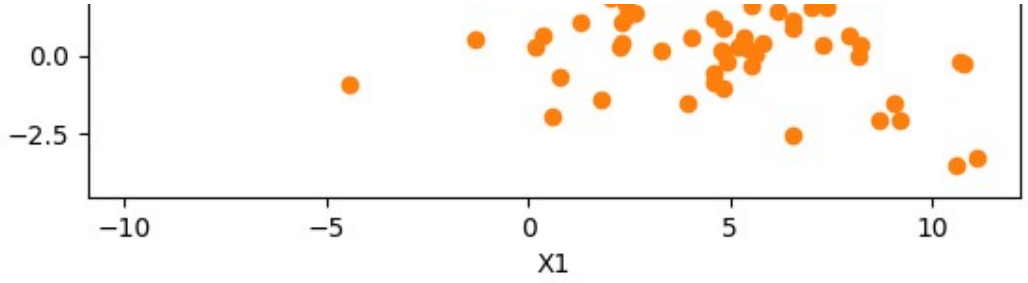

Масштабируем данные и добавляем фиктивный признак.

```
scaler = StandardScaler()
X = scaler.fit_transform(X)
X = sm.add_constant(X)
```

Обучим логистическую регрессию или, что то же самое, обобщенную линейную модель с биномиальным распределением остатков.

```
logreg_glm = sm.GLM(y, X, family=sm.families.Binomial()).fit()
print(logreg_glm.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:                      y   No. Observations:
Model:                            GLM   Df Residuals:
Model Family:                Binomial   Df Model:
Link Function:                  Logit   Scale:
Method:                          IRLS   Log-Likelihood:
Date:                Tue, 08 Jul 2025   Deviance:
Time:                        08:16:02   Pearson chi2:
No. Iterations:                    11   Pseudo R-squ. (CS):
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          z      P>|z|      [0.025
------------------------------------------------------------------------------
const          1.0781      0.870      1.239      0.215      -0.628
x1             8.6671      3.240      2.675      0.007       2.317
x2            -6.1788      2.344     -2.636      0.008     -10.773
==============================================================================
```

Сделаем прогноз и оценим accuracy.

```
y_pred = logreg_glm.predict(X).round().astype(int)
accuracy_score(y, y_pred)
```

```
0.98
```

Найдем максимум логарифма правдоподобия

$$\log \hat{L} = \sum \left[y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i) \right]$$

```
np.sum(y * np.log(logreg_glm.fittedvalues) + (1 - y) * np.log(1 - lo
```

```
np.float64(-10.266694868979346)
```

```
logreg_glm.llf
```

```
np.float64(-10.26669486897933)
```

Степень согласия

В обобщенной линейной модели для оценки степени согласия используется **девианс** модели.

Нулевая, предложенная и насыщенная модель. Предположим, что на одних и тех же данных мы построили три модели: нулевую, предложенную и насыщенную:

- *нулевая (тривиальная) модель* (null model) строится только на основе сдвига β_0, все остальные $\beta_1, \ldots, \beta_p$ равны нулю; это самая слабая из возможных моделей и лучшее, что можно сделать, это взять сдвиг равный среднему значению, $\beta_0 = \bar{y}$;
- *предложенная модель* (proposed model) — это та, которую мы обучили выше. В ней есть сдвиг β_0 и два предиктора β_1 и β_2; наконец
- в *насыщенной модели* (saturated model) количество параметров равно количеству наблюдений за исключением сдвига $n - 1$; другими словами модель идеально предсказывает каждый объект.

Проиллюстрируем возможности таких подходов, обучив на случайных данных полиномиальные модели без параметров, с двумя параметрами и с $n - 1$ параметром соответственно.

```
# создадим искусственные данные
np.random.seed(42)
x = np.sort(np.random.rand(10) * 10)
y = 2 * x + np.random.randn(10) * 2 + 5

x_plot = np.linspace(min(x), max(x), 50)

```

```python
# нулевая модель
null_coeff = np.polyfit(x, y, 0)
null_model = np.poly1d(null_coeff)
null_y = null_model(x_plot)

# предложенная модель
proposed_coeff = np.polyfit(x, y, 2)
proposed_model = np.poly1d(proposed_coeff)
proposed_y = proposed_model(x_plot)

# насыщенная модель
saturated_coeff = np.polyfit(x, y, len(x)-1)
saturated_model = np.poly1d(saturated_coeff)
saturated_y = saturated_model(x_plot)

fig, (ax1, ax2, ax3) = plt.subplots(1, 3, figsize=(22,7))
ax1.plot(x_plot, null_y, color='C0')
ax1.scatter(x,y,s=70, color='C0')
ax1.set_title('Нулевая модель', fontsize=22)
ax1.axes.xaxis.set_visible(False)
ax1.axes.yaxis.set_visible(False)
ax2.plot(x_plot, proposed_y, color='C1')
ax2.scatter(x,y,s=70, color='C1')
ax2.set_title('Предложенная модель', fontsize=22)
ax2.axes.xaxis.set_visible(False)
ax2.axes.yaxis.set_visible(False)
ax3.plot(x_plot, saturated_y, color='C2')
ax3.scatter(x,y,s=70, color='C2')
ax3.set_title('Насыщенная модель', fontsize=22)
ax3.axes.xaxis.set_visible(False)
ax3.axes.yaxis.set_visible(False)
```

Девианс (deviance, residual deviance) рассчитывается как удвоенная разница между максимальным правдоподобием насыщенной модели $\log \hat{L}_s$ и максимальным правдоподобием предложенной модели $\log \hat{L}_p$.

$$D = 2(\log \hat{L}_s - \log \hat{L}_p)$$

Другими словами, мы оцениваем насколько хорошо предложенная модель описывает данные по сравнению с «идеальной» насыщенной моделью.

Нулевой девианс (null deviance) показывает, насколько нулевая модель «отстает» от насыщенной.

$$D_{\text{null}} = 2(\log \hat{L}_s - \log \hat{L}_0)$$

Можно показать, что девианс модели обыкновенной линейной регрессии D_{linear} аналогичен сумме разности квадратов отклонений прогнозных значений от фактических.

$$D_{\text{linear}} = SS_{residuals} = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Введем понятие **масштабированного девианса** (scaled deviance) $D^* = \frac{D}{\phi}$, где ϕ — степень разброса (dispersion) случайной величины.

Для нормального распределения

$$f(y; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right)$$

масштабированный девианс одного наблюдения (unit deviance) равен

$$\begin{aligned} D^*(y, \mu) &= 2l(y; y) - 2l(\mu; y) \\ &= 2\log(f(y; y)) - 2\log(f(y; \mu)) \\ &= 2\left[-\frac{1}{2}\log(2\pi\sigma^2) - \frac{(y-y)^2}{2\sigma^2}\right] - 2\left[-\frac{1}{2}\log(2\pi\sigma^2) - \frac{(y-\mu)^2}{2\sigma^2}\right] \\ &= \frac{(y-\mu)^2}{\sigma^2} \end{aligned}$$

Поскольку в нормальном распределении $\phi = \sigma^2$,

$$D^*(y; \mu) = \frac{D(y; \mu)}{\phi} = \frac{D(y; \mu)}{\sigma^2}$$

$$D(y, \mu) = (y - \mu)^2$$

Вернемся к модели GLM с нормальным распределением остатков.

```
np.sum(((y - linreg_glm.fittedvalues) ** 2)), linreg_glm.deviance
```

```
(np.float64(46005.49837010103), np.float64(46005.49837010103))
```

При этом нулевой девианс равен SS_{total}.

```
np.sum(np.square(y-np.mean(y))), linreg_glm.null_deviance
```

```
(np.float64(1138886.6590655423), np.float64(1138886.6590655423))
```

Несложно вывести девианс модели логистической регресии $D_{logistic}$.

$$
\begin{aligned}
D_{\text{logistic}} &= -2\sum_{i=1}^{n}\Big[y_i \log \hat{y}_i + (1-y_i)\log(1-\hat{y}_i) \\
&\quad - y_i \log y_i - (1-y_i)\log(1-y_i)\Big] \\
&= -2\sum_{i=1}^{n}\Big[y_i \log \hat{y}_i + (1-y_i)\log(1-\hat{y}_i)\Big]
\end{aligned}
$$

```
-2 * np.sum(y * np.log(logreg_glm.fittedvalues) + (1 - y) * np.log(1
```

```
np.float64(20.533389737958693)
```

Нулевой девианс логистической регрессии рассчитывается через

$$
D_{\text{null logistic}} = -2\sum k \log \hat{p} + (n-k)\log(1-\hat{p}),
$$

где k — количество успехов, n — количество наблюдений и $\hat{p} = \frac{k}{n}$ — вероятность успеха на основе выборочных данных.

```
k, n = np.sum(y), len(y)
p_hat = k/n
```

```
-2 * np.sum(k * np.log(p_hat) + (n-k) * np.log(1-p_hat))
```

```
np.float64(277.25887222397813)
```

Сравним с показателями statsmodels.

```
logreg_glm.deviance, logreg_glm.null_deviance
```

```
(np.float64(20.533389737958686), np.float64(277.2588722239781))
```

Коэффициент детерминации обобщенной линейной модели, также

называемый псевдо-R^2 (pseudo-R^2), яляется обобщением показателя R^2 для обыкновенной линейной регрессии.

Коэффициент детерминации МакФаддена (McFadden) рассчитывается через

$$R^2_{\text{McF}} = 1 - \frac{D}{D_0} = \frac{\log \hat{L}_p}{\log \hat{L}_0}$$

и показывает, насколько степень согласия предложенной модели близка к степень согласия насыщенной или тривиальной модели (заметим, что псевдо-R^2 не стоит интерпретировать как долю объясненной дисперсии).

```
1 | 1 - logreg_glm.deviance/logreg_glm.null_deviance, 1 - logreg_glm.llf
```

```
1 | (np.float64(0.9259414511310167), np.float64(0.9259414511310168))
```

```
1 | logreg_glm.pseudo_rsquared(kind='mcf')
```

```
1 | np.float64(0.9259414511310168)
```

Заметим, что в модели обыкновенной линейной регрессии коэффициент МакФаддена очевидно аналогичен стандартному коэффициенту детерминации R^2.

```
1 | 1 - (linreg_glm.deviance / linreg_glm.null_deviance)
```

```
1 | np.float64(0.959604849170989)
```

Еще один *коэффициент детерминации Кокса и Снелла* (Cox and Snell, CS)

$$\begin{aligned} R^2_{\text{CS}} &= 1 - \left(\frac{\hat{L}_0}{\hat{L}_p}\right)^{2/n} \\ &= 1 - \exp\left(\frac{2}{n}\left(\log \hat{L}_0 - \log \hat{L}_p\right)\right) \end{aligned}$$

```
1 | 1 - np.exp((logreg_glm.llnull - logreg_glm.llf)*(2/n_samples))
```

```
1 | np.float64(0.7229694284920674)
```

```
1 | logreg_glm.pseudo_rsquared(kind='cs')
```

```
1 | np.float64(0.7229694284920674)
```

Список литературы

- J. A. Nelder, R. W. M. Wedderburn, Generalized Linear Models, 1972;
- M. Jordan, Bayesian Modeling and Inference, chapter 8, 2009;
- К.В. Воронцов, Лекции по алгоритмам восстановления регрессии, 2007;