Метод главных компонент

Метод главных компонент (principal component analysis, PCA) используется для понижения размерности данных.

Понижение размерности как проекция

Возьмем набор данных, состоящий из двух признаков x_1 и x_2. Поставим задачу сократить эти данные до одного измерения.

Пусть для начала данные обладают большой дисперсией только по измерению x_2.

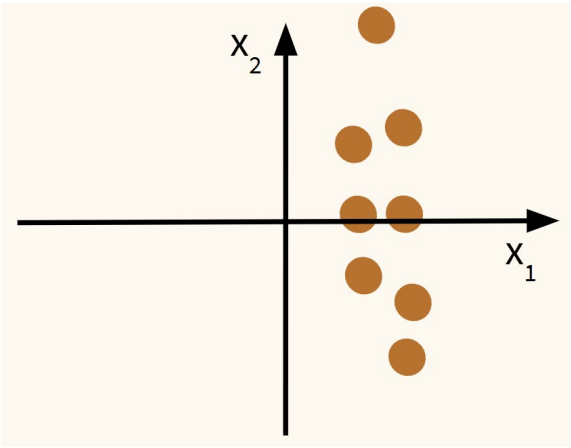

В этом случае мы можем смело отбросить признак x_1, поскольку он не обладает существенной дисперсией и несет в себе мало информации. На практике же данные чаще обладают изменчивостью по более чем одному измерению и просто отбросить одно из измерений было бы неразумно.

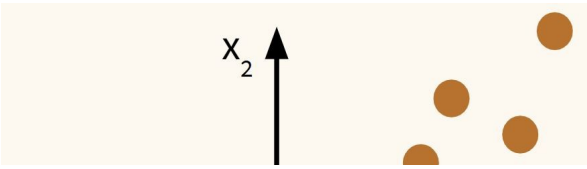

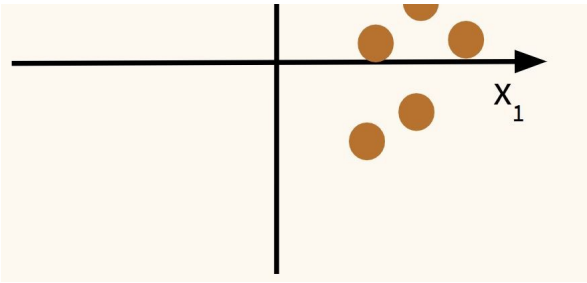

Представляется более логичным найти такое (отличное от изначальных) измерение x', проекция наблюдений на которое, будет давать наибольшую дисперсию данных.

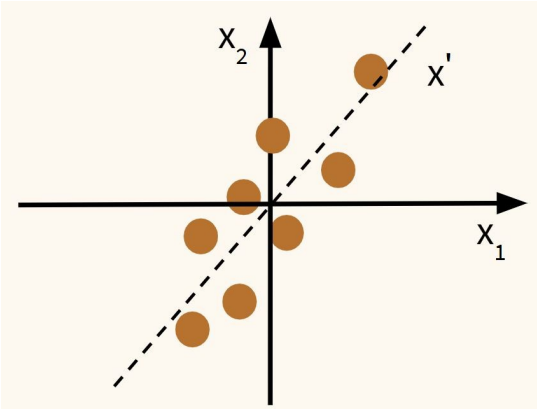

Заметим, что выше мы стандартизировали данные

$$\mathbf{x}_{std} = \frac{\mathbf{x} - \mu}{\sigma},$$

то есть привели их к нулевому среднему (так вектор проекции x' будет проходить через начало координат) и СКО равному единице (это важно, потому что мы хотели бы сравнивать изменчивость данных по каждому из изначальных измерений).

Обратим внимание, что задача нахождения оси проекции с наибольшей дисперсией данных аналогична задаче нахождения оси, минимизирующей ортогональные расстояния к проекциям наблюдений.

> Это расстояние также называют ошибкой проектирования или **reconstruction error**, потому что если мы захотим восстановить исходные данные, именно это расстояние необходимо будет компенсировать.

В самом деле, рассмотрим единственное наблюдение $\mathbf{x}_i$ и возможную ось проекции x'.

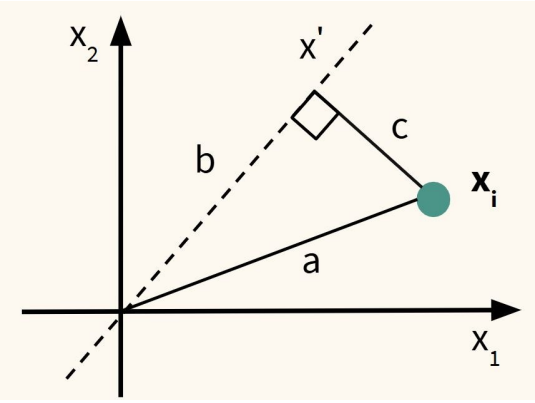

В силу того что ось проекции обязательно проходит через начало координат, расстояние a (гипотенуза прямоугольного треугольника) фиксировано, и задача максимизации катета b аналогична задаче минимизации катета c.

Формализуем сказанное выше.

Решение через ковариационную матрицу

Пусть x'_i скалярная проекция одного из наблюдений $\mathbf{x}_i$ на ось x' и вектор $\mathbf{w}$ — единичный вектор в направлении x'.

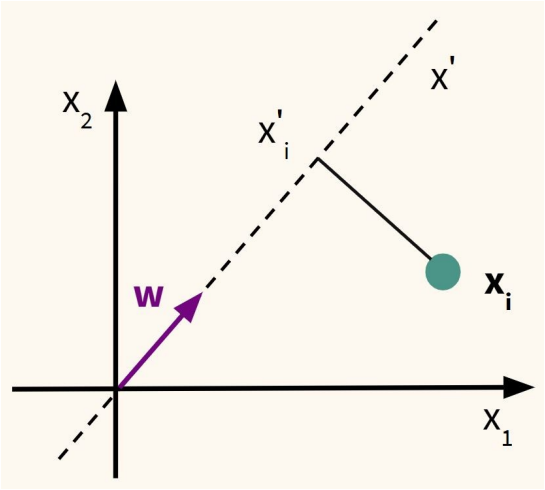

Другими словами,

$$x'_i = \frac{\mathbf{w}^\top \mathbf{x}_i}{||\mathbf{w}||}$$

Поскольку $||\mathbf{w}||^2 = 1$, то

$$x'_i = \mathbf{w}^\top \mathbf{x}_i$$

Если $\boldsymbol{\mu}$ — вектор средних значений, то скалярную проекцию среднего (среднее всех проекций) можно выразить через

$$\bar{x}' = \mathbf{w}^\top \boldsymbol{\mu}$$

Не будем забывать, что после стандартизации $\bar{x}' = \mathbf{w}^\top \mathbf{0} = 0$. Тогда дисперсию проекций x'_i на x' можно записать как

$$\mathbb{V}\left[\{x'_i\}_{i=1}^N\right] = \mathbb{V}\left[\{\mathbf{v}^\top \mathbf{x}_i\}_{i=1}^N\right] = \frac{1}{N}\sum_{i=1}^N (\mathbf{w}^\top \mathbf{x}_i - \mathbf{w}^\top \boldsymbol{\mu})^2$$

Поскольку $\mathbf{w}^\top \boldsymbol{\mu} = 0$,

$$\mathbb{V}\left[\{\mathbf{w}^\top \mathbf{x}_i\}_{i=1}^N\right] = \frac{1}{N}\sum_{i=1}^N (\mathbf{w}^\top \mathbf{x}_i)^2$$

Таким образом, задача сводится к нахождению вектора $\mathbf{w}^*$, такого что

$$\mathbf{w}^* = \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmax}} \frac{1}{N}\sum_{i=1}^N (\mathbf{w}^\top \mathbf{x}_i)^2$$

Вектор $\mathbf{w}^*$ при этом называется **первой главной компонентой** (first principal component, PC1). Еще раз заметим, что эта задача аналогична задаче минимизации ортогональных расстояний к проекциям x'_i

$$\begin{aligned}\mathbf{w}^* &= \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmin}} \frac{1}{N}\sum_{i=1}^N ||\mathbf{x}_i - (\mathbf{w}^\top \mathbf{x}_i)\mathbf{w}||^2 \\ &= \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmin}} \frac{1}{N}\sum_{i=1}^N ||\mathbf{x}_i||^2 - (\mathbf{w}^\top \mathbf{x}_i)^2,\end{aligned}$$

в силу того, что $\mathbf{w}^\top \mathbf{w} = ||\mathbf{w}||^2 = 1$. Перепишем задачу максимизации

дисперсии с помощью матричной формы записи.

$$\begin{aligned}\mathbf{w}^* &= \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmax}} \frac{1}{N}\sum_{i=1}^{N}(\mathbf{w}^\top\mathbf{x}_i)^2 \\ &= \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmax}} \frac{1}{N}\{||\mathbf{X}\mathbf{w}||^2\} \\ &= \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmax}}\{\mathbf{w}^\top\mathbf{\Sigma}\mathbf{w}\},\end{aligned}$$

где $\mathbf{\Sigma} = N^{-1}\mathbf{X}^\top\mathbf{X} = N^{-1}\sum_{i=1}^{N}\mathbf{x}_i\mathbf{x}_i^\top$ — ковариационная матрица *стандартизированной* матрицы признаков $\mathbf{X}$. При этом решение задачи

$$\mathbf{w}^* = \underset{\mathbf{w}:||\mathbf{w}||^2=1}{\operatorname{argmax}}\{\mathbf{w}^\top\mathbf{\Sigma}\mathbf{w}\}$$

аналогично задаче

$$\mathbf{w}^* = \operatorname{argmax}\left\{\frac{\mathbf{w}^\top\mathbf{\Sigma}\mathbf{w}}{\mathbf{w}^\top\mathbf{w}}\right\},$$

где $\frac{\mathbf{w}^\top\mathbf{\Sigma}\mathbf{w}}{\mathbf{w}^\top\mathbf{w}}$ — **отношение Рэлея** (Rayleigh quotient). Применив метод множителей Лагранжа, получим

$$\mathcal{L}(\mathbf{w},\lambda) = \mathbf{w}^\top\mathbf{\Sigma}\mathbf{w} - \lambda(\mathbf{w}^\top\mathbf{w} - 1)$$

Дифференцируя по $\mathbf{w}$, получим

$$\begin{aligned}\frac{\partial\mathcal{L}}{\partial\mathbf{w}} &= 2\mathbf{\Sigma}\mathbf{w} - \lambda 2\mathbf{w} &= 0 \\ \mathbf{\Sigma}\mathbf{w} &= \lambda\mathbf{w}\end{aligned}$$

Таким образом, задача сводится к нахождению собственных значений λ и соответствующих им собственных векторов $\mathbf{w}$ матрицы $\mathbf{\Sigma} = N^{-1}\mathbf{X}^\top\mathbf{X}$.

Взяв первые m компонент $\mathbf{w}_j$, сформируем матрицу $\mathbf{W}_{d\times m}$, где d — количество изначальных измерений. При умножении на матрицу данных $\mathbf{X}_{n\times d}$, мы получим их проекцию $\mathbf{Z}_{n\times m}$ на выбранные m главных компонент.

$$\mathbf{Z} = \mathbf{X}\cdot\mathbf{W}$$

В частности, для $m = 2$ получим,

$$\mathbf{Z} = \mathbf{X} \cdot \mathbf{W} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{pmatrix} \cdot \underbrace{\begin{pmatrix} w_1^{(1)} & w_1^{(2)} \\ w_2^{(1)} & w_2^{(2)} \\ \vdots & \vdots \\ w_d^{(1)} & w_d^{(2)} \end{pmatrix}}_{m=2} = \begin{pmatrix} | & | \\ \mathbf{PC1} & \mathbf{PC2} \\ | & | \end{pmatrix}$$

Заметим, что результатом $\mathbf{Z} \cdot \mathbf{W}^\top + \boldsymbol{\mu}$ будет (приближенно) восстановленная (reconstructed) матрица $\mathbf{X}$. При этом, что логично, чем больше компонент было использовано для проекции, тем выше будет качество восстановления данных.

Кроме этого, скажем, что собственные значения λ_j показывают, какую часть общей дисперсии объясняет каждый из собственных векторов. В частности, долю **объясненной дисперсии** (explained variance) первой компоненты можно найти по формуле

$$\frac{\lambda_1}{\lambda_1 + \lambda_2 + \ldots + \lambda_d}$$

Добавим, что с точки зрения **спектрального разложения** (spectral decomposition), симметричную квадратную ковариационную матрицу $\boldsymbol{\Sigma}_{d \times d}$ можно разложить на

$$\boldsymbol{\Sigma} = \mathbf{W} \boldsymbol{\Lambda} \mathbf{W}^\top,$$

где столбцы матрицы $\mathbf{W}_{d \times d}$ являются собственными векторами $\boldsymbol{\Sigma}$, а диагональные элементы $\boldsymbol{\Lambda}$ соответствующими собственными значениями.

Умножив на $\mathbf{W}$, получим

$$\boldsymbol{\Sigma} \mathbf{W} = \mathbf{W} \boldsymbol{\Lambda} \mathbf{W}^\top \mathbf{W} = \mathbf{W} \boldsymbol{\Lambda},$$

что, если положить $\mathbf{w}_i$ как i-ый столбец $\mathbf{W}$ и $\lambda_i = \boldsymbol{\Lambda}_{ii}$, соответствует решению

$$\boldsymbol{\Sigma} \mathbf{w}_i = \lambda_i \mathbf{w}_i.$$

Решение через сингулярное разложение

Одновременно для матрицы данных $\mathbf{X}_{n\times d}$ можно построить **сингулярное разложение** (singular value decomposition, SVD). В частности,

$$\mathbf{X} = \mathbf{U}\mathbf{\Gamma}\mathbf{V}^\top,$$

где $\mathbf{U}_{n\times n}$ — матрица левых сингулярных векторов, $\mathbf{\Gamma}_{n\times d}$ — матрица, элементы главной диагонали которой называются сингулярными числами и $\mathbf{V}_{d\times d}$ — матрица правых сингулярных векторов.

Интересно, что

$$\begin{aligned}
\mathbf{X} &= \mathbf{U}\mathbf{\Gamma}\mathbf{V}^\top \\
\mathbf{X}^\top &= (\mathbf{U}\mathbf{\Gamma}\mathbf{V}^\top)^\top = \mathbf{V}\mathbf{\Gamma}\mathbf{U}^\top \\
\mathbf{X}^\top\mathbf{X} &= \mathbf{V}\mathbf{\Gamma}(\mathbf{U}^\top\mathbf{U})\mathbf{\Gamma}\mathbf{V}^\top \\
\mathbf{X}^\top\mathbf{X} &= \mathbf{V}\mathbf{\Gamma}^2\mathbf{V}^\top
\end{aligned}$$

Другими словами, матрица $\mathbf{W}$ спектрального разложения $\mathbf{\Sigma} = N^{-1}\mathbf{X}^\top\mathbf{X}$ соответствует матрице $\mathbf{V}^\top$ сингулярного разложения $\mathbf{X}$. При этом $N^{-1}\mathbf{\Gamma}^2 = \mathbf{\Lambda}$.

Код на Питоне

Откроем блокнот к занятию⧉

Создадим класс PCA.

```
class PCA:

  def __init__(self, n_components, solver='covariance'):
    self.n_components = n_components
    self.mean = None
    self.explained_variance = None
    self.solver = solver

  def fit(self, X):
```

```
    self.mean = np.mean(X, axis=0)

    if self.solver == 'covariance':
      covariances = (X - self.mean).T.dot((X - self.mean)) / (X.shape[
      eigenvalues, eigenvectors = np.linalg.eig(covariances)

      idxs = np.argsort(eigenvalues)[::-1]
      eigenvalues = eigenvalues[idxs]
      eigenvectors = eigenvectors[idxs].T

    elif self.solver == 'svd':
      X = X - self.mean
      U, S, Vt = np.linalg.svd(X)

      eigenvalues, eigenvectors = S**2 / (X.shape[0]-1), Vt

    self.W = eigenvectors[:self.n_components]
    self.explained_variance = np.sum(eigenvalues[:self.n_components])

    return self

  def transform(self, X):

    X -= self.mean
    return np.dot(X, self.W.T)

  def transform_inverse(self, X):

    return np.dot(X, self.W) + self.mean
```

Понизим размерность датасета Iris с четырех до двух измерений.

```
from sklearn.datasets import load_iris
iris = load_iris()
X, y = iris.data, iris.target

from sklearn.preprocessing import StandardScaler
X_std = StandardScaler().fit_transform(X)
```

Применим как метод ковариационной матрицы, так и SVD, посмотрим на величину объясненной дисперсии и сравним получившиеся датасеты.

```
pca = PCA(n_components=2, solver='covariance')
X_pca = pca.fit(X_std).transform(X_std)
print(X_pca.shape, pca.explained_variance)
```

```
(150, 2) 0.9581320720000165
```

```
pca_svd = PCA(n_components=2, solver='svd')
```

```
X_pca_svd = pca_svd.fit(X_std).transform(X_std)
print(X_pca_svd.shape, pca_svd.explained_variance)
```

```
(150, 2) 0.9581320720000165
```

```
np.allclose(X_pca, X_pca_svd)
```

```
True
```

Посмотрим на результат на графике.

```
plt.figure()
colors = ['navy', 'turquoise', 'darkorange']

for color, i, class_name in zip(colors, [0, 1, 2], iris.target_names):
  plt.scatter(X_pca[y == i, 0], X_pca[y == i, 1], color=color, alpha=0
plt.legend(loc="best", shadow=False, scatterpoints=1)
plt.title('Iris 2D PCA projection')
plt.xlabel('PC1')
plt.ylabel('PC2')

plt.show()
```

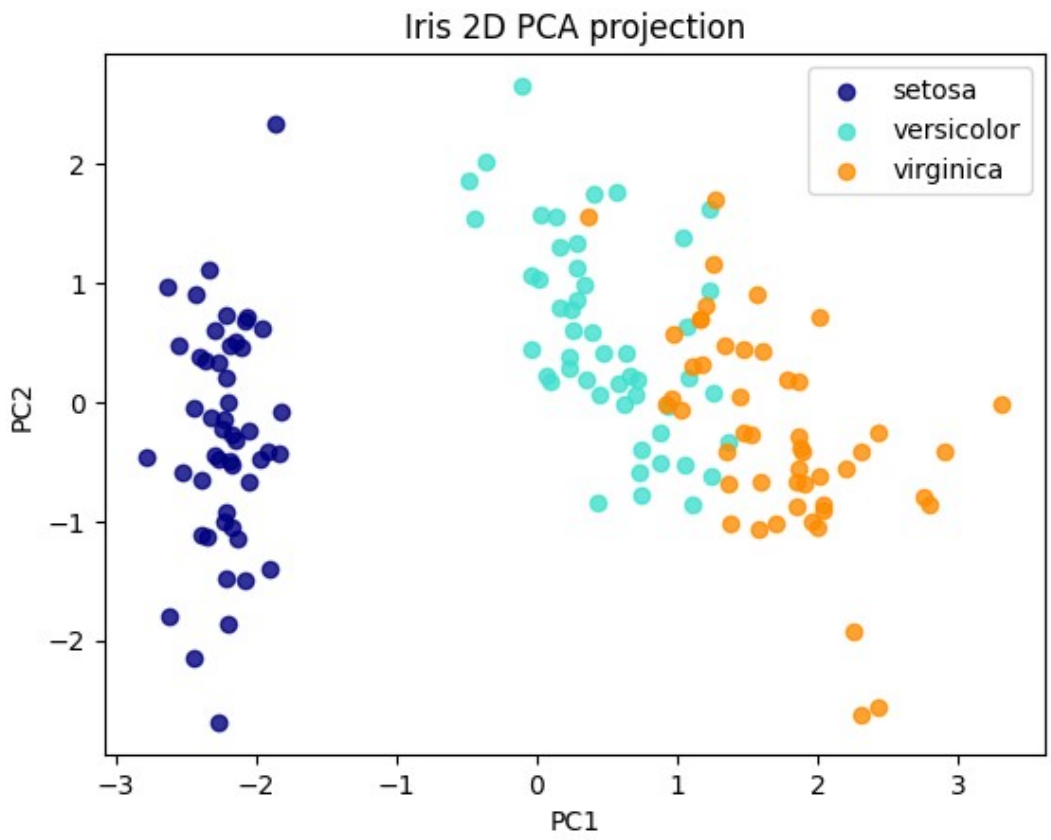

Для того чтобы оценить, на какое количество компонент проецировать исходные данные, можно использовать метод локтя.

```
components_range = range(1,5)
explained_vars = [PCA(n_components=i).fit(X_std).explained_variance fo
plt.plot(components_range, explained_vars, '--o')
plt.xlabel('Number of components')
plt.ylabel('Explained variance')
plt.xticks(components_range)
plt.gca().invert_xaxis()
plt.title('Explained variance by number of components')
plt.show()
```

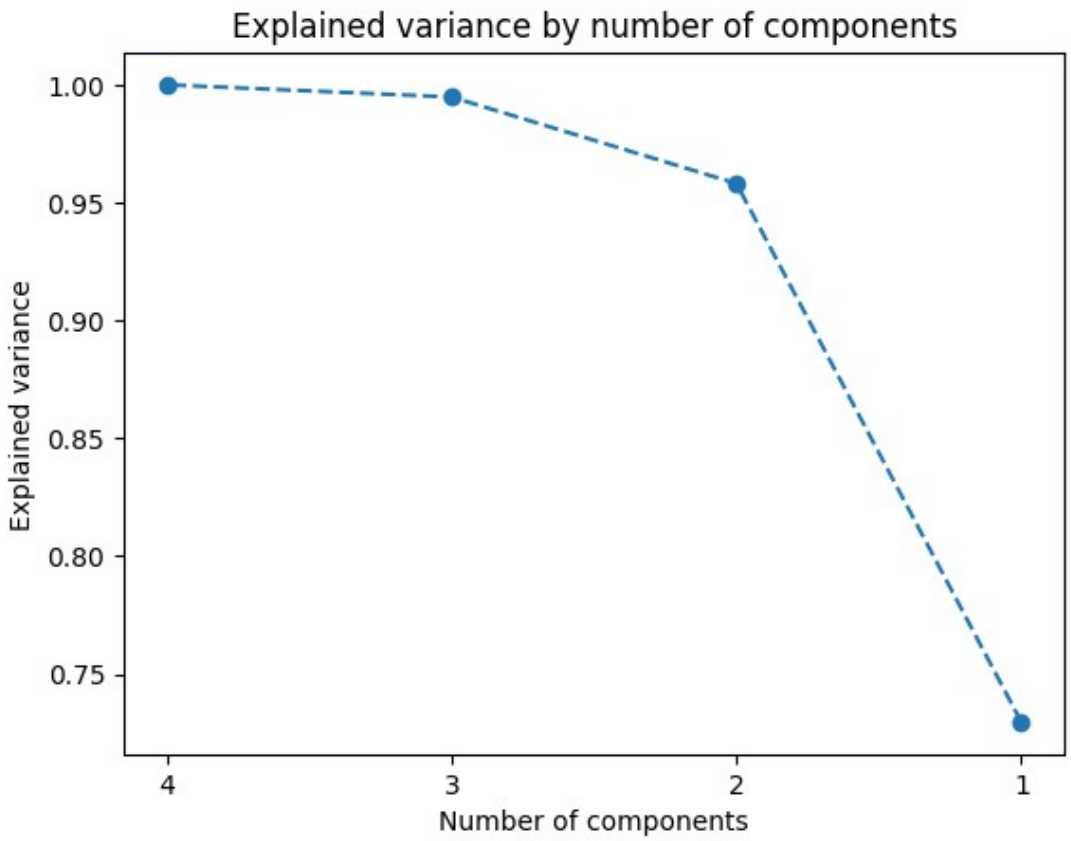

Одна компонента объясняет менее 0,75 дисперсии, в то время как две компоненты уже более 0,95.

Если использовать не все компоненты проекции, то полностью восстановить данные не получится.

```
X_reconstructed = pca.transform_inverse(X_pca)
X_reconstructed[0], X_std[0]
```

```
(array([-0.99888895,  1.05319838, -1.30270654, -1.24709825]),
 array([-0.90068117,  1.01900435, -1.34022653, -1.3154443 ]))
```

```
# данные совпадают при достаточно большом допустимом отклонении
np.allclose(X_reconstructed, X_std, atol=0.8)
```

```
True
```

Метод собственных лиц

Описание метода

M. Turk и A. Pentland (1991) предложили использовать метод главных компонент для распознавания лиц. Основная идея заключается в том, чтобы взять набор изображений лиц

$$\Gamma_1, \Gamma_2, \ldots, \Gamma_n = \mathbf{\Gamma}_{n \times d},$$

где n — количество изображений, а d — количество измерений (пикселей) в изображении Γ_i. Найти среднее лицо (mean face), т.е. вектор

$$\boldsymbol{\psi}_{d \times 1} = \frac{1}{N} \sum_{i=1}^{N} \Gamma_i$$

и центрировать данные $\mathbf{\Phi}_{n \times d} = \mathbf{\Gamma} - \boldsymbol{\psi}$. После этого применить метод главных компонент и найти собственные векторы матрицы $\mathbf{\Phi}$.

Взяв первые m компонент, получим матрицу собственных векторов (eigenvectors) или, в контексте задачи, **собственных лиц** (eigenfaces) $\mathbf{W}_{d \times m}$. Каждая из m координат проекции

$$\mathbf{\Omega}_{n \times m} = \mathbf{\Phi}_{n \times d} \cdot \mathbf{W}_{d \times m}$$

т.е. $\mathbf{\Omega}^\top = [\omega_1, \omega_2, \ldots, \omega_m]$ являются коэффициентами (весами) линейных комбинаций конкретного лица в собственном базисе.

Для нового лица $\Phi' = \Gamma' - \boldsymbol{\psi}$ мы также можем рассчитать проекцию ω' на собственный базис

$$\omega' = \Phi' \cdot \mathbf{W}.$$

После этого достаточно рассчитать евклидово расстояние до каждого из известных векторов $\mathbf{\Omega}^\top = [\omega_1, \omega_2, \ldots, \omega_m]$

$$\epsilon^2_{n \times 1} = ||(\mathbf{\Omega} - \omega')||^2$$

и выбрать то известное лицо, расстояние до которого минимально

$$\underset{n}{\operatorname{argmin}}\{\epsilon^2_{n\times 1}\}.$$

Примечание. В данных с высокой размерностью, в которых количество признаков существенно больше количества наблюдений, $d >> n$, ковариационную матрицу $N^{-1}(\mathbf{X}^\top\mathbf{X})_{d\times d}$ удобнее рассчитать через $N^{-1}(\mathbf{X}\mathbf{X}^\top)_{n\times n}$.

В частности,

$$\frac{1}{N}\mathbf{X}^\top\mathbf{X}\mathbf{w} = \lambda\mathbf{w}$$

$$\frac{1}{N}\mathbf{X}\mathbf{X}^\top(\mathbf{X}\mathbf{w}) = \lambda(\mathbf{X}\mathbf{w})$$

Таким образом, $\mathbf{w}' = \mathbf{X}\mathbf{w}$ являются собственными векторами $\mathbf{X}\mathbf{X}^\top$, и для того чтобы найти собственные векторы $\mathbf{X}^\top\mathbf{X}$ достаточно умножить $\mathbf{w}'$ на $\mathbf{X}^\top$.

При этом собственные значения $\mathbf{X}\mathbf{X}^\top$ и $\mathbf{X}^\top\mathbf{X}$ совпадают. Помимо этого, поскольку $\mathbf{w}$ не обязательно нормализованы, необходимо привести их к единичной норме

$$\mathbf{w} = \frac{\mathbf{w}}{||\mathbf{w}||}.$$

Алгоритм на Питоне

Подготовка данных

Возьмем датасет Olivetti Faces, в котором собраны 400 фотографий лиц 40 различных людей по 10 изображений для каждого человека.

```
from sklearn.datasets import fetch_olivetti_faces
olivetti_faces = fetch_olivetti_faces()
X, y, images = olivetti_faces.data, olivetti_faces.target, olivetti_fa
X.shape, y.shape, images.shape
```

```
((400, 4096), (400,), (400, 64, 64))
```

Посмотрим на лицо каждого из 40 человек.

```
fig, ax=plt.subplots(4, 10, figsize=(16, 8))
ax=ax.flatten()

for unique_id in np.unique(y):
  image_index=unique_id*10
  ax[unique_id].imshow(images[image_index], cmap='gray')
  ax[unique_id].axis('off')
  ax[unique_id].set_title(f'face id:{unique_id}')

plt.show()
```

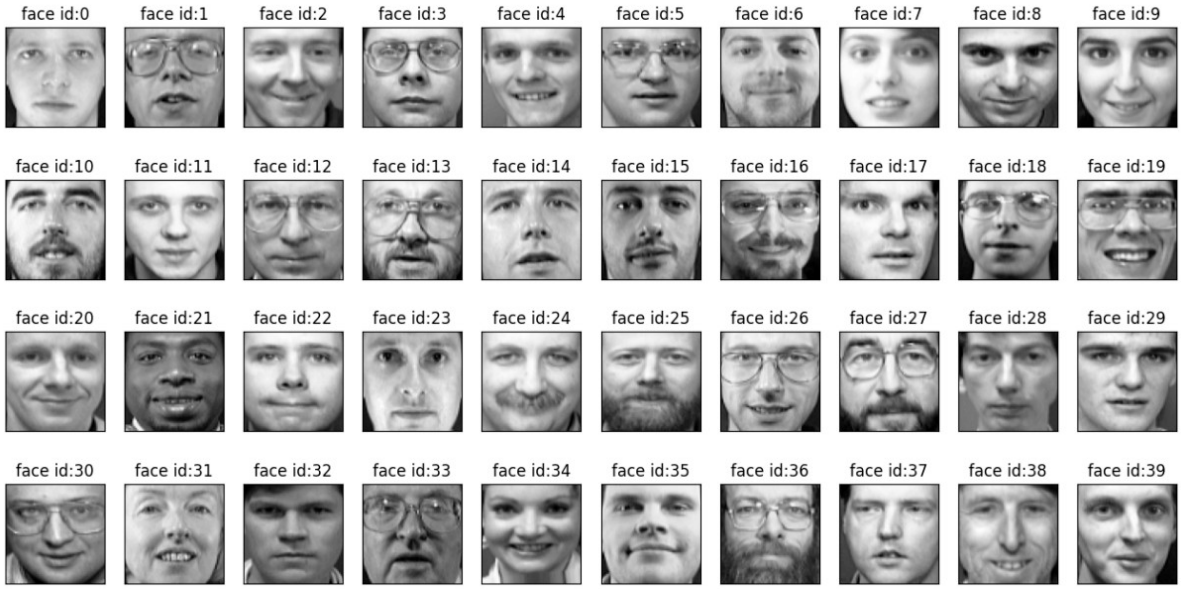

Выведем все десять фотографий первых трех людей.

```
rows, cols = 3, 10
fig, ax=plt.subplots(rows, cols, figsize=(16,6))

for i in range(rows):
  for j in range(cols):
    image_index=i*10 + j
    ax[i,j].imshow(images[image_index], cmap='gray')
    ax[i,j].axis('off')
    ax[i,j].set_title(f'face id:{i}')

plt.tight_layout()
plt.show()
```

Поставим перед алгоритмом две задачи:

1. распознать лицо человека, чьи фотогорафии содежатся в обучающей выборке; а также
2. попробовать найти лицо человека, фотографий которого в выборке нет.

Для этого разделим данные таким образом, чтобы последняя (десятая) фотография человека с id 38 и все десять изображений человека с id 39 оказались в обучающей выборке.

Другими словами, поместим первые 389 изображений в обучающую выборку, а оставшиеся 11 в тестовую.

```
X_train, y_train, images_train = X[:389], y[:389], images[:389]
X_train.shape, y_train.shape, images_train.shape
```

```
((389, 4096), (389,), (389, 64, 64))
```

```
X_test, y_test, images_test = X[-11:], y[-11:], images[-11:]
X_test.shape, y_test.shape, images_test.shape
```

```
((11, 4096), (11,), (11, 64, 64))
```

```
np.unique(y_test, return_counts=True)
```

```
(array([38, 39]), array([ 1, 10]))
```

Посмотрим на фотографию человека, присутствующего в обучающей выборке (in-train-sample), и человека, не содержащегося в ней (out-of-train-sample) лиц.

```
fig = plt.figure(figsize = (3,2))
fig.suptitle('Test dataset', size=11, weight='bold')
ax1 = fig.add_subplot(121)
ax1.set_title(f'Face id: {y_test[0]} \n In-train-sample', {'fontsize'
ax1.imshow(images_test[0], cmap='gray')
ax1.axis('off')
```

```
ax2 = fig.add_subplot(122)
ax2.set_title(f'Face id: {y_test[1]} \n Out-of-train-sample', {'fontsi
ax2.imshow(images_test[1], cmap='gray')
ax2.axis('off')
plt.tight_layout()
plt.show()
```

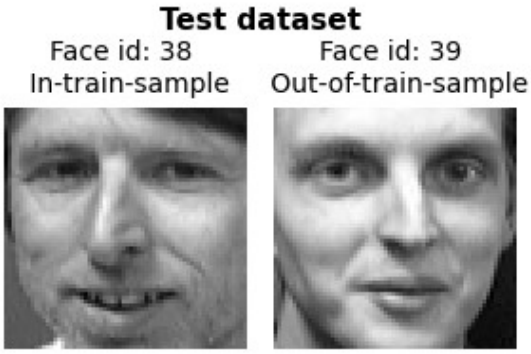


```
# также сохраним в переменную размерность изображения
faceshape = images_train[0].shape
faceshape
```

```
(64, 64)
```

Нахождение собственных лиц

Вначале вычислим «среднее лицо».

```
mean = np.mean(X_train, axis=0)
mean.shape
```

```
(4096,)
```

```
plt.figure(figsize=(2,2))
plt.imshow(mean.reshape(faceshape), cmap='gray')
plt.title('Mean face', size=10)
plt.axis('off')
plt.show()
```

Теперь, поскольку $d >> n$, найдем собственные векторы $\mathbf{X}\mathbf{X}^\top$, а затем преобразуем в собственные векторы $\mathbf{X}^\top\mathbf{X}$, умножив на $\mathbf{X}^\top$.

```
X_centered = X_train - mean
covariance_matrix = (X_centered @ X_centered.T) / (X_centered.shape[0]
covariance_matrix.shape
```

```
(389, 389)
```

```
eigenvalues, eigenvectors = np.linalg.eig(covariance_matrix)
idxs = np.argsort(eigenvalues)[::-1]
eigenvalues = eigenvalues[idxs]
eigenvectors = eigenvectors[:,idxs]
eigenvectors_converted = X_centered.T @ eigenvectors
eigenvectors_converted.shape
```

```
(4096, 389)
```

Не забудем нормализовать собственные векторы $\mathbf{X}^\top\mathbf{X}$.

```
eigenvectors_converted = eigenvectors_converted.T / np.sqrt((eigenvect
eigenvectors_converted.shape
```

```
(389, 4096)
```

Объясненная дисперсия

Найдем количество компонент, которые объясняют не менее 90% дисперсии.

```
total = sum(eigenvalues)

# найдем долю дисперсии, объясненную каждым из собственных значений
explained_variance = [(i / total) * 100 for i in eigenvalues]
explained_variance = np.round(explained_variance, 2)

# вычислим кумулятивную дисперсию первых n собственных значений
cumulative_explained_variance = np.cumsum(explained_variance)

# найдем количество компонент, которые объясняют не менее 90% дисперси
variance_threshold = 90
n_components = np.argwhere(cumulative_explained_variance >=
                           variance_threshold).min()+1
print(n_components)
```

```
66
```

Посмотрим на результат на графике.

```
plt.plot(cumulative_explained_variance)
plt.plot(n_components, variance_threshold, 'o', color='r')
plt.axhline(y=variance_threshold, xmax=0.2, linestyle='--', color='r')
plt.axvline(x=n_components, ymax=0.84, linestyle='--', color='r')
plt.text(0.5, 93, '90% explained \n variance', color='red')
plt.xlabel('Number of Dimensions')
plt.ylabel('Cumulative Explained Variance')
plt.show()
```

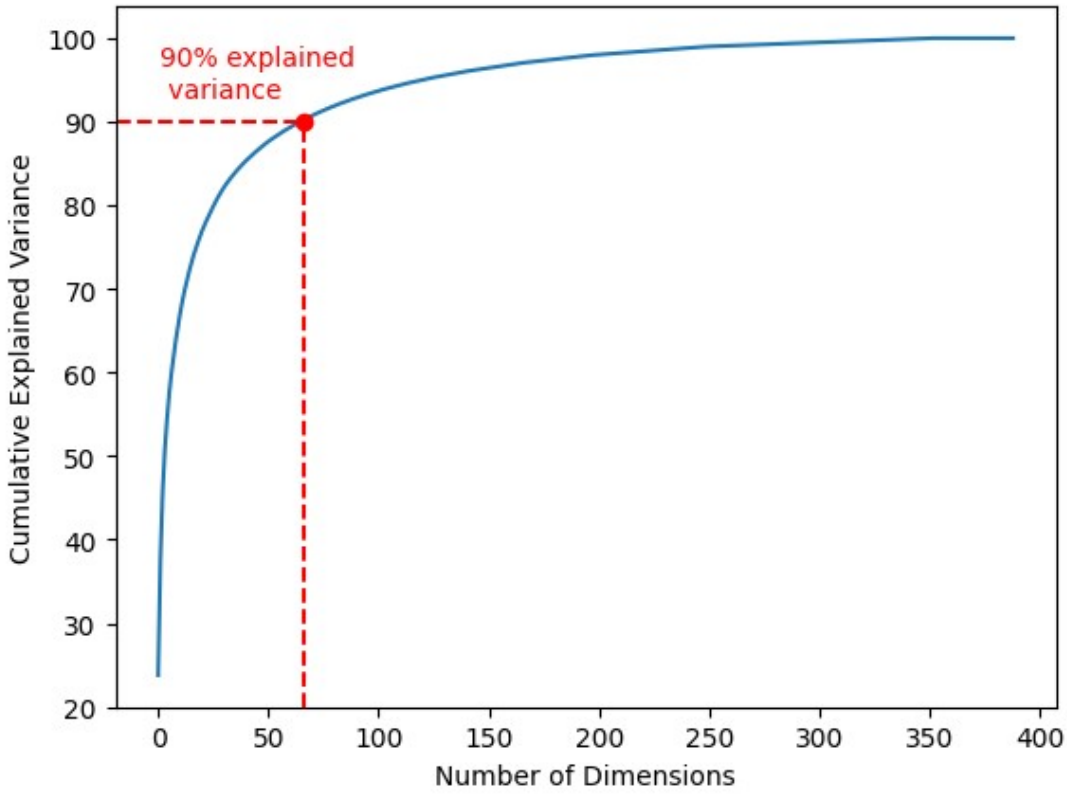

Оставленные компоненты и будут собственными лицами (eigenfaces) $\mathbf{W}$.

```
eigenfaces = eigenvectors_converted[:n_components]
eigenfaces.shape
```

```
(66, 4096)
```

Посмотрим на первые девять собственных лиц.

```
fig, axes = plt.subplots(3,3,figsize=(5,5))
for i in range(9):
  axes[i%3][i//3].imshow(eigenfaces[i].reshape(faceshape), cmap='gray'
  axes[i%3][i//3].axis('off')
plt.tight_layout()
```

```
plt.show()
```

С помощью $\mathbf{W}$ выполним проекцию $\mathbf{X}$ на пространство меньшей размерности и найдем коэффициенты (веса) $\mathbf{\Omega}$.

```
weights = eigenfaces @ (X_train - mean).T
weights.shape
```

```
(66, 389)
```

Распознавание лиц

Возьмем первое тестовое изображение. Напомню, это человек с id 38, другие изображения которого *есть* в обучающей выборке (**in-train-sample**).

```
X_test[0].shape
```

```
(4096,)
```

```
in_sample_query = X_test[0].reshape(1,-1)
```

```
in_sample_query_weight = eigenfaces @ (in_sample_query - mean).T
euclidean_distance = np.linalg.norm(weights - in_sample_query_weight,
in_sample_best_match = np.argmin(euclidean_distance)
print(in_sample_best_match)
```

```
385
```

```
fig = plt.figure(figsize = (4,3))
fig.suptitle('In-train-sample match', size = 10, weight='bold')
ax1 = fig.add_subplot(121)
ax1.set_title(f'Face id: {y_test[0]} \n In-train-sample', {'fontsize'
ax1.imshow(images_test[0], cmap='gray')
ax1.axis('off')
ax2 = fig.add_subplot(122)
ax2.set_title(f'Face id: {y_train[in_sample_best_match]} \n Best match
ax2.imshow(images_train[in_sample_best_match], cmap='gray')
ax2.axis('off')
plt.tight_layout()
plt.show()
```

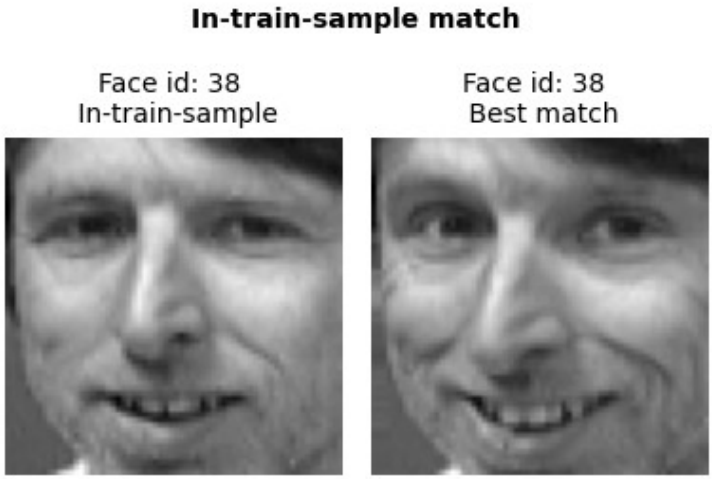

Алгоритм отработал верно. Теперь попробуем найти в обучающей выборке изображение лица человека, фотографий которого там *нет* (**out-of-train-sample**).

```
out_of_sample_query = X_test[1].reshape(1,-1)
out_of_sample_query_weight = eigenfaces @ (out_of_sample_query - mean)
euclidean_distance = np.linalg.norm(weights - out_of_sample_query_weig
out_of_sample_best_match = np.argmin(euclidean_distance)
print(out_of_sample_best_match)
```

```
89
```

```
fig = plt.figure(figsize = (4,3))
fig.suptitle('Out-of-train-sample match', size = 10, weight='bold')
ax1 = fig.add_subplot(121)
```

```
ax1.set_title(f'Face id: {y_test[1]} \n Out-of-train-sample', {'fontsi
ax1.imshow(images_test[1], cmap='gray')
ax1.axis('off')
ax2 = fig.add_subplot(122)
ax2.set_title(f'Face id: {y_train[out_of_sample_best_match]} \n Best m
ax2.imshow(images_train[out_of_sample_best_match], cmap='gray')
ax2.axis('off')
plt.tight_layout()
plt.show()
```

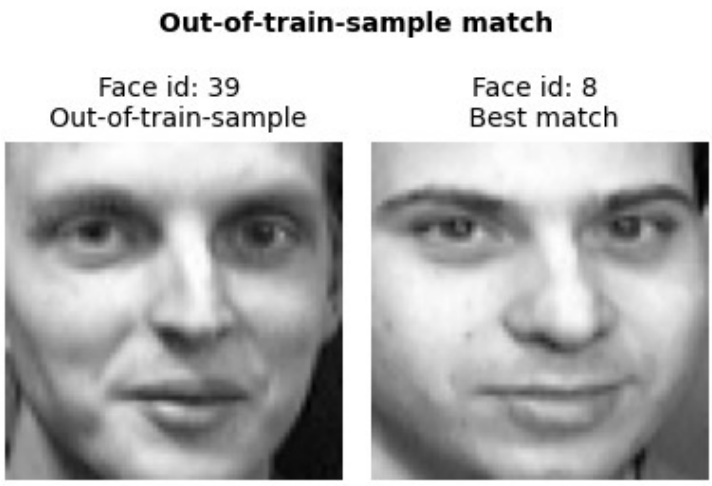

Ожидаемо, найти фотографию этого человека в обучающей выборке не удалось. Вместе с тем можно заметить определенное сходство предложенного алгоритмом изображения с исходным.