Проверка градиента

При нахождении частных производных нейросети несложно допустить ошибку. Одновременно, в силу сложности алгоритма, даже в этом случае модель может по-прежнему выдавать достаточно хороший результат.

Оценить правильность расчета частных производных можно с помощью метода **проверки градиента** (gradient checking).

Основная идея

Основная идея заключается в том, что (1) значение градиента, рассчитанное нейросетью в процессе обратного распространения ошибки при некоторых весах θ, должно примерно соответствовать (2) его численной оценке в этой точке.

$$\nabla J(\theta) \approx \frac{J(\theta + \varepsilon) - J(\theta - \varepsilon)}{2\varepsilon}$$

Начнем разбирать это выражение.

Значение градиента

Первый компонент, значение градиента, найти не сложно:

- необходимо задать некоторые веса θ;
- рассчитать уровень ошибки через прямое распространение; и
- найти производные относительно каждого θ всех слоев нейросети.

Другими словами выполнить одну эпоху обучения нейросети, но только не обновлять веса θ, а ограничиться расчетом градиента.

$$\theta_j := \theta_j - \alpha \nabla J(\theta)$$

Численная оценка градиента

Второй компонент, численная оценка градиента, есть не что иное, как значение градиента, рассчитанное через отношение приращений.

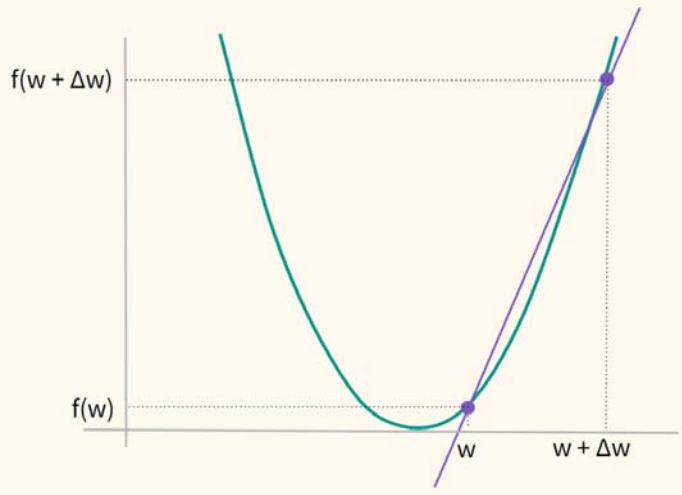

Вспомним, что при стремлении Δw к нулю, мы получим точное значение производной в точке w.

$$f'(w) = \lim_{\Delta w \to 0} \frac{f(w + \Delta w) - f(w)}{\Delta w}$$

Конечно, компьютер не позволит нам бесконечно уменьшать значение Δw, однако мы можем положить это значение очень малым, и тогда численная (то есть найденная с помощью компьютера) оценка должна быть примерно равна значению производной.

$$f'(w) \approx \frac{f(w + \Delta w) - f(w)}{\Delta w}$$

Заменим Δw на ε, а w на θ для сохранения предложенной выше нотации. Кроме того, будем брать точку для расчета секущей линии не с одной стороны (one-sided) от параметра, а с двух (two-sided) на расстоянии $\pm\varepsilon$ от θ.

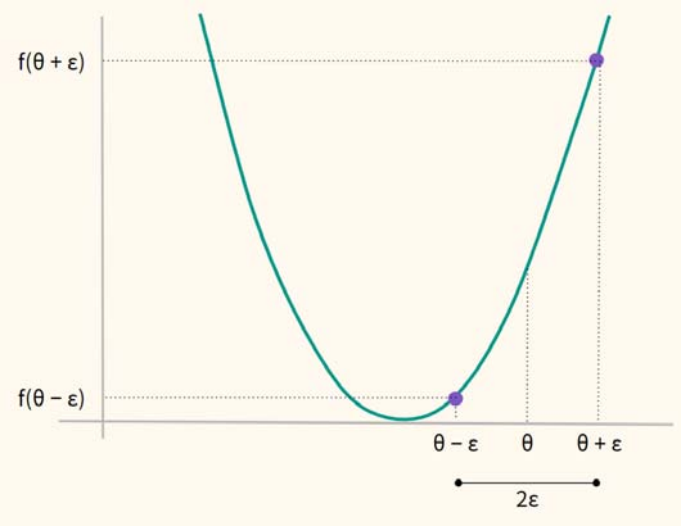

Так мы получим,

$$f'(\theta) \approx \frac{f(\theta + \varepsilon) - f(\theta - \varepsilon)}{2\varepsilon}$$

Если выданное нейросетью значение градиента совпадет в пределах некоторого небольшого порога с его численной оценкой, значит обратное распространение работает правильно.

Откроем блокнот к этому занятию

Простые примеры

Один параметр

Вначале приведем простой пример с одним параметром. Рассмотрим следующую функцию потерь.

$$f(\theta) = \theta^2$$

```
def f(theta):
  return theta ** 2
```

Производная этой функции равна $f'(\theta) = 2\theta$.

```
def derivative(theta):
  return 2 * theta
```

Положим $\theta = 3$ и найдем значение производной в этой точке.

$$f'(3) = 2 \cdot 3 = 6$$

```
theta = 3
deriv = derivative(3)
deriv
```

```
6
```

Это первый компонент. Теперь выполним численную оценку производной в этой же точке, положив $\varepsilon = 1\text{e}{-7}$.

$$f'_{\text{numeric}} = \frac{f(\theta + \varepsilon) - f(\theta - \varepsilon)}{2\varepsilon} =$$

$$\frac{f(3 + 1\text{e}{-7}) - f(3 - 1\text{e}{-7})}{2 \cdot 1\text{e}{-7}} \approx 5{,}999999$$

```
eps = 1e-7
```

```
derivNumeric = (f(theta + eps) - f(theta - eps)) / (2 * eps)
derivNumeric
```

```
5.999999990180527
```

Если разница между значением производной и ее численной оценкой меньше, чем ε, то можно считать, что производная взята верно.

```
deriv - derivNumeric, deriv - derivNumeric < eps
```

```
(9.819473234529141e-09, True)
```

Два параметра

Рассмотрим функцию потерь с двумя параметрами

$$f(\theta_1, \theta_2) = \theta_1^2 + \theta_2^2$$

```
def f(theta1, theta2):
  return theta1 ** 2 + theta2 ** 2
```

и соответствующими частными производными

$$\frac{\partial}{\partial \theta_1} f(\theta_1, \theta_2) = 2\theta_1, \quad \frac{\partial}{\partial \theta_2} f(\theta_1, \theta_2) = 2\theta_2$$

```
def partial1(theta1):
  return 2 * theta1
```

```
def partial2(theta2):
  return 2 * theta2
```

Найдем значение градиента в точке $(3, 4)$.

$$\nabla f(3, 4) = \begin{bmatrix} \frac{\partial}{\partial \theta_1} \\ \frac{\partial}{\partial \theta_1} \end{bmatrix} f(3, 4) = \begin{bmatrix} 2 \cdot 3 \\ 2 \cdot 4 \end{bmatrix} = \begin{bmatrix} 6 \\ 8 \end{bmatrix}$$

```
theta1, theta2 = 3, 4
grad = np.array([partial2(theta1), partial2(theta2)])
grad
```

```
array([6, 8])
```

Численную оценку при этом будем проводить, находя отношение приращений отдельно по каждому измерению

$$\frac{\partial}{\partial \theta_1} f(\theta_1, \theta_2) \approx \frac{f(\theta_1 + \varepsilon, \theta_2) - (\theta_1 - \varepsilon, \theta_2)}{2\varepsilon}$$

$$\frac{\partial}{\partial \theta_2} f(\theta_1, \theta_2) \approx \frac{f(\theta_1, \theta_2 + \varepsilon) - (\theta_1, \theta_2 - \varepsilon)}{2\varepsilon}$$

```
partial1Numeric = (f(theta1 + eps, theta2) - f(theta1 - eps, theta2)) / (2 * eps)
partial2Numeric = (f(theta1, theta2 + eps) - f(theta1, theta2 - eps)) / (2 * eps)

gradNumeric = np.array([partial1Numeric, partial1Numeric])
gradNumeric
```

```
array([5.99999998, 8.        ])
```

Оценим разницу между значением градиента и его численной оценкой по формуле

$$\text{difference} = \frac{||\nabla f(\theta)_{\text{numeric}} - \nabla f(\theta)||_2}{||\nabla f(\theta)_{\text{numeric}}||_2 + ||\nabla f(\theta)||_2}$$

В числителе мы находим евклидово расстояние разницы между фактическим градиентом и его численной оценкой, а в знаменателе нормализуем эту разницу на сумму длин соответствующих векторов.

```
numerator = np.linalg.norm(grad - gradNumeric)
denominator = np.linalg.norm(grad) + np.linalg.norm(gradNumeric)
difference = numerator / denominator
difference, difference < eps
```

```
(9.637876920383396e-10, True)
```

Перейдем к проверке частных производных нейросети.

Проверка градиента нейросети

Для проверки градиента нейросети необходимо сравнить фактическое значение частной производной каждого из θ_j параметров с соответствующей численной оценкой.

$$
\begin{aligned}
\frac{\partial}{\partial\theta_1}J(\theta) &\approx \frac{J(\theta_1+\varepsilon,\theta_2,\theta_3,\ldots,\theta_j)-J(\theta_1-\varepsilon,\theta_2,\theta_3,\ldots,\theta_j)}{2\varepsilon}\\
\frac{\partial}{\partial\theta_2}J(\theta) &\approx \frac{J(\theta_1,\theta_2+\varepsilon,\theta_3,\ldots,\theta_j)-J(\theta_1,\theta_2-\varepsilon,\theta_3,\ldots,\theta_j)}{2\varepsilon}\\
\frac{\partial}{\partial\theta_3}J(\theta) &\approx \frac{J(\theta_1,\theta_2,\theta_3+\varepsilon,\ldots,\theta_j)-J(\theta_1,\theta_2,\theta_3-\varepsilon,\ldots,\theta_j)}{2\varepsilon}\\
\ldots & \qquad \ldots\\
\frac{\partial}{\partial\theta_j}J(\theta) &\approx \frac{J(\theta_1,\theta_2,\theta_3,\ldots,\theta_j+\varepsilon)-J(\theta_1,\theta_2,\theta_3,\ldots,\theta_j-\varepsilon)}{2\varepsilon}
\end{aligned}
$$

Технически нам нужно будет сформировать два вектора, $\nabla J(\theta)$ и $\nabla_{\text{numeric}}J(\theta)$ и сравнить их через нормализованное евклидово расстояние.

Подготовка данных

В первую очередь подготовим данные. Возьмем небольшой датасет о вине из библиотеки sklearn, поскольку проверка градиета является вычислительно затратной операцией и, например, на данных MNIST будет выполняться очень долго.

```
# возьмем функцию для one-hot encoding
def ohe(y):
  examples, features = y.shape[0], len(np.unique(y))
  zeros_matrix = np.zeros((examples, features))
  for i, (row, digit) in enumerate(zip(zeros_matrix, y)):
    zeros_matrix[i][digit] = 1

  return zeros_matrix
```

```
# подгрузим данные
data = load_wine()

# сформируем две матрицы Numpy, в которых наблюдения будут столбцами
X = pd.DataFrame(data.data, columns = data.feature_names)
X = ((X - X.mean())/X.std()).values.T
y = data.target
y_enc = ohe(y).T

X.shape, y_enc.shap
```

```
((13, 178), (3, 178))
```

Как мы видим, у нас будет 13 признаков, 178 наблюдений и 3 класса целевой переменной.

Архитектура сети

Проверим градиент нейросети, которую мы создали в конце основного занятия с тем отличием, что

- мы уменьшим количество нейронов входного слоя до 13-ти (вместо 784 пикселей картинок MNIST);
- выходной слой будет состоять из трех нейронов по числу классов целевой переменной;

- два скрытых слоя будут содержать не 64, а 16 нейронов.

При этом функции активации (сигмоиду и softmax), а также функция потерь (категориальная кросс-энтропия) сохранятся и в текущей архитектуре. Кроме этого, сохраним смещение.

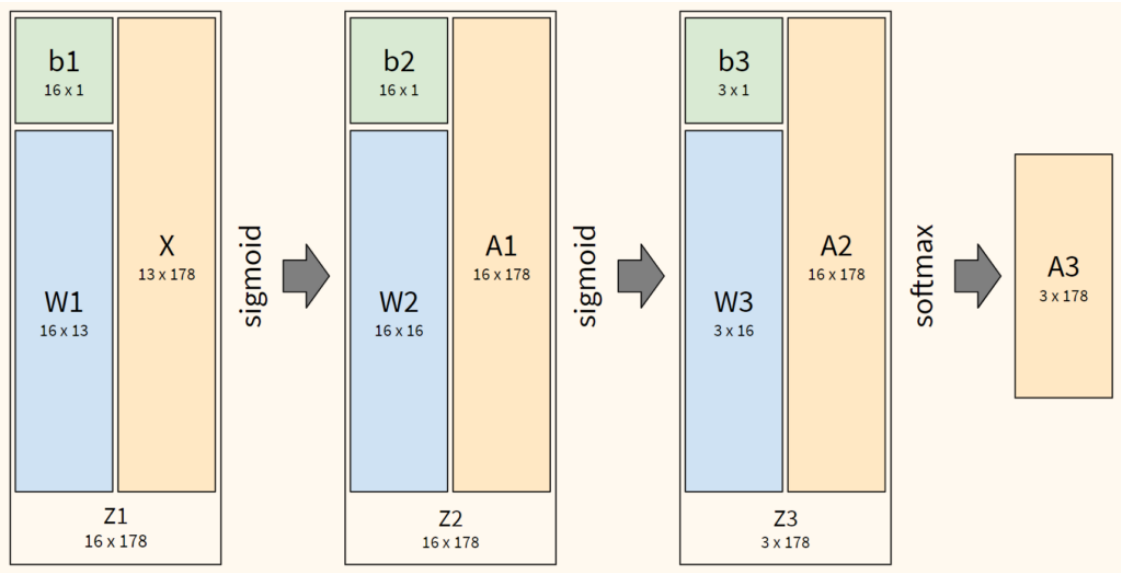

Примечание. Обратите внимание, по сравнению с предыдущими архитектурами, мы перестали называть входящий слой (данные) $A^{(1)}$ и просто сохраним обозначение X (подобную замену мы делали для единообразия нотации и наглядности).

```
# в частности в коде исчезла вот эта строчка
A1 = X
```

Таким образом, индексы активационных слоев сместятся на один вперед.

В результате предложенных изменений частные производные останутся прежними. Сократится лишь количество весов. Если в архитектуре нейросети для MNIST у нас было

$$\underbrace{64 \cdot 784}_{W^{(1)}} + \underbrace{64 \cdot 1}_{b^{(1)}} + \underbrace{64 \cdot 64}_{W^{(2)}} + \underbrace{64 \cdot 1}_{b^{(2)}} + \underbrace{10 \cdot 64}_{W^{(3)}} + \underbrace{10 \cdot 1}_{b^{(3)}} = 55050$$

параметров, то благодаря предложенным изменениям их останется только

$$16 \cdot 13 + 16 \cdot 1 + 16 \cdot 16 + 16 \cdot 1 + 3 \cdot 16 + 3 \cdot 1 = 547$$

Это существенно ускорит выполнение кода.

Необходимые функции

Объявим необходимые для данной архитектуры функции.

Служебные функции

Начнем с функций активации, а также целевой функции.

```
def sigmoid(z):
  s = 1 / (1 + np.exp(-z))
```

```
  return s

def softmax(z):
  z = z - np.max(z, axis = 0, keepdims = True)
  numerator = np.exp(z)
  denominator = np.sum(numerator, axis = 0, keepdims = True)
  softmax = numerator / denominator
  return softmax

def cross_entropy(probs, y_enc, epsilon = 1e-9):
  n = probs.shape[1]
  ce = -np.sum(y_enc * np.log(probs + epsilon)) / n

  return ce
```

Кроме этого, поместим в отдельные функции код

- инициализации параметров;
- прямого; и
- обратного распространения.

Инициализация параметров

Функция инициализации параметров на вход примет данные и точку отсчета для повторимости результата, а на выходе выдаст словарь из весов $W^{(1)}, W^{(2)}, W^{(3)}$ и смещений $b^{(1)}, b^{(2)}, b^{(3)}$.

```
def initialize(x, y, random_state = 42):

  np.random.seed(random_state)

  parameters = {}

  parameters['W1'] = np.random.randn(16, x.shape[0])
  parameters['b1'] = np.random.randn(16, 1)

  parameters['W2'] = np.random.randn(16, 16)
  parameters['b2'] = np.random.randn(16, 1)

  parameters['W3'] = np.random.randn(y.shape[0], 16)
  parameters['b3'] = np.random.randn(y.shape[0], 1)

  return parameters
```

Прямое и обратное распространение

После этого,

- функция прямого распространения один раз получит случайные начальные параметры от функции инициализации; а затем
- в цикле:
  - будет взаимодействовать с функцией обратного распространения через кортеж параметров и значений активационных функций cache;
  - функция же обратного распространения будет выдавать словарь обновленных

параметров, которые станут новыми входными данными прямого распространения на следующей эпохе.

Дополнительно, функция прямого распространения будет выдавать уровень ошибки, а обратного — словарь со значениями текущих частных производных $\frac{\partial J}{\partial W^{(1)}}$, $\frac{\partial J}{\partial W^{(2)}}$, $\frac{\partial J}{\partial W^{(3)}}$ и $\frac{\partial J}{\partial b^{(1)}}$, $\frac{\partial J}{\partial b^{(2)}}$, $\frac{\partial J}{\partial b^{(3)}}$. Они понадобятся для выполнения проверки градиента.

```python
def forward(x, y, parameters):

  n = x.shape[1]

  W1 = parameters['W1']
  b1 = parameters['b1']
  W2 = parameters['W2']
  b2 = parameters['b2']
  W3 = parameters['W3']
  b3 = parameters['b3']

  Z1 = np.dot(W1, x) + b1
  A1 = sigmoid(Z1)

  Z2 = np.dot(W2, A1) + b2
  A2 = sigmoid(Z2)

  Z3 = np.dot(W3, A2) + b3
  A3 = softmax(Z3)

  loss = cross_entropy(A3, y)

  cache = (A1, W1, b1, A2, W2, b2, A3, W3, b3)

  return loss, cache
```

```python
def backward(x, y, cache, lr = 0.1):

  (A1, W1, b1, A2, W2, b2, A3, W3, b3) = cache

  n = x.shape[1]

  W3_delta = A3 - y
  W2_delta = np.dot(W3.T, W3_delta) * A2 * (1 - A2)
  W1_delta = np.dot(W2.T, W2_delta) * A1 * (1 - A1)

  W3_derivative = np.dot(W3_delta, A2.T) / n
  b3_derivative = np.sum(W3_delta, axis = 1, keepdims = True) / n

  W2_derivative = np.dot(W2_delta, A1.T) / n
  b2_derivative = np.sum(W2_delta, axis = 1, keepdims = True) / n

  W1_derivative = np.dot(W1_delta, x.T) / n
```

```
  b1_derivative = np.sum(W1_delta, axis = 1, keepdims = True) / n

  parameters = {}

  parameters['W3'] = W3 - lr * W3_derivative
  parameters['b3'] = b3 - lr * b3_derivative
  parameters['W2'] = W2 - lr * W2_derivative
  parameters['b2'] = b2 - lr * b2_derivative
  parameters['W1'] = W1 - lr * W1_derivative
  parameters['b1'] = b1 - lr * b1_derivative

  gradients = {}

  gradients['dW3'] = W3_derivative
  gradients['db3'] = b3_derivative
  gradients['dW2'] = W2_derivative
  gradients['db2'] = b2_derivative
  gradients['dW1'] = W1_derivative
  gradients['db1'] = b1_derivative

  return parameters, gradients
```

Обучение и прогноз

Обучим модель, сделаем прогноз (пока без проверки градиента) и оценим его качество.

```
def fit_nn(x, y, epochs = 1000, lr = 0.1):

  parameters = initialize(x, y)
  loss_history = []

  for i in range(epochs):

    loss, cache = forward(x, y, parameters)
    # функция backward() выдает два словаря: parameters и gradients
    # словарь gradients пока не нужен, и мы оставляем _
    parameters, _ = backward(x, y, cache, lr)

    if i % (epochs / 5) == 0:
      print('Эпоха:', i)
      print('Ошибка:', loss)
      print('-----------------------')

    loss_history.append(loss)

  print('Итоговая ошибка', loss)
  print('Нейросеть успешно обучена')

  return parameters, loss_history
```

```
def predict_nn(x, y, parameters):

  W1 = parameters['W1']
  b1 = parameters['b1']
  W2 = parameters['W2']
  b2 = parameters['b2']
  W3 = parameters['W3']
  b3 = parameters['b3']

  Z1 = np.dot(W1, x) + b1
  A1 = sigmoid(Z1)
  Z2 = np.dot(W2, A1) + b2
  A2 = sigmoid(Z2)
```

```
    Z3 = np.dot(W3, A2) + b3
    A3 = softmax(Z3)

    return np.argmax(A3, axis = 0)
```

```
params, l_history = fit_nn(X, y_enc, epochs = 2000, lr = 0.05)
```

```
Эпоха: 0
Ошибка: 2.688947392020406
-----------------------
Эпоха: 400
Ошибка: 0.12260412116100283
-----------------------
Эпоха: 800
Ошибка: 0.06027754882884962
-----------------------
Эпоха: 1200
Ошибка: 0.03802885456674395
-----------------------
Эпоха: 1600
Ошибка: 0.02675376526940447
-----------------------
Итоговая ошибка 0.020180935722946634
Нейросеть успешно обучена
```

```
plt.plot(l_history)
plt.title('Loss history')
plt.xlabel('loss')
plt.ylabel('iterations');
```

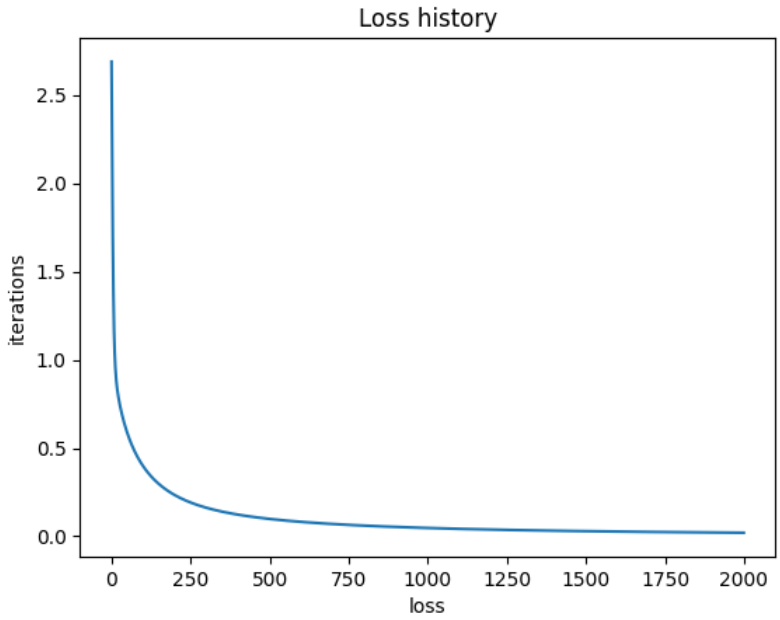


```
y_pred = predict_nn(X, y_enc, params)
accuracy_score(y, y_pred)
```

```
1.0
```

Перейдем к проверке градиента этой нейросети.

Проверка градиента после инициализации

Вначале сравним фактические градиенты с их численной оценкой сразу после инициализации параметров. Для этого сделаем следующее:

1. инициализируем параметры и поместим их в словарь;
2. найдем фактические значения градиентов при этих параметрах,
   - получив их из функции обратного распространения; и
   - преобразовав словарь в длинный вектор из 547 градиентов;
3. выполним численную оценку градиента для каждого из параметров, для чего
   - сформируем вектор из 547 параметров;
   - в цикле пройдемся по каждому из этих параметров и численно оценим соответствующую частную производную через $\frac{J(\theta_j+\varepsilon)-J(\theta_j-\varepsilon)}{2\varepsilon}$; и
   - сформируем вектор из 547 численных оценок градиентов; наконец
4. сравним фактические градиенты с их численной оценкой через нормализованное евклидово расстояние.

Переход от словаря к вектору и обратно

Словарь градиентов в вектор

Во втором пункте приведенной выше последовательности шагов нам нужно преобразовать словарь с ключами dW1, db1, dW2, db2, dW3, db3 в вектор размерностью (547, 1).

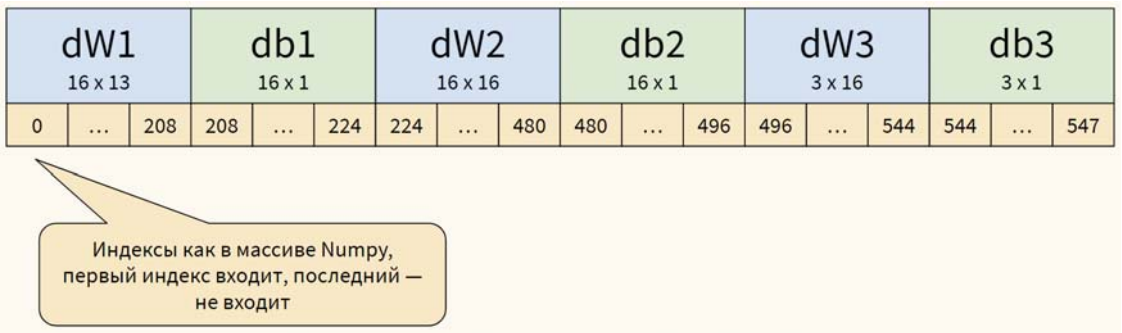

Для этого, в цикле пройдемся по ключам словаря градиентов, «вытянем» соответствующие матрицы значений и соединим их через **функцию np.concatenate()**.

```
# на вход функция примет словарь градиентов и
def gradients_to_vector(gradients):

  # создаст массив из "вытянутых" значений словаря
  return np.concatenate([np.reshape(gradients[key], (-1,1)) for key in ['dW1', 'db1', '
```

Словарь параметров в вектор

Третий пункт предполагает, что мы аналогичным образом преобразуем словарь параметров в вектор.

```
def dictionary_to_vector(parameters):
  return np.concatenate([np.reshape(parameters[key], (-1,1)) for key in ['W1', 'b1', 'W
```

Вектор параметров в словарь

Наконец в том же третьем пункте для того, чтобы рассчитать $J(\theta_j + \varepsilon)$ и $J(\theta_j - \varepsilon)$ нам необходимо поместить в словарь векторы $\theta_j + \varepsilon$ и $\theta_j + \varepsilon$ размерностью (547, 1) перед их «отправкой» в функцию прямого распространения.

0	…	208	208	…	224	224	…	480	480	…	496	496	…	544	544	…	547
W1 16 x 13			b1 16 x 1			W2 16 x 16			b2 16 x 1			W3 3 x 16			b3 3 x 1		

```
def vector_to_dictionary(theta):

  parameters = {}

  parameters['W1'] = theta[:208].reshape((16,13))
  parameters['b1'] = theta[208:224].reshape((16,1))
  parameters['W2'] = theta[224:480].reshape((16,16))
  parameters['b2'] = theta[480:496].reshape((16,1))
  parameters['W3'] = theta[496:544].reshape((3,16))
  parameters['b3'] = theta[544:547].reshape((3,1))

  return parameters
```

Примечание. Мы могли бы автоматизировать расчет индексов, однако в учебных целях пропишем индексы каждого из параметров вручную.

Перейдем непосредственно к проверке градиента.

Инициализация параметров

Выполним инициализацию параметров.

```
parameters = initialize(X, y_enc, random_state = 42)
```

Значение градиента

Найдем фактические значения градиентов при инициализированных параметрах и поместим их в вектор.

```
_, cache = forward(X, y_enc, parameters)
_, gradients = backward(X, y_enc, cache)

grad = gradients_to_vector(gradients)
grad.shape
```

```
(547, 1)
```

Численная оценка градиента

Выполним численную оценку градиентов. Преобразуем словарь параметров в вектор.

```
parameters_values = dictionary_to_vector(parameters)
parameters_values.shape
```

```
(547, 1)
```

Сохраним количество параметров, а также создадим нулевые векторы для $J(\theta_j + \varepsilon)$, $J(\theta_j - \varepsilon)$ и $\nabla_{\text{numeric}} J(\theta)$. Не забудем про константу ε.

```
num_parameters = parameters_values.shape[0]

J_plus = np.zeros((num_parameters, 1))
J_minus = np.zeros((num_parameters, 1))

gradNumeric = np.zeros((num_parameters, 1))

epsilon = 1e-7
```

В цикле пройдем по каждому из 547 параметров и для каждого найдем численную оценку производной.

$$\frac{J(\theta_1+\varepsilon,\theta_2,\theta_3,...,\theta_{547})-J(\theta_1-\varepsilon,\theta_2,\theta_3,...,\theta_{547})}{2\varepsilon}$$
$$\frac{J(\theta_1,\theta_2+\varepsilon,\theta_3,...,\theta_{547})-J(\theta_1,\theta_2-\varepsilon,\theta_3,...,\theta_{547})}{2\varepsilon}$$
$$\frac{J(\theta_1,\theta_2,\theta_3+\varepsilon,...,\theta_{547})-J(\theta_1,\theta_2,\theta_3-\varepsilon,...,\theta_{547})}{2\varepsilon}$$
$$...$$
$$\frac{J(\theta_1,\theta_2,\theta_3,...,\theta_{547}+\varepsilon)-J(\theta_1,\theta_2,\theta_3,...,\theta_{547}-\varepsilon)}{2\varepsilon}$$

```
# будем брать по одному параметру j
for j in range(num_parameters):

  thetaplus = np.copy(parameters_values)
  # добавим epsilon к параметру j
  thetaplus[j][0] = thetaplus[j][0] + epsilon
  # найдем значение целевой функции J(theta) с учетом theta_j + epsilon
  J_plus[j], _ = forward(X, y_enc, vector_to_dictionary(thetaplus))

  thetaminus = np.copy(parameters_values)
  # вычтем epsilon из параметра j
  thetaminus[j][0] = thetaminus[j][0] - epsilon
  # найдем значение целевой функции J(theta) с учетом theta_j - epsilon
  J_minus[j], _ = forward(X, y_enc, vector_to_dictionary(thetaminus))

  # оценим частную производную для данного параметра j
  gradNumeric[j] = (J_plus[j] - J_minus[j]) / (2 * epsilon)
```

```
gradNumeric.shape
```

```
(547, 1)
```

Сравнение градиента с его оценкой

Осталось сравнить фактическое значение градиента с его численной оценкой.

```
numerator = np.linalg.norm(grad - gradNumeric)
denominator = np.linalg.norm(grad) + np.linalg.norm(gradNumeric)
difference = numerator / denominator
difference, difference < epsilon
```

```
(2.779329944458319e-08, True)
```

Поместим приведенный выше код проверки градиента в функции.

```
def gradient_vector(parameters, x, y):

  _, cache = forward(x, y, parameters)
  _, gradients = backward(x, y, cache)

  return gradients_to_vector(gradients)
```

```
def gradNumeric_vector(parameters, x, y, epsilon):

  parameters_values = dictionary_to_vector(parameters)
  num_parameters = parameters_values.shape[0]

  J_plus = np.zeros((num_parameters, 1))
  J_minus = np.zeros((num_parameters, 1))

  gradNumeric = np.zeros((num_parameters, 1))

  for j in range(num_parameters):

    thetaplus = np.copy(parameters_values)
    thetaplus[j][0] = thetaplus[j][0] + epsilon
    J_plus[j], _ = forward(X, y_enc, vector_to_dictionary(thetaplus))

    thetaminus = np.copy(parameters_values)
    thetaminus[j][0] = thetaminus[j][0] - epsilon
    J_minus[j], _ = forward(X, y_enc, vector_to_dictionary(thetaminus))

    gradNumeric[j] = (J_plus[j] - J_minus[j]) / (2 * epsilon)

  return gradNumeric
```

```
def difference(grad, gradNumeric):

  numerator = np.linalg.norm(grad - gradNumeric)
  denominator = np.linalg.norm(grad) + np.linalg.norm(gradNumeric)

  return numerator / denominator
```

```
def gradient_checking(x, y, random_state, epsilon = 1e-7):

  params = initialize(x, y, random_state)

  grad = gradient_vector(params, x, y)
  gradNumeric = gradNumeric_vector(params, x, y, epsilon)

  diff = difference(grad, gradNumeric)

  return diff, diff < epsilon
```

```
gradient_checking(X, y_enc, random_state = 42)
```

```
(2.779329944458319e-08, True)
```

Проверка градиента при обучении

Убедимся, что значение градиента совпадает с его численной оценкой не только при начальных весах, но и в целом в процессе обучения нейросети.

```
def fit_nn_with_gradcheck(x, y, epochs = 2000, lr = 0.05,
                          random_state = 42, epsilon = 1e-7):

  # инициализируем параметры
```

```python
  parameters = initialize(x, y, random_state)

  # в цикле
  for i in range(epochs):

    # сохраним текущие параметры (для проверки градиента)
    current_parameters = parameters.copy()

    # выполним прямое и
    loss, cache = forward(x, y, parameters)
    # обратное распространение, получив градиенты, а также
    # обновленные параметры (для дальнейшего обучения)
    parameters, gradients = backward(x, y, cache, lr)

    # периодически
    if i % (epochs / 5) == 0:
      print('Эпоха:', i)
      print('Ошибка:', loss)

      # создадим вектор градиентов, а также
      grad = gradients_to_vector(gradients)
      # вектор численной оценки градиентов на основе текущих параметров,
      gradNumeric = gradNumeric_vector(current_parameters, x, y, epsilon)
      # сравним эти векторы
      diff = difference(grad, gradNumeric)
      # и выведем результат сравнения
      print('Отклонение градиента:', diff)
      print('Проверка градиента пройдена:', diff < epsilon)
      print('-----------------------')

  print('Итоговая ошибка', loss)
  print('Нейросеть успешно обучена')

  return None
```

```python
fit_nn_with_gradcheck(X, y_enc)
```

```
Эпоха: 0
Ошибка: 2.688947392020406
Отклонение градиента: 2.779329944458319e-08
Проверка градиента пройдена: True
-----------------------
Эпоха: 400
Ошибка: 0.12260412116100283
Отклонение градиента: 1.402760136760584e-08
Проверка градиента пройдена: True
-----------------------
Эпоха: 800
Ошибка: 0.06027754882884962
Отклонение градиента: 1.815097040410587e-08
Проверка градиента пройдена: True
-----------------------
Эпоха: 1200
Ошибка: 0.03802885456674395
Отклонение градиента: 2.294359641688344e-08
Проверка градиента пройдена: True
-----------------------
Эпоха: 1600
Ошибка: 0.02675376526940447
Отклонение градиента: 2.861245060697362e-08
Проверка градиента пройдена: True
-----------------------
Итоговая ошибка 0.020180935722946634
Нейросеть успешно обучена
```

Проверки пройдены успешно.

Подведем итог

Выше мы рассмотрели метод проверки правильности расчета частных производных параметров нейросети.

При создании нейронных сетей с помощью библиотеки (Keras, Tensorflow, PyTorch), необходимость в проверке градиента отсутствует, однако умение провести такое сравнение градиента и его численной оценки дает лучшее понимание работы алгоритма.