Рекуррентная нейронная сеть

>

Во многих случаях прогнозирование некоторого значения, например, завтрашней цены на акцию или следующего слова в предложении зависит от того, какой была цена сегодня или, например, вчера, а в случае текста от того, какие слова стояли перед прогнозируемым словом.

Рекуррентная нейронная сеть (recurrent neural network, RNN) способна учитывать предыдущие наблюдения или, говоря иначе, работать с последовательностью (sequence) объектов.

Основная идея

Архитектура рекуррентной сети

Рассмотрим следующую задачу. Пусть нам известно, что завтрашняя $t+1$ цена на акцию компании зависит от ее стоимости сегодня t и вчера $t-1$.

Посмотрим, какая архитектура нейронной сети позволит учитывать эти изменения.

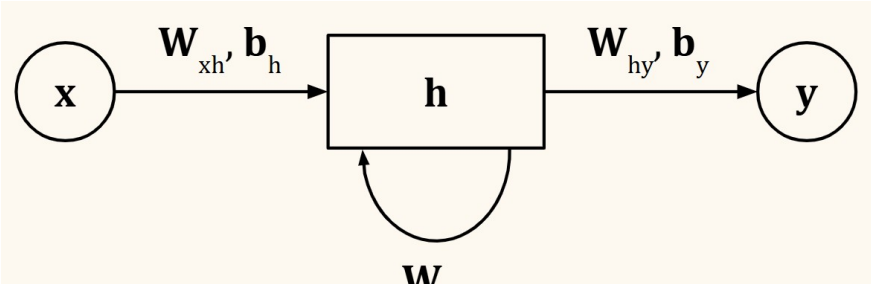

$\mathbf{W}_{hh}$

Нейросеть будет состоять из трех слоев: входного $\mathbf{x}$, скрытого $\mathbf{h}$ и выходного $\mathbf{y}$, при этом

- веса и смещение между входным и скрытым слоями обозначим как $\mathbf{W}_{xh}$ и $\mathbf{b}_h$ соответственно;
- веса и смещение между скрытым и выходным слоем как $\mathbf{W}_{hy}$ и $\mathbf{b}_y$; при этом
- в архитектуре рекуррентной нейронной сети появится еще один набор параметров $\mathbf{W}_{hh}$, который позволит учитывать предыдущие наблюдения при прогнозировании очередного значения.

Рассмотрим этот процесс пошагово. Будем подавать на вход сначала данные за вчера $\mathbf{x}^{t-1}$, умножать на веса входного слоя $\mathbf{W}_{xh}$, добавлять смещение $\mathbf{b}_h$ и пропускать эти значения через функцию активации φ.

Так мы получим значение скрытого слоя $\mathbf{h}^{t-1}$.

$$\mathbf{h}^{t-1} = \varphi(\mathbf{W}_{xh} \cdot \mathbf{x}^{t-1} + \mathbf{b}_h)$$

Дальше в случае полносвязной архитектуры мы могли бы умножить на веса $\mathbf{W}_{hy}$ и смещение $\mathbf{b}_y$ выходного слоя и получить прогнозное значение $\hat{\mathbf{y}}^t$.

$$\hat{\mathbf{y}}^t = \mathbf{W}_{hy} \cdot \mathbf{h}^{t-1} + \mathbf{b}_y$$

Прогноз был бы сделан на сегодня, однако эта цена на акцию нам уже известна. Нам лишь хотелось бы, чтобы цена за вчера была учтена в сегодняшнем прогнозе на завтра.

Для этого одновременно подадим значение за сегодня $\mathbf{x}^t$ и значение скрытого слоя на предыдущем шаге $\mathbf{h}^{t-1}$ в аналогичную архитектуру

$$\mathbf{h}^t = \varphi(\mathbf{W}_{xh} \cdot \mathbf{x}^t + \mathbf{W}_{hh} \cdot \mathbf{h}^{t-1} + \mathbf{b}_h)$$

и уже после этого рассчитаем прогнозное значение на завтра $\hat{\mathbf{y}}^{t+1}$.

$$\hat{\mathbf{y}}^{t+1} = \mathbf{W}_{hy} \cdot \mathbf{h}^t + \mathbf{b}_y$$

Таким образом, нам понадобится два «экземпляра» или две **ячейки** (cell) рекуррентной нейронной сети.

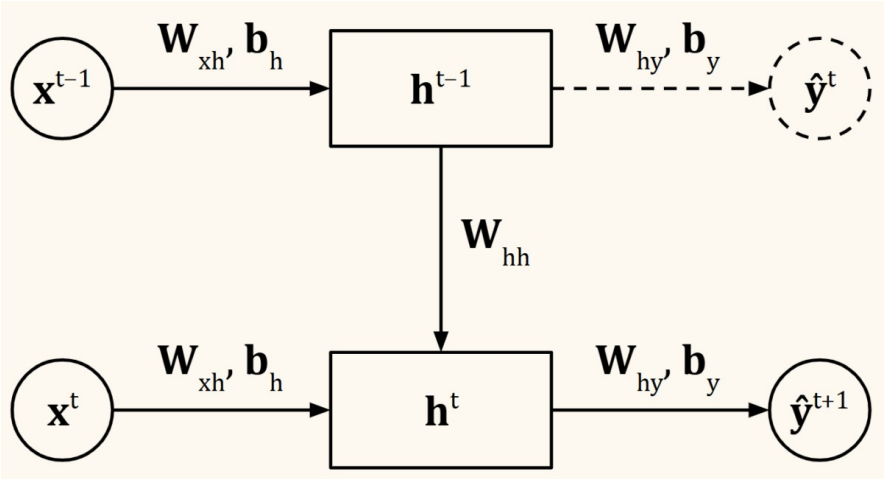

Заметим, что схема с петлей (loop), которую мы изобразили выше, как раз и указывает на возможность «развернуть» (unroll) эти ячейки.

Обратим внимание на два важных момента:

- параметры $\mathbf{W}_{xh}, \mathbf{b}_h, \mathbf{W}_{hh}, \mathbf{W}_{hy}, \mathbf{b}_y$ едины для всех шагов архитектуры;
- количество этих шагов может быть различным в зависимости от длины подаваемой последовательности (в коде мы будем разворачивать ячейки с помощью цикла for).

Вторая особенность позволяет подавать в нейросеть временные ряды, последовательности слов или, например, букв различной длины.

Типы архитектуры

Выше мы показали, что одна ячейка RNN может выдавать выходное значение $\mathbf{y}^t$ или не выдавать, в зависимости от того, нужен ли нам прогноз на этом шаге или нет.

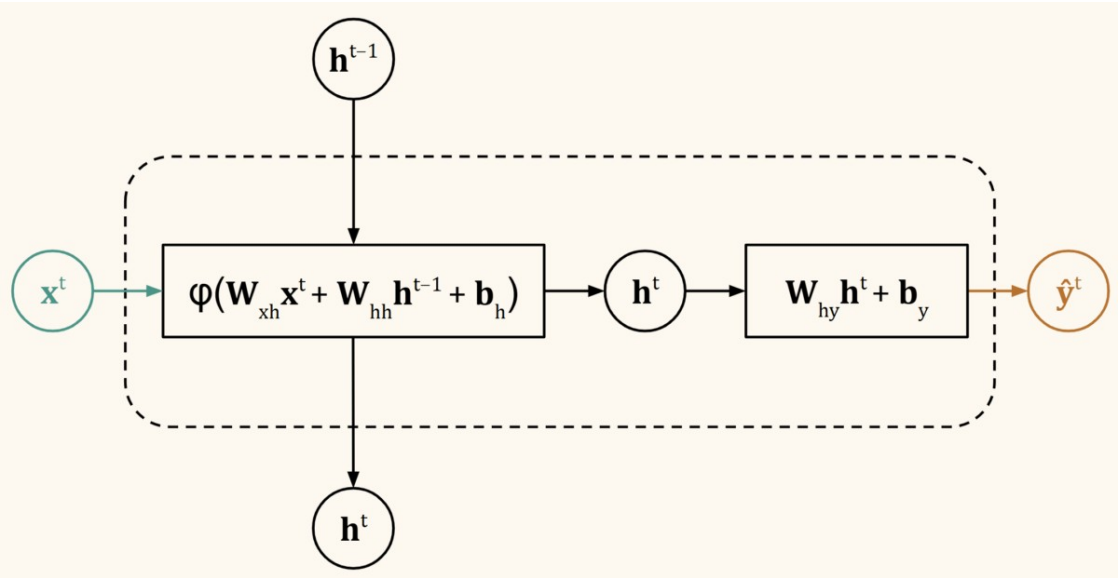

Примечание. Обратите внимание, мы изменили нотацию, сделав ее более универсальной. Теперь вход и выход на шаге t обозначаются как $\mathbf{x}^t$ и $\hat{\mathbf{y}}^t$.

Несложно представить, что в зависимости от того, сколько входов T_x и выходов T_y мы хотим «подключить» в течение одного разворачивания ячеек во времени, возможны различные типы архитектуры:

- «**много в один**» (many-to-one): подавая предложения, состоящие из различного количества слов $T_x > 1$ мы можем предсказывать их тональность (sentiment analysis) $T_y = 1$;
- «**один во много**» (one-to-many): подавая изображение на вход $T_x = 1$, мы хотели бы получить аннотацию, состоящую из нескольких слов (image captioning) $T_y > 1$;
- «**много во много**» (many-to-many) предполагает два варианта:
    - подход $T_x = T_y$ можно использовать для распознавания именованных сущностей (named entity recognition, NER), когда каждому слову ставится в соответствие тип сущности; или же

- $T_x \neq T_y$; в этом случае речь может идти, например, о машинном переводе (machine translation).

Символьная языковая модель

Рекуррентная нейронная сеть может запоминать последовательности *слов* (word-level) естественного языка, а может запоминать последовательности *символов* (character-level или character-based). Во втором случае говорят о **символьной языковой модели** (character-level language model).

Поскольку на вход и на выход подается различное количество символов, речь идет об архитектуре many-to-many.

Откроем блокнот к этому занятию

Подготовка данных

Будем обучать модель на рассказах Артура Конан Дойля о Шерлоке Холмсе.

sholmes.txt **Скачать**

```
with open('/content/sholmes.txt') as f:
  # метод .read() преобразует весь файл в одну строку
  data = f.read()
```

Составим список уникальных символов (также называемый вокабуляром, хотя последний термин относится скорее к уникальным словам).

```
chars = sorted(list(set(data)))
```

Запомним количество уникальных символов.

```
chars_size = len(chars)
chars_size
```

```
54
```

Создадим два словаря. Первый будет находить индекс символа по ключу, содержащему этот символ. Второй, наоборот, символ по индексу.

```
char_to_ix = {ch:i for i, ch in enumerate(chars)}
ix_to_char = {i:ch for i, ch in enumerate(chars)}

char_to_ix['e'], ix_to_char[32]
```

```
(32, 'e')
```

Архитектура сети

На каждом шаге мы подаем по одному символу $\mathbf{x}^t$. Каждый символ закодирован в one-hot вектор размерностью 54 x 1 таким образом, чтобы единица соответствовала порядку символа в перечне уникальных символов.

Например, символ `e` можно закодировать так:

```
a_vector = np.zeros((chars_size,1))
a_vector[32] = 1
```

Определимся с количеством нейронов (каждого) скрытого слоя, длиной последовательности (в этом примере мы зафиксируем подаваемое за один раз количество символов) и скоростью обучения.

```
hidden_size = 100
seq_length = 15
learning_rate = .01
```

На выходе меткой $\hat{\mathbf{y}}^t$ будет та же последовательность, сдвинутая на один символ вправо. В самом деле, если последовательность символов представляет собой слово ‘hello’, то нам бы хотелось, чтобы на основе буквы ‘h’ с наибольшей вероятностью прогнозировалась буква ‘e’.

Инициализация весов

Ранее мы уже объяснили, почему не стоит инициализировать веса нулевыми значениями.

Помимо этого возможна инициализация весов небольшими случайными значениями, взятыми из равномерного распределения

$$\mathbf{W}_{\text{random}} \sim \mathcal{U}\left[-\frac{1}{\sqrt{n}}; \frac{1}{\sqrt{n}}\right],$$

где n — количество нейронов предыдущего слоя (в случае входного слоя речь идет о количестве признаков), или стандартного нормального распределения с уменьшенной дисперсией

$$\mathbf{W}_{\text{random}} \sim \mathcal{N}\left(0; \frac{1}{1000}\right)$$

Еще одним подходом является **инициализация Ксавье**, также называемая **инициализацией Глоро**, по имени автора Ксавье Глоро (Xavier Glorot). В частности, предлагается также использовать равномерное

$$\mathbf{W}_{\text{Xavier}} \sim \mathcal{U}\left[-\sqrt{\left(\frac{6}{(n_{\text{in}} + n_{\text{out}})}\right)}; \sqrt{\left(\frac{6}{(n_{\text{in}} + n_{\text{out}})}\right)}\right]$$

или нормальное

$$\mathbf{W}_{\text{Xavier}} \sim \mathcal{N}\left(0; \sqrt{\frac{2}{(n_{\text{in}} + n_{\text{out}})}}\right)$$

распределения, где n_{in} — количество нейронов предыдущего слоя (или признаков в случае входного слоя), а n_{out} — количество нейронов последующего. Обоснование подхода выходит за рамки этого занятия.

```
np.random.seed(33)

n_in, n_out = chars_size, hidden_size
stddev = np.sqrt(2 / (n_in + n_out))
Wxh = np.random.normal(scale = stddev, size=(hidden_size, chars_si

n_in, n_out = hidden_size, hidden_size
stddev = np.sqrt(2 / (n_in + n_out))
Whh = np.random.normal(scale = stddev, size=(hidden_size, hidden_s

n_in, n_out = hidden_size, chars_size
stddev = np.sqrt(2 / (n_in + n_out))
Why = np.random.normal(scale = stddev, size=(chars_size, hidden_si

bh = np.zeros((hidden_size, 1))
by = np.zeros((chars_size, 1))
```

Функции активации

Функция гиперболического тангенса

Функцией активации будет **функция гиперболического тангенса** (hyperbolic tangent function, tanh), которая приводит значения к диапазону от -1 до 1.

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

```
plt.figure(figsize=(3,3))
x = np.linspace(-3, 3, 100)
plt.plot(x, (np.exp(x) - np.exp(-x)) / (np.exp(x) + np.exp(-x)))
```

```
plt.title('Hyperbolic tangent')
plt.xlabel('x')
plt.ylabel('tanh(x)')
plt.show()
```

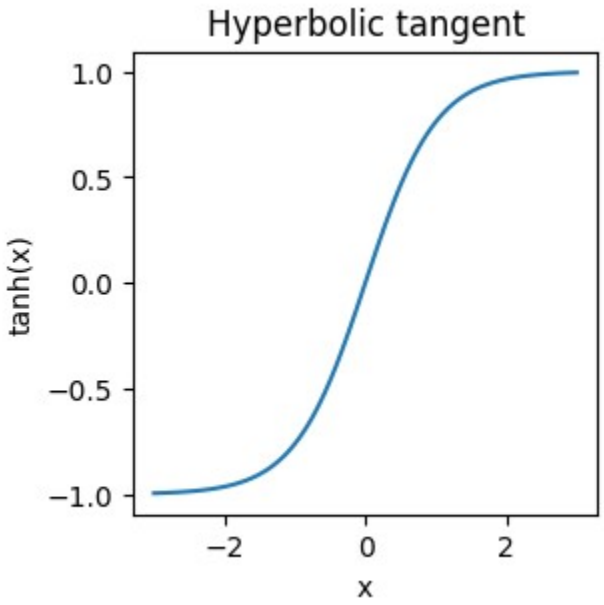

Далее будем использовать функцию **np.tanh()**.

Функция softmax

Кроме этого, на выходе мы будем подавать значения $\hat{\mathbf{y}}^t$ в функцию softmax, ожидаемо работающую в паре с функцией кросс-энтропии.

```
# используем вычислительно устойчивый вариант функции
def softmax(x):
  x = x - np.max(x)
  p = np.exp(x)
  return p / np.sum(p)
```

Прямое распространение

Предположим, что последовательность состоит из символов, образующих слово hello. В этом случае мы развернем четыре скрытых ячейки.

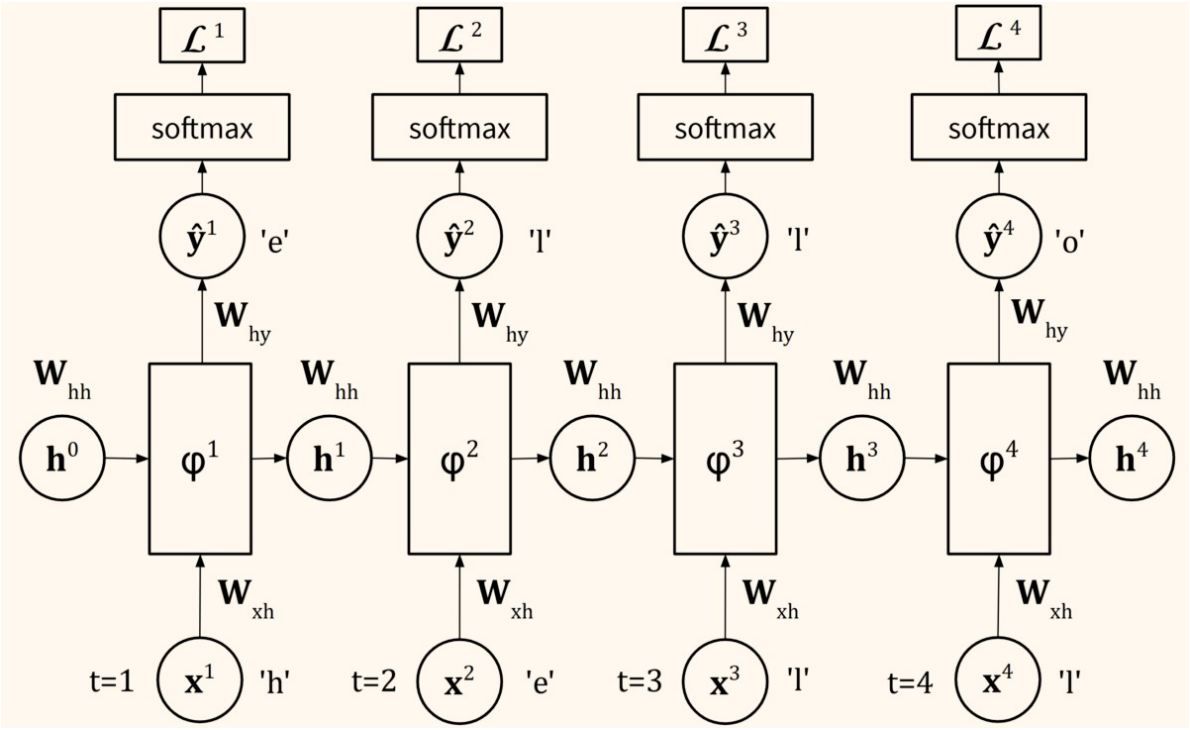

Примечание. Смещения $\mathbf{b}_h$ и $\mathbf{b}_y$ не показаны.

С точки зрения вероятностей речь опять же идет о том, чтобы при подаче на вход, например, буквы ‘h’ с наибольшей вероятностью прогнозировалась буква ‘e’.

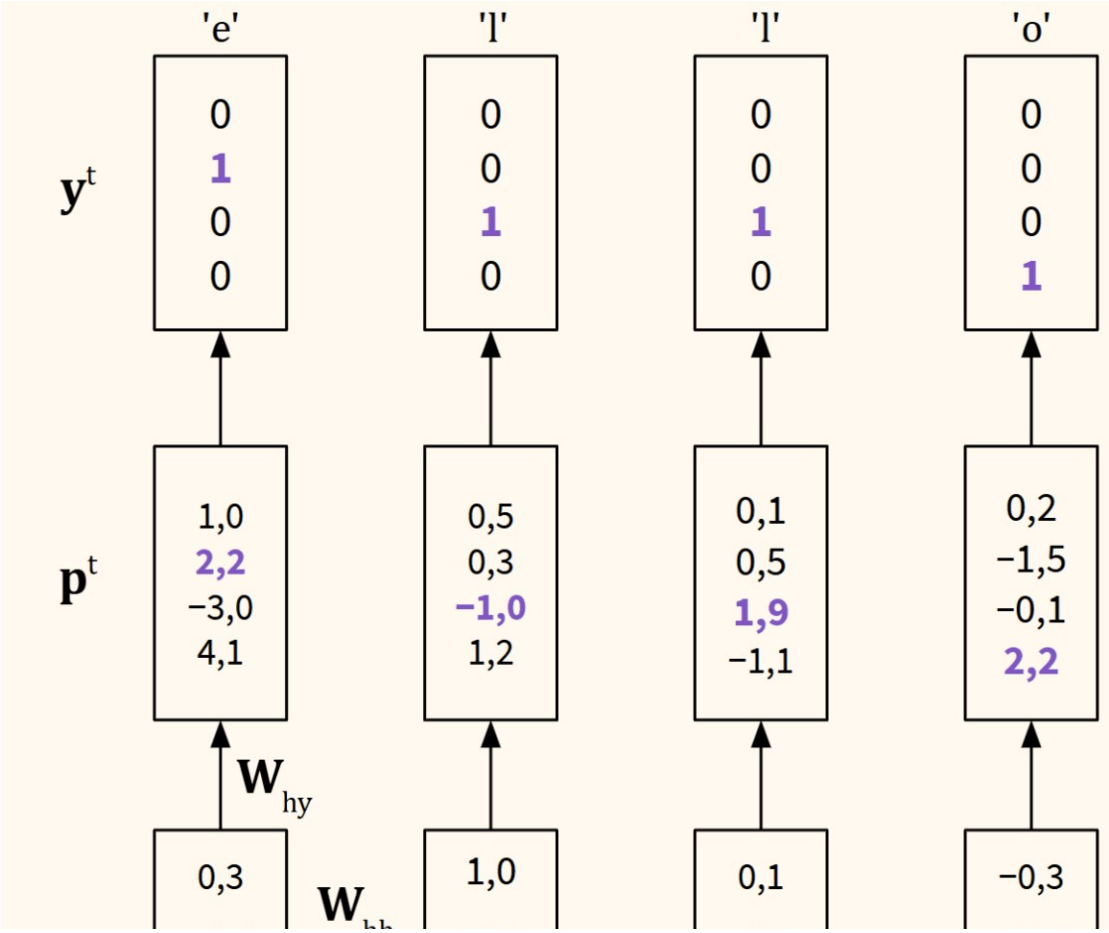

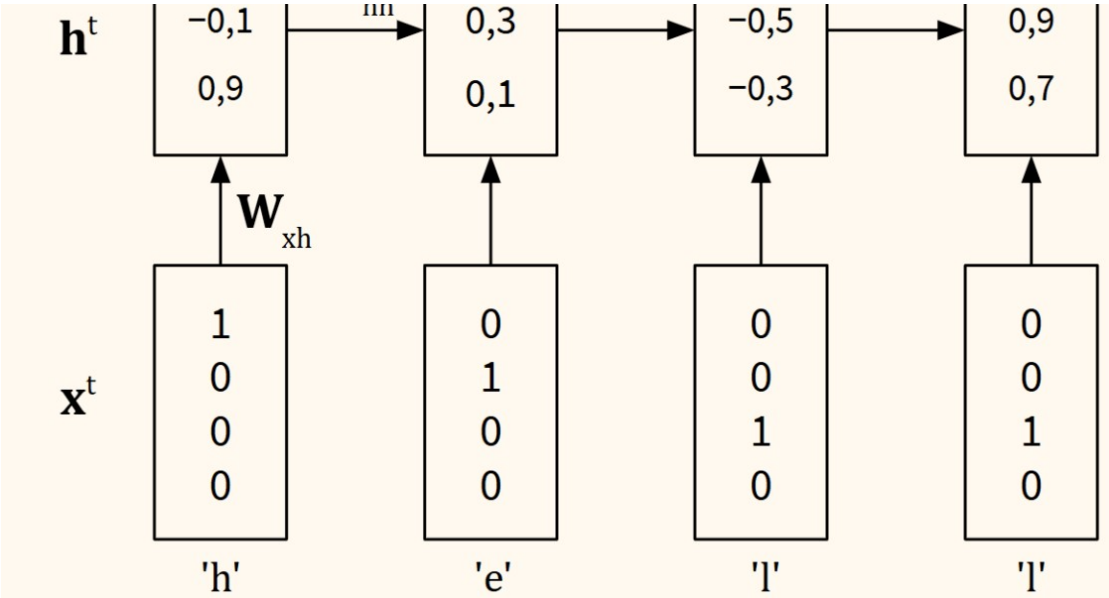

Приведем формулу расчета значений скрытых слоев

$$\mathbf{h}^t = \tanh(\mathbf{W}_{xh}\mathbf{x}^t + \mathbf{W}_{hh}\mathbf{h}^{t-1} + \mathbf{b}_h)$$

и выходных значений

$$\hat{\mathbf{y}}^t = \mathbf{W}_{hy}h^t + \mathbf{b}_y$$

Технически в процессе обучения нейросеть будет запоминать текст «кусками» по 15 символов в каждом. Для этого вначале нам необходимо составить список порядковых номеров символов очередной последовательности.

```
inputs = [char_to_ix[ch] for ch in data[p:p+seq_length]]
targets = [char_to_ix[ch] for ch in data[p+1:p+seq_length+1]]
```

Опять же целевая последовательность совпадает с входной, но со сдвигом на один символ вперед.

Переменная `p` выполняет роль указателя (pointer). Вначале значение указателя равно нулю `p = 0`, а затем после каждой эпохи обучения увеличивается на длину последовательности.

```
p += seq_length
```

Создадим словари, в которые для каждой последовательности будем записывать значения входного $\mathbf{x}^t$ и скрытого $\mathbf{h}^t$ слоев, логитов $\hat{\mathbf{y}}^t$ и

вероятностей $\mathbf{p}^t$.

```
xs, hs, ys, ps = {}, {}, {}, {}
```

Первое значение скрытого слоя будет нулевым.

```
hs[-1] = np.zeros((hidden_size, 1))
```

В цикле выполним прямое распространение.

```
for t in range(len(inputs)):
  # создадим one-hot вектор символа,
  xs[t] = np.zeros((chars_size,1))
  xs[t][inputs[t]] = 1
  # найдем значение скрытого слоя,
  hs[t] = np.tanh(np.dot(Wxh, xs[t]) + np.dot(Whh, hs[t-1]) + bh)
  # значение выходного слоя
  ys[t] = np.dot(Why, hs[t]) + by
  # и вероятности
  ps[t] = softmax(ys[t])
```

Кросс-энтропия

Кросс-энтропию на шаге t можно рассчитать по формуле

$$\mathcal{L}^t(\mathbf{y}^t, \mathbf{p}^t) = -\sum_{i=1}^{C} y_i^t \log p_i^t,$$

где C — количество классов, т.е. уникальных символов.

Обозначим «правильный» класс (символ) C_i через $i = j$. Поскольку для всех остальных классов $i \neq j, y_i = 0$, то формулу можно упростить

$$\mathcal{L}^t(\mathbf{y}^t, \mathbf{p}^t) = -\log p_i^t$$

Общая кросс-энтропия является суммой значений кросс энтропии на каждом из t шагов последовательности длины T.

$$\mathcal{L} = \sum_{t=1}^{T} \mathcal{L}^t(\mathbf{y}^t, \mathbf{p}^t)$$

```
# будем аккумулировать ошибку в цикле прямого распространения
# небольшая константа добавлена для вычислительной устойчивости
loss += -np.log(ps[t][targets[t], 0] + 1e-10)
```

Обратное распространение

Перейдем к обратному распространению. Рассмотрим поток градиентов на $t = 1$ шаге.

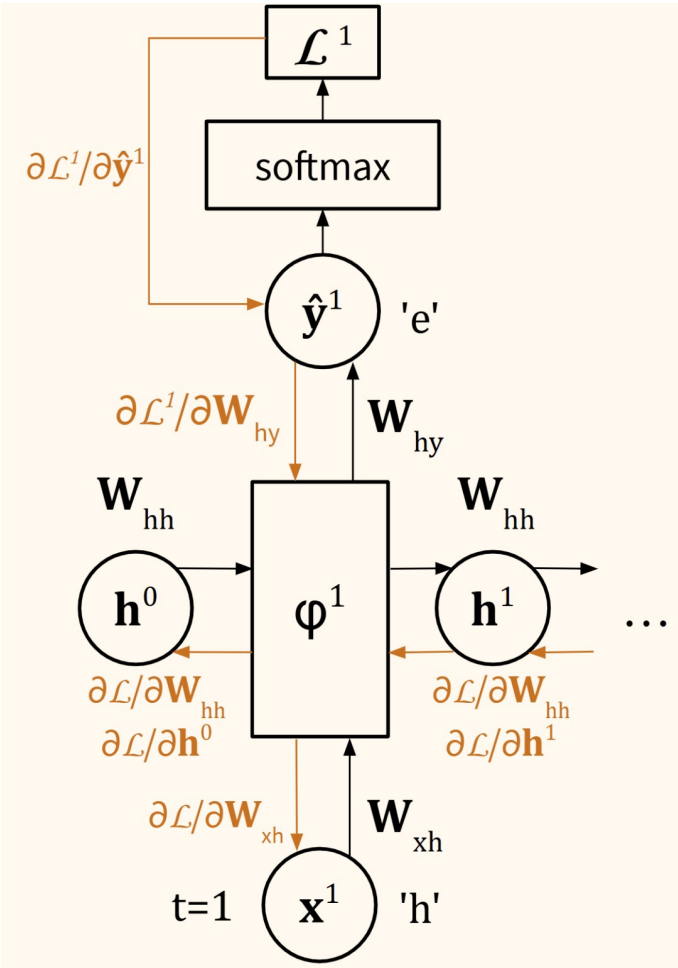

Обратное распространение ошибки во времени

В примере выше градиент рассчитывается от шага $t = 4$ к шагу $t = 1$ на каждый из скрытых слоев, а также на каждый параметр $\mathbf{W}_{hy}, \mathbf{b}_y,$

$\mathbf{W}_{hh}, \mathbf{b}_h$ и $\mathbf{W}_{xh}$.

> Такое распространение ошибки называется **обратным распространением ошибки во времени** (backpropagation through time, BPTT).

Более того, поскольку мы зафиксировали длину последовательности через параметр `seq_length` речь идет о truncated BPTT.

Дополнительно заметим, что поскольку параметры модели используются t раз, то значения их градиентов суммируются на каждом из шагов обратного распространения.

```
# подготовим массивы для расчета частных производных параметров
dWxh, dWhh, dWhy = np.zeros_like(Wxh), np.zeros_like(Whh), np.zero
dbh, dby = np.zeros_like(bh), np.zeros_like(by)
# и скрытого слоя на шаге t+1
dhnext = np.zeros_like(hs[0])
```

```
# ошибку будем распространять от последнего шага к первому
for t in reversed(range(len(inputs))):
```

Перейдем к расчету частных производных.

Производная кросс-энтропии и softmax

Начнем с производной softmax. Вспомним, что softmax является вектор-функцией, преобразующей логиты $\hat{\mathbf{y}}$ в вероятности $\mathbf{p}$

$$\text{softmax} : \mathbb{R}^n \to \mathbb{R}^n,$$

где каждую координату p_i можно найти через

$$p_i = \frac{e^{\hat{y}_i}}{\sum_{l=1}^{n} e^{\hat{y}_l}}, \quad \forall i = 1, \ldots, n$$

Все возможные частные производные такой вектор-функции образуют матрицу Якоби $J_{n\times n}$ (Jacobian matrix).

$$J = \begin{pmatrix} \frac{\partial p_1}{\partial \hat{y}_1} & \frac{\partial p_1}{\partial \hat{y}_2} & \cdots & \frac{\partial p_1}{\partial \hat{y}_n} \\ \frac{\partial p_2}{\partial \hat{y}_1} & \frac{\partial p_2}{\partial \hat{y}_2} & \cdots & \frac{\partial p_2}{\partial \hat{y}_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial p_n}{\partial \hat{y}_1} & \frac{\partial p_n}{\partial \hat{y}_2} & \cdots & \frac{\partial p_n}{\partial \hat{y}_n} \end{pmatrix}$$

Найдем частные производные логарифма данной функции. Тогда по правилу производной сложной функции

$$\frac{\partial}{\partial \hat{y}_j} \log p_i = \frac{1}{p_i} \cdot \frac{\partial p_i}{\partial \hat{y}_j}$$

Выразим $\frac{\partial p_i}{\partial \hat{y}_j}$,

$$\frac{\partial p_i}{\partial \hat{y}_j} = p_i \cdot \frac{\partial}{\partial \hat{y}_j} \log p_i,$$

что и будет частными производными J. Возьмем логарифм от p_i.

$$\log p_i = \log \left(\frac{e^{\hat{y}_i}}{\sum_{l=1}^{n} e^{\hat{y}_l}} \right) = \hat{y}_i - \log \left(\sum_{l=1}^{n} e^{\hat{y}_l} \right)$$

Найдем частные производные разницы.

$$\frac{\partial}{\partial \hat{y}_j} \log p_i = \frac{\partial \hat{y}_i}{\partial \hat{y}_j} - \frac{\partial}{\partial \hat{y}_j} \log \left(\sum_{l=1}^{n} e^{\hat{y}_l} \right)$$

Заметим, что

$$\frac{\partial \hat{y}_i}{\partial \hat{y}_j} = \begin{cases} 1, & \text{если } i = j \\ 0, & \text{если } i \neq j, \end{cases}$$

что можно записать через индикатор $\mathbf{1}\{i = j\}$. Тогда,

$$\frac{\partial}{\partial \hat{y}_j} \log p_i = \mathbf{1}\{i = j\} - \frac{\partial}{\partial \hat{y}_j} \log \left(\sum_{l=1}^{n} e^{\hat{y}_l} \right)$$

Воспользовавшись производной логарифма $\frac{d}{dx} \log x = \frac{1}{x}$ и правилом производной сложной функции,

$$\frac{\partial}{\partial \hat{y}_j} \log p_i = \mathbf{1}\{i = j\} - \frac{1}{\sum_{l=1}^{n} e^{\hat{y}_l}} \cdot \left(\frac{\partial}{\partial \hat{y}_j} \sum_{l=1}^{n} e^{\hat{y}_l} \right)$$

Наконец,

$$\frac{\partial}{\partial \hat{y}_j} \sum_{l=1}^{n} e^{\hat{y}_l} = \frac{\partial}{\partial \hat{y}_j} [e^{\hat{y}_1} + e^{\hat{y}_2} + \ldots + e^{\hat{y}_j} + \ldots + e^{\hat{y}_n}] = \frac{\partial}{\partial \hat{y}_j} [e^{\hat{y}_j}] = e^{\hat{y}_j}$$

Как следствие,

$$\frac{\partial}{\partial \hat{y}_j} \log p_i = \mathbf{1}\{i = j\} - \frac{e^{\hat{y}_j}}{\sum_{l=1}^{n} e^{\hat{y}_l}} = \mathbf{1}\{i = j\} - p_j$$

Подставим результаты в выражение для $\frac{\partial p_i}{\partial \hat{y}_j}$

$$\frac{\partial p_i}{\partial \hat{y}_j} = p_i \cdot \frac{\partial}{\partial \hat{y}_j} \log p_i = p_i \cdot \mathbf{1}\{i = j\} - p_j$$

Для $n = 4$ получим,

$$J = \begin{pmatrix} p_1 \cdot (1 - p_1) & -p_1 \cdot p_2 & -p_1 \cdot p_3 & -p_1 \cdot p_4 \\ -p_2 \cdot p_1 & p_2 \cdot (1 - p_2) & -p_2 \cdot p_3 & -p_2 \cdot p_4 \\ -p_3 \cdot p_1 & -p_3 \cdot p_2 & p_3 \cdot (1 - p_3) & -p_3 \cdot p_4 \\ -p_4 \cdot p_1 & -p_4 \cdot p_2 & -p_4 \cdot p_3 & p_4 \cdot (1 - p_4) \end{pmatrix}$$

Еще раз приведем функцию кросс-энтропии

$$\mathcal{L}(\mathbf{y}, \mathbf{p}) = -\sum_{i=1}^{C} y_i \ \log p_i$$

Найдем $\frac{\partial \mathcal{L}}{\partial \hat{y}_j}$, подставляя полученные выше результаты.

$$
\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \hat{y}_j} &= -\frac{\partial}{\partial \hat{y}_j} \sum_{i=1}^{C} y_i \cdot \log p_i = -\sum_{i=1}^{C} y_i \cdot \frac{\partial}{\partial \hat{y}_j} \log p_i \\
&= -\sum_{i=1}^{C} \frac{y_i}{p_i} \cdot \frac{\partial p_i}{\partial \hat{y}_j} \\
&= -\sum_{i=1}^{C} \frac{y_i}{p_i} \cdot p_i \cdot (\mathbf{1}\{i=j\} - p_j) = -\sum_{i=1}^{C} y_i \cdot (\mathbf{1}\{i=j\} - p_j) \\
&= \sum_{i=1}^{C} y_i \cdot p_j - \sum_{i=1}^{C} y_i \cdot (\mathbf{1}\{i=j\} - p_j)
\end{aligned}
$$

Поскольку индикаторная функция равна нулю везде, кроме $i = j$,

$$
\begin{aligned}
\frac{\partial \mathcal{L}}{\partial \hat{y}_j} &= \sum_{i=1}^{C} y_i \cdot p_j - y_j \\
&= p_j \cdot \sum_{i=1}^{C} y_i - y_j \\
&= p_j - y_j,
\end{aligned}
$$

в силу того, что $\sum_{i=1}^{C} y_i = 1$. В векторной нотации,

$$
\frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} = \mathbf{p} - \mathbf{y}
$$

При этом, поскольку $\mathbf{y}$ — это one-hot вектор, то $\frac{\partial \mathcal{L}}{\partial \hat{y}_i}$ можно записать так

$$
\frac{\partial \mathcal{L}}{\partial \hat{y}_i} = \begin{cases} p_i & \text{если } i \neq j \\ p_i - 1 & \text{если } i = j \end{cases}
$$

```
dy = np.copy(ps[t])
dy[targets[t]] -= 1
```

Распространение ошибки на $\mathbf{W}_{hy}$ и $\mathbf{b}_y$

По правилу производной сложной функции

$$\frac{\partial \mathcal{L}^t}{\partial \mathbf{W}_{hy}} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t} \cdot \frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{W}_{hy}}$$

Продифференцируем $\hat{\mathbf{y}}^t = \mathbf{W}_{hy}\mathbf{h}^t + \mathbf{b}$, где $\mathbf{h}^t$ — значение ячейки текущего скрытого слоя, относительно $\mathbf{W}_{hy}$.

$$\frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{W}_{hy}} = \mathbf{h}^t$$

Тогда,

$$\frac{\partial \mathcal{L}^t}{\partial \mathbf{W}_{hy}} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t}\mathbf{h}^t$$

Аналогично,

$$\frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{b}_y} = 1, \quad \frac{\partial \mathcal{L}^t}{\partial \mathbf{b}_y} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t}$$

Общий градиент для всех t шагов можно найти через

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{hy}} = \sum_{t=T}^{1} \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t}\mathbf{h}^t, \quad \frac{\partial \mathcal{L}}{\partial \mathbf{b}_y} = \sum_{t=T}^{1} \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t},$$

где нотация $\sum_{t=T}^{1}$ указывает на то, что мы начинаем с последнего шага T и заканчиваем первым.

```
dWhy += np.dot(dy, hs[t].T)
dby += dy
```

Распространение ошибки на $\mathbf{h}^t$

Частные производные относительно скрытого слоя $\mathbf{h}^t$ определяются градиентом, «проходящим» через текущий выходной слой $\partial \hat{\mathbf{y}}^t$ и градиентом, «проходящим» через предыдущий скрытый слой $\mathbf{h}^{t+1}$.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}^t} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t} \cdot \frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{h}^t} + \frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^{t+1}} \cdot \frac{\partial \mathbf{h}^{t+1}}{\partial \mathbf{h}^t}$$

Вначале займемся градиентом из текущего выходного слоя.

$$\frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{h}^t} = \mathbf{W}_{hy}$$

$$\frac{\partial \mathcal{L}^t}{\partial \mathbf{h}^t} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t} \cdot \frac{\partial \hat{\mathbf{y}}^t}{\partial \mathbf{h}^t} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}} \cdot \mathbf{W}_{hy}$$

Теперь займемся градиентом из предыдущего выходного слоя.
Поскольку на каждом шаге t

$$\mathbf{h}^t = \tanh(\mathbf{W}_{xh}\mathbf{x}^t + \mathbf{W}_{hh}\mathbf{h}^{t-1} + \mathbf{b}_h)$$

в первую очередь найдем производную $\frac{\partial \tanh(\mathbf{h}^t)}{\partial \mathbf{h}^t}$.

$$\begin{aligned}
\frac{d}{dx}\left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right) &= \frac{e^x - e^{-x}}{(e^x + e^{-x})^2} d(e^x - e^{-x}) - \frac{e^x - e^{-x}}{(e^x + e^{-x})^2} d(e^x + e^{-x}) \\
&= \frac{(e^x + e^{-x})(e^x + e^{-x})}{(e^x + e^{-x})^2} - \frac{(e^x - e^{-x})(e^x - e^{-x})}{(e^x + e^{-x})^2} \\
&= \frac{(e^x + e^{-x})^2 - (e^x - e^{-x})^2}{(e^x + e^{-x})^2} \\
&= 1 - \left(\frac{e^x - e^{-x}}{e^x + e^{-x}}\right)^2 = 1 - \tanh(x)^2
\end{aligned}$$

После этого, используя правило производной сложной функции, найдем $\frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^t}$.

$$\begin{aligned}
\frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^t} &= \frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^{t+1}} \cdot \frac{\partial \mathbf{h}^{t+1}}{\partial \mathbf{h}^t} \\
&= \frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^{t+1}} (1 - (\mathbf{h}^t)^2) \mathbf{W}_{hh}
\end{aligned}$$

Соберем все вместе.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}^t} = \frac{\partial \mathcal{L}^t}{\partial \hat{\mathbf{y}}^t} \cdot \mathbf{W}_{hy} + \frac{\partial \mathcal{L}^{t+1}}{\partial \mathbf{h}^{t+1}} (1 - (\mathbf{h}^t)^2) \mathbf{W}_{hh}$$

В коде с учетом матричного умножения получим.

```
dh = np.dot(Why.T, dy) + dhnext
dhraw = (1 - hs[t] * hs[t]) * dh
dhnext = np.dot(Whh.T, dhraw)
```

При этом еще раз скажем, что на первом с конца шаге $\mathbf{h}^T$ значением `dhnext` будет нулевой вектор $\mathbf{0}$.

Распространение ошибки на $\mathbf{W}_{xh}$, $\mathbf{W}_{hh}$ и $\mathbf{b}_h$

Веса $\mathbf{W}_{xh}$, $\mathbf{W}_{hh}$ и $\mathbf{b}_h$ используются на каждом из шагов прямого распространения.

Как следствие, поскольку, например, изменение $\mathbf{W}_{xh}$ влияет на каждый $\mathbf{h}^t$ и в совокупности эти значения влияют на $\hat{\mathbf{y}}^t$ и затем на $\mathcal{L}^t$, то для расчета частных производных вначале необходимо распространить ошибку на каждую из ячеек $\mathbf{h}^t$.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}_{xh}} = \sum_{t=T}^{1} \frac{\partial \mathcal{L}^t}{\partial \mathbf{h}^t} \cdot \frac{\partial \mathbf{h}^t}{\partial \mathbf{W}_{xh}}$$

Аналогичное рассуждение можно провести для $\mathbf{W}_{hh}$ и $\mathbf{b}_h$.

Остается найти частные производные от скрытого слоя $\mathbf{h}^t$ до параметров модели

$$\begin{aligned}
\frac{\partial \mathbf{h}^t}{\partial \mathbf{W}_{xh}} &= (1 - (\mathbf{h}^t)^2)\, \mathbf{x}^t \\
\frac{\partial \mathbf{h}^t}{\partial \mathbf{W}_{hh}} &= (1 - (\mathbf{h}^t)^2)\, \mathbf{h}^{t-1} \\
\frac{\partial \mathbf{h}^t}{\partial \mathbf{b}_h} &= (1 - (\mathbf{h}^t)^2)
\end{aligned}$$

В коде это можно выразить следующим образом.

```
dWxh += np.dot(dhraw, xs[t].T)
dWhh += np.dot(dhraw, hs[t-1].T)
dbh += dhraw
```

Приведем весь код обратного распространения.

```
dhnext = np.zeros_like(hs[0])

for t in reversed(range(len(inputs))):
  dy = np.copy(ps[t])
  dy[targets[t]] -= 1
  dWhy += np.dot(dy, hs[t].T)
  dby += dy
  dh = np.dot(Why.T, dy) + dhnext
  dhraw = (1 - hs[t] * hs[t]) * dh
  dWxh += np.dot(dhraw, xs[t].T)
  dWhh += np.dot(dhraw, hs[t-1].T)
  dbh += dhraw
  dhnext = np.dot(Whh.T, dhraw)
```

Взрыв и затухание градиента

Предположим без ограничения общности, что вместо функции гиперболического тангенса мы используем линейную активацию $g(\mathbf{z}) = \mathbf{z}$. В этом случае распространение ошибки от одного скрытого слоя до другого примет вид

$$\frac{\partial \mathbf{h}^{t+1}}{\partial \mathbf{h}^{t}} = \mathbf{W}_{hh}$$

Таким образом, распространение ошибки на $\mathbf{h}^1$ можно найти через

$$\begin{aligned}\frac{\partial \mathcal{L}}{\partial \mathbf{h}^1} &= \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} \cdot \frac{\partial \hat{\mathbf{y}}}{\partial \mathbf{h}^4} \cdot \frac{\partial \mathbf{h}^4}{\partial \mathbf{h}^3} \cdot \frac{\partial \mathbf{h}^3}{\partial \mathbf{h}^2} \cdot \frac{\partial \mathbf{h}^2}{\partial \mathbf{h}^1} \\ &= \frac{\partial \mathcal{L}}{\partial \hat{\mathbf{y}}} \cdot \frac{\partial \hat{\mathbf{y}}}{\partial \mathbf{h}^4} \cdot \mathbf{W}_{hh} \cdot \mathbf{W}_{hh} \cdot \mathbf{W}_{hh}\end{aligned}$$

При большом количестве скрытых слоев в случае если $\mathbf{W}_{hh}$ больше единицы, градиент может «взорваться» (explode) и это дестабилизирует процесс обучения. Наоборот, если $\mathbf{W}_{hh}$ меньше единицы, он может «затухнуть» (vanish), и веса перестанут обновляться.

Проблему взрыва градиента можно решить, ограничив значения градиента минимальным и максимальным значением (gradient value clipping)

```
for dparam in [dWxh, dWhh, dWhy, dbh, dby]:
  np.clip(dparam, -1, 1, out=dparam)
```

Проблему затухания градиента можно скорректировать через инициализацию весов единичной матрицей (identity RNN) и использованием ReLU в качестве функции активации или использованием архитектуры LSTM.

Запоминание непосредственного прошлого

Кроме этого заметим, что RNN способна запомнить только непосредственное прошлое (immediate past).

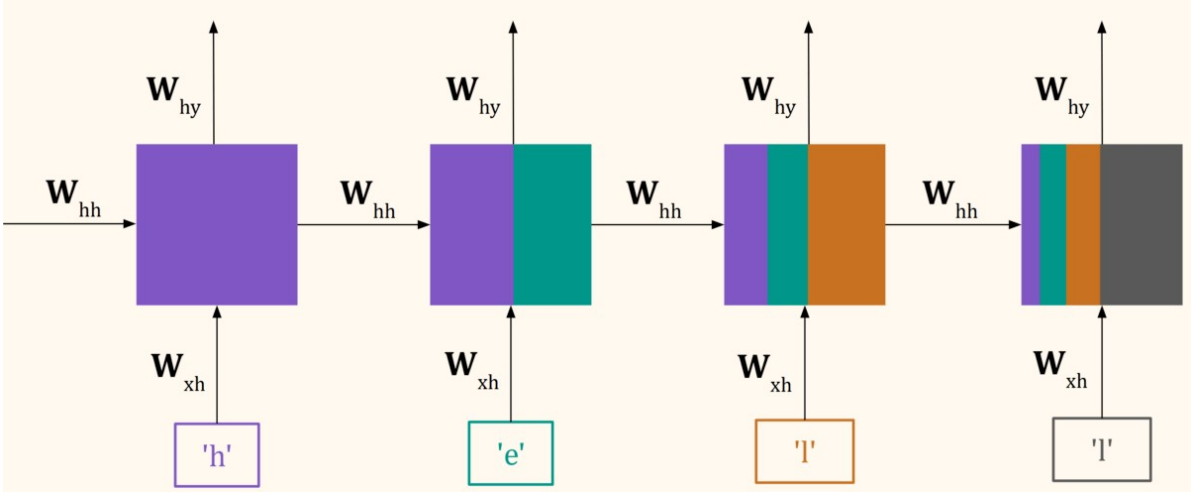

Чем больше длина последовательности, тем меньший вес имеют первые ее элементы, и тем меньше они влияют на уровень ошибки.

Обновление параметров

Обновим параметры модели.

```
Wxh -= learning_rate * dWxh
```

```
Whh -= learning_rate * dWhh
Why -= learning_rate * dWhy
bh -= learning_rate * dbh
by -= learning_rate * dby
```

Расчет уровня ошибки

Поскольку уровень ошибки рассчитывается после «прочтения» каждой последовательности символов, его значение может сильно колебаться. Имеет смысл применить экспоненциальное сглаживание.

```
# зададим уровень ошибки перед началом обучения
smooth_loss = -np.log(1.0 / chars_size) * seq_length
```

```
# в процессе обучения будем обновлять уровень ошибки,
# отдавая предпочтение предыдущим значениям
smooth_loss = smooth_loss * 0.999 + loss * 0.001
```

Генерирование текста

Периодчески в процессе обучения будем просить рекуррентную нейросеть генерировать новый текст. Для этого инициализируем $\mathbf{h}^0$ и $\mathbf{x}^0$ последним (на данный момент) значением скрытого слоя и первым символом текущей обучающей последовательности соответственно.

```
h = hs[len(inputs)-1]
x = np.zeros((chars_size, 1))
x[inputs[0]] = 1
```

Кроме этого объявим список, в который будем помещать сгенерированные символы.

```
ixes = []
```

Далее в цикле, равном длине генерируемой последовательности, рассчитаем вероятностное распределение следующего символа и выберем из списка уникальных символов новый символ с учетом этого распределения.

```
# пусть новый текст состоит из ста символов
for t in range(100):
  # рассчитаем вероятностное распределение нового символа,
  h = np.tanh(np.dot(Wxh, x) + np.dot(Whh, h) + bh)
  y = np.dot(Why, h) + by
  probs = softmax(y)

  # выберем этот символ,
  ix = np.random.choice(range(chars_size), p=probs.ravel())
  # закодируем его и
  x = np.zeros((chars_size, 1))
  x[ix] = 1
  # поместим в список
  ixes.append(ix)
```

Остается вывести получившийся текст.

```
txt = ''.join(ix_to_char[ix] for ix in ixes)
print(txt)
print('-----')
```

Обучение модели

Приведем код цикла обучения модели и результат обучения.

```
for n in range(int(len(data)/seq_length)):

  # перед началом обучения или, если алгоритм "прочитал" весь текс
  # обнулим значения скрытого слоя и указателя
  if n == 0 or p + seq_length + 1 >= len(data):
    h_prev = np.zeros((hidden_size, 1))
    p = 0

  inputs = [char_to_ix[ch] for ch in data[p:p+seq_length]]
  targets = [char_to_ix[ch] for ch in data[p+1:p+seq_length+1]]

  xs, hs, ys, ps = {}, {}, {}, {}

  hs[-1] = np.copy(h_prev)
  loss = 0

  for t in range(len(inputs)):
    xs[t] = np.zeros((chars_size,1))
```

```
    xs[t][inputs[t]] = 1
    hs[t] = np.tanh(np.dot(Wxh, xs[t]) + np.dot(Whh, hs[t-1]) + bh
    ys[t] = np.dot(Why, hs[t]) + by
    ps[t] = softmax(ys[t])
    loss += -np.log(ps[t][targets[t], 0] + 1e-10)

  dWxh, dWhh, dWhy = np.zeros_like(Wxh), np.zeros_like(Whh), np.ze
  dbh, dby = np.zeros_like(bh), np.zeros_like(by)
  dhnext = np.zeros_like(hs[0])

  for t in reversed(range(len(inputs))):
    dy = np.copy(ps[t])
    dy[targets[t]] -= 1
    dWhy += np.dot(dy, hs[t].T)
    dby += dy
    dh = np.dot(Why.T, dy) + dhnext
    dhraw = (1 - hs[t] * hs[t]) * dh
    dWxh += np.dot(dhraw, xs[t].T)
    dWhh += np.dot(dhraw, hs[t-1].T)
    dbh += dhraw
    dhnext = np.dot(Whh.T, dhraw)

  for dparam in [dWxh, dWhh, dWhy, dbh, dby]:
    np.clip(dparam, -1, 1, out=dparam)

  Wxh -= learning_rate * dWxh
  Whh -= learning_rate * dWhh
  Why -= learning_rate * dWhy
  bh -= learning_rate * dbh
  by -= learning_rate * dby

  p += seq_length

  smooth_loss = smooth_loss * 0.999 + loss * 0.001

  if n % 20000 == 0:

    print('epoch %d, loss: %f' % (n, smooth_loss))
    h = hs[len(inputs)-1]
    x = np.zeros((chars_size, 1))
    x[inputs[0]] = 1
    ixes = []

    for t in range(100):
      h = np.tanh(np.dot(Wxh, x) + np.dot(Whh, h) + bh)
      y = np.dot(Why, h) + by
```

```
        probs = softmax(y)

        ix = np.random.choice(range(chars_size), p=probs.ravel())
        x = np.zeros((chars_size, 1))
        x[ix] = 1
        ixes.append(ix)

    txt = ''.join(ix_to_char[ix] for ix in ixes)
    print(txt)
    print('-----')
```

```
epoch 0, loss: 59.837298
y1bm*ube.dn)hq]z!.h7zs2"?*ogx3,2 "qb8?s(su?p*ag`is."[l4h`u5!wv;z]?(
-----
epoch 20000, loss: 34.225128
mis eloteds.
"ti'ned? hedeverse sters.
"if inew liow she ofe. herse's hro, goes wef eiss indweal
che
-----
epoch 40000, loss: 32.534210
miss ble, theation he thes spimidings
this me wipliuncs broves towe sive us compide more
she the min
-----
epoch 60000, loss: 32.153032
u aplidctrasuagrspan, bring-taggatley. oul? well that al
and that iveary that is the say. agd am awf
-----
epoch 80000, loss: 31.535463
-h4 rame on tur& lanearl, credod
belled a pexed  re burner-the si2et ere butteredly wy the buere by
-----
epoch 100000, loss: 31.079432
n. the that mowe thought they had 1thing that i jess. in throuss i
was the this s
-----
epoch 120000, loss: 31.131806
fore
amorging midveger of his
that these filvem. 3implet'ard rearct at out been tr4inder a for a
-----
epoch 140000, loss: 30.102242
it from traight
had duxed ithan hrent if
what in j&il.
```

```
his pacige. holmes"
came lames mr ba!all deen
-----
epoch 160000, loss: 30.424752
 at
tire that there as as i
dartingervationter it spamber was rea1enosuteared thened to luttan
-----
epoch 180000, loss: 29.812610
se and been a man
edat and greetered neried.
he 0ast ecomenteling the could jepery e pxelle and ahe
-----
epoch 200000, loss: 30.529648
am a bedoor that 'aden?"
"deado atked a askerent
a amen-don becean at hoable to for a crsed a qund a
-----
```

Список литературы

- Karpathy A., The Unreasonable Effectiveness of Recurrent Neural Networks, 2015.