

Тест по темам «Методы анализа данных без учителя и тематическое моделирование»

1. В чем состоит основное отличие задачи кластеризации от задачи классификации?
  - А) В кластеризации объекты имеют метки классов, а в классификации — нет
  - Б) В кластеризации обучающая выборка не содержит ответов, и требуется разбить объекты на группы по схожести
  - В) В кластеризации используется только один признак
  - Г) Кластеризация — это задача обучения с учителем
2. Какой метод кластеризации основан на разделении смеси вероятностных распределений и использует Е-шаг и М-шаг?
  - А) Метод k-средних (k-means)
  - Б) DBSCAN
  - В) ЕМ-алгоритм
  - Г) Агломеративная кластеризация
3. Какой метод кластеризации позволяет автоматически определять количество кластеров и эффективно работать с кластерами произвольной формы, выделяя также шумовые точки?
  - А) Метод k-средних
  - Б) DBSCAN
  - В) Иерархическая кластеризация
  - Г) ЕМ-алгоритм
4. Что такое дендрограмма в контексте иерархической кластеризации?
  - А) График зависимости ошибки от числа кластеров
  - Б) Дерево, показывающее последовательное объединение кластеров, позволяющее выбрать нужное число кластеров без перезапуска алгоритма
  - В) Матрица расстояний между объектами
  - Г) Визуализация центров кластеров
5. Какой функционал минимизирует метод k-средних?
  - А) Среднее межкластерное расстояние
  - Б) Сумма квадратов расстояний от объектов до центров своих кластеров
  - В) Среднее расстояние до ближайшего соседа
  - Г) Дивергенция Кульбака-Лейблера
6. В чем заключается основная проблема «проклятия размерности» для метрических методов?
  - А) Невозможность хранить данные в памяти
  - Б) С ростом размерности расстояния между объектами становятся примерно одинаковыми, и метод теряет различительную способность
  - В) Увеличивается время обучения модели
  - Г) Уменьшается количество признаков
7. Для чего используется статистика Хопкинса?
  - А) Для выбора числа кластеров
  - Б) Для проверки наличия кластерной структуры в данных
  - В) Для оценки качества кластеризации при наличии разметки
  - Г) Для визуализации кластеров
8. Какая метрика качества кластеризации использует энтропию классов и кластеров и позволяет оценить однородность и полноту?

- А) Коэффициент силуэта
- Б) Индекс Джини
- В) V-мера (V-measure)
- Г) Среднеквадратичная ошибка

9. В чем заключается основная идея метода главных компонент (PCA)?

- А) Отобрать признаки с максимальной корреляцией с целевой переменной
- Б) Найти такие линейные комбинации исходных признаков (главные компоненты), которые сохраняют максимальную дисперсию данных
- В) Случайным образом спроецировать данные в пространство меньшей размерности
- Г) Удалить признаки с низкой дисперсией

10. Какое утверждение о сингулярном разложении (SVD) верно?

- А) SVD позволяет представить матрицу  $X$  в виде произведения трех матриц:  $X = U\Sigma V^T$
- Б) SVD используется только для решения систем линейных уравнений
- В) SVD неприменим для разреженных матриц
- Г) SVD всегда дает единственное разложение

11. Что такое лемма Джонсона-Линденштраусса?

- А) Утверждение о существовании линейного отображения в пространство меньшей размерности, которое приближенно сохраняет расстояния между точками
- Б) Теорема о сходимости градиентного спуска
- В) Утверждение о нормальности распределения признаков
- Г) Теорема о единственности разложения матрицы

12. Какое из утверждений о L1- и L2-регуляризации при отборе признаков верно?

- А) L1-регуляризация (Lasso) может обнулять веса признаков, выполняя отбор
- Б) L2-регуляризация (Ridge) всегда обнуляет веса признаков
- В) L1-регуляризация не влияет на разреженность весов
- Г) Оба метода дают одинаковый результат

13. Как в случайном лесе оценивается важность признаков с помощью out-of-bag (OOB) ошибки?

- А) Значения признака перемешиваются, и оценивается, как увеличивается OOB-ошибка
- Б) Признак удаляется, и оценивается изменение ошибки
- В) Сравниваются коэффициенты линейной регрессии
- Г) Используется корреляция Пирсона

14. В чем состоит идея метода ALS (alternating least squares) для матричного разложения?

- А) Одновременная оптимизация обеих матриц градиентным спуском
- Б) Поочередная фиксация одной матрицы и решение задачи наименьших квадратов для другой, повторяя до сходимости
- В) Использование сингулярного разложения
- Г) Случайная инициализация и перебор всех вариантов

15. Какая функция потерь в матричном разложении соответствует предположению о пуассоновском распределении данных и приводит к неотрицательным матрицам?

- А) Норма Фробениуса
- Б) Дивергенция Кульбака-Лейблера
- В) L1-норма
- Г) Дивергенция Итакура-Саито

16. В чем заключается особенность задачи implicit feedback (например, матрица покупок) по сравнению с explicit feedback?
- А) Данные содержат только положительные примеры, отсутствует информация о том, что объект не понравился
  - Б) Данные содержат только отрицательные примеры
  - В) Данные являются непрерывными
  - Г) Данные всегда полные и без пропусков
17. Какая мера качества используется для обнаружения аномалий при параметрическом восстановлении плотности?
- А) Сравнение вероятности нового объекта с порогом
  - Б) Косинусное расстояние
  - В) Коэффициент корреляции
  - Г) Манхэттенское расстояние
18. Как работает одноклассовый SVM (one-class SVM) для поиска аномалий?
- А) Обучается на двух классах: нормальные объекты и аномалии
  - Б) Отделяет обучающую выборку от начала координат, строя разделяющую гиперплоскость, и использует ядровой трюк
  - В) Использует метод главных компонент для выделения выбросов
  - Г) Вычисляет среднее и стандартное отклонение
19. Что такое формула Парзена-Розенблатта?
- А) Метод параметрического восстановления плотности
  - Б) Непараметрический метод оценки плотности вероятности с использованием ядер
  - В) Формула для вычисления косинусного расстояния
  - Г) Алгоритм кластеризации
20. Какой метод визуализации данных лучше всего сохраняет локальную структуру и позволяет визуализировать данные с четкими кластерами, например, MNIST?
- А) Метод главных компонент (PCA)
  - Б) Многомерное шкалирование (MDS)
  - В) t-SNE (t-Distributed Stochastic Neighbor Embedding)
  - Г) Случайные проекции
21. В чем отличие метода SNE от классического многомерного шкалирования (MDS)?
- А) SNE использует дивергенцию Кульбака-Лейблера для сохранения пропорций расстояний, а не самих расстояний
  - Б) SNE является линейным методом
  - В) SNE не требует вычисления попарных расстояний
  - Г) MDS всегда работает лучше SNE
22. Какое базовое предположение лежит в основе вероятностных тематических моделей (PLSA, LDA)?
- А) Порядок слов в документе важен (bag of sequences)
  - Б) Документ представляет собой смесь тем, а тема — распределение слов
  - В) Каждый документ посвящен только одной теме
  - Г) Все слова в документе независимы
23. Что представляет собой матрица  $\Phi$  (фи) в тематической модели?
- А) Распределение тем в документах ( $p(t|d)$ )
  - Б) Распределение слов в темах ( $p(w|t)$ )

- В) Матрицу частот слов в документах
  - Г) Ковариационную матрицу
24. Какую задачу решает аддитивная регуляризация тематических моделей (ARTM)?
- А) Уменьшает количество тем
  - Б) Добавляет в модель дополнительные критерии (разреживание, сглаживание, декорреляцию) для улучшения интерпретируемости и учета априорной информации
  - В) Ускоряет сходимость ЕМ-алгоритма
  - Г) Преобразует LDA в PLSA
25. Что такое перплексия (perplexity) как критерий качества тематической модели?
- А) Мера интерпретируемости тем
  - Б) Мера, обратная правдоподобию, показывающая, насколько хорошо модель предсказывает тестовые данные
  - В) Количество тем в модели
  - Г) Размер словаря
26. Как оценивается когерентность (согласованность) темы?
- А) По частоте слов в документах
  - Б) По средней поточечной взаимной информации (PMI) топ-слов темы
  - В) По перплексии
  - Г) По количеству документов в теме
27. В чем заключается метод интрузий (intrusion) для оценки качества тем?
- А) В список топ-слов темы добавляется чужое слово, и эксперты должны его найти
  - Б) В документ добавляется чужой абзац
  - В) Удаляется одно слово из темы
  - Г) Сравниваются две темы между собой
28. Какую возможность предоставляют мультимодальные тематические модели?
- А) Работать только с одним языком
  - Б) Учитывать одновременно несколько типов данных (например, слова, авторов, ссылки) в рамках единой тематической структуры
  - В) Строить только бинарные распределения
  - Г) Автоматически определять количество тем
29. Что такое дивергенция Кульбака-Лейблера (KL-divergence)?
- А) Симметричная мера расстояния между распределениями
  - Б) Несимметричная мера, показывающая, насколько одно распределение отличается от другого
  - В) Метод кластеризации
  - Г) Функция активации
30. Какое утверждение о Latent Dirichlet Allocation (LDA) верно?
- А) LDA не использует априорные распределения
  - Б) LDA является байесовской версией PLSA, использующей априорные распределения Дирихле для матриц  $\Phi$  и  $\Theta$
  - В) LDA всегда дает более разреженные темы, чем PLSA
  - Г) LDA не требует указания числа тем