

Методичка по практическим заданиям

Обучение с подкреплением: прямое обучение от опыта агента по полным эпизодам

15 вариантов для самостоятельной реализации на Python

Документ предназначен для практической работы студентов. Во всех вариантах предполагается эпизодическая постановка задачи и обучение агента методом Monte Carlo по полным эпизодам. Задания подобраны так, чтобы их можно было реализовать без внешних библиотек машинного обучения - достаточно Python, базовых структур данных и генератора случайных чисел.

Как понимать используемые среды

Линейный мир - это цепочка состояний, расположенных по прямой. Агент обычно может выполнять только два действия: LEFT и RIGHT. Состояние удобно хранить как целое число.

GridWorld - это прямоугольная сетка клеток. Состояние задаётся координатой (row, col), а действиями являются UP, DOWN, LEFT и RIGHT. В более сложных вариантах на поле могут появляться препятствия, штрафные клетки, монеты и телепорты.

Что должно быть в программе студента

- Класс среды с методами `reset()` и `step(action)`.
- Представление состояний, действий и наград.
- Генерация полного эпизода до терминального состояния или лимита шагов.
- Хранение таблицы $Q(s, a)$.
- Вычисление возвратов G_t и обновление оценок после завершения эпизода.
- epsilon-жадная стратегия выбора действий.
- Вывод итоговой стратегии и краткий анализ полученного результата.

Рекомендуемая структура отчёта

Раздел	Что студенту стоит показать
Постановка задачи	Описание среды, состояний, действий и наград.
Реализация	Ключевые части кода: среда, агент, цикл обучения.
Результаты	Таблица Q , итоговая стратегия, число успешных эпизодов.

Вывод	Почему агент выбрал именно такую стратегию.
-------	---

Вариант 1. Линейный мир из 3 состояний

Условие	Агент работает в среде из трёх клеток, расположенных по прямой: [0] [1] [2]. Стартовое состояние - 1. Состояние 0 является проигрышным терминальным состоянием, состояние 2 - целевым терминальным состоянием.
Дано	● Действия: LEFT и RIGHT. ● Переходы детерминированные: LEFT уменьшает номер состояния на 1, RIGHT увеличивает на 1. ● Награды: попадание в 0 -> -5, попадание в 2 -> +5, любой обычный шаг -> -1. ● Эпизод завершается при достижении состояний 0 или 2.
Требуется	● Реализовать класс среды с методами reset() и step(action). ● Реализовать агента Monte Carlo с таблицей $Q(s, a)$. ● Обучить агента по полным эпизодам и показать, что из состояния 1 выгоднее идти вправо. ● Вывести итоговую стратегию и таблицу оценок.
Подсказки	Это самый простой учебный вариант: фактически агенту нужно научиться в одном нетерминальном состоянии выбирать лучшее из двух действий. Удобно кодировать состояние как целое число.

Вариант 2. Линейный мир из 5 состояний

Условие	Среда представляет собой цепочку из пяти состояний: [0] [1] [2] [3] [4]. Агент стартует в состоянии 2. Слева находится проигрышное терминальное состояние, справа - целевое.
Дано	● Действия: LEFT и RIGHT. ● Награды: попадание в 0 -> -10, попадание в 4 -> +10, обычный шаг -> -1. ● Эпизод заканчивается при достижении 0 или 4.
Требуется	● Реализовать эпизодическое обучение Monte Carlo. ● Использовать epsilon-жадную стратегию выбора действий. ● Показать, как меняется стратегия после серии эпизодов. ● Сделать краткий вывод: почему агент стремится к правой границе.
Подсказки	Этот вариант чуть интереснее, потому что у агента есть промежуточные состояния 1, 2 и 3. Полезно вывести стратегию отдельно для каждого нетерминального состояния.

Вариант 3. Линейный мир с ловушкой

Условие	Используется линейный мир из шести состояний: [0] [1] [2] [3] [4] [5]. Агент стартует в 2. Состояние 0 - проигрыш, состояние 5 - цель. Состояние 3 является штрафным, но не терминальным.
Дано	● Действия: LEFT и RIGHT. ● Награды: 0 -> -10, 5 -> +10, попадание в 3 -> -5, любой другой обычный шаг -> -1. ● Эпизод завершается только в состояниях 0 и 5.
Требуется	● Смоделировать среду и обучить агента. ● Проанализировать, как штрафная клетка влияет на оценки Q. ● Вывести итоговую стратегию и объяснить, как агент учитывает ловушку.
Подсказки	Здесь важно не перепутать: состояние 3 не заканчивает эпизод, а только даёт сильный штраф. Такой вариант показывает, что плохими могут быть не только финалы, но и промежуточные позиции.

Вариант 4. Линейный мир со случайными переходами

Условие	Среда такая же, как в варианте 2, но действия агента исполняются не всегда точно. Если агент выбирает направление, среда может выполнить другое действие.
Дано	● Базовая цепочка состояний: [0] [1] [2] [3] [4], старт из 2. ● Вероятность корректного выполнения действия - 0.8. ● С вероятностью 0.2 среда выполняет случайное движение. ● Награды: 0 -> -10, 4 -> +10, обычный шаг -> -1.
Требуется	● Добавить стохастичность в переходы среды. ● Обучить агента и сравнить поведение с детерминированным вариантом. ● Сделать вывод, может ли агент обучиться хорошей стратегии при случайности переходов.
Подсказки	Удобно сначала вычислить желаемое действие, а затем с заданной вероятностью заменить его случайным. Состояние всё равно можно хранить одним числом.

Вариант 5. Линейный мир с шумной наградой

Условие	Структура среды совпадает с вариантом 2, но штраф за обычный шаг не фиксирован. На каждом шаге он выбирается случайно, что создаёт шум в наблюдениях.
Дано	● Состояния: [0] [1] [2] [3] [4], старт из 2. ● Награды терминальных состояний: 0 -> -10, 4 -> +10. ● Награда за обычный шаг случайно равна -1 или -2.
Требуется	● Реализовать случайную награду за шаг. ● Провести обучение по эпизодам. ● Показать, что несмотря на шум, агент всё равно выявляет выгодное направление. ● Вывести среднюю награду по последним эпизодам.
Подсказки	Этот вариант полезен для обсуждения дисперсии оценок. Желательно использовать достаточно много эпизодов, чтобы усреднение сгладило случайные отклонения.

Вариант 6. GridWorld 2x2

Условие	Среда представляет собой квадрат 2x2. Агент стартует в левой верхней клетке, цель находится в правой нижней. Каждая клетка описывается координатой (row, col).
Дано	● Поле: S . / . G. ● Действия: UP, DOWN, LEFT, RIGHT. ● Если действие выводит за границы поля, агент остаётся на месте. ● Награды: цель -> +10, обычный шаг -> -1.
Требуется	● Реализовать сеточную среду и переходы по координатам. ● Обучить агента достижению цели. ● Показать итоговую стратегию для каждой клетки.
Подсказки	Это первый вариант, где состояние удобно хранить как кортеж. для отображения стратегии можно использовать стрелки или текстовые обозначения действий.

Вариант 7. GridWorld 3x3 с препятствием

Условие	Среда - поле 3x3. Агент стартует в левом верхнем углу. В центральной клетке расположено препятствие, в правом нижнем углу - цель.
Дано	● Поле: S . . / . X . / . . G. ● X обозначает недоступную клетку. ● Если агент пытается войти в X, он остаётся на месте. ● Награды: цель -> +10, любой обычный шаг -> -1.
Требуется	● Реализовать запрет на вход в клетку-препятствие. ● Обучить агента искать путь в обход препятствия. ● Сформировать итоговую стратегию и коротко прокомментировать её.
Подсказки	При реализации step(action) сначала вычислите предполагаемую новую клетку, затем проверьте границы и наличие препятствия. Только после этого меняйте состояние.

Вариант 8. GridWorld с двумя целями

Условие	На поле есть две терминальные цели: одна даёт большую награду, другая меньшую. Агент должен сам определить, к какой из них выгоднее идти.
Дано	● Пример поля 3x3: S . A / . . . / B . . ● A - терминальная цель с наградой +10, B - терминальная цель с наградой +5. ● Обычный шаг -> -1. ● Действия стандартные: UP, DOWN, LEFT, RIGHT.
Требуется	● Реализовать среду с двумя конечными состояниями. ● Обучить агента и посмотреть, какую цель он предпочитает. ● Объяснить, как расстояние до целей влияет на результат.
Подсказки	Интерес задания в том, что ближайшая цель не всегда оптимальна. Всё зависит от расстояния до неё и штрафа за каждый шаг.

Вариант 9. GridWorld с телепортом

Условие	В одной из клеток сетки расположен телепорт. При попадании на эту клетку агент мгновенно переносится в другую позицию поля: фиксированную или случайную.
Дано	● Пример поля 3x3: S . T / . . . / . . G. ● T - клетка телепорта. ● После входа на T агент переносится либо в заранее заданную клетку, либо в случайную клетку, не являющуюся целью. ● Награды: цель -> +10, обычный шаг -> -1.
Требуется	● Реализовать логику телепорта в среде. ● Обучить агента и исследовать, помогает или мешает телепорт достижению цели. ● Описать получившуюся стратегию.
Подсказки	Лучше начать с фиксированного телепорта - например, в левый нижний угол. После этого можно усложнить задачу случайным переносом.

Вариант 10. GridWorld со штрафными клетками

Условие	На поле присутствуют клетки, вход в которые разрешён, но сопровождается дополнительным штрафом. Агент должен научиться обходить их, если это выгодно.
Дано	● Пример поля 3x3: S . . / P P . / . . G. ● P - штрафная клетка. ● Попадание на P даёт дополнительную награду -3. ● Обычный шаг -> -1, цель -> +10.
Требуется	● Реализовать среду с несколькими типами клеток. ● Обучить агента выбирать маршрут с учётом штрафов. ● Сравнить кратчайший и наиболее выгодный путь.
Подсказки	Этот вариант хорошо показывает отличие между кратчайшим путем и путём с максимальной суммарной наградой. Удобно хранить штрафные клетки во множестве координат.

Вариант 11. Сбор монеты и достижение цели

Условие	В сетке находится промежуточный бонусный объект - монета. Агент должен решить, стоит ли сначала зайти за монетой, а затем идти к цели.
Дано	● Пример поля 3x3: S . C / . . . / . . G. ● C - клетка монеты, G - цель. ● При первом попадании на C агент получает +5, затем монета исчезает. ● Цель даёт +10, обычный шаг -> -1.
Требуется	● Реализовать изменяемое состояние среды: монета может быть собрана только один раз. ● Обучить агента в такой постановке. ● Показать, выгодно ли собирать монету перед достижением цели.
Подсказки	Нужно помнить не только координату агента, но и факт, забрана монета или нет. Проще всего включить этот признак в описание состояния.

Вариант 12. Ограничение на число шагов

Условие	Используется любая простая среда: линейный мир или GridWorld. Дополнительно вводится жёсткий лимит на длину эпизода. Если агент не успевает дойти до цели, эпизод заканчивается неудачей.
Дано	● Максимальная длина эпизода, например 10 шагов. ● Цель: +10. ● Обычный шаг: -1. ● При исчерпании лимита можно задать 0 или дополнительный штраф -5.
Требуется	● Добавить в цикл эпизода контроль максимального числа шагов. ● Проверить, как лимит влияет на обучение. ● Сделать вывод: научится ли агент действовать быстрее.
Подсказки	Это задание хорошо подходит для обсуждения практики моделирования: даже простая среда становится другой задачей, если меняется условие завершения эпизода.

Вариант 13. Случайный старт

Условие	Среда остаётся прежней, но начальное состояние выбирается случайно из двух или более допустимых вариантов. Агент должен научиться хорошей стратегии для разных стартовых условий.
Дано	● Пример линейного мира: [0] [1] [2] [3] [4] [5]. ● Старт выбирается случайно: либо состояние 1, либо состояние 4. ● Цель и проигрыш задаются как в обычном линейном мире. ● Обычный шаг: -1.
Требуется	● Реализовать случайный выбор стартового состояния в <code>reset()</code>. ● Обучить агента и сравнить поведение из разных начальных позиций. ● Вывести стратегию для всех нетерминальных состояний.
Подсказки	Такой вариант показывает, что политика должна быть общей, а не «заточенной» под один старт. Полезно отдельно посчитать долю успешных эпизодов для каждого старта.

Вариант 14. Награда зависит от длины пути

Условие	Среда обычная, но награда за достижение цели зависит от того, насколько быстро агент дошёл до неё. Чем короче путь, тем больше итоговая награда.
Дано	● Если цель достигнута за 5 шагов или меньше -> +10. ● Если цель достигнута позже -> +3. ● Обычный шаг -> -1. ● Сама структура мира может быть линейной или сеточной.
Требуется	● Учесть число шагов при вычислении награды за терминальное состояние. ● Обучить агента и проверить, стремится ли он к более коротким маршрутам. ● Сформулировать вывод о влиянии временного фактора на стратегию.
Подсказки	Награду за терминальный переход удобно вычислять внутри <code>action</code> , если среда хранит счётчик уже выполненных шагов в текущем эпизоде.

Вариант 15. Стохастическая цель

Условие	Среда содержит целевое состояние, но сама цель не гарантирует одинаковую награду. При достижении цели итоговая выплата выбирается случайным образом по заданным вероятностям.
Дано	● При достижении цели: с вероятностью 0.7 агент получает +10, с вероятностью 0.3 получает 0. ● Обычный шаг $\rightarrow$ -1. ● При наличии проигрышного состояния можно сохранить штраф -10.
Требуется	● Реализовать случайную награду в терминальном состоянии. ● Провести обучение и показать, что оценки Q формируются как усреднение по множеству эпизодов. ● Объяснить, почему при вероятностной цели нужно больше эпизодов для устойчивого результата.
Подсказки	Этот вариант хорошо иллюстрирует статистическую природу Monte Carlo-обучения. Желательно сравнить результаты при 100, 500 и 2000 эпизодах.