

1. Прямое обучение от опыта агента: общий смысл

1.1. Что такое прямое обучение

Прямое обучение от опыта агента — это такой способ обучения с подкреплением, при котором агент учится не через заранее известную модель среды, а непосредственно из собственного взаимодействия с ней.

То есть агент:

- наблюдает состояние,
- выбирает действие,
- получает награду,
- переходит в новое состояние,
- запоминает полученный опыт,
- меняет свои оценки и стратегию на основе реально пережитых переходов.

Здесь слово “**прямое**” означает, что знания извлекаются **напрямую** из **наблюдаемых траекторий**:

$$(s_t, a_t, r_{t+1}, s_{t+1})$$

без обязательного построения:

- вероятностей переходов $P(s'|s, a)$,
- модели наград $R(s, a)$,
- полной математической модели среды.

Такой подход называют **model-free** — безмодельным.

1.2. Что именно учит агент

Агент обычно учит одно или несколько из следующего:

1. Функцию ценности состояния

$$V^\pi(s)$$

Показывает, насколько выгодно находиться в состоянии s , если дальше следовать стратегии π .

2. Функцию ценности действия

$$Q^\pi(s, a)$$

Показывает, насколько выгодно в состоянии s выбрать действие a , а потом следовать стратегии π .

3. Саму стратегию

$$\pi(a|s)$$

Она задаёт правило выбора действий в состояниях.

1.3. Два больших варианта прямого обучения

Прямое обучение по опыту можно организовать по-разному. Два важнейших класса:

А. Обучение по полному возврату

Агент оценивает действие или состояние по **сумме будущих наград**.

Это классический случай эпизодического обучения, например Монте-Карло:

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

Б. Обучение по средней награде

Агент ориентируется не столько на суммарную награду до конца эпизода, сколько на **средний выигрыш в расчёте на шаг** при длительном взаимодействии.

Это особенно важно для **непрерывных задач без естественного конца**, где эпизоды либо отсутствуют, либо искусственны.

2. Почему возникает обучение по средней награде

2.1. Ограниченность эпизодической постановки

Во многих задачах удобно использовать эпизоды:

- игра началась и закончилась,
- робот стартовал и достиг цели,
- партия завершилась победой или проигрышем.

Тогда естественно говорить о суммарной награде за эпизод.

Но есть задачи другого типа:

- управление промышленной установкой,
- работа сервера,
- непрерывное обслуживание сети,
- управление транспортным потоком,
- работа рекомендательной системы,
- автономное управление устройством без чёткого конца.

В таких задачах взаимодействие может идти **неограниченно долго**, и тогда понятие "суммарной награды до конца эпизода" становится неудобным.

2.2. Проблема дисконтирования

Один стандартный выход — использовать дисконтирование:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

где $0 \leq \gamma < 1$.

Это делает бесконечную сумму конечной и математически удобной.

Но дисконтирование — это не всегда то, что хочется интерпретировать содержательно.

Оно означает, что:

- далёкие награды менее важны,
- будущее искусственно “обесценивается”.

В некоторых прикладных задачах это неестественно. Например, при долгосрочном управлении системой часто важнее не “скидка на будущее”, а **реальная средняя эффективность работы системы**.

2.3. Идея средней награды

Поэтому вводят критерий **средней награды**:

$$\rho^\pi = \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E}_\pi \left[\sum_{t=1}^n r_t \right]$$

Это средний выигрыш в расчёте на один шаг, если агент действует по стратегии π очень долго.

Такой критерий отвечает на вопрос:

Насколько в среднем эффективна данная стратегия на длинном горизонте?

3. Обучение по средней награде: интуитивный смысл

3.1. Что измеряется

Вместо вопроса:

“Какую суммарную награду я получу до конца эпизода?”

рассматривается вопрос:

“Сколько в среднем награды я получаю за один шаг при длительной работе?”

Это особенно полезно в бесконечногоризонтных задачах.

3.2. Пример интуиции

Предположим, агент управляет системой обработки заявок.

Есть две стратегии:

- стратегия А за 1000 шагов даёт 1000 единиц награды,
- стратегия В за 1000 шагов даёт 1500 единиц награды.

Тогда:

- средняя награда стратегии А: 1 за шаг,
- средняя награда стратегии В: 1.5 за шаг.

Очевидно, стратегия В лучше, даже если задача не имеет естественного конца.

3.3. Почему просто суммарная награда здесь неудобна

Если процесс бесконечный, суммарная награда стремится к бесконечности для любой “хорошей” стратегии. Тогда сравнивать стратегии по общей сумме бессмысленно: у всех она бесконечна.

Поэтому требуется нормировка — деление на число шагов.

Так возникает критерий средней награды.

4. Формальное определение средней награды

Пусть стратегия π фиксирована. Тогда её средняя награда определяется как:

$$\rho^\pi = \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E}_\pi \left[\sum_{t=0}^{n-1} r_{t+1} \right]$$

где:

- r_{t+1} — награда на шаге,
- n — число шагов,
- $\mathbb{E}_\pi$ — математическое ожидание при следовании стратегии π .

Эта величина показывает **долговременную производительность стратегии**.

4.1. Оптимальная средняя награда

Если мы сравниваем все допустимые стратегии, то ищем стратегию, которая максимизирует среднюю награду:

$$\rho^* = \max_{\pi} \rho^{\pi}$$

Та стратегия, для которой достигается максимум, считается оптимальной в смысле средней награды.

5. Почему одной средней награды недостаточно

На первый взгляд может показаться, что если у стратегии есть число ρ^{π} , то этого достаточно. Но это не так.

Средняя награда описывает **общее качество стратегии**, но не говорит, **какие именно состояния лучше, а какие хуже относительно этого среднего уровня**.

Нужен ещё один объект — **относительная ценность**.

6. Разделяющая оценка ценности стратегии: основная идея

6.1. Что значит “разделяющая”

В задачах со средней наградой общую ценность естественно представить как две части:

Часть 1. Глобальный уровень качества стратегии

$$\rho^{\pi}$$

Это средняя награда за шаг.

Часть 2. Локальное отклонение конкретного состояния от этого уровня

Обычно его обозначают как:

$$h^{\pi}(s)$$

или иногда $V_{\text{diff}}^{\pi}(s)$.

Эта функция показывает, насколько состояние s выгоднее или хуже по сравнению со средним долговременным уровнем.

Именно поэтому говорят о **разделении оценки**:

- отдельно оценивается средняя награда,
 - отдельно оценивается относительная ценность состояния.
-

6.2. Интуитивное толкование

Если ρ^π — это “средний фон” стратегии, то $h^\pi(s)$ — это “поправка” на конкретное состояние.

Например:

- стратегия в среднем приносит 2 единицы награды за шаг;
- но в одном состоянии агент находится в особенно выгодной позиции;
- в другом — в невыгодной.

Тогда:

- ρ^π одинаково для всей стратегии,
 - $h^\pi(s)$ различается от состояния к состоянию.
-

7. Дифференциальная ценность состояния

7.1. Определение

Дифференциальная, или относительная, ценность состояния при стратегии π определяется как накопленное отклонение награды от среднего уровня:

$$h^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} (r_{t+1} - \rho^\pi) \mid s_0 = s \right]$$

Интуитивно это означает:

- на каждом шаге мы сравниваем реальную награду r_{t+1} со средней наградой ρ^π ,
 - если награда выше среднего, это положительный вклад,
 - если ниже среднего, отрицательный,
 - суммарно это показывает, насколько выгодно начать именно из состояния s .
-

7.2. Почему вычитается средняя награда

Если просто суммировать награды в бесконечном процессе, сумма будет расти без ограничений.

Но если вычитать средний уровень ρ^π , то мы оцениваем не абсолютное накопление, а отклонение от нормы.

Это делает ценность осмысленной:

- положительная $h^\pi(s)$ — состояние лучше среднего,
 - отрицательная $h^\pi(s)$ — состояние хуже среднего.
-

8. Уравнение Беллмана для средней награды

В классическом дисконтированном случае Беллман выглядит так:

$$V^\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a) [r + \gamma V^\pi(s')]$$

В случае средней награды используется другое уравнение:

$$\rho^\pi + h^\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a) [r + h^\pi(s')]$$

или эквивалентно:

$$h^\pi(s) = \sum_a \pi(a|s) \sum_{s',r} p(s', r|s, a) [r - \rho^\pi + h^\pi(s')]$$

8.1. Смысл этого уравнения

Оно говорит, что ценность состояния складывается из:

- немедленной награды,
- минус средняя награда,
- плюс ценность следующего состояния.

То есть теперь шаг оценивается не как:

“получу награду и перейду в будущее”

а как:

“получу награду относительно среднего фона и перейду в следующее состояние”.

9. Дифференциальная ценность действия

Аналогично можно определить функцию относительной ценности действия:

$$q^{\pi}(s, a) = \sum_{s', r} p(s', r | s, a) [r - \rho^{\pi} + h^{\pi}(s')]$$

Она показывает, насколько выгодно в состоянии s выбрать действие a , если далее продолжать следовать стратегии π , с учётом того, что общий фоновый выигрыш ρ^{π} уже вынесен отдельно.

10. Почему это называется управлением

10.1. Оценка против управления

В RL различают две задачи:

1. Оценка стратегии

Нужно понять, насколько хороша уже заданная стратегия.

2. Управление

Нужно не просто оценить, а **найти или приблизить оптимальную стратегию**.

Когда говорится “**управление с разделяющей оценкой ценности стратегии**”, имеется в виду, что агент:

- оценивает стратегию через две составляющие,
 - использует эти оценки для улучшения стратегии,
 - стремится выйти на оптимальную стратегию по критерию средней награды.
-

10.2. Как улучшается стратегия

Если агент знает относительные ценности действий $q(s, a)$, то он может выбирать действие с максимальной ценностью:

$$\pi_{\text{new}}(s) = \arg \max_a q(s, a)$$

Это означает: выбирается действие, которое даёт наибольшее превышение над средним уровнем награды в долгосрочной перспективе.

11. Прямое обучение по средней награде из опыта

Теперь перейдём к самому важному: как агент учится этому не зная модели среды, то есть по непосредственному опыту.

11.1. Основная идея

Агент наблюдает переходы:

$$(s_t, a_t, r_{t+1}, s_{t+1})$$

и должен в процессе взаимодействия оценивать:

- среднюю награду ρ ,
 - относительные ценности $h(s)$ или $q(s, a)$,
 - и на основе этого улучшать стратегию.
-

11.2. В чём отличие от дисконтированного обучения

В дисконтированных методах обновление строится на величине вроде:

$$r_{t+1} + \gamma V(s_{t+1}) - V(s_t)$$

В случае средней награды естественная ошибка обучения выглядит так:

$$\delta_t = r_{t+1} - \rho + h(s_{t+1}) - h(s_t)$$

или в действием-ориентированной форме:

$$\delta_t = r_{t+1} - \rho + \max_{a'} Q(s_{t+1}, a') - Q(s_t, a_t)$$

Это аналог TD-ошибки, но вместо γ здесь появляется вычитание средней награды ρ .

12. Ошибка обучения при средней награде

12.1. Определение

Ключевая величина:

$$\delta_t = r_{t+1} - \rho_t + h_t(s_{t+1}) - h_t(s_t)$$

где:

- r_{t+1} — реально полученная награда,

- ρ_t — текущая оценка средней награды,
 - $h_t(s)$ — текущая оценка относительной ценности.
-

12.2. Интуиция

Эта ошибка показывает, насколько:

- текущая награда оказалась выше или ниже среднего уровня,
- плюс насколько полезным оказалось следующее состояние относительно текущего.

Если $\delta_t > 0$, переход оказался лучше, чем ожидалось.

Если $\delta_t < 0$, хуже.

13. Обновление оценки средней награды

Поскольку ρ неизвестно, агент должен её оценивать. Обычно обновление записывают так:

$$\rho_{t+1} = \rho_t + \beta \delta_t$$

где β — малая скорость обучения для средней награды.

Это означает:

- если наблюдаемая ситуация систематически лучше текущей оценки среднего, ρ увеличивается;
- если хуже — уменьшается.

Иногда ρ обновляют не на каждом шаге, а только на некоторых шагах, например при выборе жадного действия. Но базовая идея именно такая: средняя награда подстраивается по наблюдаемой TD-ошибке.

14. Обновление относительной ценности состояния

Для функции $h(s)$ типичное TD-обновление:

$$h_{t+1}(s_t) = h_t(s_t) + \alpha \delta_t$$

а значения других состояний не меняются.

Здесь α — скорость обучения ценности.

Таким образом агент подстраивает относительную ценность состояния под реальный опыт.

15. Обновление ценности действия

Если агент учит $Q(s, a)$, а не $h(s)$, то обновление может иметь вид:

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha \left(r_{t+1} - \rho_t + \max_{a'} Q_t(s_{t+1}, a') - Q_t(s_t, a_t) \right)$$

Это аналог Q-learning, но в постановке **средней награды**, а не дисконтированного возврата.

16. R-learning как типичный пример

Одним из известных алгоритмов для обучения по средней награде является **R-learning**.

Он специально рассчитан на задачу максимизации средней награды.

16.1. Идея R-learning

Алгоритм оценивает:

- $R(s, a)$ — относительную ценность действия,
- ρ — среднюю награду.

Обновление ценности действия:

$$R(s_t, a_t) \leftarrow R(s_t, a_t) + \alpha \left(r_{t+1} - \rho + \max_a R(s_{t+1}, a) - R(s_t, a_t) \right)$$

Обновление средней награды:

$$\rho \leftarrow \rho + \beta \left(r_{t+1} + \max_a R(s_{t+1}, a) - \max_a R(s_t, a) - \rho \right)$$

обычно при определённых условиях, например когда выбранное действие жадное.

16.2. Почему здесь две оценки

Алгоритм одновременно решает две задачи:

Первая

Найти общий средний выигрыш стратегии.

Вторая

Понять, какие состояния и действия относительно этого фона особенно хороши.

Без первой оценки нельзя правильно нормировать выигрыш.

Без второй нельзя выбирать лучшие действия.

17. Что значит “разделяющая оценка ценности стратегии” в содержательном смысле

Этот термин можно понять так:

17.1. Ценность стратегии не хранится одним числом

Она раскладывается на две компоненты:

ценность стратегии = средний уровень + относительное отклонение

то есть:

$$\text{Value} = \rho^\pi + h^\pi(s)$$

или для действий:

$$\text{Action value} = \rho^\pi + q^\pi(s, a)$$

17.2. Зачем такое разделение нужно

Оно позволяет различать:

- насколько в целом хороша стратегия,
- и насколько конкретное состояние/действие лучше или хуже среднего режима работы.

Это особенно важно в стационарных бесконечных задачах.

18. Сравнение с дисконтированной ценностью

18.1. Дисконтированная постановка

Там ценность состояния:

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \mid s_t = s \right]$$

То есть оценивается полная сумма будущих наград с дисконтированием.

18.2. Постановка средней награды

Здесь вместо этого вводятся:

- средняя награда ρ^π ,
- относительная ценность $h^\pi(s)$.

Это полезно, потому что для бесконечных процессов именно такое представление отражает стационарную природу задачи.

18.3. Принципиальное различие

В дисконтированном случае функция ценности уже сама по себе является конечным “интегральным” показателем.

В случае средней награды одна функция ценности уже недостаточна: нужно выделять фон и отклонение от фона.

19. Пример на интуитивном уровне

Представим систему, где агент управляет тремя режимами работы устройства:

- режим А даёт награду примерно 2 за шаг,
- режим В — примерно 1 за шаг,
- режим С — примерно 3 за шаг, но иногда переводит систему в плохие состояния.

Агент должен не просто посмотреть на мгновенные награды, а понять:

1. каков средний выигрыш стратегии в целом;
2. какие состояния после определённых действий являются стратегически выгодными;
3. какие действия дают устойчивое превышение над средним уровнем.

Тогда:

- ρ отражает “среднюю производительность”,
- $h(s)$ показывает, насколько состояние s является удачным или неудачным относительно этой производительности,

- стратегия выбирает действия, повышающие долгосрочное отклонение над средним.
-

20. Задача управления: пошаговая схема

Теперь запишем логически, как работает управление с разделяющей оценкой.

Шаг 1. Инициализация

Задаются начальные оценки:

- $Q(s, a)$ или $h(s)$,
 - ρ ,
 - стратегия исследования, например ε -жадная.
-

Шаг 2. Наблюдение текущего состояния

Агент получает состояние s_t .

Шаг 3. Выбор действия

Выбирается действие a_t :

- либо жадно по текущим оценкам,
 - либо случайно с небольшой вероятностью для исследования.
-

Шаг 4. Выполнение действия

Агент получает:

- награду r_{t+1} ,
 - новое состояние s_{t+1} .
-

Шаг 5. Вычисление ошибки

Например, в варианте с действиями:

$$\delta_t = r_{t+1} - \rho_t + \max_{a'} Q_t(s_{t+1}, a') - Q_t(s_t, a_t)$$

Шаг 6. Обновление ценности

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha \delta_t$$

Шаг 7. Обновление средней награды

$$\rho_{t+1} = \rho_t + \beta \delta_t$$

или одна из близких форм.

Шаг 8. Улучшение стратегии

Агент всё чаще выбирает действия с лучшими относительными ценностями.

21. Почему здесь важны две скорости обучения

Обычно используются две скорости:

- α — для ценностей состояний/действий,
- β — для средней награды.

Это нужно потому, что:

- относительные ценности могут меняться быстрее,
- средняя награда должна стабилизироваться аккуратнее.

Часто β выбирают меньше, чем α .

22. Оценка стратегии и управление: различие в этой теме

22.1. Если стратегия фиксирована

Тогда задача — просто оценить:

- среднюю награду ρ^π ,
- относительные ценности $h^\pi(s)$ или $q^\pi(s, a)$.

Это **prediction** — предсказание или оценка.

22.2. Если стратегия улучшается

Тогда после оценки агент меняет правило выбора действий, стремясь максимизировать среднюю награду.

Это уже **control** — управление.

23. Содержательная роль относительной ценности

Средняя награда ρ сама по себе не помогает выбрать действие в конкретном состоянии, потому что она глобальна.

Для выбора действия нужна **структура различий** между состояниями и действиями.

Именно это дают:

- $h(s)$ — относительная ценность состояний,
- $q(s, a)$ — относительная ценность действий.

Они отвечают на вопрос:

Какой выбор улучшает положение относительно обычного среднего режима?

24. Связь с преимуществом действия

В некотором смысле относительная ценность близка по идее к понятию **advantage**:

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

В задачах средней награды роль “базового уровня” играет не только ценность состояния, но и сама средняя награда ρ .

Поэтому разделяющая оценка — это родственник идеи “baseline + advantage”: мы выносим общий фон отдельно, а локальную полезность оцениваем отдельно.

25. Преимущества обучения по средней награде

25.1. Естественность для непрерывных задач

Метод хорошо соответствует задачам без эпизодов и без естественного конца.

25.2. Содержательная интерпретация

Часто средняя производительность системы — более естественный критерий, чем дисконтированная сумма.

25.3. Устойчивость долгосрочного критерия

Оптимизируется именно то, что важно на длинном горизонте: награда в среднем за единицу времени.

26. Недостатки и сложности

26.1. Более сложная теория

По сравнению с обычной дисконтированной постановкой здесь нужно одновременно оценивать:

- и средний выигрыш,
 - и относительные ценности.
-

26.2. Трудности настройки

Нужно аккуратно выбирать скорости обучения, чтобы:

- ρ не колебалась слишком сильно,
 - ценности не расходились,
 - стратегия успевала адаптироваться.
-

26.3. Сложность анализа сходимости

Математически методы средней награды часто сложнее, чем привычные дисконтированные TD-методы.

27. Пример псевдокода

Ниже упрощённый общий псевдокод управления по средней награде.

```
Инициализировать  $Q(s,a)$  произвольно  
Инициализировать  $\rho$  произвольно  
Задать  $\alpha, \beta, \epsilon$ 
```

```
Повторять для каждого шага:
```



```
наблюдать состояние  $s$ 
```

```
выбрать действие  $a$ :
```

```
    с вероятностью  $\epsilon$  случайное действие
```

```
    иначе  $a = \operatorname{argmax}_a Q(s, a)$ 
```

```
выполнить  $a$ , получить награду  $r$  и новое состояние  $s'$ 
```

```
 $\delta = r - \rho + \max_{a'} Q(s', a') - Q(s, a)$ 
```

```
 $Q(s, a) = Q(s, a) + \alpha * \delta$ 
```

```
 $\rho = \rho + \beta * \delta$ 
```

```
# или близкое правило обновления  $\rho$ 
```

```
 $s = s'$ 
```

Это общий принцип. Конкретные алгоритмы могут отличаться в деталях.

28. Концептуальная разница между двумя постановками

Ниже главное различие в одной таблице.

Постановка	Что оптимизируется	Главная ценность
Дисконтированная	сумма дисконтированных наград	$V(s), Q(s, a)$
Средняя награда	средняя награда за шаг	$\rho, h(s), q(s, a)$

То есть в дисконтированной задаче критерий “вшит” в саму функцию ценности, а в задаче средней награды критерий и локальная ценность разделены.

29. Как это понимать в учебном смысле

Если формулировать совсем просто:

Прямое обучение от опыта агента

Агент учится на реально наблюдаемых переходах, а не по заранее известной модели среды.

Обучение по средней награде

Агент оценивает качество стратегии по тому, сколько награды она приносит в среднем за один шаг на длинном промежутке времени.

Управление с разделяющей оценкой ценности стратегии

Агент хранит и обновляет две разные характеристики стратегии:

- средний общий уровень награды,
- относительные ценности состояний или действий по отношению к этому уровню,

и использует их для улучшения поведения.

30. Итоговая формулировка

Можно дать такое итоговое определение.

Прямое обучение от опыта агента в постановке средней награды — это безмодельный подход обучения с подкреплением, в котором агент на основе последовательности реально наблюдаемых переходов оценивает долгосрочную среднюю награду стратегии и относительные ценности состояний или действий, а затем использует эти оценки для улучшения стратегии.

Управление с разделяющей оценкой ценности стратегии означает, что ценность стратегии представляется не одной функцией, а как сочетание:

долговременной средней награды ρ

и

относительной ценности $h(s)$ или $q(s, a)$,

что позволяет отдельно учитывать:

- общий уровень эффективности стратегии,
 - и локальное качество конкретных состояний и действий.
-

31. В самом сжатом виде

Ключевые формулы темы:

Средняя награда стратегии

$$\rho^\pi = \lim_{n \rightarrow \infty} \frac{1}{n} \mathbb{E}_\pi \left[\sum_{t=0}^{n-1} r_{t+1} \right]$$

Дифференциальная ценность состояния

$$h^{\pi}(s) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} (r_{t+1} - \rho^{\pi}) \mid s_0 = s \right]$$

TD-ошибка для средней награды

$$\delta_t = r_{t+1} - \rho_t + h_t(s_{t+1}) - h_t(s_t)$$

или для Q -оценок:

$$\delta_t = r_{t+1} - \rho_t + \max_{a'} Q_t(s_{t+1}, a') - Q_t(s_t, a_t)$$

Обновление ценности

$$Q_{t+1}(s_t, a_t) = Q_t(s_t, a_t) + \alpha \delta_t$$

Обновление средней награды

$$\rho_{t+1} = \rho_t + \beta \delta_t$$
