

ОБУЧЕНИЕ НА ОСНОВЕ МОДЕЛЕЙ В ОБУЧЕНИИ С ПОДКРЕПЛЕНИЕМ

Подробный теоретический материал
по темам: модель среды, использование модели и
эвристический поиск

1. Введение

Обучение с подкреплением изучает, как агент должен действовать в среде, чтобы максимизировать суммарную награду. В классической постановке агент последовательно наблюдает состояние среды, выбирает действие, получает числовую награду и переходит в новое состояние. Постепенно он формирует стратегию поведения, то есть правило выбора действий в зависимости от ситуации.

Существует два больших семейства методов обучения с подкреплением. Первое семейство — безмодельные методы. Они не строят явного представления динамики среды и учатся напрямую оценивать полезность состояний, действий или саму стратегию. Второе семейство — методы обучения на основе моделей. В них агент либо заранее располагает моделью среды, либо строит её по собранному опыту и затем использует для планирования, прогнозирования последствий действий и ускорения обучения.

Идея модельного подхода чрезвычайно важна: если агент умеет хотя бы приблизительно предсказывать, что произойдёт после действия, он может рассуждать не только по уже пережитому опыту, но и по мысленно проигрываемым сценариям. Благодаря этому снижается цена ошибок, возрастает эффективность использования данных и появляется возможность более осмысленного поиска решений.

2. Понятие модели в обучении с подкреплением

Под моделью в обучении с подкреплением понимают описание поведения среды, которое позволяет предсказывать результаты действий агента. В самом общем виде модель должна отвечать минимум на два вопроса: в какое состояние попадёт агент после выбора действия и какую награду он при этом получит. Иначе говоря, модель описывает динамику переходов и механизм формирования награды.

Если обозначить текущее состояние через s , действие через a , следующее состояние через s' , а награду через r , то модель может задаваться в вероятностной форме как распределение $p(s', r | s, a)$. Такое описание особенно естественно для стохастических сред, где одно и то же действие в одинаковом состоянии может приводить к различным последствиям с некоторыми вероятностями.

В детерминированном случае модель может быть представлена как две функции: функция перехода $T(s, a)$, возвращающая следующее состояние, и функция награды $R(s, a)$ или $R(s, a, s')$, возвращающая соответствующую награду. В стохастическом случае переходы и награды задаются

распределениями, а потому модель хранит либо сами вероятности, либо параметры, из которых эти вероятности можно вычислить.

2.1. Какие компоненты включает модель

- Модель переходов: описание того, как действия изменяют состояние среды.
- Модель награды: описание того, какая награда возникает при выполнении действия.
- Иногда дополнительно — модель наблюдений, если агент видит не полное состояние, а лишь частичное наблюдение.
- При необходимости — модель терминальности, то есть правило завершения эпизода.

С практической точки зрения модель может быть полной и частичной. Полная модель позволяет выполнять планирование практически так же, как если бы агент взаимодействовал с реальной средой. Частичная модель описывает только отдельные аспекты, например только переходы без точной награды, либо корректно работает лишь в ограниченной области пространства состояний.

2.2. Источники модели

Модель может быть получена тремя основными способами. Во-первых, она может быть дана заранее как часть постановки задачи. Это характерно для хорошо формализованных сред: настольные игры, задачи управления с известными уравнениями, маршрутизация по заранее известной карте. Во-вторых, модель может быть оценена по данным, накопленным в ходе взаимодействия агента со средой. В этом случае говорят о *learned model*, то есть модели, выученной из опыта. В-третьих, может использоваться гибридный подход: часть структуры среды известна, а часть параметров уточняется по наблюдениям.

Таким образом, модель — это не просто вспомогательная таблица. Это средство внутреннего представления причинно-следственных связей в задаче: какие действия к чему приводят, какие последствия выгодны, а какие — нет.

3. Зачем нужна модель среды

Наличие модели делает обучение качественно более сильным. Без модели агент учится только на реально случившихся переходах. С моделью он получает дополнительный источник опыта: мысленные эксперименты. Агент может рассматривать альтернативные действия, которые он ещё не предпринимал в текущем состоянии, прогнозировать их результаты и обновлять свои оценки без непосредственного обращения к реальной среде.

Модель особенно ценна в ситуациях, где взаимодействие со средой дорого, медленно или опасно. Например, при управлении техническим объектом ошибка может привести к поломке, в робототехнике — к падению робота, в финансовых системах — к реальным потерям. В этих условиях возможность сначала «проиграть» сценарии внутри модели значительно повышает надёжность и экономичность обучения.

3.1. Сравнение безмодельного и модельного подходов

Характеристика	Без модели	С моделью
Источник обучения	Только реальные переходы	Реальные и смоделированные переходы
Планирование	Практически отсутствует	Есть, иногда является центральным элементом
Требование к данным	Обычно выше	Ниже при хорошей модели
Риск ошибок модели	Нет ошибки модели	Есть риск смещения из-за неточной модели
Скорость реакции на новые цели	Нередко ниже	Выше за счёт перепланирования

4. Использование данных о модели в обучении с подкреплением

Использование модели сводится не только к предсказанию следующего шага. В модельном обучении данные о среде применяются для решения сразу нескольких задач: планирование на несколько шагов вперёд, улучшение стратегии, генерация дополнительного обучающего опыта, оценка долгосрочных последствий действий и более глубокое исследование пространства состояний.

4.1. Планирование

Планирование — это вычисление качественного плана действий с опорой на модель среды. Получив текущее состояние, агент может мысленно развернуть дерево возможных действий и переходов, оценить накопленную награду по ветвям и выбрать наиболее перспективное действие. При этом расчёт может быть как исчерпывающим, так и приближённым.

Если среда невелика и модель известна точно, применяют динамическое программирование: итерации по ценности, итерации по стратегии и другие методы вычисления оптимальной стратегии на основе уравнений Беллмана. Если пространство состояний велико, используют

ограниченное по глубине планирование, выборочные симуляции, Monte Carlo Tree Search и различные эвристики.

4.2. Генерация искусственного опыта

Одно из сильнейших применений модели состоит в генерации дополнительных переходов, которых агент в действительности не переживал. Зная или оценивая $p(s', r | s, a)$, можно брать уже посещённые состояния, мысленно запускать из них разные действия и пополнять обучающую выборку синтетическими примерами. Это резко увеличивает информационную отдачу каждого реального шага взаимодействия.

Именно на этой идее основаны архитектуры типа Dyna. Агент одновременно учится по реальному опыту и обучает модель среды. Затем с помощью модели он создаёт дополнительные воображаемые переходы и обновляет оценки так, будто действительно прошёл эти участки среды. В результате реальные наблюдения используются многократно: сначала напрямую, потом косвенно через модель.

4.3. Улучшение стратегии через look-ahead

Даже если у агента уже есть приближённая стратегия, модель позволяет усилить её локальным просмотром вперёд. Допустим, стратегия предлагает выбрать действие a . Агент может сравнить не только непосредственную награду этого действия, но и результаты на 2–5 шагов вперёд, оценив несколько сценариев. Такой механизм нередко приводит к лучшему выбору, чем чистое следование текущей стратегии.

Эта идея важна и в комбинации с нейросетями. Сеть может быстро предлагать априорные вероятности действий и оценку ценности состояния, а модель и поиск уточняют решение, устраняя часть ошибок грубой аппроксимации.

4.4. Обнаружение редких, но важных последствий

Модель помогает учитывать отдалённые и редкие последствия действий. Без неё агент часто переоценивает краткосрочные выгоды и недооценивает длинные цепочки событий. С помощью модели можно проследить, что действие, дающее небольшую награду сейчас, приводит к попаданию в область состояний с высокими долгосрочными потерями, или наоборот открывает путь к крупной будущей награде.

5. Виды моделей в обучении с подкреплением

По способу представления и получения модели можно выделить несколько типичных классов.

- Табличные модели. Для каждого состояния и действия хранятся вероятности переходов и ожидаемые награды. Подход удобен в малых дискретных средах.
- Параметрические модели. Переходы и награды задаются через параметры некоторой функции, например линейной регрессии или нейронной сети.
- Детерминированные модели. Для пары «состояние–действие» возвращается одно предсказанное следствие.
- Стохастические модели. Возвращается распределение возможных исходов либо выборка из такого распределения.
- Локальные модели. Корректны лишь в части пространства состояний или в окрестности текущей траектории.
- Абстрактные модели. Описывают не исходные наблюдения, а более компактные скрытые представления среды.

6. Преимущества и ограничения модельного обучения

Главное преимущество модельного подхода — высокая эффективность использования данных. Один реальный переход может быть «размножен» в процессе планирования и использован многократно. Кроме того, модель облегчает перенос знаний: если меняется целевая функция или появляются новые ограничения, агент может перепланировать поведение, не начиная обучение с нуля.

Однако модельное обучение несёт и серьёзный риск: ошибка модели способна систематически исказить поведение агента. Если агент многократно планирует внутри неверной модели, он начинает уверенно принимать неправильные решения. Это называют накоплением ошибки модели. Особенно опасна ситуация долгого воображаемого rollout, когда небольшая локальная неточность разрастается с каждым шагом.

Отсюда вытекают важные инженерные следствия. Модель должна регулярно сверяться с реальными данными. Горизонт планирования не всегда следует делать большим. Часто полезно комбинировать короткое модельное планирование с безмодельной оценкой ценности или ограничивать поиск наиболее надёжными частями модели.

7. Эвристический поиск

Эвристический поиск — это способ направленного перебора вариантов, при котором для выбора наиболее перспективных ветвей используется эвристика, то есть приближённая оценка близости к цели или ожидаемой полезности состояния. В контексте обучения с подкреплением эвристический поиск тесно связан с моделью: чтобы исследовать будущее, нужно уметь хотя бы приблизительно предсказывать последствия действий.

В отличие от слепого перебора, эвристический поиск стремится не рассматривать все возможные продолжения одинаково. Он концентрирует вычислительные ресурсы на тех направлениях, которые выглядят более выгодными. Это особенно важно в задачах с огромным пространством состояний, где полный перебор невозможен.

7.1. Что такое эвристика

Эвристика — это функция, оценивающая перспективность состояния или частичного плана. Она может выражать приблизительное расстояние до цели, ожидаемую будущую награду, риск, стоимость достижения результата или иную полезную характеристику. В задачах поиска пути эвристика часто оценивает оставшуюся дистанцию, а в обучении с подкреплением она нередко играет роль приближённой функции ценности.

Важно понимать, что эвристика не обязана быть точной. Её задача — не идеально вычислить ответ, а сделать поиск существенно эффективнее. Хорошая эвристика снижает число проверяемых вариантов и ускоряет нахождение качественного решения. Плохая эвристика, напротив, может увести поиск в ложные области.

7.2. Как эвристический поиск используется в RL

- Для выбора действия с просмотром на несколько шагов вперёд.
- Для сокращения дерева поиска: разворачиваются только самые многообещающие ветви.
- Для задания порядка рассмотрения действий.
- Для комбинирования со значением состояния: глубина поиска ограничена, а оставшаяся часть оценивается эвристикой или value-функцией.

Классический пример — алгоритм A* в задачах маршрутизации. Хотя сам A* обычно рассматривают как алгоритм поиска пути, по смыслу он демонстрирует, как эвристика помогает использовать модель переходов для целенаправленного движения к цели. В более общем RL-подходе эвристика может оценивать не расстояние, а ожидаемую суммарную награду.

Другой важный пример — Monte Carlo Tree Search. Этот метод строит дерево решений не полностью, а выборочно, концентрируясь на ветвях, которые кажутся перспективными по накопленной статистике и априорным оценкам. В современных системах эвристические оценки часто выдаются нейросетью, а поиск использует их для фокусировки вычислений.

7.3. Связь эвристики с функцией ценности

Во многих задачах граница между эвристикой и функцией ценности размыта. Если агент уже умеет приближённо оценивать ценность состояния, эта оценка естественным образом становится эвристикой для поиска. Тогда поиск и обучение взаимно усиливают друг друга: ценностная функция направляет поиск, а результаты поиска дают более качественные целевые значения для последующего обучения.

8. Типовая схема модельного обучения

Обобщённую схему работы агента, обучающегося на основе модели, можно описать так:

- Агент взаимодействует со средой и собирает реальные переходы.
- По накопленным данным обновляется модель переходов и награды.
- С использованием модели выполняется планирование или генерация искусственного опыта.
- Обновляются функция ценности, стратегия или оба компонента.
- Улучшенная стратегия снова применяется в реальной среде, и цикл повторяется.

Эта схема подчёркивает, что модель не заменяет реальный опыт полностью. Она усиливает обучение, но сама должна подпитываться наблюдениями. Чем точнее и полезнее модель, тем больше выигрывает агент. Чем сложнее среда и чем хуже калибрована модель, тем осторожнее нужно использовать результаты планирования.

9. Практические замечания

- Если среда мала и известна, модельный подход часто приводит к почти точному решению.
- Если среда сложна, полезно строить не полную модель всего мира, а компактную модель наиболее значимых аспектов динамики.
- Длинные воображаемые траектории опасны, если модель ещё неточна.
- Нередко лучший результат даёт гибрид: модель отвечает за локальное планирование, а безмодельный компонент — за устойчивую оценку долгосрочной ценности.

10. Заключение

Обучение на основе моделей — это направление обучения с подкреплением, в котором агент использует представление динамики среды для прогнозирования, планирования и повышения эффективности обучения. Понятие модели включает описание переходов, наград и, при необходимости, других аспектов взаимодействия. Данные о модели позволяют не только предсказывать следующий шаг, но и проводить

мысленные эксперименты, улучшать стратегию, оценивать долгосрочные последствия действий и уменьшать потребность в дорогом реальном опыте.

Эвристический поиск выступает естественным продолжением этой идеи: имея модель, агент может не просто перебирать будущее, а направлять поиск с помощью приближённых оценок перспективности состояний. В результате соединяются три мощных механизма — представление среды, обучение по опыту и целенаправленное планирование. Именно эта связка делает модельное обучение одним из наиболее содержательных и практически значимых разделов современного обучения с подкреплением.

11. Краткие выводы для запоминания

- Модель в RL описывает, к каким состояниям и наградам приводят действия агента.
- Модель может быть известной заранее, выученной из данных или гибридной.
- Главное достоинство модели — возможность планирования и генерации дополнительного опыта.
- Главный риск — систематическая ошибка модели и накопление смещения при длинных прогнозах.
- Эвристический поиск использует приближённые оценки, чтобы исследовать прежде всего самые перспективные варианты.