

ЗАДАЧИ ОБУЧЕНИЯ С ПОДКРЕПЛЕНИЕМ, В КОТОРЫХ ТРЕБУЕТСЯ ОЦЕНКА ФУНКЦИИ

Характеристики состояния системы.

Алгоритмы машинного обучения для оценки функции ценности (цены/стоимости)

Учебный материал / конспект

Подготовлено в структурированном виде для печати и самостоятельного изучения

Важно: в русскоязычной литературе по обучению с подкреплением встречаются термины «функция ценности», «функция стоимости», «функция цены» и «функция полезности». В данной методичке основной используется термин «функция ценности», а выражение «функция цены» трактуется как близкое по смыслу и относящееся к оценке ожидаемой выгоды или потерь.

1. Общая постановка задачи

Обучение с подкреплением рассматривает ситуацию, в которой агент взаимодействует со средой, наблюдает состояние системы, выбирает действие, получает награду и переходит в новое состояние. Цель агента состоит не в разовом выборе удачного действия, а в выработке такой стратегии поведения, которая максимизирует суммарную ожидаемую награду на длительном горизонте.

Во многих практических задачах невозможно заранее выписать оптимальную стратегию в явном виде. Пространство состояний слишком велико, среда может быть частично стохастической, а последствия решения проявляются лишь через несколько шагов. Поэтому центральной подзадачей становится оценка функции, которая позволяет количественно сравнивать состояния, действия и целые траектории. Именно такая оценка превращает обучение в систематический процесс выбора лучшего поведения, а не в перебор случайных действий.

Под «оценкой функции» в контексте RL обычно понимают построение приближенной зависимости, связывающей состояние или пару «состояние–действие» с ожидаемым будущим выигрышем. Если агент умеет оценивать такие величины, то он может отвечать на ключевые вопросы: насколько перспективно текущее состояние, какое действие лучше выполнить сейчас, насколько хороша текущая стратегия и нужно ли ее изменить.

2. Какие задачи RL требуют оценки функции

Оценка функции нужна почти во всех нетривиальных постановках обучения с подкреплением. Ниже перечислены наиболее важные классы задач, где без функциональной аппроксимации или хотя бы без вычисления оценок ценности обойтись невозможно.

- Оценка стратегии. Требуется определить, насколько хороша фиксированная стратегия, то есть какова ожидаемая суммарная награда при следовании ей из каждого состояния.
- Улучшение стратегии. Чтобы заменить текущую стратегию на лучшую, нужно уметь сравнивать альтернативные действия по их ожидаемой ценности.
- Управление в больших пространствах состояний. Если состояние описывается десятками или сотнями признаков, хранить табличные значения невозможно; нужна приближенная функция.
- Предсказание долгосрочных последствий. Когда награда запаздывает, локальные наблюдения недостаточны, и требуется оценивать отложенный эффект решений.
- Обучение в непрерывных задачах управления. В робототехнике, экономике, энергетике и логистике состояние и действия часто непрерывны, что делает табличные методы неприменимыми.
- Обобщение опыта. Агент должен переносить выводы с уже посещенных состояний на похожие, иначе обучение будет слишком медленным.

Таким образом, задача оценки функции является мостом между сырыми данными взаимодействия и рациональным управлением. Именно она обеспечивает обобщение, устойчивость и масштабируемость методов RL.

3. Какие функции оцениваются в RL

В теории и практике обучения с подкреплением выделяют несколько взаимосвязанных функций.

1. Функция ценности состояния $V(s)$ — ожидаемый суммарный дисконтированный выигрыш при старте из состояния s и дальнейшем следовании выбранной стратегии.
2. Функция ценности пары состояние–действие $Q(s, a)$ — ожидаемый суммарный выигрыш, если в состоянии s выполнить действие a , а затем продолжать согласно стратегии.
3. Функция преимущества $A(s, a)$ — показывает, насколько действие a лучше или хуже среднего поведения в состоянии s . Она полезна для стабилизации градиентных методов.
4. Модель переходов и наград — в ряде алгоритмов дополнительно оцениваются вероятности переходов и математические ожидания награды. Это тоже можно трактовать как функциональную оценку, но уже на уровне модели среды.

Функция	Что оценивает	Для чего используется
$V(s)$	Качество состояния как стартовой точки	Оценка стратегии, критик, анализ траекторий
$Q(s, a)$	Качество конкретного действия в состоянии	Выбор действия, Q-learning, SARSA, DQN
$A(s, a)$	Относительное преимущество действия	Actor-Critic, PPO, A2C/A3C

$P(s' s,a), R(s,a)$	Динамику среды и ожидаемую награду	Планирование, model-based RL
---------------------	------------------------------------	------------------------------

4. Характеристики состояния системы

Состояние системы — это информационное описание ситуации, которое агент получает от среды и использует для принятия решения. Качество обучения в значительной степени определяется тем, насколько правильно выбрано представление состояния. Если оно бедное и не содержит существенных признаков, то даже мощный алгоритм не сможет восстановить адекватную функцию ценности.

Характеристики состояния можно разделить на несколько групп.

4.1. Структурные характеристики

- Полнота описания. Состояние должно содержать все существенные переменные, от которых зависят будущие награды и переходы.
- Марковость. Желательно, чтобы текущее состояние было достаточной статистикой прошлого: если известен текущий вектор признаков, история не нужна.
- Разрешающая способность. Состояние должно различать ситуации, в которых оптимальные действия различаются.
- Компактность. Избыточные признаки затрудняют обучение и повышают требования к данным.

4.2. Числовые и семантические характеристики

- Непрерывные признаки: координаты, скорость, температура, уровень запасов, цена ресурса, время до дедлайна.
- Категориальные признаки: режим работы, тип объекта, класс клиента, тип препятствия, стадия технологического процесса.
- Булевы индикаторы: авария/норма, цель достигнута/не достигнута, ресурс доступен/недоступен.
- Временные признаки: номер шага, сезон, час, фаза цикла, время простоя.
- Агрегированные показатели: средняя нагрузка, накопленная задержка, остаток энергии, число ошибок за интервал.

4.3. Требования к признаковому описанию состояния

При построении характеристик состояния особенно важны масштабирование, устойчивость к шуму и интерпретируемость. Разные признаки могут иметь несопоставимые диапазоны значений, поэтому без нормализации нейросетевые и линейные методы обучаются хуже. Если данные шумные, полезно использовать сглаживание, скользящие окна, фильтры или агрегированные статистики. Если система применяется в управлении реальным объектом, желательно сохранять смысл признаков, чтобы можно было анализировать причины тех или иных решений агента.

Критерий	Хорошее состояние	Плохое состояние
----------	-------------------	------------------

Полнота	Содержит все ключевые переменные процесса	Не включает факторы, влияющие на награду
Компактность	Лишние признаки удалены	Есть шумовые и дублирующие признаки
Масштаб	Признаки нормированы и сопоставимы	Диапазоны сильно различаются
Интерпретируемость	Понятно, как признак влияет на решение	Признаки трудно объяснить содержательно

5. Почему оценка функции становится необходимой

В простейших учебных задачах можно хранить значения $V(s)$ или $Q(s,a)$ в таблице. Однако в реальных системах число состояний может быть огромным или бесконечным. Например, если робот описывается координатами, скоростями и углами, то даже грубая дискретизация приводит к взрывному росту числа комбинаций. В таких условиях требуется не хранение всех значений, а построение функции-аппроксиматора, которая по признаковому описанию состояния выдаёт оценку ценности.

Оценка функции позволяет обобщать опыт. Если агент научился тому, что состояния с похожими параметрами обычно приводят к схожим результатам, то знания переносятся на ранее не встречавшиеся состояния. Это и есть главный выигрыш от машинного обучения в RL: агент не просто запоминает, а выявляет закономерности.

6. Алгоритмы машинного обучения для оценки функции ценности

Методы оценки функции ценности можно условно разделить на линейные, нелинейные классические и нейросетевые. Выбор класса алгоритма зависит от размера данных, требований к скорости, интерпретируемости и сложности закономерностей.

6.1. Линейная аппроксимация

Линейная модель предполагает, что ценность представима как взвешенная сумма признаков: $V(s) \approx w^T x(s)$, где $x(s)$ — вектор признаков состояния. Несмотря на простоту, такой подход важен методологически: он хорошо интерпретируется, быстро обучается и часто служит базовой моделью.

- Преимущества: простота, малое число параметров, устойчивость, понятность весов.
- Недостатки: ограниченная выразительность, слабая способность описывать сложные нелинейные зависимости.
- Типовые алгоритмы обучения: стохастический градиентный спуск, least squares temporal difference (LSTD), TD(0) с линейной аппроксимацией.

6.2. Полиномиальные и базисные разложения

Если линейной зависимости недостаточно, пространство признаков расширяют с помощью полиномиальных признаков, радиальных базисных функций, сплайнов и других преобразований. Формально модель остается линейной по параметрам, но становится нелинейной по исходным характеристикам состояния. Это компромисс между интерпретируемостью и гибкостью.

6.3. Деревья решений и ансамбли

Деревья решений, случайный лес, градиентный бустинг и похожие ансамблевые методы способны аппроксимировать сложные нелинейные зависимости и автоматически выявлять важные признаки. Их можно использовать для аппроксимации функции ценности или модели переходов, особенно если состояние описывается табличными признаками умеренной размерности.

- Преимущества: хорошая работа с неоднородными признаками, устойчивость к нелинейностям и взаимодействиям признаков.
- Недостатки: сложнее встраивать в онлайн-обновления на каждом шаге, чем линейные модели и нейросети с градиентным обучением.
- Практическое применение: офлайн-оценка ценности по накопленным эпизодам, построение модели среды, анализ важности факторов.

6.4. Метод k ближайших соседей и локальные оценки

Локальные непараметрические методы строят оценку на основе похожих ранее наблюдавшихся состояний. Они полезны как концептуально простая форма обобщения: ценность нового состояния определяется по ценности соседних состояний. Однако в больших размерностях такие методы страдают от «проклятия размерности» и плохо масштабируются.

6.5. Нейронные сети

Нейронные сети стали основным инструментом оценки функции ценности в задачах большой размерности. Они позволяют приближать сложные нелинейные зависимости и работать с изображениями, временными рядами, сенсорными потоками и комбинированными признаками. На этом строятся Deep Q-Network, actor-critic методы, PPO, SAC, DDPG и другие современные алгоритмы.

- Полносвязные сети подходят для векторных признаков состояния.
- Сверточные сети эффективны, когда состояние представлено изображением или картой.
- Рекуррентные сети и трансформеры полезны при частичной наблюдаемости и наличии временного контекста.
- Обучение обычно выполняется по TD-ошибке, Monte-Carlo целям или их комбинациям.

6.6. Специализированные алгоритмы RL, непосредственно оценивающие функцию

Хотя Q-learning, SARSA, TD(0), TD(λ), Monte-Carlo методы и actor-critic относятся к обучению с подкреплением, по сути они представляют собой также алгоритмы машинного обучения для оценки функции. Их отличие в том, что обучающая выборка формируется не извне, а в ходе взаимодействия агента со средой.

Алгоритм	Что оценивает	Особенности
Monte-Carlo	V или Q по полным эпизодам	Простая идея, но высокая дисперсия оценок
TD(0), TD(λ)	V(s)	Онлайн-обновления, хорошая практическая устойчивость
SARSA	Q(s,a)	On-policy, учитывает текущую исследовательскую стратегию
Q-learning	Q(s,a)	Off-policy, стремится к жадной стратегии
DQN	Q(s,a) нейросетью	Replay buffer, target network
Actor-Critic	Политику и V/Q	Одновременное обучение актора и критика

7. Как формируется обучающая цель для функции ценности

В классическом supervised learning имеется готовая целевая метка. В RL такой метки заранее нет, поэтому её приходится конструировать из наблюдаемых наград и оценок будущего. Это называется бутстрэппингом. Типичный целевой сигнал имеет вид: $r + \gamma V(s')$ или $r + \gamma \max_a Q(s', a)$. Разность между текущей оценкой и новой целевой величиной называется TD-ошибкой.

Именно TD-ошибка играет роль сигнала обучения. Если ошибка велика, параметры аппроксиматора корректируются сильнее. Если мала — слабее. Поэтому точность и стабильность оценки функции зависят не только от выбранного алгоритма машинного обучения, но и от того, насколько качественно сформирован целевой сигнал.

8. Связь характеристик состояния и качества функции ценности

Даже самый современный алгоритм не сможет хорошо аппроксимировать ценность, если входное состояние не отражает реальной динамики системы. Например, если в задаче управления запасами не включить текущий остаток товара и время доставки, оценка будущих издержек станет систематически ошибочной. Если в задаче автономного вождения опустить скорость и относительное положение препятствий, функция ценности потеряет способность различать безопасные и опасные ситуации.

Отсюда следует важный методический вывод: проектирование состояния — это не второстепенная подготовка данных, а центральная часть RL-постановки. На практике улучшение набора признаков часто даёт больший эффект, чем усложнение алгоритма.

9. Примеры прикладных задач

Робототехника. Состояние включает координаты, скорости, углы сочленений, данные лидаров и камер. Функция ценности оценивает перспективность текущей конфигурации для достижения цели без столкновений.

Логистика и складское управление. Состояние описывается запасами, очередями заказов, загрузкой транспорта, временем доставки. Ценность отражает ожидаемые затраты и качество обслуживания.

Финансовые системы. Состояние может содержать рыночные признаки, объем позиции, риск-показатели, транзакционные издержки. Функция оценивает ожидаемую полезность будущего портфеля.

Энергетика. Состояние задается нагрузкой, прогнозом потребления, доступностью источников энергии и тарифами. Ценность показывает выгодность текущего режима управления.

Игровые среды и симуляторы. Состояние включает позицию объектов, ресурсы игрока, статус миссий. Оценка ценности позволяет выбирать действия с учетом дальних последствий.

10. Основные проблемы при оценке функции

- Смещение и дисперсия оценок. Monte-Carlo методы дают несмещенные, но шумные оценки; TD-методы уменьшают дисперсию, но вносят смещение.
- Переобучение аппроксиматора. Слишком гибкая модель может хорошо описывать отдельные траектории, но плохо переноситься на новые состояния.
- Нестабильность при off-policy обучении. Когда политика сбора опыта и целевая политика различаются, обучение может расходиться.
- Нестационарность данных. По мере улучшения стратегии распределение посещаемых состояний меняется, и задача оценки постоянно «сдвигается».
- Слабое признаковое представление. Если характеристики состояния подобраны плохо, функция ценности оказывается нерепрезентативной независимо от алгоритма.

11. Практические рекомендации по выбору алгоритма

5. Если пространство состояний невелико и дискретно, начинать следует с табличных TD-методов: они дают понятный эталон.
6. Если признаков немного и нужна интерпретируемость, разумно использовать линейную аппроксимацию или базисные разложения.
7. Если состояние имеет табличную структуру средней сложности, полезно сравнить линейные модели с деревьями и бустингом в офлайн-режиме.
8. Если состояние высокоразмерно или представлено изображениями, временными рядами и сложными сигналами, требуются нейросетевые методы.
9. При проектировании состояния сначала следует обеспечить содержательную полноту признаков, а уже затем наращивать сложность модели.
10. Необходимо контролировать метрики: среднюю награду, TD-ошибку, стабильность обновлений, распределение посещаемых состояний и чувствительность к гиперпараметрам.

12. Итоговые выводы

Задачи обучения с подкреплением, в которых требуется оценка функции, составляют ядро современной интеллектуальной адаптивной системы управления. Без количественной оценки состояния и действий невозможно сравнивать альтернативы, учитывать отложенные последствия и улучшать стратегию. Поэтому оценка функции ценности — это не вспомогательная процедура, а центральный механизм, через который агент превращает опыт во взвешенное решение.

Характеристики состояния системы определяют, какую информацию получает алгоритм и способен ли он вообще выявить закономерности. Если состояние построено удачно, то даже относительно простые методы могут обеспечить хорошие результаты. Если же состояние неполно или неадекватно, то усложнение модели редко спасает ситуацию.

Алгоритмы машинного обучения для оценки функции ценности охватывают широкий спектр подходов — от линейных моделей и базисных разложений до ансамблей и глубоких нейронных сетей. Выбор конкретного метода должен опираться на размерность задачи, тип признаков, требования к скорости, интерпретируемости и устойчивости. На практике наилучший результат обычно достигается не отдельным «сильным» алгоритмом, а согласованной связкой: корректное описание состояния, адекватный способ формирования целевого сигнала и подходящий аппроксиматор функции ценности.

13. Контрольные вопросы

- Почему в задачах RL недостаточно учитывать только мгновенную награду?
- Чем отличаются функции $V(s)$, $Q(s,a)$ и $A(s,a)$?
- Какие требования предъявляются к представлению состояния системы?
- В чем состоят достоинства и ограничения линейной аппроксимации?
- Почему нейронные сети особенно востребованы в задачах большой размерности?
- Что такое TD-ошибка и какую роль она играет в обучении?
- Почему качество признаков состояния часто важнее усложнения алгоритма?