

ВОПРОСЫ И ПРАКТИЧЕСКИЕ ЗАДАНИЯ К ЭКЗАМЕНУ

по дисциплине «Обучение с подкреплением»

Комплект включает 60 теоретических вопросов и 30 практических вопросов (заданий), сформированных на основе материалов по дисциплине.

Структура комплекта

№	Раздел	Количество
1	Теоретические вопросы к экзамену	60
2	Практические вопросы и задания	30
3	Всего позиций	90

60 вопросов к экзамену

Раздел 1. Общие основы RL, агент, среда, награда, стратегии

1. Что такое обучение с подкреплением и чем оно отличается от обучения с учителем?
2. Какие основные элементы включает схема «агент - среда - действие - награда - новое состояние»?
3. Что понимается под состоянием среды в обучении с подкреплением?
4. Что такое действие агента и как задается множество допустимых действий?
5. Что такое награда и какую роль она играет в обучении?
6. В чем состоит цель агента в обучении с подкреплением?
7. Что такое стратегия (policy) и как она задает поведение агента?
8. Чем детерминированная стратегия отличается от стохастической?
9. Что такое оценочная обратная связь в RL?
10. В чем состоит проблема баланса «исследование - использование»?
11. Что представляет собой жадная стратегия выбора действий?
12. Что такое epsilon-жадная стратегия и зачем она нужна?
13. В чем идея стратегии Softmax?
14. В чем состоит метод UCB и чем он полезен?
15. Что такое многорукий бандит и почему его считают упрощенной моделью RL?

Раздел 2. Марковские процессы, ценность, возврат

16. Что такое марковское свойство?
17. Что такое марковский процесс принятия решений (MDP)?
18. Какие компоненты входят в формальное описание MDP?
19. Что такое функция ценности состояния $V(s)$?
20. Что такое функция ценности действия $Q(s, a)$?
21. Чем функция $Q(s, a)$ отличается от функции $V(s)$?
22. Что такое функция преимущества $A(s, a)$?

23. Что такое возврат и как он вычисляется в эпизодической задаче?
24. Какую роль играет коэффициент дисконтирования γ ?
25. Почему мгновенной награды недостаточно для принятия оптимального решения?
26. Что такое оптимальная функция ценности?
27. Как интерпретировать долгосрочную ожидаемую награду?
28. Почему в RL важны отложенные последствия решений?
29. Что такое бутстрэппинг и в каких методах он используется?
30. Чем эпизодические задачи отличаются от продолжающихся?

Раздел 3. Прямое обучение от опыта, Monte Carlo, средняя награда, TD

31. Что понимается под прямым обучением от опыта агента?
32. Почему методы Monte Carlo относят к прямому обучению по опыту?
33. В чем заключается обучение по полным эпизодам?
34. Как вычисляется возврат в методах Monte Carlo?
35. Чем First-Visit Monte Carlo отличается от Every-Visit Monte Carlo?
36. Каковы преимущества методов Monte Carlo?
37. Каковы недостатки методов Monte Carlo?
38. Что такое обучение по средней награде и для каких задач оно подходит?
39. Почему критерий средней награды важен для продолжающихся задач?
40. Что означает разделяющая оценка ценности стратегии?
41. Что такое дифференциальная ценность состояния?
42. В чем состоит идея R-learning?
43. Что такое метод временных различий TD?
44. Чем TD-обучение отличается от Monte Carlo?
45. Что такое TD-ошибка и как она используется в обновлении оценок?
46. В чем суть метода Q-learning?
47. Чем Q-learning отличается от SARSA?

48. Что означает on-policy и off-policy обучение?

49. В чем состоит идея TD(λ)?

50. Что такое policy gradient и в чем смысл градиентной оптимизации стратегии?

Раздел 4. Планирование, модель, оценка функции, иерархия и мультиагентность

51. Что такое обучение на основе моделей в RL?

52. Что понимается под моделью среды в обучении с подкреплением?

53. Какие компоненты включает модель среды: переходы и награды?

54. Чем model-based подход отличается от model-free подхода?

55. Как используется модель для планирования и генерации искусственного опыта?

56. Что такое эвристический поиск и как он связан с model-based RL?

57. В каких задачах RL требуется оценка функции?

58. Какие требования предъявляются к описанию состояния системы?

59. Какие алгоритмы машинного обучения применяются для оценки функции ценности?

60. В чем состоят идеи и различия иерархического RL, MAXQ, ALISP, а также методов полной и непрямой координации в мультиагентном обучении?

30 практических вопросов и заданий к экзамену

Блок А. Короткие расчетно-аналитические задачи

1. Для бандита с 4 ручками и известными средними наградами объяснить, какую ручку выберет жадная стратегия и в чем ее недостаток.
2. Для заданного значения ϵ описать поведение ϵ -жадной стратегии и вычислить вероятность случайного выбора.
3. По небольшой таблице наград за 5 шагов вычислить полный возврат без дисконтирования.
4. По той же последовательности вычислить возврат при $\gamma = 0.9$.
5. Для одного эпизода Monte Carlo вычислить оценки $Q(s, a)$ по схеме First-Visit.
6. Для того же эпизода выполнить обновление по схеме Every-Visit и сравнить результат.
7. Для заданных $Q(s, a)$ определить лучшее действие в каждом состоянии.
8. По формуле TD(0) выполнить одно обновление $V(s)$ при заданных r , γ , $V(s')$, α .
9. По формуле Q-learning выполнить одно обновление $Q(s, a)$.
10. По формуле SARSA выполнить одно обновление $Q(s, a)$ и сравнить с Q-learning.

Блок В. Задачи по модели и планированию

11. По описанию среды указать, что должно входить в модель переходов и модель награды.
12. Для небольшой детерминированной среды построить таблицу переходов $T(s, a)$.
13. Для той же среды задать таблицу наград $R(s, a)$.
14. Пояснить, как агент может использовать накопленный опыт для построения приближенной модели среды.
15. Объяснить, как в Dyna-подобной схеме сочетаются реальные и воображаемые переходы.
16. Для небольшого GridWorld указать, какие состояния следует обновлять в первую очередь при эвристическом приоритете.
17. По фрагменту стратегии в GridWorld прокомментировать, как агент обходит препятствия и движется к цели.
18. Сравнить поведение агента при $\text{planning_steps} = 0$ и $\text{planning_steps} > 0$.
19. Предложить эвристику для ускорения поиска в задаче навигации.
20. Объяснить, какие ошибки могут возникать при неточной модели среды.

Блок С. Оценка функции и признаки состояния

21. Для заданной прикладной задачи предложить набор признаков состояния и обосновать его полноту.
22. Определить, какие признаки состояния являются лишними, шумовыми или недостаточными.
23. Объяснить, почему плохое описание состояния ухудшает оценку функции ценности.
24. Сравнить табличную оценку $Q(s, a)$ и аппроксимацию функцией.
25. Предложить, какой метод лучше использовать для оценки функции: линейную модель, дерево решений или нейросеть, и объяснить выбор.
26. Для описанной задачи управления определить, что лучше оценивать: $V(s)$, $Q(s, a)$ или $A(s, a)$.

Блок D. Иерархическое и мультиагентное обучение

27. Для сложной задачи управления разбить глобальную цель на 3-5 субкомпонент и объяснить логику декомпозиции.
28. Для примера складского робота предложить иерархию подзадач в духе MAXQ.
29. Для процедурной задачи описать, как мог бы выглядеть каркас ALISP.
30. Для мультиагентной системы привести пример полной координации и пример не прямой координации, сравнив их преимущества и ограничения.

Рекомендуемая схема формирования экзаменационного билета

- 1) один вопрос из разделов 1-2;
- 2) один вопрос из разделов 3-4;
- 3) одно практическое задание из блока А-Д.